

Agentic Intelligent Tutoring Systems: até onde agentes de IA reconstróem os grafos de comportamento de especialistas humanos

João Carlos Queiroz · EducaOFF / STI Unplugged · contato@educaoff.com.br

Resumo. Décadas de evidência educacional apontam o feedback específico e imediato como uma das intervenções de maior impacto na aprendizagem, e nenhuma tecnologia entrega esse tipo de feedback melhor do que os sistemas tutores inteligentes, os STIs. Ainda assim, o mundo abandonou os STIs, e o motivo nunca foi pedagógico: foi o custo de construí-los, horas de engenharia de conhecimento cujo núcleo, exercício a exercício, é o grafo de comportamento, o mapa de acertos e erros que permite ao tutor reagir a cada passo do aluno. Este artigo pergunta até onde um pipeline de agentes de IA em produção reconstrói esses grafos, e mede a resposta da forma mais controlada que conseguimos desenhar. Cinco tutores públicos do Mathtutor (CMU), com 105 problemas autorados por demonstração no CTAT, serviram de referência; para cada problema, os agentes receberam exatamente o que o especialista teve, o enunciado e a interface da tela, e nunca o grafo dele; a cadeia completa de produção (alunos simulados, compilador determinístico, materialização) gerou 630 grafos, espelhada byte a byte do código em produção, com verificação por hash. A obediência ao problema foi provada por um critério objetivo, com aprovação em 100% dos 630 grafos, de modo que nenhuma análise usa recorte. Os resultados dependem, acima de tudo, da granularidade da referência. Nos quatro tutores de frações, com 3 a 5 estados de valor por problema, os agentes reproduzem 73% a 99% dos estados na ordem exata e o caminho inteiro em até 97% dos grafos no melhor braço; no tutor de tabela de porcentagens, com 24 estados por problema, a cobertura cai para 9% a 30% e nenhum grafo reproduz o caminho inteiro, porque os agentes agregam em 5 a 12 passos o que o especialista decompôs célula a célula. Nenhuma cobertura é reportada sozinha: um grafo de linha de base, que apenas repete os números do enunciado, atinge 12% a 56% de cobertura, e a leitura correta usa a cobertura ajustada ao acaso e o F1, o equilíbrio entre cobertura e precisão; por essas lentes, o braço fraco fica abaixo da linha de base no tutor de 24 estados, e o braço forte, que cobre mais, perde precisão e chega a ficar abaixo do fraco em F1 em dois corpora. Entregar a interface ao agente, a única hipótese direcional pré-registrada, elevou a concordância no corpus original em +0,27 a +0,32 de cobertura e +0,46 de caminho íntegro no braço forte. Uma rodada final de auditoria corrigiu uma assimetria da própria régua (o clique de concluir, já descontado do lado do especialista, passou a ser descontado também do lado do agente): no agregado, a precisão de estados sobe de 0,72 para 0,82 e o F1 de 0,71 para 0,76, sem mover nenhuma cobertura, por invariante testado. E as dicas, antes medidas só por presença, foram comparadas por conteúdo com dois instrumentos independentes: pelo juiz cego, aprovado em controles, os agentes empatam com o especialista em especificidade (1,97 contra 1,96) e escalonamento (1,89 contra 1,88) e perdem em um único ponto, a acionabilidade (2,09 a 2,13 contra 2,81), porque uma política documentada da plataforma proíbe a dica final de entregar a resposta, que é exatamente o que o especialista do CTAT faz em 85% dos passos (os agentes, em 2%). Os erros extras dos agentes seguem sem veredito: os dois juízes disponíveis reprovaram no gate pré-declarado de calibração. O experimento inteiro custou cerca de US\$ 22 de processamento, contra 200 a 300 horas de especialista por hora de instrução da autoria clássica. As limitações estão declaradas sem eufemismo, incluindo quatro decisões de régua tomadas após ver dados, publicadas com a tabela contrafactual que mostra o efeito de cada uma.

Palavras-chave: sistemas tutores inteligentes; grafos de comportamento; example-tracing; autoria assistida por IA; validação; linha de base; Mathtutor.

1. Introdução e justificativa

Começamos pelo tamanho do problema. Seis em cada dez crianças e adolescentes do mundo, 617 milhões, não atingem a proficiência mínima em leitura e matemática (UNESCO Institute for Statistics, 2017), e a estimativa mais recente para os países de renda baixa e média é ainda mais dura: 70% das crianças de 10 anos não conseguem ler e compreender um texto simples (World Bank et al., 2022). A comunidade internacional reconhece a gravidade disso nos Objetivos de Desenvolvimento Sustentável da ONU: de forma direta no ODS 4, que trata de educação de qualidade, e também no ODS 5, o de equidade de gênero, porque a defasagem educacional costuma penalizar mais as meninas em contextos vulneráveis. Qualquer proposta de tecnologia educacional séria deveria ser julgada contra essa escala, e é contra ela que este artigo se posiciona.

O que a ciência já sabe sobre o que funciona? As duas maiores sínteses de evidência da área, o Teaching and Learning Toolkit da Education Endowment Foundation e o Visible Learning de John Hattie (2009), chegam a uma conclusão notavelmente parecida: o feedback está entre as intervenções que mais aceleram a aprendizagem, com seis meses de progresso adicional segundo o Toolkit, e a metacognição e autorregulação aparece ainda mais alto, com oito meses (Education Endowment Foundation, revisões de 2021 e 2025). Guarde esses dois nomes, porque a tensão entre eles organiza todo o argumento deste artigo.


Existe uma tecnologia desenhada precisamente para entregar feedback da melhor qualidade possível: o sistema tutor inteligente, ou STI, da tradição dos tutores cognitivos (Anderson et al., 1995). Um STI guiado acompanha o aluno passo a passo dentro de um problema, como um professor particular paciente. Quando o aluno comete um erro que o sistema conhece, o tutor não diz apenas “tente de novo”: ele reconhece qual confusão de raciocínio produziu aquele erro específico e responde com a explicação certa para aquela confusão, na hora exata em que ela aconteceu. A eficácia dessa abordagem é das mais bem documentadas da tecnologia educacional, rivalizando com a tutoria humana individual (VanLehn, 2011). O próprio Toolkit da EEF registra uma nuance que interessa aqui: o feedback entregue por tecnologia rende, em média, menos do que o geral, quatro meses. A lição não é que o digital funciona menos; é que o efeito não vem do meio, vem da especificidade e do momento do feedback.

Se os STIs funcionam tão bem, por que não estão em toda parte? A resposta é prosaica: custo de autoria. Vale abrir essa conta, porque é sobre ela que este artigo age. Construir um STI não é escrever um conteúdo; é um ciclo de engenharia de conhecimento pedagógico com várias frentes (Murray, 2003; Aleven et al., 2016): investigar como os alunos pensam e onde erram naquele domínio, pela análise cognitiva da tarefa (Lovett, 1998; Clark et al., 2008); desenhar e construir a interface do tutor, específica para cada tipo de problema; demonstrar, exercício a exercício, o caminho de resolução e os erros prováveis, que viram o grafo de comportamento; escrever as dicas de cada passo e as devolutivas de cada erro; mapear os componentes de conhecimento; e testar tudo com alunos. Somadas, as estimativas clássicas da literatura falam em 200 a 300 horas de desenvolvimento para cada hora de instrução produzida (Aleven et al., 2009; 2016). Ferramentas de autoria mudaram essa conta: em projetos reais medidos com o CTAT, da Universidade Carnegie Mellon, a razão caiu para a faixa de 50 a 100 horas por hora de instrução, de 4 a 8 vezes mais custo-efetiva que as estimativas anteriores (Aleven et al., 2016); com o ASSISTments Builder, que mede apenas o tempo dentro das ferramentas, para 28 a 40 (Razzaq et al., 2009). É um avanço real, que ainda mantém a barreira proibitiva na escala do problema. E repare onde essa conta se amortiza e onde não: a interface e o molde do problema podem ser reaproveitados entre exercícios parecidos; o que precisa ser pensado exercício a exercício, sem atalho, é o mapa de passos, erros, confusões, dicas e devolutivas, isto é, o grafo de comportamento com as suas mensagens. O

resultado é que, quando a inteligência artificial generativa explodiu, o mercado educacional não voltou aos STIs: apostou em tutores conversacionais, chatbots de estilo socrático construídos sobre modelos de linguagem. A Figura I resume os dois lados dessa equação.


A equação: o que mais funciona x o que custa construir

A · Impacto na aprendizagem (EEF Toolkit, meses de progresso adicional)



Revisões vigentes: junho/2021 (feedback) e maio/2025 (metacognição). O STI guiado entrega os dois fatores; o chatbot os demanda na entrada.

B · Custo de autoria (por hora de instrução produzida)



O US\$ 22 cobre a geração do grafo (o núcleo que não se amortiza), não o tutor completo; a revisão docente continua no circuito.

Fontes: painel A, páginas do Teaching and Learning Toolkit da EEF; painel B, literatura citada e fontes S1 e S20 do repositório (custos por chamada).

Figura I. A equação que este artigo ataca. No painel A, os valores vigentes do Teaching and Learning Toolkit da EEF: seis meses de progresso adicional para feedback e oito para metacognição e autorregulação (revisões de junho de 2021 e maio de 2025). No painel B, o custo que afastou o mundo dos STIs, de 200 a 300 horas de trabalho especializado por hora de instrução, ou de 50 a 100 horas com ferramentas como o CTAT (Aleven et al., 2009; 2016), comparado ao custo medido neste experimento: 630 grafos de comportamento, para 105 problemas de cinco tutores, por cerca de US\$ 22 de processamento (fontes S1 e S20). Uma precisão importante: esse valor cobre a geração do grafo, que é o núcleo caro da autoria, e não o tutor completo.

Nossa tese é que a aposta nos chatbots olha para o lugar errado, e a razão está na própria evidência de impacto. Um diálogo socrático aberto exige muito de quem aprende: que o aluno saiba o que não sabe, formule a própria dúvida, planeje o próprio estudo e se mantenha na tarefa sem uma estrutura externa que o conduza. Esse conjunto de habilidades tem nome, metacognição e autorregulação, e a psicologia do desenvolvimento mostra que elas amadurecem tarde e de forma desigual entre as crianças (Flavell, 1979; Kuhn, 2000; Veenman et al., 2006). Não é preciso sair da literatura de tutores para ver cada peça do problema isoladamente: a habilidade de pedir ajuda na hora certa, exatamente a que um diálogo aberto mais exige, é ela mesma deficitária nos alunos e precisou virar objeto de tutoria dentro dos próprios STIs (Aleven, McLaren, Roll & Koedinger, 2006; Roll et al., 2011); e a autorregulação que sustenta estudar sem condução externa é uma construção de toda a escolaridade, não um pré-requisito disponível no começo dela (Zimmerman, 2002). Ou seja: os tutores conversacionais demandam metacognição na entrada e devolvem, na saída, um feedback frequentemente genérico. Eles invertem os dois fatores de maior impacto da literatura, justamente para as populações que menos dispõem dessas habilidades. O STI guiado faz o contrário: conduz a trajetória, o que reduz a carga metacognitiva, e entrega o feedback mais específico que existe.

Sobra, então, um único obstáculo real entre os STIs e a escala do problema: o custo da engenharia de conhecimento que não se amortiza, cujo produto é o grafo de comportamento com as suas dicas e devolutivas. Este artigo apresenta e valida a nossa resposta a esse obstáculo, organizada em duas contribuições conceituais e um argumento de implantação.

A primeira é o *Augmented Teacher in the Lead*. Não defendemos IA no comando, nem apenas professor no comando. Propomos o professor com a capacidade de liderança *augmentada*: a IA gera o material

pesado, e o professor, na sua rotina, com o seu julgamento pedagógico, revisa, ajusta e publica. O humano indispensável do nosso desenho não é um engenheiro de conhecimento raro e caro. É o professor.

A segunda é o *Agentic Intelligent Tutoring System*, o AITS. Um AITS é um STI clássico em tudo o que importa para o aluno: guiado, de baixa carga metacognitiva, com feedback diagnóstico. O que muda é a fábrica. O núcleo de autoria que não se amortiza, o grafo de comportamento com as suas mensagens, passa a ser gerado por agentes de IA especializados e montado por um compilador determinístico, sob revisão docente. A IA fica na linha de produção, não na sala de aula. À técnica de geração damos o nome de *GraphForge*.

As duas contribuições se completam com o argumento de implantação que dá nome ao programa: o *STI Unplugged*. Poderia-se objetar que basta ajustar um modelo de linguagem (fine-tuning) para que ele conduza o aluno passo a passo em vez de conversar livremente. Mas servir um modelo desses a cada aluno, a cada clique, exige conexão e computação contínuas, exatamente o que falta nas redes de ensino onde a defasagem se concentra. O AITS desacopla os dois momentos: a IA é necessária na fábrica, quando o grafo é gerado; o tutor pronto é um artefato leve, que roda sem internet e em hardware modesto, sem nenhuma chamada a modelos durante o uso.

Tudo isso só se sustenta se respondermos a uma pergunta científica direta: os grafos que os agentes criam são bons? E a resposta honesta precisa dizer não só onde eles se aproximam do especialista, mas onde deixam de se aproximar. Este artigo mede as duas coisas. Cinco tutores públicos do Mathtutor (CMU), somando 105 problemas autorados por especialistas, servem de referência; os agentes da cadeia completa de produção recebem exatamente o mesmo insumo que o especialista teve, o problema e a interface, e os 630 grafos que eles entregam são comparados, estado a estado e sem tolerância, com o grafo de cada especialista, sob regras, métricas e verificações declaradas antes de cada coleta, na tradição do pré-registro (Nosek et al., 2018), e auditadas depois dela. A mensagem central tem três níveis, que estruturam os resultados. Primeiro, o insumo importa: entregar a interface ao agente, a única hipótese direcional pré-registrada do programa, elevou a concordância no corpus original em +0,27 a +0,32 de cobertura e em +0,46 de caminho íntegro no braço forte. Segundo, a granularidade da referência é a fronteira do método: onde o especialista decompôs o problema em 3 a 5 estados, os agentes reproduzem 73% a 99% dos estados na ordem exata e, nos melhores casos, o caminho inteiro em 88% a 97% dos grafos; onde o especialista tratou cada célula de uma tabela como um passo, 24 estados por problema, a cobertura cai para 9% a 30% e nenhum grafo reproduz o caminho inteiro. Terceiro, nenhum desses números pode ser lido sem linha de base: um grafo que apenas repete os números do enunciado atinge 12% a 56% de cobertura, e é contra esse piso, e com precisão e F1, que os resultados são reportados.

O caminho até esses números está organizado assim: a Seção 2 situa o trabalho na literatura; a Seção 3 explica o que é um grafo de comportamento, de onde vieram as referências e como os agentes geram os seus grafos; a Seção 4 define a régua de comparação e as suas salvaguardas, incluindo a linha de base e a tabela contrafactual; a Seção 5 apresenta os resultados; a Seção 6 discute os três achados; a Seção 7 assume as limitações; a Seção 8 documenta a reprodutibilidade; a Seção 9 conclui.

2. Trabalhos relacionados

Example-tracing e CTAT. Os tutores por rastreamento de exemplos (example-tracing tutors) são o paradigma de STI que dispensa programação: o autor demonstra as soluções e os erros na própria interface, e o sistema generaliza essas demonstrações num grafo de comportamento que interpreta o aluno passo a passo (Aleven et al., 2009; 2016). O CTAT, da Universidade Carnegie Mellon, é a ferramenta de

autoria de referência desse paradigma, com efetividade de custo medida em projetos reais (razões de 50 a 100 horas por hora de instrução, contra 200 a 300 das estimativas clássicas; Aleven et al., 2016) e uma base instalada de centenas de estudos. É exatamente esse formalismo, e essa origem, que este artigo usa como padrão de comparação.

Mathtutor como corpus público. O Mathtutor (mathtutor.web.cmu.edu) é o sítio aberto que a equipe do CTAT construiu com tutores de matemática do 6º ao 8º ano, autorados por demonstração pela própria equipe (Aleven, McLaren & Sewall, 2009a). Os pacotes são servidos publicamente com o manifesto de cada problema, o grafo do especialista (arquivo *.brd*), a interface HTML e os componentes de conhecimento, o que os torna, até onde sabemos, o maior conjunto aberto de grafos de comportamento autorados por especialistas: no levantamento que fizemos para este trabalho, 54 pacotes e 710 grafos (fonte S19). Cinco desses pacotes formam o corpus deste artigo.

Autoria assistida por IA. Reduzir o custo de autoria de STIs é uma agenda antiga, com duas décadas de ferramentas para não programadores (Murray, 2003; Razzaq et al., 2009; Aleven et al., 2016). A geração de conteúdo tutor por modelos de linguagem é a fronteira atual dessa agenda, e é nela que este artigo se insere, com uma diferença de ênfase: em vez de perguntar apenas “o que a IA consegue gerar?”, perguntamos “quanto do que um especialista humano autorou a IA reconstrói, medido estado a estado, contra uma linha de base de acaso e com as decisões de medição publicadas?”. Até onde sabemos, é a primeira comparação desse tipo entre grafos de comportamento gerados por agentes em produção e grafos de especialistas em escala de múltiplos tutores.


3. Metodologia

3.1 O que é um grafo de comportamento

Imagine um aluno resolvendo um problema de frações em uma plataforma digital: “você dividiu um pão igualmente entre 5 pessoas; mostre na reta numérica quanto cada pessoa recebeu”. Ele ajusta a reta, marca um ponto, digita um número e clica em confirmar. Nesse instante, o tutor precisa tomar uma decisão silenciosa: a resposta está certa? Está errada de um jeito conhecido, que merece uma explicação específica? Ou está errada de um jeito que ninguém previu? Quem responde a essa pergunta, em milissegundos, é o grafo de comportamento.

Pense no grafo como o mapa de trilhas daquele problema. A trilha principal é o caminho correto: a sequência de passos que resolve o problema, cada passo representado por um nó ligado ao seguinte. Dos pontos dessa trilha saem desvios sinalizados: as transições de erro. Cada desvio registra o valor errado que o autor previu que alunos digitariam ali, a confusão de raciocínio que produz esse erro (a *misconception*, no termo consagrado da área; Brown & Burton, 1978; VanLehn, 1990) e a devolutiva, a explicação que o tutor entrega quando o aluno cai naquele desvio. Completam o mapa as dicas disponíveis em cada passo. A Figura 1 resume a decisão do tutor; a qualidade do grafo determina o teto pedagógico do tutor, porque decide com que frequência um erro real recebe a explicação sob medida em vez do “tente de novo”.

O que acontece no instante em que o aluno responde





A qualidade do grafo decide com que frequência um erro real cai no caso 2 (explicação sob medida) e não no caso 3.

Figura 1. O que acontece no instante em que o aluno responde. O tutor compara a resposta com as transições previstas no grafo para aquele passo. Há três saídas possíveis: avançar (resposta correta), explicar a confusão específica (erro previsto) ou oferecer apoio genérico (erro que ninguém previu). A qualidade do grafo decide com que frequência um erro real cai no segundo caso, o da explicação sob medida, em vez de cair no terceiro.

A Figura 2 mostra um grafo de verdade, o do exercício do pão, construído pelo especialista do Mathtutor. O arquivo bruto tem mais do que o caminho que o aluno percorre: tem também ações executadas pelo próprio tutor (mostrar a resposta na tela, revelar um componente) e marcas de interface. A Seção 4.1 explica como a régua separa, lendo o próprio arquivo, o que é passo do aluno do que é ação do sistema; neste exercício sobram 4 estados de valor do aluno. A quantidade de passos que um autor escolhe é o comprimento do caminho dele (a literatura também chama isso de granularidade), e ela será o eixo do resultado mais importante deste artigo.

Grafo do especialista — exercício real: "dividir um pão entre 5 pessoas; mostrar 1/5 na reta"



O problema e a tela REAIS deste exercício

É nesta interface que o especialista autorou o grafo acima, por demonstração: enunciado do pão, caixas F1/F2 da fração, reta numérica, campo "Number of parts", botões Hint e Done. A Figura 4 amplia a tela e marca cada componente (fonte S9).

Figura 2. A anatomia de um grafo de comportamento, no exercício real do pão. O caminho correto do especialista, como gravado no arquivo, com as 4 transições de erro de valor penduradas (valor errado + confusão + devolutiva; as demais transições do arquivo são mecânicas). As caixas menores definem posição relativa e o comprimento do caminho (granularidade). A faixa inferior mostra o problema e a tela reais em que o especialista autorou, ampliados na Figura 4. Do caminho bruto, a régua deste artigo compara os 4 estados de valor que são ações do aluno (Seção 4.1).

3.2 O que é, para nós, um grafo de qualidade

Antes de medir qualquer coisa, precisamos combinar o que estamos chamando de qualidade. Para o nosso programa de validação, um grafo de comportamento é bom quando responde bem a cinco perguntas. A Figura 3 apresenta as cinco de uma vez, cada uma com a medida que a responde.

Primeira pergunta: ele funciona? Um grafo pode estar quebrado por dentro, com desvios que apontam para pontos inexistentes do mapa ou caminhos sem saída. Essa é a exigência mínima, verificada por auditoria estrutural automática do compilador.

Segunda pergunta: ele reconstrói o caminho do especialista? O caminho de referência é uma sequência de estados; a pergunta é se esses estados existem no grafo do agente, e se aparecem na mesma ordem. As

medidas são a cobertura de estados, lida com e sem exigência de ordem, e o caminho íntegro, que só vale quando o caminho inteiro está presente, na ordem. E, porque cobertura é um tipo de recall que não pune quem gera estados a mais, ela nunca é lida sozinha: acompanha uma linha de base de acaso, a cobertura ajustada, a precisão e o F1 (Seção 4.2).


Terceira pergunta: cada elemento está no lugar certo? O erro e a dica que o especialista ancorou num estado precisam aparecer ancorados no mesmo estado do grafo do agente. A medida é elemento a elemento e binária, sem tolerância de posição, com duas exclusões declaradas para erros que a régua de valores não alcança (Seção 4.2).

Quarta pergunta: o feedback é adequado? De nada adianta mapear o erro se a devolutiva e as dicas não conversam com o aluno; o feedback específico é, desde a introdução, a razão de ser do tutor guiado.

Quinta pergunta: os elementos construídos a mais têm valor? Os agentes constroem grafos com elementos (estados, erros, dicas) que o especialista não indicou no dele. Isso pode ser riqueza ou ruído.

Este artigo responde às perguntas 1, 2 e 3 por inteiro, e à pergunta 4 na metade das dicas. As escadas de dicas foram comparadas por conteúdo, com uma régua determinística e um juiz cego aprovado em controles (Seções 4.4, 4.5 e 5.7); as devolutivas de erro seguem fora, para uma frente futura. Na pergunta 5, os estados extras entram na precisão (que pune o excesso) e são contados; os erros extras foram levados a julgamento e o julgamento é honesto sobre si mesmo: os dois juízes disponíveis reprovaram no gate de calibração pré-declarado, e o artigo reporta a lacuna em vez de um número frágil (Seção 7).

O que é um grafo de qualidade: cinco perguntas, e a medida que responde a cada uma



As perguntas 2 e 3 precisam de um grafo de especialista como comparação: por isso os corpora do Mathtutor. Régua, exclusões e linha de base: Seções 4 e 5; fontes S12, S13, S26 e S27.

Figura 3. As cinco perguntas que definem qualidade no programa de validação, e a medida que responde a cada uma. As perguntas 1 a 3 são respondidas pela régua de estados sobre o grafo materializado (Seções 4 e 5), sempre com linha de base, precisão e F1 ao lado da cobertura. A pergunta 4 é respondida nesta versão para as dicas (régua de conteúdo + juiz cego, Seções 4.4–4.5 e 5.7); as devolutivas de erro seguem em frente separada. Na pergunta 5, os extras de estado entram na precisão; os erros extras ficaram sem veredito porque os juízes reprovaram no gate de calibração (Seção 7).

3.3 As referências: cinco tutores públicos do Mathtutor


Para responder às perguntas 2 e 3 precisamos de grafos construídos por especialistas humanos. Fomos buscá-los na maior fonte aberta disponível: o Mathtutor, o sítio público da equipe do CTAT na Universidade Carnegie Mellon, cujos tutores foram autorados por demonstração pela própria equipe do

projeto (Aleven, McLaren & Sewall, 2009a). Cada pacote é servido publicamente com o manifesto dos problemas, o grafo do especialista (o arquivo *.brd*), a interface HTML e os componentes de conhecimento; catalogamos 54 pacotes com 710 grafos e escolhemos cinco, priorizando pacotes cujo especialista modelou erros e variando deliberadamente a tarefa e a granularidade (fonte S19):

Tutor	Tarefa	Problemas	Estados de valor por problema	Erros do especialista
6.17 Fraction Identification	marcar a fração na reta numérica	24	4	4 a 6 por problema (média 4,6)
6.19 Fractions and Estimates	fração e número misto na reta 0–N	23	4 a 6 (média 4,35)	2 a 3
6.18 Equivalent Fractions	fração equivalente em duas retas	20	3	2 a 3 (nenhum avaliável por valor)
6.20 Fraction Ordering	comparar frações em duas retas	19	5	2 a 4 (média 3,8)
8.12 Factors, Scaling, and Percents	tabela de razões até a porcentagem	19	24	10 a 11 (média 10,6)

São 105 problemas de especialista. A coluna decisiva é a dos estados de valor: nos tutores de frações, o especialista decompôs cada problema em 3 a 5 passos avaliáveis; no 8.12, ele tratou cada célula de uma tabela como um passo, 24 por problema. Essa variação não é um acidente do corpus, é o desenho: ela permite medir como a concordância se comporta quando a granularidade da referência muda, e o 8.12 foi mantido mesmo com expectativa declarada de resultado baixo, registrada no pré-registro antes da coleta (fonte S3). As Figuras 4 a 8 apresentam os cinco tutores no mesmo formato, um por figura: em cima, a tela real, ampliada e anotada componente a componente, carregada com um problema do próprio pacote; no meio, o grafo que o especialista autorou para exatamente esse problema, lido do arquivo *.brd* sob a régua vigente (os estados de valor com as suas dicas, os erros modelados com a devolutiva resumida, e o que fica fora da régua); e, na faixa final, o grafo que os agentes materializaram para o mesmo problema, na primeira réplica de cada braço, para a comparação ficar à vista em todos os tutores. É a interface de cada tela que os agentes recebem em forma de descrição textual neutra (Seção 3.5).

A interface do tutor CTAT usada na comparação: uma tela para os 24 problemas



- 1 enunciado do problema (statement2)
- 2 pergunta da fração: F1 (numerador) e F2 (denominador)
- 3 reta numérica (numline): o aluno marca o ponto
- 4 "Number of parts" + OK (denom): divide a reta
- 5 botão Hint: escada de dicas por passo
- 6 botão Done: concluir (input "-1" no CTAT)
- 7 devolutivas e os 5 componentes de conhecimento (barras)

Completam os 7 componentes lógicos do pacote dois controles sem desenho próprio: showAnswer (registra a fração) e writeFractionStep (exibe a etapa de escrever a fração).

UM MOLDE, 24 TUTORES (mass production): a tela é parametrizada problema a problema pela tabela massproduction.txt:
 00bubble · 01watermelon · 02watermelon · 03summerBooks · 04soccerSeason · 05flu · 06lemonade · 07pizza · 08dentists ·
 09mathCompetition · 10children · 11project · 12apples · 13cleanRoom · 14centimeter · 15fishStick · 16bonusQuestion ·
 17pencils · 18gum · 19Painting · 20birthday · 21mm · 22biscuit · 23textbookPack.

O grafo do especialista deste problema (lido do arquivo .brd; régua vigente): 4 estados de valor




O grafo do AGENTE no mesmo problema (materializado, 1ª réplica de cada braço; fonte S6):



Faixa roxa: runs 00bubble_rep1.json dos dois braços; é o registro do braço econômico que as Figuras 10 e 12 abrem em detalhe (cobertura 0,75; caminho íntegro 0).
 Fontes: S12, S6, S21 e o dataset.

Figura 4. 6.17 Fraction Identification, o corpus original. Em cima, a tela real (captura), anotada: o enunciado; as caixas F1/F2 da fração; a reta numérica; o campo “Number of parts”; os botões Hint e Done; as devolutivas e os componentes de conhecimento; a faixa lista os 24 problemas gerados do mesmo molde (mass production). No meio, o grafo do especialista do problema do pão (00bubble), lido do arquivo: os 4 estados de valor com as suas dicas, os 4 erros modelados com a devolutiva resumida, e o que fica fora da régua (ações do tutor e o Done). Na faixa final, o grafo do agente no mesmo problema, na primeira réplica de cada braço: 6 passos no braço econômico e 7 no forte, contra 4 estados de valor; é o registro do braço econômico que as Figuras 10 e 12 abrem em detalhe. Fontes: S19, S12, S6, S21 e o dataset.


6.18 Equivalent Fractions: a tela real (problema 01_1)



- 1 enunciado do problema (statement)
- 2 Linha 1: a fração dada (1/4) já vem marcada pelo tutor
- 3 Linha 2: o aluno divide a reta (campo + OK) e marca o ponto equivalente
- 4 a fração dada em caixas (L1/L2) e a pergunta "One fourth equals how many eighths?"
- 5 seletor de comparação entre as frações: $\frac{1}{4} / = / \neq$
- 6 o aluno digita o numerador; o denominador alvo (8) já aparece
- 7 botões Hint e Done
- 8 janela de dicas/devolutivas e componentes de conhecimento (barras)

Estado inicial real do problema 01_1, lido do próprio grafo do especialista (startNodeMessages): a segunda variante da tela (linha com rótulos) começa oculta.

O grafo do especialista deste problema (lido do arquivo .brd; régua vigente): 3 estados de valor




O grafo do AGENTE no mesmo problema (materializado, 1ª réplica de cada braço; fonte S6):



Os 2 erros modelados ficam fora da régua de valores (não ancorável + indistinguível): por isso a métrica de erros é N/A no 6.18 (Seção 4.2). Dicas: 8 nos estados de valor. Faixa roxa: runs 01_1_rep1.json dos dois braços (os agentes incluem a fração equivalente 2/8 e o passo da comparação). Fontes: S12, S6 e o dataset.

Figura 5. 6.18 Equivalent Fractions, no problema 01_1 (“1/4 em oitavos”). Em cima, a tela do pacote no estado inicial real: a fração dada já marcada na Linha 1; a Linha 2 para o aluno dividir e marcar; as caixas da igualdade com o denominador alvo exibido; o seletor de comparação. No meio, o grafo do especialista: 3 estados de valor, e os 2 erros modelados que ficam fora da régua de valores (um pertence à outra variante do problema; o outro tem o valor da própria resposta, um erro de componente), a razão do N/A na métrica de erros deste corpus (Seção 4.2). Na faixa final, o grafo do agente no mesmo problema (5 e 7 passos): os dois braços criam estados além da referência, como a fração equivalente 2/8 e o passo da comparação, o excesso que a precisão da Tabela 2 pune. Fontes: S19, S17, S12, S6 e o dataset.

6.19 Fractions and Estimates: a tela real (problema 00bubble)



- 1 enunciado do problema (statement)
- 2 pergunta da fração: caixas f1 (numerador) e f2 (denominador)
- 3 reta numérica de 0 a 1: o aluno marca 5/7 (as divisões de 7 ficam ocultas no início)
- 4 botões Hint e Done
- 5 janela de dicas/devolutivas e componentes de conhecimento (barras)

A etapa de conversão a número misto (botão Convert e caixas m1/m2/m3) começa oculta e é revelada pelo tutor quando a fração pede; é dela que vem o estado de convenção "0" (Seção 5.1).

O grafo do especialista deste problema (lido do arquivo .brd; régua vigente): 4 estados de valor



O grafo do AGENTE no mesmo problema (materializado, 1ª réplica de cada braço; fonte S6):



Faixa roxa: runs 00bubble_rep1.json dos dois braços. O "0" da parte inteira aparece nos dois, mas no FIM do caminho, fora da ordem da referência: é exatamente a falha que derruba o caminho íntegro do corpus (Seção 5.1). Fontes: S12, S6 e o dataset.

Figura 6. 6.19 Fractions and Estimates, no problema 00bubble (5/7). Em cima, a tela do pacote: a pergunta da fração (f1/f2), a reta de 0 a 1 e, oculta no início, a etapa de conversão a número misto que o tutor revela quando a fração pede. No meio, o grafo do especialista: 4 estados de valor, incluindo o “0” da parte inteira, o estado de convenção da interface, e os 2 erros de inversão modelados. Na faixa final, o grafo do agente no mesmo problema (5 e 8 passos): o “0” aparece nos dois braços, mas no fim do caminho, fora da ordem da referência, exatamente a falha que derruba o caminho íntegro do corpus (Seção 5.1). Fontes: S19, S17, S12, S6 e o dataset.

6.20 Fraction Ordering: a tela real (problema 01book)

1 Levar and Laura are reading a novel as a class assignment. Use the number line to find out which student has read less of the novel.

2 Levar has read $\frac{1}{4}$ of the novel.
Laura has read $\frac{1}{5}$ of the novel.

3 Line 1 Amount Levar read

4 Line 2 Amount Laura read

5 Who has read less of the novel? -----


6 Hint Done Previous Next

7 como Frac
Div Num Line
Find Value Num Line
Frac Less1

- 1 enunciado do problema (statement)
- 2 as duas frações do problema (var1 e var2)
- 3 Linha 1: dividir a reta (campo + OK) e marcar $\frac{1}{4}$
- 4 Linha 2: dividir a reta e marcar $\frac{1}{5}$
- 5 a pergunta final e as alternativas reais (comboBox)
- 6 botões Hint e Done
- 7 janela de dicas/devolutivas e componentes de conhecimento (barras)

O quinto estado deste tutor é textual: a alternativa escolhida no seletor; a régua a compara como valor canonizado (Seção 5.1).

O grafo do especialista deste problema (lido do arquivo .brd; régua vigente): 5 estados de valor



O grafo do AGENTE no mesmo problema (materializado, 1ª réplica de cada braço; fonte S6):



Figura 7. 6.20 Fraction Ordering, no problema 01book ($\frac{1}{4} \times \frac{1}{5}$). Em cima, a tela do pacote: o enunciado com as duas frações, as duas retas com campo de divisão, e a pergunta final com as alternativas reais do seletor. No meio, o grafo do especialista: 5 estados de valor, o último textual (a alternativa escolhida, comparada por valor canonizado), e os 4 erros modelados, todos avaliáveis. Na faixa final, o grafo do agente no mesmo problema (6 e 8 passos): nesta réplica do braço econômico, a alternativa final materializada é a errada (“Levar...” em vez de “Laura...”); um erro real de conteúdo que a régua captura como estado não casado (Seção 5.1). Fontes: S19, S17, S12, S6 e o dataset.

8.12 Factors, Scaling, and Percents (problema CD sales)

Using the method of equivalent fractions, please answer in the spaces provided.

Bruce Springtime has just released a new CD. In the first hour, 5000 were sold.

Part 1) If BuyMart sold 25 copies, what percentage of the first hour sales did they sell?

Part 2) If Trina bought 4 CDs to share with her friends, what percentage of the first hour sales did she buy?

	Operation	Scale Factor			
Total			=		%
Part 1			=		%
Part 2			=		%

6


7

Apply scale-factor-to-ratio
Enter-given-quantities
Identify-percent
Identify-operation-needed
Identify-scale-factor

- 1 enunciado com as duas partes do problema
- 2 frações originais: os números dados (linhas Total, Part 1 e Part 2)
- 3 a operação de escala (x ou /), escolhida por linha
- 4 o fator de escala digitado pelo aluno
- 5 a fração sobre 100 e a porcentagem final
- 6 botões Hint e Done
- 7 janela de dicas/devolutivas e componentes de conhecimento (barras)

Cada célula desta tabela é um passo avaliável no grafo do especialista: 24 estados de valor por problema, a granularidade mais fina do experimento (Seção 5.3).

O grafo do especialista deste problema (lido do arquivo .brd; régua vigente): 24 estados de valor, célula a célula



O grafo do AGENTE no mesmo problema (materializado, 1ª réplica de cada braço; fonte S6):



Cada célula da tabela é um passo: 24 estados de valor por problema (duas fileiras verdes). Pontos vermelhos: passos onde o especialista modelou erro (11 neste problema). Na faixa roxa, o grafo materializado do agente no mesmo problema (runs CD sales_rep1.json dos dois braços): 6 e 12 passos; o P1 do braço econômico agrega seis células. Fontes: S12, S6 e o dataset.

Figura 8. 8.12 Factors, Scaling, and Percents, no problema CD sales. Em cima, a tela do pacote: a tabela de razões com as linhas Total, Part 1 e Part 2 (frações originais, operação, fator de escala, fração sobre 100 e porcentagem). No meio, o grafo do especialista: 24 estados de valor, um por célula, com os 11 erros modelados marcados; é a granularidade mais fina do experimento. Na faixa final, o grafo do AGENTE no mesmo problema, na primeira réplica de cada braço: o braço econômico resolve em 6 passos, o primeiro agregando seis células de uma vez, e o braço forte em 12, contra os 24 do especialista. É essa diferença de estilo de decomposição que o Gráfico 1 quantifica (médias 5,1 e 12,1; Seção 5.3). Fontes: S19, S17, S12, S6 e o dataset.


Quatro ressalvas de honestidade acompanham a escolha e reaparecem nas limitações. Primeira: todos os tutores vêm da mesma equipe, sem metadado de autor individual nos arquivos; tratamos a referência como o trabalho de um bom autor institucional, não como consenso da área, e não existe banda humano contra humano que diga o quanto dois especialistas concordariam entre si. Segunda: a qualidade desses grafos é pressuposta, não verificada de forma independente; há inclusive uma razão de princípio para não tratar especialista como gabarito absoluto, o ponto cego do especialista sobre as dificuldades de quem está começando (Nathan & Petrosino, 2003). Terceira: no 6.17, comprovamos que os 24 problemas são instâncias de um único molde de autoria (mass production); a diversidade efetiva da referência é menor do que a contagem de problemas sugere. Quarta: os critérios com que esses pacotes foram publicados no sítio não estão documentados publicamente; à época da coleta, o processo de publicação era interno à equipe do projeto, o que sugere curadoria, mas não a comprova.

3.4 Como os agentes criam um grafo, e o que exatamente foi medido

Os agentes não desenham o grafo. O que eles fazem é resolver o problema, em texto, como alunos simulados: um agente o resolve como um aluno avançado, registrando cada passo e o raciocínio; outro o resolve errando de propósito, como um aluno em risco, produzindo para cada passo os erros prováveis, com a confusão que os explica e a devolutiva correspondente; um terceiro faz o percurso de um aluno médio, que precisa de dicas. Tudo o que os agentes produzem é texto. Quem constrói o grafo é um compilador determinístico, o GraphForge: ele lê esses textos e monta nós e ligações, validando a integridade do conjunto, sempre o mesmo grafo para o mesmo conteúdo. Depois da síntese vem a materialização: o agente 6, um agente planejador com auxiliares, escreve o exercício concreto (o enunciado final e o valor esperado de cada passo), e o agente 7 reexecuta o GraphForge sobre esse artefato. É esse grafo materializado, o *behaviorGraph*, que a plataforma entrega ao aluno, e é ele que a régua compara: medimos no código de produção que o grafo do estágio de síntese carrega rótulos genéricos e não é o comparador operacional de valores (fonte S20, §7). A Figura 9 mostra a cadeia; a Figura 10 a percorre com os artefatos reais de um registro.

Dois cuidados de instrumentação definem o que “os agentes” significa aqui. Primeiro, **fidelidade**: os módulos dos agentes são espelhados byte a byte do repositório de produção do EducaOFF, pelo fecho de imports mais os diretórios varridos em tempo de execução, com a versão exata do código de origem gravada (o commit 5263488) e a impressão digital criptográfica de cada arquivo (o hash: se um único byte mudar, ele muda), conferível contra a produção (85 arquivos; fonte S18). A auditoria encontrou uma versão do espelho defasada e incompleta no meio do experimento; todos os grafos foram então rematerializados na versão corrigida, e o efeito da correção foi medido de forma pareada e é desprezível ($|\Delta| \leq 0,07$, com os intervalos cruzando zero; fonte S11). Segundo, **passos livres**: o GraphForge de produção corta o comprimento do caminho por perfil de aluno, uma decisão de produto; na validação esse corte é desligado, para medir quantos passos os agentes realmente geram.


A técnica GraphForge e a cadeia completa: agentes resolvem em texto, o compilador constrói, a materialização dá o valor



Fidelidade: os módulos dos agentes são ESPELHADOS BYTE A BYTE da produção (commit 5263488; 85 arquivos com hash conferível; fonte S18). Estrutura por construção: 630 coletas e 630 materializações nos 5 corpos, 0 falhas (fonte S1). O corte de caminho por perfil de aluno, decisão de produto, fica desligado na validação (passos livres).

Figura 9. A técnica GraphForge e a cadeia completa: os agentes resolvem o problema em texto, o compilador constrói o grafo, a materialização dá o valor concreto. Da esquerda para a direita: a descrição do problema entra (com a interface, Seção 3.5); os agentes 3a/3b/3c resolvem o problema (acertando, errando de propósito e pedindo ajuda), tudo em texto; o compilador determinístico lê esses textos e constrói e valida o grafo da síntese (rótulos ainda genéricos: não é o comparador); o agente 6 escreve o exercício concreto e o valor esperado de cada passo, sob problema fixo com verificação de obediência; o agente 7 reexecuta o GraphForge; o behaviorGraph resultante é o que a plataforma entrega, e é nele que a régua mede; o professor revisa e publica; o aluno usa um STI guiado comum.

Como os agentes montaram o grafo de um exercício real (registro 00bubble_rep1, braço custo-benefício)



Registro real 00bubble_rep1 (fonte S21), braço custo-benefício, materialização vigente; trechos citados na íntegra. É este grafo materializado que entra na comparação com o especialista (Figura 9 e Seções 4 e 5).

Figura 10. Como os agentes montaram o grafo de um exercício real, com os artefatos do registro 00bubble_rep1 do 6.17 (braço flash-lite, materialização vigente). O problema e a tela entram (①); os agentes resolvem o problema em texto (a linha em itálico cita um trecho literal do registro), produzindo o caminho, os erros prováveis com misconception e devolutiva, e as dicas (②); o GraphForge lê esses textos e constrói e valida o mapa (③); os agentes 6 e 7 colocam os números do problema (④), e nasce o behaviorGraph, aqui reproduzido na íntegra: as respostas corretas de cada passo, os sete erros ancorados nos seus estados com a confusão de cada um, uma devolutiva real e uma das 24 dicas reais (quatro por passo). Fonte: S21.


3.5 O desenho do experimento

Para cada um dos 105 problemas, o agente recebe o **envelope A**: o enunciado literal (com os campos que o compõem declarados por corpus, porque em dois pacotes os dados do problema não moram no campo padrão), a resposta correta, os componentes de conhecimento (KCs, a sigla da área para as habilidades que cada passo exercita) e uma **descrição textual neutra da interface**, a mesma tela que o especialista tinha, com os componentes e o estado inicial, sem nenhum valor de resposta, dica ou feedback. O **envelope B**, o grafo do especialista, jamais entra na geração: ele só é lido na comparação, e a verificação cética conferiu isso com um gancho no próprio leitor de arquivos, além de um teste anti-vazamento que varre os 105 problemas (fontes S2 §F e S17). Uma única glosa interpretativa é declarada: o papel de cada componente da tela vem da interface compartilhada, não do grafo.

São 3 réplicas por problema (modelos de linguagem têm sorteio interno; a escolha de 3 é justificada por decomposição de variância, fonte S22) em **dois braços** que diferem só no modelo dos alunos simulados: o braço custo-benefício, com o gemini-3.1-flash-lite, o modelo econômico que a plataforma roda por padrão, e um braço de comparação com o qwen3-max. A materialização usa o mesmo modelo nos dois braços (gpt-5.6-luna). No total, $105 \times 3 \times 2 = 630$ **grafos de comportamento**, todos coletados e materializados sem falha estrutural. O custo por corpus ficou entre US\$ 3,29 e US\$ 3,92, e o experimento inteiro, incluindo as rematerializações de robustez, em torno de US\$ 22 (fontes S5 e S20 §14).

O modo de autoria permanece deliberadamente diferente entre os dois lados: o especialista autorou por demonstração na tela viva; os agentes autoram por simulação textual, sem executar a interface. Essa diferença não é um viés a corrigir: é a pergunta de pesquisa. O que a tela viva dá ao especialista e o texto não dá ao agente só pode pesar contra o agente, de modo que os resultados são, nesse aspecto, um piso. A Figura 11 resume o que entra em cada autor e as barreiras verificadas em código.

O mesmo insumo dos dois lados: o problema e a interface; nunca o grafo do especialista



Uma única glosa interpretativa declarada: o papel de cada componente da tela vem da interface compartilhada, não do grafo. Mesma informação, modo de autoria diferente (demonstração x simulação em texto): essa diferença é a pergunta de pesquisa. Fontes: S17, S3 e S4.

Figura 11. O que entra em cada autor. À esquerda, o insumo do especialista (problema + tela viva do tutor); à direita, o dos agentes: enunciado literal, resposta, KCs e a descrição textual neutra da interface, entregue pelos canais que os agentes de produção já leem. As barreiras valem sempre: o grafo do especialista nunca entra (verificação automática por geração) e dicas/feedback do pacote nunca entram (teste anti-vazamento em todos os problemas). Fontes: S17, S3 e S4.

3.6 Obediência provada, não presumida

O agente 6 é, em produção, um escritor de histórias: por design, inventa contexto e números para criar exercícios novos. Na validação o problema precisa ser fixo, o do especialista. A obediência não é presumida: é verificada registro a registro por um critério objetivo e direto, o **gate por enunciado**, que confere se o enunciado que o agente 6 escreveu é o problema do CTAT ou um problema inventado. Por esse critério, a aprovação foi de **100% nos 630 grafos dos cinco corpora**; em consequência, nenhuma análise deste artigo usa recorte, todas usam todos os grafos (fontes S16, S6 e S1).

Também mantivemos, como análise de robustez, a família anterior de gates **por valores dos passos**, com quatro níveis de sensibilidade declarados e datados. Ela funciona bem em tarefas de transcrição (no 6.20, o gate estrito aprova 100% do braço econômico e 88% do forte), mas reprova a própria resolução em tarefas de cálculo em etapas: no 8.12, aprova 0 de 57 grafos do braço forte, com 57 de 57 enunciados limpos, porque fatores de escala e porcentagens calculadas são valores legítimos que não constam do enunciado. É por isso que o critério primário é o enunciado, a evidência direta de “usou o problema do especialista?”, e os gates por valor viram sensibilidade (fontes S5 do 8.12 e S6).

4. A régua de estados e as suas salvaguardas

4.1 O que conta como estado: lido do próprio arquivo do especialista, com as decisões publicadas

No CTAT, o estado de um passo é identificado pela resposta daquele passo; no grafo do agente, pelo valor esperado que o agente 6 escreveu. Antes de comparar, os valores dos dois lados passam pela canonização dos valores de entrada (0,2, 1/5 e 2/10 são o mesmo ponto da reta; dicas e devolutivas não são entrada e não se canonizam).

O caminho de referência é lido do próprio *.brd* do especialista, e nem toda aresta dele é um passo do aluno. Quatro exclusões definem o **estado de valor**, cada uma verificável no arquivo: (i) entradas sentinela da interface (o clique em Done, que o CTAT grava como “-1”; o SetVisible vazio), declarada em 15/08; (ii) arestas cujo *<Actor>* é o tutor, não o aluno (mostrar a resposta, revelar componente, configurar a reta), declarada em 16/08; (iii) o seletor de variante do problema, um componente de controle que escolhe qual ramo do exercício vale e nem existe na tela, declarada em 17/08; (iv) arestas de configuração do problema, que não agem sobre componente algum da tela, declarada em 19/08 ao preparar um sexto corpus e sem efeito nos cinco publicados. As três primeiras foram tomadas **depois de ver dados**, e o artigo as trata como tal: são rotuladas post hoc, com data, e a Tabela 3 (Seção 5.4) publica a tabela contrafactual, o que os mesmos grafos dariam sob cada definição, da régua ingênua à vigente. Dois atenuantes verificáveis acompanham o rótulo: a política de ator e sentinela já estava congelada em código de fidelidade de produção desde 16/07, um mês antes do bloco, o que torna a mudança correção de inconsistência, não conveniência; e nenhuma das decisões andou contra os agentes, uma assimetria que fica declarada (fontes S2 §E1 e S12).

4.2 As métricas, incluindo a linha de base que a auditoria exigiu

Estrutura. A cobertura de estados em ordem é a fração dos estados de valor da referência encontrados no grafo do agente como subsequência ordenada, pelo casamento máximo possível (tecnicamente, a subsequência comum mais longa, LCS); em palavras: procura-se a sequência do especialista dentro da sequência do agente, na mesma ordem, podendo pular passos extras no meio. A cobertura sem ordem conta o estado presente em qualquer posição. O caminho íntegro é binário: 1 só quando o caminho inteiro está presente, na ordem. A Figura 12 aplica as métricas, na íntegra, a um registro real.


Ancoragem. Um erro do especialista conta quando o seu valor aparece no grafo do agente ancorado no estado casado correspondente. Duas exclusões declaradas em 18/08 protegem o denominador: erros não ancoráveis (a aresta sai de um estado fora do caminho de referência, tipicamente o ramo de variante não usado) e erros indistinguíveis por valor (o valor errado do especialista é a própria resposta correta do estado, um erro de componente ou de ordem que uma régua de valores não alcança). Quando todos os erros de um corpus caem nessas exclusões, a métrica é N/A, nunca zero; é o caso do 6.18, onde 30 dos 50 erros do especialista pertencem ao ramo de variante e os 20 restantes são indistinguíveis por valor (nos demais corpora de frações as exclusões são raras: 0 de 110 no 6.17, 0 de 54 no 6.19 e 1 de 74 no 6.20; fontes S5 do 6.18 e S6). A métrica de dicas satura no grafo materializado (o agente 6 escreve dicas em todos os passos) e não é usada como evidência.

Linha de base, precisão e F1. A auditoria adversarial do experimento apontou o que a cobertura sozinha esconde: ela é recall puro, e nada pune gerar estados a mais. A correção tem três peças, calculadas por registro (fonte S13). Primeiro, uma **linha de base de acaso**: um grafo “papagaio”, do mesmo tamanho do

grafo do agente, cujos valores são apenas os números do enunciado e a resposta, em ordem cíclica; é o que se obtém sabendo somente o que o envelope A entrega, sem decompor nada. Segundo, a **cobertura ajustada**, $(\text{observada} - \text{base}) / (1 - \text{base})$: zero significa indistinguível do papagaio, um significa o teto. Terceiro, a **precisão de estados** (dos estados que o agente criou, quantos existem na referência) e o **F1**, a média harmônica entre cobertura e precisão. Regra editorial deste artigo, imposta pela auditoria: **nenhuma cobertura bruta aparece sem a linha de base ao lado**. O caminho íntegro dispensa ajuste: a base dele é aproximadamente zero (0,000 em quatro corpora; 0,056 e 0,167 no 6.17), de modo que um agente que o atinge não pode tê-lo feito por acaso.

Incerteza. Os resultados vêm acompanhados de um intervalo de confiança de 95%, entre colchetes: a faixa de valores compatível com os dados, já que 105 problemas são uma amostra e o número exato mudaria um pouco com outros problemas. Esse intervalo é calculado por bootstrap, um procedimento que re-sorteia os exercícios milhares de vezes e observa o quanto a média muda a cada sorteio; o sorteio é feito por exercício inteiro (em cluster), porque as três réplicas de um mesmo exercício se parecem entre si, e tratá-las como independentes fingiria mais certeza do que os dados têm (variante BCa nas análises por corpus, Efron, 1987; no agregado, variante percentílica estratificada por corpus, isto é, sorteando dentro de cada corpus para que nenhum domine os demais, rotulada como tal após correção da auditoria). Quando uma métrica dá o mesmo valor em todos os exercícios (quando satura, como as dicas em 1,000), o re-sorteio não tem o que variar, e o intervalo vem de um limite exato clássico (Clopper-Pearson), de novo para não declarar certeza que os dados não têm. O desvio padrão entre réplicas é agrupado: uma única estimativa que soma a variação observada em todos os exercícios. E uma honestidade final: cerca de 800 intervalos foram calculados ao longo do programa e cerca de 40 são publicados, sem correção formal de multiplicidade; com essa quantidade, alguns extremos aparecem por sorte, e por isso os intervalos deste artigo são **descritivos**, não testes confirmatórios: a única hipótese direcional pré-declarada do programa é o efeito da interface (fontes S2 §A e §E4, S12 e S15).

A régua aplicada ao exemplo real: o grafo do agente contra o grafo do especialista (mesmo registro da Figura 6)



Casamento por subsequência ordenada máxima (LCS), sem tolerância; valores canonizados (0,2 = 1/5). O casamento é determinístico e prefere o mais à esquerda: por isso o '5' do especialista casa com P1 e o '1' fica fora de ordem. Registro 00bubble_rep1, braço custo-benefício (fontes S21 e S12).

Figura 12. A régua aplicada a um registro real (o mesmo exercício do pão da Figura 10, registro 00bubble_rep1, braço flash-lite). O caminho de referência vigente tem 4 estados de valor (as ações do aluno); as ações do tutor e as sentinelas, lidas do próprio arquivo, ficam fora, dos dois lados. Placar deste grafo: cobertura em ordem 3/4 = 0,75; sem ordem 4/4 = 1,00; caminho íntegro 0; erros do especialista no estado casado 2/4 = 0,50; 1 estado extra do agente. Fontes: S21 e S12.

4.3 O reparo de simetria da precisão

A auditoria final (19/08) encontrou um defeito de simetria na própria régua, e o reparo tem metodologia que precisa ser contada. O defeito: o arquivo do especialista grava o clique em Done como a entrada sentinela “-1”, e a régua já a descontava do lado humano; o agente escreve o mesmo clique de concluir como “ok”, “done”, “concluído” ou “convert”, e esses passos entravam na conta da precisão como acerto impossível de existir (o falso positivo garantido: o passo do agente contava contra uma referência da qual o passo equivalente já havia sido descontado). Medido: 439 dos 4.469 estados de agente, 9,8%, presentes nos cinco corpora (7,6% a 11,6%). O reparo neutraliza o passo em vez de removê-lo (erros e dicas são ancorados por número de passo; remover deslocaria a numeração), e um teste de simetria obrigatório no suíte prova que a correção não favorece o agente: a mesma regra, rodada contra o caminho de valor do especialista, atinge 0 de 807 estados; ela remove do agente exatamente o que a régua já removia do humano, e nada além. O invariante também é testado: cobertura em ordem, cobertura sem ordem, caminho íntegro, erros e dicas no estado certo saem idênticos nas duas régua. O efeito, sem uma única chamada de modelo: no agregado dos 630 grafos, a precisão de estados vai de 0,7173 [0,6977; 0,7362] para 0,8205 [0,8038; 0,8363] e o F1 de 0,7081 [0,6932; 0,7228] para 0,7620 [0,7476; 0,7764], intervalos sem sobreposição; cobertura (0,7439), linha de base (0,3962) e ajustada (0,5931) não se movem. O 8.12 quase não muda (F1 0,191 para 0,193 e 0,427 para 0,435): lá o gargalo é recall, 24 campos contra 5 a 12 passos, e nenhum reparo de precisão toca nisso. Vale registrar também a regra que o próprio teste rejeitou: suspeitamos que 14,1% dos valores de erro do agente fossem prosa e que a régua já filtrasse prosa do lado humano; as duas premissas eram falsas (no 8.12, 132 dos 209 erros do especialista são o operador “*”, entrada legítima do seletor; dos 850 valores suspeitos do agente, 73,9% são opções reais de seletor do 6.20 e apenas 2, 0,2%, são lixo). A regra foi descartada e o teste que prova a sua assimetria permanece no suíte para impedir que volte (fontes S25, S30 e S24).


4.4 A régua de dicas: da saturação a seis medidas de conteúdo

Antes do método, o objeto. Num tutor guiado, as dicas de um passo formam uma escada: a primeira orienta de leve, as seguintes vão ficando mais específicas, e o último degrau é o mais direto de todos. No CTAT clássico, esse degrau final entrega a resposta (é o chamado bottom-out: depois de todo o andaime, o tutor diz o que digitar); a Figura 13 mostra uma escada real de cada lado, no mesmo passo do mesmo problema. Até esta rodada, a única métrica de dica era a presença no estado casado, e ela saturou em 1,000 em 9 das 10 células do experimento (única exceção: o braço econômico no 8.12, 0,754), porque o agente 6 escreve uma escada de dicas em todo passo. Métrica saturada não separa braço nenhum e não diz se a dica ensina. A régua nova compara conteúdo, calculada de forma idêntica para os dois lados sobre os mesmos pares: a unidade é o par (estado do especialista, passo do agente casado com ele), pelo mesmo casamento LCS da régua de estados; estados que o agente não criou ficam fora (comparar dica com o vazio não mede nada) e extras do agente são contados à parte. As seis medidas: ter dica no estado; níveis da escada; comprimento médio; a última dica da escada contém o valor esperado do passo (o bottom-out clássico do CTAT); alguma dica da escada contém o valor; e escada completa (duas ou mais dicas em que a última entrega o valor e a primeira não, a forma canônica orientação-para-bottom-out). O casamento de valor é por token com fronteira, não por substring: “5” não casa dentro de “1/5”, “15” nem “0.5”; aceitam-se a forma bruta do arquivo e a canônica. Sensibilidade declarada: toda medida de valor é recalculada só com valores de 2 ou mais caracteres, porque valor de um dígito casa com facilidade. Uma das medidas é pós-dados e vem rotulada: a do bottom-out nasceu de sondagem exploratória em 19/08, antes do pré-registro; as demais foram fixadas antes de qualquer leitura. E o limite da régua fica declarado: ela é léxica, vê o valor escrito com dígitos; uma dica que entregue a resposta por extenso não é

contada, e é exatamente essa a forma que o prompt de produção manda usar. Por isso a régua sozinha mede a política, não a qualidade; quem julga conteúdo é o juiz da Seção 4.5. Agregação como no resto do artigo: bootstrap percentílico estratificado por corpus, cluster no exercício, 10.000 reamostragens, semente 42 (fontes S26, S28 e S31).

Como as dicas foram comparadas: o mesmo passo, as duas escadas, seis medidas

O par casado vem da régua de estados (o casamento LCS da Figura 12). Exemplo real: o passo do denominador ("5") no problema do pão (00bubble).



Escadas literais dos arquivos: especialista = envelope B do 00bubble (6.17); agente = 00bubble_rep1 do braço econômico. Estados que o agente não criou ficam fora (comparar dica com o vazio não mede nada); extras são contados à parte. Agregação: bootstrap percentílico estratificado, cluster no exercício. Fontes: S26, S28, S21 e S31.

Figura 13. Como as dicas foram comparadas, num par real: o passo do denominador ("5") do problema do pão, com a escada do especialista (3 degraus; o último entrega o valor: "Digite 5 na caixa") e a escada do agente (4 degraus; o último descreve a operação sem entregar o 5, por política da plataforma). Abaixo, as seis medidas da régua aplicadas a este par, e a regra de casamento por token com fronteira ("5" não casa dentro de "1/5"). Escadas literais dos arquivos. Fontes: S26, S28 e S21.

4.5 O juiz cego das escadas

O juiz complementa a régua léxica julgando o conteúdo. O desenho é de pontuação absoluta, não de preferência pareada: cada escada é julgada sozinha, cega à origem, numa rubrica fixa. Perguntar "qual escada é melhor?" seria contaminado, porque a escada do CTAT termina entregando o valor e a do agente é proibida disso por política de produto; a pergunta viraria um referendo sobre essa política, não uma medida de qualidade. O juiz é o z-ai/glm-4.5, escolhido por ser de uma família de modelos diferente de todas as que produziram o material (OpenAI materializa os grafos; Google e Qwen geram os alunos simulados): quem julga não pode ser parente de quem fez. As dimensões, de 0 a 3: especificidade (a escada fala deste problema e deste passo, não é conselho genérico), escalonamento (cada nível acrescenta informação em vez de repetir) e acionabilidade (depois da última dica, um aluno travado sabe o que fazer); duas perguntas de sim ou não, correção e entrega-da-resposta, esta última descritiva e não pontuada, existindo para medir a política dos dois lados sem julgá-la. Dois controles negativos entram no mesmo lote, cegos: a escada estrangeira (a escada de outro problema do mesmo corpus servida para este passo, que deve cair em especificidade) e a escada embaralhada (a escada real com os níveis fora de ordem, que deve cair em escalonamento e só nele). O gate é pré-declarado: a especificidade do estrangeiro precisa ficar ao menos 0,5 ponto abaixo da média das escadas reais, e o escalonamento do embaralhado precisa ficar abaixo do ordenado; falhando qualquer um, o juiz é descalibrado e não há veredito. A amostragem é declarada e determinística: uma réplica por exercício e braço (a primeira em ordem de arquivo), todos os estados casados dela; a escada do especialista é julgada uma única vez por corpus, exercício e estado. Volume: 1.452 escadas julgadas, nenhuma sem veredito.

Configuração declarada, e por que ela não move a conclusão. Este juiz rodou com o raciocínio do modelo suprimido, a mesma opção barateada cujo efeito a Seção 6 documenta no juiz de erros: queda de

0,929 para 0,714 no reconhecimento do gabarito humano. A informação é declarada aqui para que o leitor a tenha antes dos números, e três propriedades do desenho a tornam inofensiva para o que a Tabela 6 afirma.

A primeira, e decisiva, é que **a tabela reporta uma comparação, não um nível**. As escadas do especialista e as dos dois braços foram para a mesma pilha cega, no mesmo lote, sob o mesmo juiz e a mesma configuração. Uma calibração mais severa desloca as três colunas juntas; ela não cria nem apaga uma diferença de 0,7 ponto em acionabilidade, nem transforma em empate uma distância real de especificidade. O que a supressão de raciocínio faz, pela evidência da Seção 6, é tornar o juiz uniformemente mais rigoroso com material legítimo, e rigor uniforme é exatamente o que uma comparação pareada absorve.


A segunda é que **o gate deste juiz não é de taxa absoluta**, e sim de discriminação entre controles plantados. Ele passou nos dois, e passou de um jeito que um juiz degradado não produziria: derrubou a escada estrangeira em especificidade (0,50, queda de 1,46) e a embaralhada **apenas** em escalonamento (0,45), preservando especificidade em 2,34 e acionabilidade em 2,86. Como embaralhar não altera conteúdo, só ordem, essa seletividade é a assinatura de um instrumento que está lendo a escada. Um juiz cego ao conteúdo erraria as duas dimensões, ou nenhuma.

A terceira é que **o achado central sobre dicas não depende de juiz algum**. A régua determinística da Seção 4.4, que não usa modelo de linguagem, mede o mesmo fenômeno de forma independente e chega ao mesmo lugar: o último degrau entrega o valor em 0,849 das escadas do especialista e em 0,019 e 0,026 nas dos agentes, contra 79% e 3% a 10% no juiz. Duas medições sem premissa em comum, mesma conclusão.

Feitas as três ressalvas, permanece a leitura conservadora: as notas absolutas da Tabela 6 devem ser tomadas como piso, não como estimativa pontual. Um juiz com raciocínio tenderia a reconhecer mais mérito nas escadas reais dos dois lados, não menos. Uma análise de sensibilidade pareada, re julgando uma amostra com o raciocínio liberado, fecharia essa margem e fica registrada como trabalho disponível (fontes S27, S26 e S31).

A Figura 14 resume o desenho inteiro em uma imagem: a pilha sem identificação, o juiz, a rubrica e as duas pegadinhas com os números do gate (fontes S27, S29 e S31).

O juiz cego das escadas: uma prova sem identificação, com duas pegadinhas de controle



Amostragem determinística declarada: uma réplica por exercício e braço (a primeira em ordem de arquivo); a escada do especialista é julgada uma única vez por estado. Pontuação absoluta, não preferência pareada: perguntar 'qual é melhor?' viraria um referendo sobre a política de fechamento da escada. Fontes: S27, S29 e S31.

Figura 14. O juiz cego das escadas como uma prova sem identificação, com duas pegadinhas de controle plantadas na pilha. A escada estrangeira (de outro problema) derruba a especificidade para 0,50, queda de 1,46 contra a margem exigida de 0,5; a escada embaralhada derruba só o escalonamento (0,45), mantendo especificidade (2,34) e acionabilidade (2,86) altas. Como embaralhar não

muda o conteúdo, só a ordem, o juiz derrubou exatamente a dimensão certa sem saber que era um controle: é esse padrão que valida o instrumento. Fontes: S27, S29 e S31.

5. Resultados

A validação inteira soma 5 corpora, 105 problemas de especialista e 630 grafos de agente, sem falha estrutural e sem recorte (gate por enunciado: 100%). Os resultados seguem em sete tempos: a tabela-mestra por corpus (5.1), a leitura contra a linha de base (5.2), o gradiente de granularidade (5.3), a tabela contrafactual da régua (5.4), o efeito da interface (5.5), a comparação entre braços com o agregado (5.6) e as dicas, com o juiz cego e a validação convergente (5.7).

5.1 A tabela-mestra

Tabela 1. Régua de estados no grafo materializado, por corpus e braço (todos os grafos). Entre colchetes, o intervalo de confiança de 95%: a faixa de valores compatível com os dados, explicada na Seção 4.2 (bootstrap BCa em cluster de exercício). A coluna “ajustada” desconta a linha de base de acaso da Seção 4.2. fl = flash-lite; qw = qwen3-max. Fontes: S1, S6 e S7.

Corpus (ref.)	Braço	Cobertura em ordem	Ajustada	Sem ordem	Caminho íntegro	Erros no estado certo	Estados/ grafo
6.17 (4)	fl	0,778 [0,753; 0,816]	0,424	0,990	0,125 [0,028; 0,278]	0,299 [0,252; 0,350]	5,72
6.17 (4)	qw	0,941 [0,896; 0,969]	0,858	1,000	0,764 [0,583; 0,875]	0,629 [0,553; 0,704]	6,96
6.19 (4,35)	fl	0,725 [0,659; 0,768]	0,480	0,870	0,145 [0,072; 0,217]	0,442 [0,343; 0,543]	5,41
6.19 (4,35)	qw	0,728 [0,679; 0,760]	0,463	0,838	0,072 [0,014; 0,130]	0,693 [0,568; 0,797]	8,32
6.18 (3)	fl	0,961 [0,906; 0,983]	0,933	0,967	0,883 [0,717; 0,950]	N/A	5,52
6.18 (3)	qw	0,989 [0,967; 1,000]	0,975	0,989	0,967 [0,874; 0,983]	N/A	8,10
6.20 (5)	fl	0,919 [0,877; 0,954]	0,860	0,919	0,596 [0,386; 0,754]	0,306 [0,235; 0,376]	6,09
6.20 (5)	qw	0,933 [0,891; 0,961]	0,877	0,933	0,667 [0,456; 0,807]	0,598 [0,525; 0,667]	8,12
8.12 (24)	fl	0,087 [0,064; 0,107]	-0,042	0,292	0,000 [0,000; 0,176]	0,000 [0,000; 0,176]	5,11
8.12 (24)	qw	0,300 [0,283; 0,320]	0,134	0,694	0,000 [0,000; 0,176]	0,033 [0,017; 0,061]	12,12

Quatro leituras por corpus, com os fatos que cada um revelou. No **6.18**, o melhor resultado estrutural do experimento: com 3 estados de valor e uma tela que impõe a sequência (dividir a segunda reta, marcar, escrever o numerador), o braço forte reproduz o caminho inteiro, na ordem exata, em 97% dos grafos, e o econômico em 88%; a métrica de erros é N/A pelo desenho do próprio especialista (Seção 4.2). No **6.20**, ambos os braços acima de 0,92 de cobertura com 0,60 a 0,67 de caminho íntegro; o quinto estado é textual (a alternativa escolhida no seletor) e casou em 45 de 57 grafos do braço forte, com parte das falhas sendo escolha errada da alternativa, um erro real de conteúdo que a régua capturou. No **6.19**, a cobertura fica em 0,73 nos dois braços, mas o caminho íntegro cai (0,145 e 0,072): o que falta é quase sempre um único estado de convenção da interface, o “0” da parte inteira na conversão a número misto, que o especialista preenche e o agente pula. No **8.12**, o limite do método, tratado na Seção 5.3.

5.2 Nada de cobertura sem linha de base

Tabela 2. Cobertura observada contra a linha de base de acaso (grafo “papagaio” de mesmo tamanho, feito só com os números do enunciado e a resposta), com cobertura ajustada, precisão de estados e F1 sob a régua simétrica da Seção 4.3; e o caminho íntegro observado contra a sua base. Cobertura, base, ajustada e íntegro são idênticos nas duas régua, por invariante testado. Fontes: S7, S25 e S2 §B.

Corpus · braço	Cobertura	Base	Ajustada	Precisão	F1	Íntegro obs./base
6.17 · fl	0,778	0,524	0,424	0,997	0,871	0,125 / 0,056
6.17 · qw	0,941	0,563	0,858	0,972	0,952	0,764 / 0,167
6.19 · fl	0,725	0,380	0,480	0,872	0,780	0,145 / 0,000
6.19 · qw	0,728	0,406	0,463	0,839	0,774	0,072 / 0,000
6.18 · fl	0,961	0,417	0,933	0,704	0,809	0,883 / 0,000
6.18 · qw	0,989	0,417	0,975	0,638	0,770	0,967 / 0,000
6.20 · fl	0,919	0,421	0,860	0,908	0,913	0,596 / 0,000
6.20 · qw	0,933	0,442	0,877	0,866	0,895	0,667 / 0,000
8.12 · fl	0,087	0,123	-0,042	0,499	0,193	0,000 / 0,000
8.12 · qw	0,300	0,192	0,134	0,819	0,435	0,000 / 0,000

Uma nota de leitura antes dos fatos: a precisão e o F1 desta tabela usam a régua simétrica (Seção 4.3). Sob a régua congelada anterior, os agregados eram precisão 0,7173 [0,6977; 0,7362] e F1 0,7081 [0,6932; 0,7228]; sob a simétrica, 0,8205 [0,8038; 0,8363] e 0,7620 [0,7476; 0,7764], intervalos sem sobreposição, e a correção comprovadamente não favorece o agente (teste de simetria: 0 de 807 estados do especialista atingidos). Três fatos que só aparecem com estas colunas. Primeiro, **a cobertura bruta superestima**: 38% a 56% dela é atingível por um grafo que não sabe decompor nada; a leitura primária é a ajustada (0,42 a 0,98 nos corpora de frações) ou o F1 (0,77 a 0,95). Segundo, **o caso que justifica a métrica**: no 8.12, o braço econômico tem cobertura ajustada negativa, fica abaixo do papagaio; sem a linha de base, “0,087 de cobertura” leria como um resultado positivo pequeno, quando o veredito correto é indistinguível do acaso, na verdade pior. Terceiro, **a precisão revela o custo da verbosidade**: no 6.18, o braço forte tem cobertura 0,989 com precisão 0,638, mais de um terço dos estados que ele cria não existe na referência, e o F1 o coloca abaixo do braço econômico (0,770 contra 0,809), invertendo a leitura que a cobertura sozinha sugeria. O caminho íntegro, com base aproximadamente zero, é a métrica robusta do experimento: quem o atinge, atingiu por estrutura, não por acaso.

5.3 O gradiente de granularidade: a fronteira do método

O resultado mais informativo do experimento aparece quando os cinco corpora são postos lado a lado pela granularidade da referência. O Gráfico 1 mostra a cobertura em ordem contra o número de estados de valor por problema, nos cinco pontos medidos: com 3 estados, 0,96 e 0,99; com 4, 0,78 e 0,94; com 4,35, 0,73 e 0,73; com 5, 0,92 e 0,93; com 24, 0,09 e 0,30. A associação não é perfeitamente monotônica (o 6.19 fica abaixo do 6.20 por um estado de convenção de interface, discutido na Seção 5.1), mas o contraste entre os extremos é o achado: **onde o especialista decompõe em 3 a 5 estados, os agentes acompanham; onde tratou cada célula de uma tabela como um passo, os agentes agregam**. No 8.12, os agentes produzem 5,1 e 12,1 passos contra 24 da referência, blocos como “preencher as razões originais” no lugar de célula a célula, e o caminho íntegro é 0,000 nos dois braços. Não é desobediência nem incompreensão da tarefa: os trazes citam a tabela dezenas de vezes e o gate por enunciado aprova 100%; é uma diferença de **estilo de decomposição**, e ela define, com números, onde o método atual deixa de reproduzir o especialista (fontes S1 e S5 do 8.12).




Gráfico 1. O gradiente de granularidade: cobertura de estados em ordem (com IC de 95% em cluster de exercício) contra o número de estados de valor por problema na referência do especialista, nos cinco corpora, para os dois braços. Anotações: no 8.12 (24 estados por problema), os agentes decompõem em 5,1 (flash-lite) e 12,1 (qwen) passos por grafo, e o caminho íntegro é 0,000 nos dois braços; no extremo oposto (6.18, 3 estados), o caminho íntegro chega a 0,967. Fontes: S1 e S6.

5.4 A tabela contrafactual: o que cada decisão de régua moveu

A Seção 4.1 declarou que três das exclusões que definem “estado de valor” foram decididas depois de ver dados. A Tabela 3 publica o efeito de cada uma: os mesmos grafos, pontuados sob quatro definições encaixadas, da régua ingênua (R0, toda aresta correta do arquivo conta) à vigente (R3). Fonte: S9.

Tabela 3. Cobertura em ordem / caminho íntegro sob definições encaixadas do estado de valor (médias por braço; entre parênteses, estados de referência por problema). R1 exclui sentinelas; R2 exclui também as ações do tutor; R3 exclui também o seletor de variante (régua vigente). Valores da análise contrafactual (versão v2 dos agentes; o efeito de versão é desprezível, fonte S11). Fontes: S9 e S14.

Corpus · braço	R0 ingênua	R1	R2	R3 vigente
6.17 · fl	0,452 / 0,000 (7,0)	0,528 / 0,000 (6,0)	0,781 / 0,139 (4,0)	0,781 / 0,139 (4,0)
6.17 · qw	0,605 / 0,000 (7,0)	0,706 / 0,014 (6,0)	0,938 / 0,750 (4,0)	0,938 / 0,750 (4,0)
6.19 · fl	0,306 / 0,000 (10,0)	0,478 / 0,000 (6,3)	0,707 / 0,101 (4,3)	0,707 / 0,101 (4,3)
6.19 · qw	0,310 / 0,000 (10,0)	0,494 / 0,000 (6,3)	0,729 / 0,087 (4,3)	0,729 / 0,087 (4,3)
6.18 · fl	0,332 / 0,000 (11,0)	0,365 / 0,000 (10,0)	0,704 / 0,000 (4,0)	0,939 / 0,817 (3,0)
6.18 · qw	0,382 / 0,000 (11,0)	0,420 / 0,000 (10,0)	0,750 / 0,000 (4,0)	1,000 / 1,000 (3,0)
6.20 · fl	0,579 / 0,000 (8,0)	0,662 / 0,000 (7,0)	0,926 / 0,632 (5,0)	0,926 / 0,632 (5,0)
6.20 · qw	0,599 / 0,000 (8,0)	0,684 / 0,000 (7,0)	0,947 / 0,737 (5,0)	0,947 / 0,737 (5,0)

A leitura é dupla, e as duas metades precisam ser ditas. De um lado, a magnitude: **sob a régua ingênua, o caminho íntegro é 0,000 em todos os corpora**; a maior parte do efeito vem de R1 para R2, excluir as arestas que o próprio arquivo do especialista atribui ao tutor. De outro, a justificativa: ela é conceitual e verificável no próprio .brd (o aluno não executa “mostrar resposta” nem “configurar a reta”), e a política de ator já estava congelada em código antes do bloco. Ainda assim, o leitor deve saber que os resultados estruturais deste artigo dependem dessas definições, e é para isso que esta tabela existe.

5.5 O efeito da interface: a hipótese pré-registrada

A única hipótese direcional pré-declarada do programa é a de que entregar ao agente a mesma interface que o especialista teve aproxima os grafos. Ela foi testada no corpus original (6.17), comparando de forma pareada, mesmo exercício e mesma réplica, a rodada com interface contra a rodada anterior sem interface, sob a régua vigente: cobertura em ordem +0,267 [0,163; 0,358] no braço econômico e +0,323 [0,236; 0,403] no forte; cobertura sem ordem +0,354 e +0,323; erros no estado certo +0,235 [0,176; 0,284] e +0,388 [0,281; 0,493]; caminho íntegro +0,042 [-0,111; 0,208] e **+0,458 [0,292; 0,583]** (fonte S10). Em palavras: com a interface, o braço forte passou a reproduzir o caminho inteiro do especialista em três de cada quatro grafos do 6.17, algo que sem a interface não acontecia. Foi esse resultado que fixou a interface como insumo obrigatório do desenho em todos os corpora seguintes.

5.6 Braços e agregado: o que se sustenta e o que não

Tabela 4. Diferença pareada entre braços (qwen – flash-lite; mesmo exercício × réplica), por corpus. Fonte: S8.

Corpus	Cobertura em ordem	Sem ordem	Caminho íntegro	Erros no estado certo
6.17	+0,156 [0,108; 0,194]	+0,021 [0,000; 0,052]	+0,611 [0,417; 0,750]	+0,377 [0,292; 0,455]
6.19	+0,023 [-0,016; 0,088]	-0,012 [-0,054; 0,029]	-0,014 [-0,130; 0,101]	+0,295 [0,184; 0,413]
6.18	+0,061 [0,028; 0,094]	+0,044 [0,017; 0,078]	+0,183 [0,083; 0,283]	N/A
6.20	+0,021 [0,007; 0,039]	+0,021 [0,007; 0,039]	+0,105 [0,035; 0,193]	+0,327 [0,219; 0,428]

Uma correção de afirmação que fazemos questão de registrar: em versões anteriores deste material, escrevemos que o braço com alunos mais fortes era melhor em tudo. **Isso é falso.** Vale para o 6.17 (e para o 8.12, onde o contraste de cobertura é o maior do bloco); no 6.19, cobertura e caminho íntegro não diferem entre os braços (os intervalos cruzam zero, com o braço forte nominalmente pior no íntegro); e, pelo F1 da Tabela 2, o braço forte fica **abaixo** do econômico no 6.18 (0,770 contra 0,809) e no 6.20 (0,895 contra 0,913), porque paga a cobertura com perda de precisão; a leitura sobrevive à correção de simetria da Seção 4.3, que elevou os dois braços sem trocar a ordem. O que se sustenta em todos os corpora avaliáveis é a vantagem em **erros no estado certo** (+0,30 a +0,38): o braço forte ancora mais erros do especialista no estado exato. A afirmação honesta é: o braço com alunos mais fortes cobre mais estados e acerta mais erros no estado certo, ao custo de precisão; o balanço depende do corpus.

No agregado dos cinco corpora (pool de 315 grafos por braço; bootstrap percentílico estratificado por corpus, cluster no exercício), o braço econômico fica em 0,702 [0,684; 0,719] de cobertura em ordem, 0,820 sem ordem, 0,337 [0,286; 0,387] de caminho íntegro e 0,272 [0,239; 0,307] de erros no estado certo (4 corpora avaliáveis); o braço forte, em 0,786 [0,771; 0,800], 0,895, 0,495 [0,444; 0,543] e 0,506 [0,464; 0,547]. A heterogeneidade entre corpora é grande por construção (amplitude de cobertura de 0,087 a 0,961 no braço econômico) e é ela, não o agregado, que carrega a informação: os pools são resumo descritivo, não uma estimativa de “desempenho geral” (fonte S1).

5.7 As dicas: empate no conteúdo, distância na política

A régua determinística (Seção 4.4) mede primeiro a forma. Nos pares casados, os dois lados sempre têm dica; o especialista escreve escadas de 2,97 níveis [2,91; 3,03] no pool do braço econômico (2,93 no do

forte) e o agente sempre 4, sem variância; os comprimentos são próximos (71,7 e 68,1 caracteres por dica no especialista, 81,7 e 75,8 nos agentes). A diferença está no fechamento da escada, e ela é enorme dos dois lados da comparação (Tabela 5).

Tabela 5. Régua determinística de dicas nos pares casados (pool por braço; bootstrap percentílico estratificado, cluster no exercício). As duas colunas do especialista diferem porque o conjunto de pares casados muda com o braço. Fonte: S26.

Métrica	especialista (pool fl · pool qw)	agente flash-lite	agente qwen
última dica entrega o valor	0,849 [0,842; 0,856] · 0,859 [0,855; 0,864]	0,019 [0,010; 0,032]	0,026 [0,016; 0,037]
escada completa (≥2 níveis; última entrega, primeira não)	0,807 [0,788; 0,825] · 0,830 [0,818; 0,840]	0,019 [0,010; 0,032]	0,025 [0,015; 0,036]
algum nível entrega o valor	0,933 [0,926; 0,942] · 0,939 [0,934; 0,946]	0,048 [0,032; 0,065]	0,068 [0,052; 0,084]
níveis por passo	2,970 [2,912; 3,030] · 2,933	4,000 (sem variância)	4,000
caracteres por dica	71,7 · 68,1	81,7 [80,9; 82,5]	75,8 [75,0; 76,6]

Por corpus, a diferença aparece nas dez células sem exceção: a última dica do especialista entrega o valor em 0,573 a 1,000 dos passos; a dos agentes, em 0,000 a 0,053 (fonte S26). Isso não é falha dos agentes: é política de produto, documentada e datada no código de produção espelhado, anterior a esta análise. O prompt do agente 6 instrui, no nível final da escada: “Guie ate MUITO PERTO sem revelar o valor final. Explícite a operacao final de forma descritiva e acionavel em palavras” (fonte S32); e o gate de qualidade fiscaliza, em decisão do usuário datada de 02/08/2026: “NENHUMA pista revela a resposta. A versão anterior isentava a última pista, tratando-a como bottom-out do CTAT. O produto seguiu o caminho oposto: a dica orienta até o fim, e quem conclui o passo é o aluno” (fonte S32). Os números têm então duas leituras, reportadas juntas: como **conformidade**, o pipeline cumpre a própria política em 97,4% a 98,1% dos passos (última dica sem o valor) e em 93,2% a 95,2% (nenhum nível com o valor), ou seja, o gate funciona no material real; como **distância ao CTAT**, é exatamente aqui que o material dos agentes mais se afasta do corpus de referência, que fecha a escada com o valor em cerca de 85% dos passos.

O juiz cego (Seção 4.5) julga o conteúdo, e o seu gate passou de um jeito que valida o instrumento: o controle estrangeiro caiu para 0,50 de especificidade (1,46 ponto abaixo das escadas reais, contra margem exigida de 0,5), e o controle embaralhado manteve especificidade alta (2,34) e acionabilidade alta (2,86) derrubando só o escalonamento (0,45). Embaralhar não muda o conteúdo, só a ordem, e o juiz, sem saber que aquilo era um controle, isolou exatamente a dimensão da ordem; um juiz que carimbasse notas não produziria esse padrão (fonte S27).

O Gráfico 2 mostra o resultado de uma vez: empate visual em duas dimensões, perda localizada na terceira, e os dois instrumentos independentes chegando à mesma conclusão sobre quem entrega a resposta.




Gráfico 2. No painel A, as notas do juiz cego (0 a 3): especificidade e escalonamento empatados entre especialista e agentes; a diferença concentra-se na acionabilidade, e a causa é a política documentada da plataforma (a escada do agente não entrega a resposta). No painel B, a validação convergente: a régua léxica (a última dica contém o valor: 0,85 contra 0,02–0,03) e o juiz cego (entrega a resposta: 79% contra 3% e 10%) medem coisas diferentes por caminhos diferentes e contam a mesma história. Fontes: S26 e S27.

Tabela 6. Juiz cego das escadas (1.254 escadas reais; notas de 0 a 3; entrega da resposta é descritiva, não pontuada). Fonte: S27.

Dimensão	especialista	agente flash-lite	agente qwen
especificidade	1,96	1,97	1,97
escalonamento	1,88	1,89	1,88
acionabilidade	2,81	2,09	2,13
entrega a resposta final	79%	3%	10%

A leitura, na ordem que os dados pedem. Primeiro, **empate onde importa para a autoria**: os agentes escrevem escadas tão ancoradas no problema quanto o autor humano (1,97 contra 1,96) e tão bem escalonadas (1,89 contra 1,88). Segundo, **a perda é única e localizada**: acionabilidade, 2,81 contra 2,09 e 2,13. Terceiro, **a causa é a política documentada acima**, anterior à análise: o agente não fecha a escada com a resposta. Quarto, as duas leituras andam juntas: conformidade de 97% a 98% com a própria política, e é este o ponto em que o material mais se afasta do padrão CTAT. Quinto, **validação convergente**: a régua léxica, que só conta dígitos, mediu 0,85 contra 0,02; o juiz semântico, sem nenhuma premissa em comum com ela, mediu 79% contra 3% a 10%. Dois instrumentos independentes, a mesma conclusão; a folga entre 2% e 3% a 10% é exatamente a limitação léxica declarada, a resposta entregue por extenso.

Uma dimensão foi **retirada, e o motivo fica registrado**: a de correção matemática (especialista 83%, agentes 92% e 89%) não é interpretável, porque parte das 79 escadas de especialista marcadas incorretas é o juiz errando por julgar o passo fora do contexto da decomposição (num problema do 6.19 ele alega que “a resposta correta é 3/5, não 5”, quando 5 é o valor do campo do denominador). A contaminação é sistemática, 32% no 8.12 contra 5% a 16% nos demais, justamente o corpus mais profundo. As outras três dimensões não sofrem disso: avaliam a escada como escada, não a matemática do passo (fonte S24).

6. Discussão

Três achados estruturam o que este experimento demonstra, e cada um vem com o seu limite.

Primeiro: a interface é insumo, não detalhe. O especialista autorou demonstrando numa tela; parte dos estados dele nasce da tela. Quando o agente recebe a mesma tela, em texto, a concordância salta (+0,27 a +0,32 de cobertura, +0,46 de caminho íntegro no braço forte, Seção 5.5), e foi só com esse insumo que o caminho inteiro do especialista passou a ser reproduzível. Para o campo emergente de geração automática de tutores, a lição transfere: comparar um gerador com um autor humano sem igualar o insumo mede a diferença de informação, não a de capacidade. O limite: o efeito foi medido num único corpus (o original), como comparação pareada pré-registrada; nos demais, a interface já entrou como parte do desenho.

Segundo: a granularidade da referência é a fronteira do método. Onde o especialista decompõe em 3 a 5 estados e a tela impõe a sequência, os agentes reproduzem a estrutura quase por inteiro, até 97% de caminhos íntegros; onde o especialista decompõe célula a célula, os agentes agregam em blocos e a concordância desaba (cobertura 0,09 a 0,30, caminho íntegro zero, e o braço econômico abaixo da linha de base). O 8.12 foi mantido no experimento exatamente para expor esse limite, com a expectativa registrada antes da coleta. A leitura prática para o desenho de AITS: ou se ensina o agente a decompor no grão do especialista (por exemplo, dando à interface um papel ainda mais estruturante, célula a célula), ou se aceita que tarefas de planilha exigem outro estilo de autoria. A leitura científica: qualquer avaliação de geradores de tutores deveria reportar a granularidade da referência junto com a concordância, porque um número único esconde exatamente o que mais importa.

Terceiro: régua sem linha de base engana. Um grafo que apenas repete os números do enunciado atinge 12% a 56% de cobertura. Com a linha de base, a cobertura ajustada e o F1, três leituras mudaram de sinal neste artigo: o “resultado positivo pequeno” do 8.12 virou indistinguível do acaso (pior, no braço econômico); a “vantagem” do braço forte virou trade-off entre cobertura e precisão, com o F1 invertendo a ordem em dois corpora; e o caminho íntegro se firmou como a métrica robusta, porque a sua base é aproximadamente zero. Recomendamos a prática a qualquer trabalho que compare estruturas geradas com referências: publicar o piso de acaso da própria régua.

Quarto: a divergência de dicas é política, não incapacidade, e isso muda o que o professor revisa. Nos dois instrumentos, os agentes empatam com o especialista exatamente nas dimensões que custam tempo de autoria (ancorar a dica neste problema; escalonar sem repetir) e diferem numa decisão de produto reversível: entregar ou não a resposta na última dica. Para o desenho Augmented Teacher in the Lead, isso significa que a revisão docente das dicas não é reescrita, é uma escolha de política com um toggle documentado; e, para a comparação científica, significa que nenhuma métrica de dica pode ser lida como “os agentes erraram” sem essa nota.

Dois achados sobre juízes de LLM, que valem além deste artigo. O primeiro: suprimir o raciocínio do juiz degrada a calibração, e o controle usual é cego a isso. Numa comparação controlada, com os mesmos 42 itens de gabarito humano e o mesmo modelo (z-ai/glm-4.5), mudando só o raciocínio: com raciocínio, o juiz aprova 0,929 dos erros catalogados pelo especialista e 0,565 dos extras dos agentes; sem raciocínio, 0,714 e 0,419; e a rejeição de distratores, os itens sabidamente inválidos plantados na pilha para testar se o juiz rejeita lixo, fica idêntica, 0,982 nos dois. Ou seja: desligar o raciocínio não degradou a rejeição do lixo, degradou o reconhecimento do legítimo, e a métrica de validação mais usada para juiz de LLM (“ele rejeita distratores?”) não vê essa falha; só o controle positivo, o gabarito humano misturado cego na pilha, a detecta. Sem ele, teríamos publicado “os agentes só acertam 13% dos estados extras” atribuindo aos agentes um defeito do juiz (fontes S31 e S33). O segundo: controle negativo mal construído reprova juiz possivelmente bom. No juiz de estados, usamos os valores de erro do próprio especialista como distrator negativo, assumindo que “valor que o aluno erra” não é alvo de passo; em problema de vários passos isso

é falso, o mesmo valor é erro num passo e intermediário legítimo noutra, e o juiz aceitou 35,3% desses distratores, derrubando a rejeição total para 0,741, abaixo do gate de 0,80. O pré-registro havia declarado essa fraqueza antes de rodar, e ela se materializou: o gate ficou mais difícil do que o objeto exige (fontes S31 e S33). A conclusão que junta os dois: juiz de LLM só é confiável se os dois lados forem medidos, o que ele rejeita e o que ele reconhece, e se ambos os controles forem válidos.

O que a validação sustenta, então? Que um pipeline de agentes em produção, custando dólares por corpus, entrega grafos executáveis sem falha e, no grão em que especialistas humanos autoram tutores de frações, reconstrói a espinha estrutural desses tutores com folga sobre o acaso, chegando a reproduzir caminhos inteiros na ordem exata na maioria dos grafos dos melhores casos. E o que ela não sustenta: nenhuma afirmação do tipo “tão bom quanto um humano” (não há banda humano contra humano), nenhuma equivalência geral entre braços, nenhuma extrapolação para tarefas de granularidade fina, e nenhuma conclusão sobre a qualidade pedagógica das devolutivas e dicas, que esta régua não mede. No desenho *Augmented Teacher in the Lead*, esses números têm um uso direto: dizem ao professor revisor onde o rascunho do agente tende a chegar pronto (frações, 3 a 5 passos; escadas de dicas ancoradas e escalonadas) e onde ele exigirá reestruturação (tarefas tabulares) ou uma decisão de política (fechar ou não a escada com a resposta), e dizem ao mantenedor da plataforma que o braço econômico entrega estrutura comparável nos corpora fáceis por um quinto do custo, enquanto o braço forte compra ancoragem de erros.

7. Limitações

1. **Um único autor de referência.** Todos os tutores vêm da equipe Mathtutor/CMU, sem metadado de autor individual. Não há banda humano contra humano, logo não se sabe o teto de concordância entre especialistas; nenhuma afirmação do tipo “tão bom quanto um humano” é sustentável com estes dados.
2. **Quatro decisões pós-dados na régua.** Sentinelas (15/08), ações do tutor (16/08), seletor de variante (17/08) e as duas exclusões da régua de erros (18/08) foram declaradas depois de ver dados. Estão rotuladas post hoc, com data, e a Tabela 3 publica o contrafactual: sob a régua ingênua, o caminho íntegro é 0,000 em todos os corpora. Atenuantes verificáveis: a política de ator e sentinela estava congelada em código desde 16/07, antes do bloco; e nenhuma decisão andou contra os agentes, assimetria que fica declarada.
3. **A régua de estados mede valor, não pedagogia.** Ela não julga se um estado extra do agente é bom, não compara componente nem ação (um “5” no campo errado casa como se estivesse certo) e não avalia texto. Nesta versão, as dicas ganharam medição de conteúdo própria (Seções 4.4, 4.5 e 5.7); as devolutivas de erro seguem sem julgamento de texto, e a dimensão de correção matemática do juiz de dicas foi retirada por contaminação de contexto (Seção 5.7).
4. **O envelope A é derivado do próprio .brd.** A lista de componentes vem das arestas do especialista e os KCs, das regras do mesmo arquivo. Não vaza caminho nem erros, o que foi verificado por teste e por gancho no leitor de arquivos, mas é uma dependência da referência que fica declarada.
5. **Transcritibilidade da referência.** Parte dos estados do especialista é derivável do enunciado e da resposta que o agente recebe; é exatamente o que a linha de base quantifica. O 8.12, com 50,7% de transcritibilidade e 24 estados por problema, é o teste decisivo, e é publicado mesmo com cobertura baixa.

6. **Multiplicidade.** Cerca de 800 intervalos calculados, cerca de 40 publicados, sem correção formal. Os intervalos são descritivos; a única hipótese direcional pré-declarada é o efeito da interface.
7. **O modo de autoria difere.** O especialista demonstra na tela viva; o agente simula por texto. Mesma informação, processo diferente: é a pergunta de pesquisa, não um defeito, e só pode pesar contra o agente.
8. **A métrica antiga de dicas saturava** (1,000 em 9 das 10 células, porque o agente 6 escreve dicas em todos os passos) e nunca foi usada como evidência; foi substituída nesta versão pela régua de conteúdo e pelo juiz cego (Seções 4.4 e 4.5). A medição nova compara escadas com o padrão do especialista; ela não mede o efeito das dicas na aprendizagem de alunos.
9. **Adaptador de infraestrutura.** As temperaturas dos agentes conferem com a produção, mas os *maxTokens* do adaptador são os defaults do registro de modelos, e a produção aplica por cima um tier próprio (4 de 9 papéis divergem). O efeito não foi medido; fica declarado.
10. **Um sexto corpus foi preparado e interrompido.** O 7.12 Conversion Factors teve dataset, interface e piloto concluídos e a coleta cancelada por decisão do autor, com os cinco corpora fechados já sustentando o argumento; nada dele entra em tabela alguma, e a pasta preservada documenta a decisão (fonte S23).
11. **Os erros extras dos agentes ficaram sem veredito.** Os dois juízes disponíveis reprovaram o gate de calibração pré-declarado (aprovação do gabarito do especialista: 0,479 no z-ai/glm-4.5 sem raciocínio e 0,501 no deepseek-v4-flash, contra exigência de 0,80; ambos com rejeição de distratores alta, 0,984 e 0,957), errando na mesma direção (acordo bruto de 78,3%; kappa 0,534, a concordância que sobra depois de descontar o acaso). Pela regra, não há número, e não houve terceira tentativa. O único juiz calibrado barato, o gpt-5.6-luna, escreve 43,8% dos erros julgados (2.637 de 6.021 aparecem só depois do agente 6): seria auto-avaliação. Uma rodada anterior (14/08), com juiz calibrado, encontrou cerca de 50% de extras válidos, mas em outro objeto (corpus 6.17, grafos crus do estágio de síntese, antes da interface fixa e da materialização) e vale apenas como referência, nunca como resultado deste experimento (fontes S24, S31 e S33).
12. **Amostra de pacotes e domínio.** A validação cobre 5 dos 54 pacotes do catálogo (105 dos 710 grafos), todos de matemática do 6º ao 8º ano (frações e uma tabela de porcentagens), escolhidos pelo perfil de erros modelados e pela variação deliberada de granularidade (Seção 3.3). Some-se a isso que os critérios de publicação da plataforma à época não estão documentados publicamente (processo interno à equipe, que sugere curadoria sem comprová-la). A extensão aos demais pacotes é a continuação natural do programa.

E o limite mais importante de todos: nada aqui mede aprendizagem de alunos. Medimos a proximidade estrutural entre artefatos, não o efeito pedagógico. O desenho experimental para a pergunta causal, com alunos reais, é o degrau seguinte do programa.

8. Reprodutibilidade

Tudo o que este artigo afirma pode ser reconferido sem custo e sem chave de acesso. O repositório público (*sti-graph-validation*) contém: os cinco datasets com os envelopes A e B de cada problema e a proveniência dos pacotes; os pré-registros com todos os adendos datados, corpus a corpus; os 630 registros brutos, com traces dos agentes, grafos materializados, custos por chamada e vereditos dos gates; as análises por corpus e o consolidado, regeráveis por script; o espelho dos agentes de produção com o

commit de origem (5263488) e o hash de cada um dos 85 arquivos, verificável contra o repositório de produção; e a auditoria científica completa, com o que foi corrigido, o que ficou declarado e o que foi refutado. O Apêndice A mapeia cada fonte citada no texto (S1 a S33) ao seu arquivo. Os custos estão auditados por chamada: entre US\$ 3,29 e US\$ 3,92 por corpus, com a geração inteira em torno de US\$ 22.

9. Conclusão

O mundo tem em mãos uma das intervenções mais eficazes que a pesquisa educacional já documentou, o feedback específico e imediato entregue por tutores guiados, e a abandonou porque produzi-la custava centenas de horas de especialista por hora de instrução. Este artigo apresentou os conceitos de Augmented Teacher in the Lead e de Agentic Intelligent Tutoring Systems, a técnica GraphForge de geração de grafos de comportamento por agentes com compilação determinística e materialização, e a validação mais ampla e mais dura que conseguimos desenhar para a peça central dessa proposta: cinco tutores públicos autorados por especialistas, 105 problemas, 630 grafos gerados com o mesmo insumo do especialista e comparados estado a estado, contra linha de base de acaso e com as decisões de medição publicadas. O veredito tem forma, não é um número único: nos tutores em que o especialista decompõe em 3 a 5 passos, os agentes reconstróem a estrutura com folga sobre o acaso e chegam a reproduzir o caminho inteiro em 97% dos grafos; onde a referência é uma tabela de 24 passos, os agentes agregam e a reconstrução falha; entregar ao agente a mesma tela do especialista foi o insumo que destravou a concordância; e nenhuma dessas leituras sobrevive sem linha de base ao lado. A régua que construímos para medir tudo isso, com obediência provada, espelho verificado por hash, contrafactual publicado e piso de acaso declarado, é contribuição tão importante quanto os resultados. O professor permanece no comando. A IA assume o custo onde já sabe decompor. O tutor pronto dispensa a internet. E a fronteira que resta está, pela primeira vez, medida e nomeada.

Disponibilidade de dados e código

O corpus com sua proveniência, os registros completos de todas as gerações, as regras de comparação fixadas em código, as análises e a auditoria estão em repositório público (*sti-graph-validation*). As fontes primárias citadas ao longo do texto (S1 a S33) estão descritas no Apêndice A. As demais frentes do programa de validação (o julgamento cego de mérito dos elementos extras, o censo da plataforma e a validade preditiva com alunos reais) estão preservadas no mesmo repositório, fora dos resultados deste artigo.

Apêndice A: Fontes primárias citadas no texto

Todas no repositório público *sti-graph-validation*. Onde houver *, há um arquivo por braço (*custo-beneficio* = flash-lite; *estudantes-qwen* = qwen) e/ou por corpus.

Ref.	Arquivo	O que contém
S1	<i>resultados/EXPERIMENTO-CONSOLIDADO-2026-08/consolidado.json + RESULTADOS.md</i>	A tabela-mestra por corpus × braço e os agregados por braço (pool estratificado)
S2	<i>docs/AUDITORIA-CIENTIFICA-2026-08-18.md</i>	A auditoria adversarial: correções (§A), linha de base/precisão/F1 (§B), Δ entre braços (§C), contrafactual (§D), limitações obrigatórias (§E), refutados (§F) e fechamento (§G)
S3	<i>resultados/bloco1-mathtutor-2026-08-16/PRE-REGISTRO.md</i>	Pré-registro do bloco 1 com os adendos datados de cada corpus (interface, piloto, regras novas)

Ref.	Arquivo	O que contém
S4	<i>resultados/rodada4-interface-fixa-2026-08-15/PRE-REGISTRO.md</i>	Pré-registro do 6.17 com interface fixa (canais, lista branca, anti-vazamento)
S5	<i>RESULTADOS.md</i> de cada corpus (rodada4/6.17 e bloco1/6.19 · 6.18 · 6.20 · 8.12)	Síntese, custos, gates e leitura por corpus
S6	<i>materializado-v3-fixa-*.analise.json</i> (por corpus)	Métricas da régua por registro, gates por enunciado e por valores, agregados por corpus
S7	<i>linha-de-base-v3-fixa-*.json</i> (por corpus)	Linha de base de acaso, cobertura ajustada, precisão e F1
S8	<i>comparacao-bracos.json</i> (por corpus)	Diferença pareada qwen – flash-lite, mesmo exercício × réplica
S9	<i>contrafactual-fixa-*.json</i> (por corpus)	Os mesmos grafos sob as definições R0 a R3 da régua
S10	<i>rodada4-interface-fixa-2026-08-15/comparacao-r4-vs-r3-*.json</i>	O efeito pareado da interface no 6.17, sob a régua vigente
S11	<i>comparacao-espelho-v3-vs-v2-*.json</i> e <i>comparacao-versao-v2-vs-v1-*.json</i>	O efeito de versão dos agentes, medido de forma pareada
S12	<i>analysis/bancada-v2/comparar-caminho.mjs</i> + <i>analysis/validacao-v2/lib.mjs</i>	A régua em código: leitura do <i>.brd</i> (Actor, sentinelas, variante, configuração), LCS, exclusões da régua de erros, intervalos (incluindo saturação)
S13	<i>analysis/bancada-v2/linha-de-base.mjs</i>	O grafo papagaio, a cobertura ajustada, a precisão e o F1
S14	<i>analysis/bancada-v2/contrafactual-regua.mjs</i>	O gerador da tabela contrafactual (R0 a R3)
S15	<i>analysis/bancada-v2/consolidar-corpora.mjs</i>	O consolidador multi-corpus (pool estratificado; lista de corpora incluídos)
S16	<i>materializar-registro.js</i> + <i>analysis/bancada-v2/analisar-materializado.mjs</i>	A materialização portada e os gates de obediência (enunciado e valores)
S17	<i>interface-ctat.js</i> + testes anti-vazamento	As descrições neutras de interface, por corpus, com lista branca
S18	<i>scripts/espelhar-producao.mjs</i> + <i>producao/COMMIT-FONTE.txt</i> + <i>producao/ESPELHO.sha256</i>	O espelho byte a byte da produção (commit 5263488; 85 arquivos hashados; verificação contra a fonte)
S19	<i>docs/CATALOGO-PACOTES-MATHTUTOR-2026-08-16.md</i>	A origem pública dos pacotes (54 pacotes, 710 grafos) e o perfil de cada um
S20	<i>docs/GUIA-DO-ARTIGO.md</i> §§6–14	O histórico metodológico datado, incluindo custos totais
S21	<i>materializado-v3-fixa-custo-beneficio/runs/00bubble_rep1.json</i> (rodada 4)	O registro real usado nas Figuras 10 e 12
S22	<i>docs/JUSTIFICATIVA-REPLICAS.md</i>	O dimensionamento de 3 réplicas pela decomposição de variância
S23	<i>resultados/bloco1-mathtutor-2026-08-16/7.12/LEIA-ME.md</i>	O corpus preparado e interrompido, fora de todas as tabelas
S24	<i>resultados/juizo-2026-08-19/RESULTADOS.md</i>	A rodada de julgamento: dicas (régua e juiz), extras sem veredito e reparo de simetria
S25	<i>resultados/juizo-2026-08-19/consolidado-simetrico.json</i>	Precisão e F1 sob as régua congelada e simétrica, por corpus × braço e agregado; taxa de passos neutralizados
S26	<i>resultados/juizo-2026-08-19/dicas-consolidado.json</i>	A régua determinística de dicas: pool por braço e por corpus
S27	<i>resultados/juizo-2026-08-19/juiz-dicas-z-ai-glm-4-5.json</i>	O juiz cego das escadas: 1.452 julgamentos, notas por origem, controles e gate
S28	<i>analysis/bancada-v2/comparar-dicas.mjs</i> (régua, por corpus) e <i>analysis/bancada-v2/consolidar-dicas.mjs</i> (o pool da Tabela 5)	A régua de dicas em código (pares LCS, token com fronteira, sensibilidade Val2) e o consolidador que produz a tabela publicada
S29	<i>analysis/bancada-v2/juiz-dicas.mjs</i>	O juiz cego em código (rubrica, controles, amostragem determinística)
S30	<i>analysis/bancada-v2/regua-simetrica.mjs</i> (reparo) e <i>analysis/bancada-v2/consolidar-simetrico.mjs</i> (as duas leituras da Tabela 2)	O reparo de simetria em código, com o teste 0/807 e os invariantes, e o consolidador que publica régua congelada e simétrica lado a lado

Ref.	Arquivo	O que contém
S31	<i>docs/PRE-REGISTRO-JUIZ-E-DICAS-2026-08-19.md</i>	O pré-registro da rodada de julgamento, com as três emendas datadas
S32	<i>producao/agents/prompts/agent6-worker-prompt.js</i> (linha 556) + <i>producao/agents/patterns/quality-gate.js</i> (linhas 1353 a 1357)	A política de dicas da plataforma, documentada e datada no código espelhado
S33	<i>resultados/juizo-2026-08-19/reprovados-no-gate/</i>	Os juízes reprovados (extras e estados), item a item, com calibração por tipo de distrator

Referências

- Aleven, V., McLaren, B. M., Roll, I., & Koedinger, K. R. (2006). Toward meta-cognitive tutoring: a model of help seeking with a cognitive tutor. *International Journal of Artificial Intelligence in Education*, 16(2), 101–128.
- Aleven, V., McLaren, B. M., & Sewall, J. (2009a). Scaling up programming by demonstration for intelligent tutoring systems development: an open-access web site for middle school mathematics learning. *IEEE Transactions on Learning Technologies*, 2(2), 64–78.
- Aleven, V., McLaren, B. M., Sewall, J., & Koedinger, K. R. (2009). A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2), 105–154.
- Aleven, V., McLaren, B. M., Sewall, J., van Velsen, M., Popescu, O., Demi, S., Ringenberg, M., & Koedinger, K. R. (2016). Example-tracing tutors: intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, 26(1), 224–269.
- Anderson, J. R., Corbett, A. T., Koedinger, K. R., & Pelletier, R. (1995). Cognitive tutors: lessons learned. *Journal of the Learning Sciences*, 4(2), 167–207.
- Brown, J. S., & Burton, R. R. (1978). Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, 2(2), 155–192.
- Clark, R. E., Feldon, D. F., van Merriënboer, J. J. G., Yates, K., & Early, S. (2008). Cognitive task analysis. Em J. M. Spector, M. D. Merrill, J. van Merriënboer & M. P. Driscoll (orgs.), *Handbook of Research on Educational Communications and Technology* (3ª ed., pp. 577–593). Routledge.
- Education Endowment Foundation (2021; 2025). *Teaching and Learning Toolkit: Feedback* (revisão de junho de 2021) e *Metacognition and self-regulation* (revisão de maio de 2025). Londres: EEF. Disponível em educationendowmentfoundation.org.uk/education-evidence/teaching-learning-toolkit. Acesso em 15 ago. 2026.
- Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association*, 82(397), 171–185.
- Flavell, J. H. (1979). Metacognition and cognitive monitoring: a new area of cognitive-developmental inquiry. *American Psychologist*, 34(10), 906–911.
- Hattie, J. (2009). *Visible Learning: A Synthesis of Over 800 Meta-Analyses Relating to Achievement*. Routledge.
- Kuhn, D. (2000). Metacognitive development. *Current Directions in Psychological Science*, 9(5), 178–181.

- Lovett, M. C. (1998). Cognitive task analysis in service of intelligent tutoring system design: a case study in statistics. Em *Intelligent Tutoring Systems (ITS 1998)*, Lecture Notes in Computer Science 1452 (pp. 234–243). Springer.
- Murray, T. (2003). An overview of intelligent tutoring system authoring tools: updated analysis of the state of the art. Em T. Murray, S. Blessing & S. Ainsworth (orgs.), *Authoring Tools for Advanced Technology Learning Environments* (pp. 491–544). Kluwer.
- Nathan, M. J., & Petrosino, A. (2003). Expert blind spot among preservice teachers. *American Educational Research Journal*, 40(4), 905–928.
- Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *PNAS*, 115(11), 2600–2606.
- Razzaq, L., Patvarczki, J., Almeida, S. F., Vartak, M., Feng, M., Heffernan, N. T., & Koedinger, K. R. (2009). The ASSISTment Builder: supporting the life cycle of tutoring system content creation. *IEEE Transactions on Learning Technologies*, 2(2), 157–166.
- Roll, I., Aleven, V., McLaren, B. M., & Koedinger, K. R. (2011). Improving students' help-seeking skills using metacognitive feedback in an intelligent tutoring system. *Learning and Instruction*, 21(2), 267–280.
- UNESCO Institute for Statistics (2017). *More than one-half of children and adolescents are not learning worldwide* (Fact Sheet No. 46). Montreal: UIS.
- VanLehn, K. (1990). *Mind Bugs: The Origins of Procedural Misconceptions*. MIT Press.
- VanLehn, K. (2011). The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4), 197–221.
- Veenman, M. V. J., Van Hout-Wolters, B. H. A. M., & Afflerbach, P. (2006). Metacognition and learning: conceptual and methodological considerations. *Metacognition and Learning*, 1, 3–14.
- World Bank, UNESCO, UNICEF, FCDO, USAID, & Bill & Melinda Gates Foundation (2022). *The State of Global Learning Poverty: 2022 Update*. Washington, DC: World Bank.
- Zimmerman, B. J. (2002). Becoming a self-regulated learner: an overview. *Theory into Practice*, 41(2), 64–70.