

Agentes de IA na autoria de tutores inteligentes: avaliação de 630 reconstruções de caminhos corretos em tutores CTAT

AI Agents for Intelligent-Tutor Authoring: Evaluating 630 Reconstructions of Correct Paths in CTAT Tutors

João Carlos Queiroz · EducaOFF / STI Unplugged · contato@educaoff.com.br

Resumo. Construir um tutor inteligente capaz de acompanhar cada passo do estudante exige representar antecipadamente a solução correta, erros prováveis, dicas e respostas do sistema. Esse trabalho especializado limita a ampliação de tutores guiados. Este estudo retrospectivo e exploratório investigou se agentes de inteligência artificial conseguem produzir rascunhos estruturados desses tutores a partir do enunciado, da resposta correta e de uma descrição da interface. Foram selecionados intencionalmente cinco conjuntos de casos do Cognitive Tutor Authoring Tools (CTAT), ambiente de autoria desenvolvido na Carnegie Mellon University, totalizando 105 problemas. Duas configurações de modelos produziram três novas gerações de cada problema, resultando em 630 grafos materializados. O caminho correto, os erros, as dicas e as devolutivas do especialista não foram entregues aos agentes durante a geração. A comparação principal não avaliou o grafo inteiro: mediu a concordância entre as listas ordenadas de valores esperados no caminho correto. Tomando cada grafo como unidade, os agentes recuperaram em média 74,4% dos valores da referência na ordem correta (IC 95%: 73,0%–75,7%). A precisão média foi 59,0% (57,7%–60,4%) e o F1, que combina recuperação e concisão, foi 62,0% (60,9%–63,1%). A referência completa apareceu em ordem, ainda que com passos extras, em 262 dos 630 grafos (41,6%); somente 26 (4,1%) apresentaram sequência estritamente idêntica. Nos quatro conjuntos de frações, o recall variou de 72,5% a 98,9%. No conjunto tabular com 24 estados, caiu para 8,7% e 30,0%, conforme a configuração. O qwen recuperou mais elementos da referência; o flash-lite produziu caminhos mais concisos e obteve maior precisão e F1 no agregado. O padrão variou entre tarefas, sem vencedor universal. Todos os artefatos passaram as verificações estruturais do pipeline, mas isso não estabelece correção matemática ou qualidade pedagógica. Os resultados mostram que a abordagem já produz candidatos estruturados e auditáveis, sobretudo em caminhos curtos, mas ainda requer revisão humana e melhorias para tarefas longas. A contribuição é transformar uma promessa genérica de automação em um processo mensurável, reproduzível e com limites explícitos.

Palavras-chave: sistemas tutores inteligentes; autoria assistida por IA; CTAT; caminhos de solução; agentes de IA; reprodutibilidade; validade de construto.

Abstract. Building an intelligent tutor that follows each learner step requires authors to represent correct solutions, likely errors, hints, and tutor responses. This retrospective, exploratory study examined whether coordinated AI agents can produce structured tutor drafts from a problem statement, its correct answer, and a textual interface description. Five purposively selected Cognitive Tutor Authoring Tools (CTAT) case sets supplied 105 problems. Two model configurations generated three replications per problem, yielding 630 materialized graphs. Expert paths, errors, hints, and feedback were withheld during generation. The primary outcome did not assess the complete graph; it compared ordered lists of expected values along the correct path. Averaging across graphs, agents recovered 74.4% of reference values in the correct order (95% CI: 73.0%–75.7%). Mean precision was 59.0% (57.7%–60.4%), and F1 was 62.0% (60.9%–63.1%). The complete reference occurred in order, with extra steps allowed, in 262 of 630 graphs (41.6%); only 26 (4.1%) were strictly identical. Recall ranged from 72.5% to 98.9% in four short fraction case sets, but fell to 8.7% and 30.0% in a 24-state tabular task. Qwen recovered more reference elements, whereas flash-lite produced more concise paths and achieved higher aggregate precision and F1; neither configuration dominated across tasks. All artifacts passed structural pipeline checks, which do not establish mathematical correctness or pedagogical

quality. The approach already produces auditable candidates for human review, especially for short paths, while long tasks remain a clear engineering limit.

Keywords: intelligent tutoring systems; AI-assisted authoring; CTAT; solution paths; AI agents; reproducibility; construct validity.

1. Introdução e justificativa

Um tutor inteligente passo a passo precisa fazer mais do que informar se a resposta final está correta. A cada ação do estudante, ele deve reconhecer o que foi feito, decidir se o passo é válido, identificar erros previstos e oferecer uma orientação adequada. Para isso, alguém precisa representar previamente a solução, os estados intermediários, os erros e as dicas. Essa autoria combina conhecimento do conteúdo, compreensão de como estudantes resolvem problemas e domínio da interface.

Sistemas tutores inteligentes (STIs) procuram oferecer esse acompanhamento de modo contínuo. Sínteses de evidência educacional associam feedback e estratégias metacognitivas a ganhos médios de aprendizagem, com grande variação entre intervenções e contextos (Education Endowment Foundation, 2021, 2025). Isso não significa que qualquer feedback automatizado funcione: sua utilidade depende do conteúdo, do momento, da possibilidade de ação do estudante e da integração ao planejamento didático.

Nos tutores guiados, o sistema acompanha passos intermediários e pode responder de maneira específica a um acerto ou a um erro previsto. Revisões anteriores encontraram benefícios da tutoria humana e computacional em condições determinadas (VanLehn, 2011). Este artigo, porém, não mede aprendizagem nem compara formas de ensino. Sua pergunta antecede a sala de aula: a IA consegue produzir uma primeira estrutura do tutor suficientemente próxima de uma referência para merecer revisão humana?

Essa pergunta importa porque a autoria é um gargalo conhecido. Ela envolve analisar a tarefa, construir a interface, representar o comportamento esperado e testar o resultado (Murray, 2003; Aleven et al., 2016). Estimativas históricas de horas de desenvolvimento referem-se ao sistema completo. O custo computacional deste experimento, cerca de US\$ 22, registra apenas chamadas aos modelos e rematerializações; não inclui engenharia, curadoria, revisão docente, infraestrutura, licenciamento ou avaliação com estudantes.

Modelos de linguagem ampliaram as possibilidades de autoria. Trabalhos recentes usaram IA generativa para criar interfaces de tutores controladas por educadores (Calò & MacLellan, 2024) e para preencher espaços de estados dentro de uma arquitetura pedagógica com salvaguardas (Pal Chowdhury et al., 2024). Essas propostas convergem num princípio importante: a geração automática é mais defensável quando opera dentro de uma estrutura explícita e permanece sujeita à decisão humana.

Este trabalho segue esse princípio por meio do desenho *Augmented Teacher in the Lead*: a IA propõe um rascunho, e o professor ou especialista decide o que corrigir, aceitar ou rejeitar. O termo *Agentic Intelligent Tutoring System (AITS)* descreve a arquitetura de autoria em que agentes especializados colaboram antes da publicação. Os agentes não substituem o professor nem conversam com o estudante durante o uso do tutor.

No AITS avaliado, agentes produzem descrições de uma solução correta, de erros prováveis e de pedidos de ajuda. Um compilador determinístico, chamado *GraphForge*, converte essas descrições num grafo. Depois, uma etapa de materialização coloca os valores concretos do problema no artefato. O tutor pronto para revisão pode executar sem novas chamadas a modelos.

Um arquivo estruturalmente válido, contudo, pode omitir passos, trocar sua ordem ou acrescentar ações desnecessárias. Por isso, a pergunta não é apenas ‘o sistema gerou um arquivo?’, mas ‘quanto do caminho construído pelo especialista reaparece, na ordem esperada e sem excesso de passos?’. Essa distinção separa demonstração de engenharia de validação científica.

O objetivo principal é quantificar a concordância entre as sequências de valores dos caminhos corretos gerados pelo pipeline e as sequências extraídas de tutores CTAT existentes. Também são descritos a integridade estrutural, o posicionamento de erros e propriedades das dicas. A pesquisa não testa se o tutor ensina, economiza trabalho ou pode ser publicado sem revisão.

Foram analisados cinco conjuntos de casos, 105 problemas e 630 gerações. A contribuição é tripla: avaliar centenas de artefatos, e não apenas exemplos escolhidos; usar métricas que distinguem recuperação, excesso, ordem e igualdade; e disponibilizar uma cadeia de reanálise capaz de revelar inclusive erros na própria métrica. Os registros de protocolo foram publicados em momentos diferentes, geralmente após pilotos, de modo que o estudo é retrospectivo e exploratório, não confirmatório.

Em síntese, o resultado a ser julgado é o valor da IA como geradora de candidatos auditáveis para revisão humana. A Seção 2 situa a proposta; as Seções 3 e 4 explicam desenho, dados e métricas; a Seção 5 apresenta os resultados com leitura operacional; as Seções 6 e 7 discutem significado e limites; e as Seções 8 e 9 tratam de reprodutibilidade e conclusão.

2. Trabalhos relacionados

Autoria por demonstração e CTAT. O Cognitive Tutor Authoring Tools (CTAT) é um ambiente de autoria desenvolvido na Carnegie Mellon University. Em tutores por rastreamento de exemplos, o especialista demonstra soluções e erros na interface; o sistema registra essas demonstrações num grafo de comportamento usado para interpretar o estudante passo a passo (Aleven et al., 2009; 2016). A abordagem reduz a necessidade de programação convencional, mas não elimina análise da tarefa, desenho instrucional, revisão e teste.

Mathtutor como fonte dos casos. O Mathtutor é um sítio da Carnegie Mellon University que disponibiliza tutores CTAT para uso educacional. Seus arquivos estavam tecnicamente acessíveis sem autenticação na data da auditoria, mas o sítio declara ‘All Rights Reserved’, e a licença do CTAT é restrita a pesquisa acadêmica ou não comercial, pessoal e não transferível (Carnegie Mellon University, 2026a, 2026b). Acessibilidade técnica não equivale a autorização de republicação. Por isso, o código original e os materiais de terceiros recebem tratamentos jurídicos separados no repositório.

Autoria assistida por IA. Ferramentas para reduzir o custo de autoria antecedem os modelos de linguagem (Murray, 2003; Razzaq et al., 2009; Aleven et al., 2016). Estudos recentes mostram duas linhas complementares: apoiar o educador na criação de interfaces (Calò & MacLellan, 2024) e combinar geração linguística com estruturas pedagógicas previamente definidas (Pal Chowdhury et al., 2024). O presente estudo acrescenta uma avaliação reproduzível de caminhos corretos gerados por um pipeline multiagente. Não se reivindica prioridade histórica nem equivalência com avaliações de aprendizagem.

3. Metodologia

O desenho pode ser entendido em cinco etapas. Cada etapa deixa um registro verificável, de modo que uma falha possa ser localizada em vez de ficar escondida numa nota final.

1. Selecionar os casos de referência e extrair, de cada arquivo .brd, a sequência de valores do caminho correto.
2. Fornecer aos agentes o enunciado, a resposta correta e uma descrição da interface, mantendo ocultos o caminho, os erros, as dicas e as devolutivas do especialista.
3. Gerar três réplicas de cada problema em duas configurações de modelos, porque uma nova chamada pode produzir uma solução diferente.


4. Compilar e materializar cada solução, isto é, transformar a descrição textual num grafo com os valores concretos do exercício.
5. Comparar referência e geração com pareamento um-a-um, calcular incerteza por exercício e interpretar separadamente cobertura, excesso, erros e dicas.

3.1 O que é um grafo de comportamento

Imagine um estudante resolvendo um problema de frações numa plataforma digital: ele ajusta uma reta numérica, marca um ponto, digita um valor e confirma. O tutor precisa decidir imediatamente se aquele passo está correto, se corresponde a um erro conhecido ou se exige uma resposta genérica. O grafo de comportamento é o mapa que sustenta essa decisão.

Um grafo de comportamento reúne passos corretos, alternativas de solução, erros previstos, dicas e devolutivas. No CTAT, ele é armazenado num arquivo com extensão .brd. A Figura 1 mostra a consulta feita pelo tutor durante uma interação. Neste artigo, ‘estado de valor’ significa apenas o valor esperado num passo do caminho correto; não representa todo o estado da tela nem todas as informações do grafo.

O que acontece no instante em que o aluno responde



A qualidade do grafo decide com que frequência um erro real cai no caso 2 (explicação sob medida) e não no caso 3.

Figura 1. Esquema de consulta a um grafo de comportamento durante uma resposta. O diagrama ilustra três resultados possíveis; não representa uma medida de aprendizagem ou uma validação da qualidade do grafo.

Essa delimitação é central. Um mesmo valor pode aparecer em componentes diferentes da interface e ter funções distintas. A análise principal pergunta se os valores do caminho correto reaparecem e em que ordem; ela não verifica topologia, componente, ação, ramificação ou texto. Assim, o estudo avalia uma dimensão necessária da reconstrução, mas não o grafo completo.

3.2 O que esta validação mede

O desfecho primário é uma sequência ordenada de valores, não o grafo completo. O programa percorre o caminho correto do arquivo .brd, remove passos técnicos segundo regras declaradas e normaliza representações equivalentes. Essa normalização, chamada canonização, faz com que 0,2, 1/5 e 2/10 representem o mesmo valor. Componentes, ações, ramificações, topologia, textos e componentes de conhecimento não participam do casamento principal.

A executabilidade significa que o arquivo passou os testes estruturais necessários ao pipeline: formato válido, campos obrigatórios e possibilidade de materialização. Os 630 artefatos passaram esses testes. Isso demonstra consistência técnica da cadeia, não correção matemática, adequação da sequência ou qualidade pedagógica.

A concordância é descrita por seis indicadores. Recall responde ‘quanto da referência foi recuperado na ordem?’. Precisão responde ‘quanto do que o agente produziu participa desse mesmo alinhamento?’. F1 equilibra as duas respostas. A cobertura sem ordem verifica se os valores estão presentes mesmo quando foram deslocados; a contenção verifica se toda a referência aparece em ordem, permitindo extras; e a igualdade estrita exige a mesma sequência e o mesmo comprimento.

A análise de erros é secundária. Um erro do especialista só conta quando o seu valor aparece ligado ao estado correspondente que foi casado. Isso permite verificar posicionamento por valor, mas não garante que a ação, o componente ou a explicação do erro estejam corretos.

As dicas são comparadas por propriedades observáveis, como número de níveis, comprimento e presença explícita da resposta. Um modelo de linguagem também atuou como avaliador automático. Como não houve avaliação humana, medida de aprendizagem ou teste formal de equivalência, essa parte descreve diferenças de forma e política textual; não estabelece qualidade pedagógica.

Passos não casados são penalizados pela precisão e contabilizados como excesso. Eles não são automaticamente errados: podem representar uma decomposição útil ou uma ação desnecessária. Como seu mérito não foi julgado por especialistas, o artigo quantifica a diferença sem atribuir-lhe valor pedagógico.

Em síntese, o estudo responde com segurança à integridade estrutural e à concordância de sequências de valores. Ele oferece evidência exploratória sobre erros e dicas e deixa para estudos futuros a equivalência topológica, a qualidade dos elementos extras, o tempo de revisão docente e a aprendizagem dos estudantes.

3.3 As referências: cinco conjuntos de casos CTAT

A amostra reúne cinco conjuntos de casos, totalizando 105 problemas: 24 de identificação de frações, 23 de frações e estimativas, 20 de frações equivalentes, 19 de ordenação de frações e 19 de fatores, escalas e porcentagens. Eles foram escolhidos intencionalmente entre 54 pacotes catalogados para incluir tarefas diferentes e casos com erros modelados. Portanto, não formam uma amostra aleatória de todos os tutores, domínios ou autores.

Quadro 1. Caracterização dos cinco conjuntos de casos selecionados. A seleção é intencional; os estados de valor são o construto usado na comparação primária.

Tutor	Tarefa	Problemas	Estados de valor por problema	Erros do especialista
6.17 Fraction Identification	marcar a fração na reta numérica	24	4	4 a 6 por problema (média 4,6)
6.19 Fractions and Estimates	fração e número misto na reta 0 –N	23	4 a 6 (média 4,35)	2 a 3
6.18 Equivalent Fractions	fração equivalente em duas retas	20	3	2 a 3 (nenhum avaliável por valor)
6.20 Fraction Ordering	comparar frações em duas retas	19	5	2 a 4 (média 3,8)
8.12 Factors, Scaling, and Percents	tabela de razões até a porcentagem	19	24	10 a 11 (média 10,6)

O Quadro 1 permite comparar as tarefas. Nos quatro conjuntos de frações, o caminho correto contém em média de três a cinco valores. No 8.12, uma tabela de razões e porcentagens exige 24. Essa diferença torna o

8.12 um teste de estresse útil, mas não permite concluir que o comprimento sozinho explique o desempenho: conteúdo, interface e complexidade também mudam ao mesmo tempo.

Os arquivos de referência vêm de uma única fonte institucional e não foram avaliados por um segundo especialista. Muitos problemas são variações de um mesmo molde. Quatro conjuntos correspondem a arquivos consultados em endpoints oficiais do Mathtutor; o 6.17 é uma adaptação derivada local e não uma cópia oficial. A falta de licença aberta para redistribuição é tratada na Seção 8 e na documentação jurídica do repositório.

3.4 Como os agentes criam um grafo, e o que exatamente foi medido

Os agentes produzem descrições textuais da solução correta, de erros prováveis e de situações de pedido de ajuda. O GraphForge, um compilador determinístico, converte essas descrições em nós e transições. Em seguida, a materialização substitui rótulos genéricos pelos números e valores do problema, produzindo o grafo final que a plataforma entregaria ao professor para revisão. A Figura 2 resume essa cadeia.

O código de produção usado no experimento foi identificado por commit e por hashes, impressões digitais que mudam quando um arquivo é alterado. A auditoria encontrou uma cópia incompleta do código no meio do estudo; ela foi corrigida, os grafos foram rematerializados e a diferença pareada foi pequena, com intervalos cruzando zero. Detalhes dos 85 arquivos verificados e dos commits ficam na Seção 8 e no Apêndice A, para não interromper a explicação do método.




Figura 2. Cadeia de autoria avaliada. Os agentes descrevem soluções, erros e pedidos de ajuda; o GraphForge compila essas descrições; a materialização insere os valores concretos; e o professor revisa o artefato antes de qualquer uso educacional.

3.5 O desenho do experimento

Para cada problema, os agentes receberam o enunciado, a resposta correta, a lista de componentes da interface, componentes de conhecimento e uma descrição textual da tela. O caminho correto, os erros, as dicas e as devolutivas do especialista foram bloqueados. Entretanto, a lista de componentes e os componentes de conhecimento vieram do próprio arquivo de referência. A geração, portanto, não viu a solução demonstrada, mas também não foi completamente independente da referência.

Cada problema foi gerado três vezes em duas configurações experimentais, chamadas braços. Uma réplica é uma nova geração do mesmo enunciado, necessária porque modelos de linguagem podem responder de forma

diferente a cada chamada. No braço flash-lite, os agentes que simulavam estudantes usaram gemini-3.1-flash-lite; no braço qwen, usaram qwen3-max. As demais etapas, inclusive o modelo de materialização gpt-5.6-luna, permaneceram iguais. O total foi 105 problemas $\times$ 3 réplicas $\times$ 2 braços = 630 grafos.

A comparação não coloca especialista e agente nas mesmas condições. O especialista demonstrou a solução numa interface viva; os agentes receberam uma descrição textual, a resposta correta e metadados derivados. Não é possível saber de antemão qual lado foi favorecido. Os resultados estimam o desempenho deste pipeline com estes insumos específicos.

3.6 Verificação automatizada de aderência ao problema

Uma verificação automatizada examinou cada registro para detectar troca ou invenção do problema. Os 630 artefatos passaram. Esse resultado justifica sua inclusão na análise e mostra que o pipeline trabalhou com o enunciado previsto; não comprova que a resolução esteja matematicamente correta nem que o tutor seja pedagogicamente adequado.

Verificações antigas comparavam apenas números presentes no enunciado. Elas funcionavam em tarefas de transcrição, mas rejeitavam cálculos intermediários legítimos: no 8.12, por exemplo, fatores de escala e porcentagens corretas não aparecem literalmente no texto inicial. Por isso, a aderência ao enunciado é o critério de inclusão, e as verificações por valores permanecem apenas como análise de sensibilidade.

4. Como os caminhos foram comparados

4.1 Definição do valor comparável

Na referência, o valor comparável é a resposta esperada em cada passo do caminho correto. No grafo gerado, é o valor esperado inserido durante a materialização. Antes da comparação, formas equivalentes são canonizadas: por exemplo, 0,2, 1/5 e 2/10 passam a representar o mesmo número. Dicas e devolutivas não são valores de entrada e ficam fora dessa normalização.

Nem toda transição correta do arquivo .brd representa uma ação de conteúdo do estudante. A extração exclui cliques de encerramento, ações automáticas do tutor, seletores técnicos de variante e configurações sem componente visível. As regras foram datadas e codificadas, mas parte delas foi definida depois de observar os dados. Por isso, são decisões pós-dados e sua influência é mostrada na análise de sensibilidade, em vez de ser ocultada.

4.2 Métricas: um exemplo antes das fórmulas

Considere a referência $R = [1, 5, 5, 1/5]$ e a geração $A = [5, 1, 5, 1/5, 1/5]$. A maior sequência comum que preserva a ordem contém três ocorrências, por exemplo $[1, 5, 1/5]$. Esse pareamento é um-a-um: uma ocorrência não pode explicar duas posições. Logo, $TP = 3$; $recall = 3/4 = 0,75$; $precisão = 3/5 = 0,60$; e $F1 = 2 \times 3/(4 + 5) = 0,667$. Em linguagem comum, três de quatro posições da referência reapareceram na ordem, e três de cinco posições geradas participaram desse alinhamento.

Se a ordem for ignorada, todos os quatro valores necessários aparecem, contando repetições; a cobertura sem ordem é 1,00. Ainda assim, a referência não está integralmente contida na ordem e as sequências não são idênticas. O exemplo mostra por que presença, ordem, excesso e igualdade precisam de indicadores separados.

Formalmente, TP é o comprimento da maior subsequência comum, ou LCS . $Recall = TP/|R|$; $precisão = TP/|A|$; $F1 = 2TP/(|R|+|A|)$. Quando o agente não produz nenhum valor comparável, $precisão$ e $F1$ são zero. A

cobertura sem ordem usa a interseção de multiconjuntos, isto é, ignora a posição, mas preserva quantas vezes cada valor aparece. Contenção exige $TP = |R|$ e permite extras; igualdade estrita exige $R = A$.

Para os erros, a pergunta é mais restrita: o erro previsto pelo especialista aparece ligado ao estado correspondente? Erros que pertencem a outro ramo ou que não podem ser distinguidos apenas pelo valor saem do denominador. No 6.18, todos os erros caem nessas condições e o resultado é ‘não aplicável’, não zero. A medida informa posicionamento por valor, mas não julga a explicação dada ao estudante.

O controle ‘papagaio’ produz uma sequência do mesmo tamanho que a geração, repetindo ciclicamente números do enunciado e da resposta. Ele conhece informação real e não representa acaso. Sua função é oferecer um piso mecânico: verificar se o pipeline recupera mais do caminho do que simplesmente reutilizar números já disponíveis. O recall ajustado ao controle é $(\text{recall observado} - \text{recall do controle}) / (1 - \text{recall do controle})$: zero indica o mesmo nível do controle, um indica recuperação máxima e um valor negativo indica desempenho inferior ao controle.

Os intervalos de 95% foram estimados por bootstrap em cluster: o programa reamostrou exercícios inteiros 10.000 vezes, mantendo juntas as três réplicas do mesmo problema, com semente 42. Esse procedimento descreve a variação entre os exercícios observados. Ele não transforma os cinco conjuntos intencionalmente escolhidos numa amostra representativa de todos os tutores.

4.3 Correção do pareamento e neutralização simétrica

A versão 0.5 usava uma definição de precisão que permitia reutilizar valores repetidos, enquanto o recall exigia pareamento um-a-um. O F1 resultante combinava numeradores diferentes e ficou inflado. A versão atual usa o mesmo TP da LCS em recall e precisão e preserva repetições na cobertura sem ordem. Essa correção não alterou o recall dos 630 grafos, mas reduziu a precisão agregada de 0,821 para 0,590 e o F1 de 0,762 para 0,620, mudando a interpretação e a ordenação agregada dos braços.

4.4 Dicas: da orientação inicial à entrega explícita da resposta

Num tutor guiado, as dicas de um passo formam uma escada: começam gerais e podem tornar-se progressivamente diretas. A análise automática usa somente pares de estados casados pela LCS e descreve seis propriedades: presença de dica, número de níveis, comprimento médio, presença do valor esperado na última dica, presença do valor em qualquer nível e escada com pelo menos dois níveis em que a última dica contém o valor e a primeira não. A busca reconhece o valor como unidade completa, evitando que ‘5’ seja encontrado dentro de ‘1/5’ ou ‘15’. O critério de entrega final, também chamado bottom-out, foi formulado após uma sondagem exploratória e é rotulado como pós-dados. Dicas escritas por extenso podem escapar à regra; estados ausentes e extras não entram nessa comparação. Assim, as medidas descrevem forma e entrega explícita do valor, não correção, qualidade ou efeito sobre aprendizagem. Os agregados reamostram conjuntos e exercícios 10.000 vezes, com semente 42 (fontes S26, S28 e S31).

4.5 Juiz LLM exploratório das escadas

Um único modelo de linguagem (z-ai/glm-4.5) atribuiu notas de 0 a 3 para especificidade, progressão e acionabilidade. O conjunto incluiu 1.254 escadas reais e 198 controles, totalizando 1.452 julgamentos. As origens foram ocultadas, mas somente a primeira réplica de cada exercício e apenas estados casados entraram na amostra. Sem avaliadores humanos, confiabilidade entre avaliadores e intervalos das diferenças, as notas são exploratórias.

O avaliador foi executado numa configuração curta, sem solicitar uma etapa explícita de deliberação. Em outra análise do projeto, essa configuração reduziu o reconhecimento de itens de referência, o que impede assumir

que um eventual viés afetaria todas as origens da mesma maneira. Por isso, as médias são resultados exploratórios do instrumento, não estimativas validadas de qualidade.

Médias próximas em especificidade e escalonamento não demonstram empate ou equivalência: não foi definida margem de equivalência, não foram publicados intervalos para as diferenças e os estados ausentes não entram no julgamento. A menor acionabilidade observada nas escadas dos agentes é consistente com a política que proíbe revelar o valor final, mas o desenho não isola essa política como causa.

Os controles mostraram que o juiz respondeu na direção esperada a uma escada de outro problema e à ordem embaralhada. Isso é evidência de validade interna limitada para essas manipulações, não validação geral do juiz nem das conclusões pedagógicas.

A régua léxica independente confirma uma diferença de política textual: o valor final aparece com muito mais frequência na última dica CTAT do que nas dicas geradas. Ela não mede aprendizagem, correção ou qualidade e não torna o juiz LLM independente de validação humana.

Assim, a análise de dicas descreve propriedades do corpus e das saídas sob esta configuração. Estudos futuros devem usar amostra de estados completa, avaliadores humanos cegos, confiabilidade entre avaliadores, margens de equivalência prévias e desfechos com alunos.

5. Resultados

A análise inclui cinco conjuntos de casos, 105 problemas e 630 grafos. Todos passaram as verificações estruturais e de aderência ao enunciado. O resultado mais importante, portanto, não é simplesmente que a cadeia executou, mas quanto do caminho de referência reapareceu e quanto conteúdo adicional foi produzido.

5.1 A tabela-mestra

Tabela 1. Métricas por conjunto e braço. Recall em ordem usa LCS; recall ajustado compara o observado ao controle pela fórmula da Seção 4.2; sem ordem usa interseção de multiconjuntos; ‘referência contida’ permite passos extras; n comp. é a média de valores comparáveis por grafo após retirar passos de conclusão. Entre colchetes, IC de 95% com agrupamento por exercício. fl = flash-lite; qw = qwen3-max. Fontes: S1, S6 e S7.

Conj. (ref.)	Braço	Recall LCS	Recall ajust.	Sem ordem (multiconj.)	Referência contida	Erros no estado certo	n comp.
6.17 (4)	fl	0,778 [0,753; 0,816]	0,462	0,986	0,125 [0,028; 0,278]	0,299 [0,252; 0,350]	5,18
6.17 (4)	qw	0,941 [0,896; 0,969]	0,871	0,997	0,764 [0,583; 0,875]	0,629 [0,553; 0,704]	6,03
6.19 (4,35)	fl	0,725 [0,659; 0,768]	0,531	0,841	0,145 [0,072; 0,217]	0,442 [0,343; 0,543]	4,71
6.19 (4,35)	qw	0,728 [0,679; 0,760]	0,463	0,814	0,072 [0,014; 0,130]	0,693 [0,568; 0,797]	7,65
6.18 (3)	fl	0,961 [0,906; 0,983]	0,933	0,967	0,883 [0,717; 0,950]	N/A	4,93
6.18 (3)	qw	0,989 [0,967; 1,000]	0,975	0,989	0,967 [0,874; 0,983]	N/A	7,37
6.20 (5)	fl	0,919 [0,877; 0,954]	0,860	0,919	0,597 [0,386; 0,754]	0,306 [0,235; 0,376]	5,44
6.20 (5)	qw	0,933 [0,891; 0,961]	0,877	0,933	0,667 [0,456; 0,807]	0,598 [0,525; 0,667]	7,28
8.12 (24)	fl	0,087 [0,064; 0,107]	−0,019	0,094	0,000 [0,000; 0,176]	0,000 [0,000; 0,176]	4,28
8.12 (24)	qw	0,300 [0,283; 0,320]	0,139	0,375	0,000 [0,000; 0,176]	0,033 [0,017; 0,061]	11,63

Nos quatro conjuntos de frações, que têm caminhos médios de três a cinco valores, o recall variou de 0,725 a 0,989. Isso significa que grande parte do caminho de referência reapareceu na ordem, embora frequentemente com passos adicionais. No 8.12, com 24 valores, o recall foi 0,087 no flash-lite e 0,300 no qwen; nenhum dos 114 grafos conteve toda a referência. A Tabela 1 deve ser lida como mapa de onde o pipeline funciona melhor e onde exige nova arquitetura, não como nota única de aprovação.

5.2 Métricas alinhadas e controle determinístico

Tabela 2. Recall observado, controle papagaio determinístico de mesmo tamanho, recall ajustado ao controle, precisão e F1 com o mesmo pareamento, e contenção/igualdade estrita. O controle recebe enunciado e resposta e não representa acaso. Fontes: S7, S13 e S30.

Conj. · braço	Recall	Controle	Recall ajust.	Precisão	F1	Contida / exata
6.17 · fl	0,778	0,500	0,462	0,607	0,680	0,125 / 0,014
6.17 · qw	0,941	0,535	0,871	0,651	0,761	0,764 / 0,056
6.19 · fl	0,725	0,359	0,531	0,662	0,684	0,145 / 0,000
6.19 · qw	0,728	0,406	0,463	0,413	0,522	0,072 / 0,000
6.18 · fl	0,961	0,417	0,933	0,592	0,731	0,883 / 0,000
6.18 · qw	0,989	0,417	0,975	0,415	0,581	0,967 / 0,000
6.20 · fl	0,919	0,410	0,860	0,853	0,883	0,597 / 0,368
6.20 · qw	0,933	0,442	0,877	0,643	0,761	0,667 / 0,000
8.12 · fl	0,087	0,103	-0,019	0,452	0,144	0,000 / 0,000
8.12 · qw	0,300	0,186	0,139	0,624	0,402	0,000 / 0,000

No conjunto dos 630 grafos, o recall médio foi 0,744 [0,730; 0,757], a precisão foi 0,590 [0,577; 0,604] e o F1 foi 0,620 [0,609; 0,631]. Em termos operacionais, um grafo típico recuperou cerca de três quartos do caminho de referência, mas somente cerca de seis em cada dez posições geradas participaram do melhor alinhamento ordenado. O F1 resume esse equilíbrio; não é uma porcentagem de tutores ‘corretos’ nem uma nota escolar.

A referência inteira apareceu na ordem em 262 grafos (41,6%), permitindo passos extras. Apenas 26 (4,1%) foram estritamente idênticos. Essa distância entre contenção e igualdade é o argumento mais direto a favor da revisão humana: em muitos casos o núcleo necessário existe, mas quase sempre há algo a remover, reposicionar ou conferir.

Nos quatro conjuntos de frações, o recall superou o controle mecânico. No 8.12-flash-lite, recall e F1 não superaram claramente o controle, e a precisão foi inferior. O termo correto é ‘não superou o controle nesta configuração’, nunca ‘pior que o acaso’.

5.3 Associação descritiva entre conjunto e comprimento da referência

O contraste entre tarefas é claro: caminhos curtos de frações tiveram recall de 72,5% a 98,9%, enquanto o caminho tabular de 24 estados ficou em 8,7% e 30,0%. A leitura de engenharia é útil: a arquitetura atual é mais promissora como geradora de rascunhos para sequências curtas e precisa de decomposição ou representação mais estruturada em tarefas longas. A leitura causal, porém, não é possível, porque comprimento, conteúdo, interface e complexidade mudaram juntos.

5.4 Sensibilidade às definições pós-dados

A Tabela 3 apresenta os mesmos grafos sob definições progressivamente mais específicas do que conta como passo do estudante. Ela mostra que decisões de extração podem mudar bastante o resultado e, por isso, devem ser declaradas. A tabela foi regenerada sobre a materialização v3 usada nas análises centrais; a confirmação futura deve congelar essas regras antes de examinar um conjunto novo.

Tabela 3. Análise de sensibilidade na materialização v3: recall LCS / referência integralmente contida sob definições encaixadas. R0 inclui toda transição correta; R1 remove passos mecânicos; R2 também remove ações do tutor; R3 também remove o seletor técnico de variante. Fonte: S9.

Conj. · braço	R0 ingênua	R1	R2	R3 vigente
6.17 · fl	0,452 / 0,000 (7,0)	0,528 / 0,000 (6,0)	0,778 / 0,125 (4,0)	0,778 / 0,125 (4,0)
6.17 · qw	0,599 / 0,000 (7,0)	0,699 / 0,014 (6,0)	0,941 / 0,764 (4,0)	0,941 / 0,764 (4,0)
6.19 · fl	0,309 / 0,000 (10,0)	0,490 / 0,000 (6,3)	0,725 / 0,145 (4,3)	0,725 / 0,145 (4,3)
6.19 · qw	0,310 / 0,000 (10,0)	0,493 / 0,000 (6,3)	0,728 / 0,072 (4,3)	0,728 / 0,072 (4,3)
6.18 · fl	0,332 / 0,000 (11,0)	0,365 / 0,000 (10,0)	0,721 / 0,000 (4,0)	0,961 / 0,883 (3,0)
6.18 · qw	0,383 / 0,000 (11,0)	0,422 / 0,000 (10,0)	0,742 / 0,000 (4,0)	0,989 / 0,967 (3,0)
6.20 · fl	0,575 / 0,000 (8,0)	0,657 / 0,000 (7,0)	0,919 / 0,596 (5,0)	0,919 / 0,596 (5,0)
6.20 · qw	0,592 / 0,000 (8,0)	0,677 / 0,000 (7,0)	0,933 / 0,667 (5,0)	0,933 / 0,667 (5,0)

As exclusões possuem justificativa funcional, mas algumas foram formuladas depois da inspeção dos dados e aumentaram a concordância. Publicar a sensibilidade impede que esse ganho seja confundido com evidência independente. O teste confirmatório adequado usará as mesmas regras, sem alterações, num conjunto reservado.

5.5 Comparação exploratória entre rodadas com e sem interface

No conjunto 6.17, a rodada que adicionou uma descrição da interface apresentou aumentos de 26,7 pontos percentuais de recall no flash-lite e 32,3 pontos no qwen. O resultado sugere que representar melhor a tela pode ser uma alavanca importante de engenharia. Contudo, a comparação ocorreu entre rodadas, outros fatores podem ter mudado e apenas um conjunto foi analisado; ela orienta um experimento controlado, não demonstra causalidade.

5.6 Braços e agregado: o que se sustenta e o que não

Tabela 4. Diferenças pareadas qwen – flash-lite para o mesmo exercício e a mesma réplica. Os ICs de 95% usam o método BCA, que corrige viés e assimetria, com agrupamento por exercício. Sem ordem preserva repetições; contenção permite extras. Fonte: S8 e recálculo corrigido.

Conj.	Recall LCS	Sem ordem (multiconj.)	Referência contida	Erros no estado certo
6.17	+0,163 [0,115; 0,198]	+0,010 [−0,007; 0,035]	+0,639 [0,444; 0,764]	+0,330 [0,250; 0,409]
6.19	+0,004 [−0,025; 0,044]	−0,027 [−0,059; 0,004]	−0,073 [−0,159; −0,003]	+0,251 [0,135; 0,358]
6.18	+0,028 [−0,011; 0,067]	+0,022 [−0,011; 0,061]	+0,083 [−0,033; 0,200]	N/A
6.20	+0,014 [−0,018; 0,039]	+0,014 [−0,018; 0,039]	+0,070 [−0,088; 0,193]	+0,292 [0,192; 0,387]
8.12	+0,213 [0,188; 0,241]	+0,281 [0,254; 0,309]	0,000 [0,000; 0,000]	+0,033 [0,017; 0,061]

Não há configuração universalmente superior. O qwen recuperou mais elementos da referência no agregado: recall 0,786 e contenção integral 0,495. O flash-lite foi mais conciso: precisão 0,633, F1 0,630 e igualdade estrita 0,070, contra 0,548, 0,609 e 0,013 no qwen. O melhor F1 alternou entre tarefas, e os intervalos agregados se sobrepõem.

Essa diferença revela uma troca prática. O qwen tende a cobrir mais do caminho, mas também acrescenta mais passos; o flash-lite tende a omitir um pouco mais, porém entrega sequências mais próximas do tamanho necessário. Um fluxo futuro poderia combinar geração orientada à cobertura com uma etapa explícita de poda e revisão, mas essa possibilidade ainda é hipótese de projeto, pois o mérito dos passos extras não foi avaliado.

5.7 Dicas: diferença na entrega da resposta e juiz exploratório

Nos estados casados, os especialistas escreveram cerca de três níveis de dica por passo, enquanto os agentes produziram sempre quatro. A diferença mais forte está no último nível: a referência apresentou explicitamente o valor esperado em 84,9%–85,9% dos pares agregados; os agentes, em apenas 1,9%–2,6%. O resultado

mostra aderência consistente à política de não revelar a resposta, mas também distância clara do padrão CTAT analisado.

Tabela 5. Medidas automáticas das dicas nos pares casados, separadas por braço e reamostradas com agrupamento por exercício. As duas estimativas do especialista diferem porque o conjunto de estados casados muda com o braço. Fonte: S26.

Métrica	especialista (pares fl · pares qw)	agente flash-lite	agente qwen
última dica entrega o valor	0,849 [0,842; 0,856] · 0,859 [0,855; 0,864]	0,019 [0,010; 0,032]	0,026 [0,016; 0,037]
escada completa (≥2 níveis; última entrega, primeira não)	0,807 [0,788; 0,825] · 0,830 [0,818; 0,840]	0,019 [0,010; 0,032]	0,025 [0,015; 0,036]
algum nível entrega o valor	0,933 [0,926; 0,942] · 0,939 [0,934; 0,946]	0,048 [0,032; 0,065]	0,068 [0,052; 0,084]
níveis por passo	2,970 [2,912; 3,030] · 2,933	4,000 (sem variância)	4,000
caracteres por dica	71,7 · 68,1	81,7 [80,9; 82,5]	75,8 [75,0; 76,6]

Essa política pode preservar esforço produtivo do estudante, mas também tornar a orientação menos direta. A régua léxica identifica a diferença textual; não decide qual opção produz mais aprendizagem. Esse julgamento requer professores, especialistas e estudantes.

O avaliador automático respondeu na direção esperada aos controles de conteúdo e ordem, mas continua sendo um único modelo. As médias seguintes descrevem 1.254 escadas reais da primeira réplica selecionada; os 198 controles completam 1.452 julgamentos e servem apenas para verificar sensibilidade básica do instrumento.

Tabela 6. Médias observadas do avaliador automático exploratório (1.254 escadas reais; notas de 0 a 3). Não houve IC das diferenças, margem de equivalência ou validação humana. A última linha é a classificação do próprio avaliador nesta subamostra e, por isso, não deve ser confundida com a busca determinística da Tabela 5. Fonte: S27.

Dimensão	especialista	agente flash-lite	agente qwen
especificidade	1,96	1,97	1,97
escalonamento	1,88	1,89	1,88
acionabilidade	2,81	2,09	2,13
entrega a resposta final	79%	3%	10%

As médias de especificidade e progressão foram numericamente próximas entre referência e agentes, sem demonstrar equivalência. Em acionabilidade, a referência recebeu 2,81, contra 2,09 e 2,13. Uma explicação plausível é que evitar o valor final tornou algumas dicas menos diretamente utilizáveis. Essa interpretação é hipótese, não efeito causal, e precisa de avaliação humana.

A dimensão de correção matemática foi excluída porque o juiz errou ao avaliar alguns passos fora do contexto da decomposição, sobretudo no 8.12. Esse problema também recomenda cautela nas demais dimensões: controles específicos não eliminam todos os vieses de contexto.

6. Discussão

O resultado central não é que agentes já produzam tutores completos de forma autônoma. É que a cadeia concluiu 630 gerações, entregou artefatos estruturalmente verificáveis e permitiu medir, caso a caso, o que reapareceu, o que faltou e o que sobrou. Nos quatro conjuntos de caminhos curtos, grande parte da sequência de referência foi recuperada. Isso converte uma promessa vaga de automação em um objeto auditável de engenharia educacional.

A combinação de 41,6% de contenção integral e 4,1% de igualdade estrita define o uso mais defensável nesta etapa. Em cerca de quatro de cada dez grafos, todo o caminho do especialista estava presente na ordem, mas

quase sempre acompanhado de diferenças. O sistema pode produzir uma primeira estrutura para revisão; os dados não apoiam publicação automática. Como o tempo de revisão não foi medido, a economia de trabalho ainda é uma hipótese testável.

O desempenho no 8.12 é uma contribuição, não apenas uma falha. Ele mostra que a arquitetura atual encontra dificuldade numa tarefa longa, tabular e encadeada. Representação mais estruturada da interface, decomposição explícita, verificações intermediárias ou intervenção humana durante a geração são caminhos concretos para o próximo ciclo. Como vários fatores mudam juntos, essa fronteira é operacional, não uma lei causal sobre número de estados.

A comparação entre modelos também informa projeto. O qwen privilegiou cobertura; o flash-lite, concisão. Essa troca ajuda a escolher configurações conforme o objetivo e sugere um pipeline futuro em duas etapas, primeiro evitando omissões e depois removendo excessos. A sugestão depende de validação por especialistas, porque nem todo passo adicional é necessariamente inadequado.

As dicas evidenciam outra escolha de desenho. Os agentes obedeceram à regra de não entregar o valor final, mas receberam menor nota automatizada de acionabilidade. O desafio não é simplesmente revelar ou esconder a resposta; é criar pistas que preservem o raciocínio e indiquem uma ação concreta. Avaliação humana e estudo com estudantes são indispensáveis.

A principal contribuição científica é combinar uma arquitetura reexecutável com uma definição explícita do que foi medido. A correção das métricas separa recuperação, excesso, ordem e igualdade e mostra que a auditoria também precisa alcançar o próprio instrumento. As limitações não apagam os 630 artefatos produzidos nem a elevada cobertura nos caminhos curtos; elas impedem apenas extrapolar esses fatos para equivalência completa, qualidade pedagógica, economia ou aprendizagem.

Para professores, a leitura prática é direta: hoje o sistema deve ser tratado como autor de rascunhos estruturados, não como substituto do especialista. Seu valor potencial está em chegar à revisão com um artefato concreto, rastreável e mensurável. O próximo estudo precisa medir quanto tempo e quais tipos de correção essa revisão exige.

7. Limitações e escopo de validade

1. Amostra e generalização. Os cinco conjuntos foram escolhidos intencionalmente numa única fonte institucional e muitos problemas são variações de moldes. Eles não representam todos os domínios, interfaces, autores ou estilos de tutor. Uma replicação mais forte precisa de conjuntos novos, instituições adicionais e casos produzidos depois do treinamento dos modelos, reduzindo o risco de memorização.
2. Mensuração. O desfecho mede listas de valores, não o grafo completo. Um valor pode casar mesmo no componente errado; topologia, ações, ramificações e texto ficam fora da régua. Algumas exclusões foram definidas após observar dados. A análise de sensibilidade mostra essa flexibilidade, mas a confirmação requer regras congeladas antes de abrir um conjunto independente.
3. Comparabilidade e inferência. O especialista trabalhou numa interface viva; os agentes receberam texto, resposta correta e metadados parcialmente derivados do arquivo de referência. As réplicas do mesmo exercício não são independentes, e os intervalos descrevem os exercícios observados, não uma população de tutores. Comparações entre rodadas e entre conjuntos não isolam efeitos causais de interface, modelo ou comprimento.
4. Aplicação pedagógica. Erros e dicas foram avaliados por medidas restritas e por um único avaliador automático. Não houve participantes humanos, medida de aprendizagem, concordância entre especialistas nem tempo de revisão. Os aproximadamente US\$ 22 são custo marginal de inferência, não

custo total de autoria. Assim, o estudo não demonstra tutor pronto, economia total ou benefício educacional.

5. Direitos e reprodutibilidade. Não foi localizada licença aberta para redistribuir os materiais Mathtutor. O CTAT possui licença restrita de pesquisa não comercial e exige atribuição, enquanto o sítio Mathtutor declara todos os direitos reservados. Código, métricas e materiais de terceiros precisam permanecer separados. Uma reprodução legítima deve obter os pacotes na fonte oficial ou depender de autorização escrita; nenhum aviso deste repositório cria direitos sobre conteúdo alheio.

8. Reprodutibilidade

O código e os resultados agregados podem ser reanalisados sem novas chamadas a modelos. A coleta exige chaves, custo e versões de API que podem mudar. A análise corrigida está ancorada no commit `f33ea51080c2e2191a191b1484181068f52b5e44`. A licença MIT cobre exclusivamente o software original. Os materiais Mathtutor/CTAT não recebem sublicença deste projeto; a obtenção, o uso e a eventual redistribuição devem seguir os termos do titular. O repositório inclui um inventário de terceiros, um bloqueio contra publicação npm e um pedido de autorização pronto para envio.

9. Conclusão

Este estudo respondeu a uma pergunta estreita, mas operacionalmente importante: até que ponto agentes de IA conseguem reconstruir o caminho correto de tutores produzidos por especialistas? Em 630 gerações, todos os artefatos passaram as verificações estruturais. A recuperação média dos valores da referência foi 74,4%, a precisão foi 59,0% e o F1 foi 62,0%. A referência completa apareceu em ordem em 41,6% dos grafos, mas apenas 4,1% foram estritamente idênticos. Nos quatro conjuntos de frações com caminhos curtos, o recall foi elevado; na tarefa tabular de 24 estados, caiu acentuadamente. Esses resultados sustentam o uso da arquitetura como geradora de candidatos auditáveis para revisão humana, especialmente em tarefas curtas. O valor do trabalho está em substituir uma promessa vaga de automação por um pipeline verificável, uma régua coerente e uma fronteira empírica clara. O próximo passo deve combinar regras congeladas, casos novos, descrição controlada da interface, avaliação humana dos elementos extras e das dicas, medição do trabalho de revisão e estudo com estudantes.

Disponibilidade de dados e código

Código original, protocolos, hashes, resultados agregados e documentação estão em <https://github.com/Joaoqueiroz-silva/sti-graph-validation>; a análise numérica desta versão está ancorada no commit `f33ea51080c2e2191a191b1484181068f52b5e44`. A licença MIT não se estende aos materiais Mathtutor/CTAT. Como não foi localizada autorização aberta de redistribuição, os pacotes devem ser obtidos diretamente das fontes oficiais sob seus próprios termos, e uma release arquivística do corpus não deve ser criada sem permissão escrita ou saneamento integral do histórico.

Agradecimentos e atribuição CTAT

Este trabalho utilizou o Cognitive Tutor Authoring Tools (CTAT) como tecnologia e formalismo de referência. Em atendimento à atribuição acadêmica indicada pela licença do CTAT, cita-se Aleven, McLaren, Sewall e Koedinger (2009), ‘A new paradigm for intelligent tutoring systems: example-tracing tutors’. O projeto é independente e não é afiliado, patrocinado nem endossado pela Carnegie Mellon University.

Agradece-se à equipe CTAT/Mathtutor pela disponibilização educacional da tecnologia e dos tutores em seus sítios oficiais.

Declarações

Conflito de interesses. O autor participa do desenvolvimento da plataforma EducaOFF/STI Unplugged e da arquitetura AITS avaliada. Essa relação cria interesse direto no resultado; a mitigação adotada é disponibilizar código, registros e regras para auditoria, sem alegar avaliação independente.

Financiamento. Não informado nos materiais auditados desta versão.

Contribuições do autor. O autor realizou concepção, desenvolvimento do software, curadoria dos dados, execução, análise e redação; as métricas corrigidas foram verificadas por reanálise independente dos registros depositados.

Ética. O estudo analisa artefatos de software e não envolve participantes humanos nem dados pessoais. Isso não substitui avaliação ética de um futuro estudo com estudantes.

Uso de inteligência artificial na preparação do manuscrito. Modelos de IA produziram os artefatos estudados e auxiliaram a revisão metodológica, estatística e linguística desta versão. O autor permanece responsável por verificar cálculos, fontes, direitos e conteúdo final.

Apêndice A: Fontes primárias citadas no texto

As fontes S1–S33 estão no repositório indicado na seção de disponibilidade. Caminhos são relativos à raiz. Arquivos históricos com métricas anteriores permanecem identificados como superados; materiais de terceiros estão sujeitos aos termos e às restrições descritos em DATA-LICENSE.md e THIRD_PARTY_NOTICES.md.

Ref.	Arquivo	O que contém
S1	resultados/EXPERIMENTO-CONSOLIDADO-2026-08/consolidado.json + RESULTADOS.md	Tabelas corrigidas por conjunto $\times$ braço e agregados usados na versão v0.7
S2	docs/AUDITORIA-CIENTIFICA-2026-08-18.md	A auditoria adversarial: correções (§A), linha de base/precisão/F1 (§B), Δ entre braços (§C), contrafactual (§D), limitações obrigatórias (§E), refutados (§F) e fechamento (§G)
S3	resultados/bloco1-mathtutor-2026-08-16/PRE-REGISTRO.md	Pré-registro do bloco 1 com os adendos datados de cada corpus (interface, piloto, regras novas)
S4	resultados/rodada4-interface-fixa-2026-08-15/PRE-REGISTRO.md	Pré-registro do 6.17 com interface fixa (canais, lista branca, anti-vazamento)
S5	RESULTADOS.md de cada corpus (rodada4/6.17 e bloco1/6.19 · 6.18 · 6.20 · 8.12)	Síntese, custos, gates e leitura por corpus
S6	materializado-v3-fixa-*.analise.json (por corpus)	Métricas da régua por registro, gates por enunciado e por valores, agregados por corpus
S7	linha-de-base-v3-fixa-*.json (por corpus)	Controle papagaio determinístico de tamanho comparável, excesso sobre controle e P/F1 com TP=LCS
S8	comparacao-bracos.json (por corpus)	Diferença pareada qwen – flash-lite, mesmo exercício $\times$ réplica
S9	contrafactual-v3-fixa-*.json (por conjunto)	Os mesmos grafos materializados em v3 sob as definições R0 a R3; os arquivos v2 permanecem identificados como históricos
S10	rodada4-interface-fixa-2026-08-15/comparacao-r4-vs-r3-*.json	O efeito pareado da interface no 6.17, sob a régua vigente
S11	comparacao-espelho-v3-vs-v2-*.json e comparacao-versao-v2-vs-v1-*.json	O efeito de versão dos agentes, medido de forma pareada
S12	analysis/bancada-v2/comparar-caminho.mjs + analysis/validacao-v2/lib.mjs	A régua em código: leitura do .brd (Actor, sentinelas, variante, configuração), LCS, exclusões da régua de erros, intervalos (incluindo saturação)
S13	analysis/bancada-v2/linha-de-base.mjs	Implementação corrigida: TP=LCS 1:1, multiconjuntos, controle de tamanho comparável e igualdade estrita

Ref.	Arquivo	O que contém
S14	<i>analysis/bancada-v2/contrafactual-regua.mjs</i>	O gerador da tabela contrafactual (R0 a R3)
S15	<i>analysis/bancada-v2/consolidar-corpora.mjs</i>	O consolidador multi-corpus (pool estratificado; lista de corpora incluídos)
S16	<i>materializar-registro.js</i> + <i>analysis/bancada-v2/analisar-materializado.mjs</i>	A materialização portada e os gates de obediência (enunciado e valores)
S17	<i>interface-ctat.js</i> + testes anti-vazamento	As descrições neutras de interface, por corpus, com lista branca
S18	<i>scripts/espelhar-producao.mjs</i> + <i>producao/COMMIT-FONTE.txt</i> + <i>producao/ESPELHO.sha256</i>	O espelho byte a byte da produção (commit 5263488; 85 arquivos hashados; verificação contra a fonte)
S19	<i>docs/CATALOGO-PACOTES-MATHTUTOR-2026-08-16.md</i>	Endpoints tecnicamente acessíveis dos pacotes e perfil de cada conjunto; acessibilidade não implica licença de redistribuição
S20	<i>docs/GUIA-DO-ARTIGO.md</i> §§6–14	O histórico metodológico datado, incluindo custos totais
S21	<i>materializado-v3-fixa-custo-beneficio/runs/00bubble_rep1.json</i> (rodada 4)	Registro individual preservado para auditoria interna das métricas; sua redistribuição depende dos direitos sobre o conteúdo-fonte
S22	<i>docs/JUSTIFICATIVA-REPLICAS.md</i>	O dimensionamento de 3 réplicas pela decomposição de variância
S23	<i>resultados/bloco1-mathtutor-2026-08-16/7.12/LEIA-ME.md</i>	O corpus preparado e interrompido, fora de todas as tabelas
S24	<i>resultados/juizo-2026-08-19/RESULTADOS.md</i>	A rodada de julgamento: dicas (régua e juiz), extras sem veredito e reparo de simetria
S25	<i>resultados/juizo-2026-08-19/consolidado-simetrico.json</i>	Artefato histórico da régua anterior; mantido para auditoria e superado pela correção v0.6
S26	<i>resultados/juizo-2026-08-19/dicas-consolidado.json</i>	A régua determinística de dicas: pool por braço e por corpus
S27	<i>resultados/juizo-2026-08-19/juiz-dicas-z-ai-glm-4-5.json</i>	O juiz cego das escadas: 1.452 julgamentos, notas por origem, controles e gate
S28	<i>analysis/bancada-v2/comparar-dicas.mjs</i> (régua, por corpus) e <i>analysis/bancada-v2/consolidar-dicas.mjs</i> (o pool da Tabela 5)	A régua de dicas em código (pares LCS, token com fronteira, sensibilidade Val2) e o consolidador que produz a tabela publicada
S29	<i>analysis/bancada-v2/juiz-dicas.mjs</i>	O juiz cego em código (rubrica, controles, amostragem determinística)
S30	<i>analysis/bancada-v2/regua-simetrica.mjs</i> (reparo) e <i>analysis/bancada-v2/consolidar-simetrico.mjs</i> (as duas leituras da Tabela 2)	Neutralização simétrica de conclusão e consolidação das métricas corrigidas
S31	<i>docs/PRE-REGISTRO-JUIZ-E-DICAS-2026-08-19.md</i>	O pré-registro da rodada de julgamento, com as três emendas datadas
S32	<i>producao/agents/prompts/agent6-worker-prompt.js</i> (linha 556) + <i>producao/agents/patterns/quality-gate.js</i> (linhas 1353 a 1357)	A política de dicas da plataforma, documentada e datada no código espelhado
S33	<i>resultados/juizo-2026-08-19/reprovados-no-gate/</i>	Os juízes reprovados (extras e estados), item a item, com calibração por tipo de distrator

Referências

- Aleven, V., McLaren, B. M., Roll, I., & Koedinger, K. R. (2006). Toward meta-cognitive tutoring: A model of help seeking with a cognitive tutor. *International Journal of Artificial Intelligence in Education*, 16(2), 101–130.
- Aleven, V., McLaren, B. M., & Sewall, J. (2009). Scaling up programming by demonstration for intelligent tutoring systems development: an open-access web site for middle school mathematics learning. *IEEE Transactions on Learning Technologies*, 2(2), 64–78. <https://doi.org/10.1109/TLT.2009.22>
- Aleven, V., McLaren, B. M., Sewall, J., & Koedinger, K. R. (2009). A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2), 105–154.
- Aleven, V., McLaren, B. M., Sewall, J., van Velsen, M., Popescu, O., Demi, S., Ringenberg, M., & Koedinger, K. R. (2016). Example-tracing tutors: Intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, 26(1), 224–269. <https://doi.org/10.1007/s40593-015-0088-2>
- Anderson, J. R., Corbett, A. T., Koedinger, K. R., & Pelletier, R. (1995). Cognitive tutors: lessons learned. *Journal of the Learning Sciences*, 4(2), 167–207.
- Brown, J. S., & Burton, R. R. (1978). Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, 2(2), 155–192.
- Calò, T., & MacLellan, C. J. (2024). Towards educator-driven tutor authoring: generative AI approaches for creating intelligent tutor interfaces. *Proceedings of the Eleventh ACM Conference on Learning @ Scale*, 305–309. <https://doi.org/10.1145/3657604.3664694>
- Carnegie Mellon University. (2026a). Cognitive Tutor Authoring Tools (CTAT): software license agreement for academic or non-profit noncommercial research use. <https://github.com/CMUCTAT/CTAT/blob/4716009beab7f9b9099b822b30f8770bb4cdca08/LICENSE.md>
- Carnegie Mellon University. (2026b). Mathtutor: a free site where middle school students learn math. Copyright © 2009–2026 Carnegie Mellon University, All Rights Reserved. <https://mathtutor.web.cmu.edu/>
- Clark, R. E., Feldon, D. F., van Merriënboer, J. J. G., Yates, K., & Early, S. (2008). Cognitive task analysis. Em J. M. Spector, M. D. Merrill, J. van Merriënboer & M. P. Driscoll (orgs.), *Handbook of Research on Educational Communications and Technology* (3^a ed., pp. 577–593). Routledge.
- Clopper, C. J., & Pearson, E. S. (1934). The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika*, 26(4), 404–413. <https://doi.org/10.1093/biomet/26.4.404>
- Education Endowment Foundation. (2021). Feedback. Teaching and Learning Toolkit. <https://educationendowmentfoundation.org.uk/education-evidence/teaching-learning-toolkit/feedback>
- Education Endowment Foundation. (2025). Metacognition and self-regulation. Teaching and Learning Toolkit. <https://educationendowmentfoundation.org.uk/education-evidence/teaching-learning-toolkit/metacognition-and-self-regulation>
- Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association*, 82(397), 171–185. <https://doi.org/10.1080/01621459.1987.10478410>
- Flavell, J. H. (1979). Metacognition and cognitive monitoring: a new area of cognitive-developmental inquiry. *American Psychologist*, 34(10), 906–911.
- Hattie, J. (2009). *Visible Learning: A Synthesis of Over 800 Meta-Analyses Relating to Achievement*. Routledge.
- Kuhn, D. (2000). Metacognitive development. *Current Directions in Psychological Science*, 9(5), 178–181.
- Lovett, M. C. (1998). Cognitive task analysis in service of intelligent tutoring system design: a case study in statistics. Em *Intelligent Tutoring Systems (ITS 1998)*, Lecture Notes in Computer Science 1452 (pp. 234–243). Springer.
- Murray, T. (2003). An overview of intelligent tutoring system authoring tools: updated analysis of the state of the art. Em T. Murray, S. Blessing & S. Ainsworth (orgs.), *Authoring Tools for Advanced Technology Learning Environments* (pp. 491–544). Kluwer.
- Nathan, M. J., & Petrosino, A. (2003). Expert blind spot among preservice teachers. *American Educational Research Journal*, 40(4), 905–928.
- Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *PNAS*, 115(11), 2600–2606.
- Pal Chowdhury, S., Zouhar, V., & Sachan, M. (2024). AutoTutor meets large language models: a language model tutor with rich pedagogy and guardrails. *Proceedings of the Eleventh ACM Conference on Learning @ Scale*, 5–15. <https://doi.org/10.1145/3657604.3662041>
- Razzaq, L., Patvarczki, J., Almeida, S. F., Vartak, M., Feng, M., Heffernan, N. T., & Koedinger, K. R. (2009). The ASSISTment Builder: supporting the life cycle of tutoring system content creation. *IEEE Transactions on Learning Technologies*, 2(2), 157–166.
- Roll, I., Aleven, V., McLaren, B. M., & Koedinger, K. R. (2011). Improving students’ help-seeking skills using metacognitive feedback in an intelligent tutoring system. *Learning and Instruction*, 21(2), 267–280.
- UNESCO Institute for Statistics (2017). *More than one-half of children and adolescents are not learning worldwide* (Fact Sheet No. 46). Montreal: UIS.

- VanLehn, K. (1990). *Mind Bugs: The Origins of Procedural Misconceptions*. MIT Press.
- VanLehn, K. (2011). The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4), 197–221. <https://doi.org/10.1080/00461520.2011.611369>
- Veenman, M. V. J., Van Hout-Wolters, B. H. A. M., & Afflerbach, P. (2006). Metacognition and learning: conceptual and methodological considerations. *Metacognition and Learning*, 1, 3–14.
- World Bank, UNESCO, UNICEF, FCDO, USAID, & Bill & Melinda Gates Foundation (2022). *The State of Global Learning Poverty: 2022 Update*. Washington, DC: World Bank.
- Zimmerman, B. J. (2002). Becoming a self-regulated learner: an overview. *Theory into Practice*, 41(2), 64–70.