

Evidências para validação técnica em camadas da autoria de grafos de comportamento assistida por agentes de LLM: fidelidade, concordância CTAT, transporte e montagem

João Carlos Queiroz
EducaOFF / STI Unplugged
contato@educaoff.com.br

Artigo completo · estudo exploratório auditável · Campanhas 1–4 · versão 6.0
Execução dos geradores e painel auxiliar: 15 de julho de 2026

Resumo

Este artigo investiga em que medida o fluxo legado da EducaOFF produz evidências necessárias para validar tecnicamente os grafos de comportamento que monta. Validação é operacionalizada como um perfil de camadas: caminho correto, ramos buggy e remediações, scaffolds de dicas, preservação de conteúdo e identidade no transporte e integridade reprodutível da montagem. As Campanhas 1–3 desenvolveram e testaram o instrumento em uma bancada adaptada; a Campanha 4, estudo principal, avalia diretamente os agentes implantados e separa suas saídas do montador determinístico GraphForge. Foram usados 24 exercícios de frações na reta numérica, organizados em seis estados de quatro problemas e executados em três réplicas com a imagem de produção congelada. Os agentes 3a, 3b e 3c receberam o contrato multi-problema implantado e usaram `google/gemini-3.5-flash`; os grafos CTAT de referência permaneceram inacessíveis até o fechamento das saídas. Dezesete de 18 estados foram concluídos; a falha restante entrou como ausência/zero na análise por intenção de executar. O traço correto do 3a obteve recall concreto ordenado zero porque o próprio prompt exige placeholders genéricos; a correspondência exata da resposta final foi 0,111 (IC95% 0,028–0,222). O 3b recuperou 0,176 (0,113–0,242) dos valores errados únicos da referência. No braço de capacidade do 3c, o sucesso estrito por problema foi 0,278 (0,167–0,403), a média macro por exercício da validade estrita entre cadeias emitidas foi 0,382 (0,257–0,507) e a média macro da taxa de vazamento literal entre dicas emitidas foi 0,226 (0,172–0,285). O extrator reteve 22,1% dos itens do 3a, 86,0% dos erros do 3b e 82,9% das dicas do 3c; `problemId` foi perdido em todos os fluxos, e a política operacional pulou o 3c nos 17 estados completos. O GraphForge foi determinístico em 34/34 pares de reexecução. No nível do grafo, esses resultados localizam fragilidades na instanciação do caminho correto, na cobertura e localização dos ramos buggy, no uso e na segurança das dicas e na rastreabilidade; a montagem determinística não corrige essas perdas. Nos critérios observáveis, o perfil não sustenta classificar os grafos produzidos pelo fluxo como bem gerados e prontos para uso autônomo: a montagem é repetível, mas conteúdo, segurança e rastreabilidade apresentam fragilidades essenciais. Um painel auxiliar cego com GLM-5.2, Qwen 3.7 Plus e DeepSeek V4 Pro permitiu calcular medianas com pelo menos dois juízes válidos para as 204 saídas observadas, mas apresentou forte efeito teto, 65 julgamentos ausentes concentrados no GLM e sensibilidade em apenas seis de oito dimensões mudadas. As campanhas históricas não são combinadas estatisticamente com a Campanha 4, pois entradas, runtimes e estimandos diferem. Assim, os BRDs são úteis para medir concordância com uma referência de autoria, mas não constituem verdade pedagógica universal. Os dados sustentam validação técnica parcial e diagnóstico por camada, não equivalência a especialistas, validade pedagógica do tutor final ou eficácia educacional.

Palavras-chave: sistemas tutores inteligentes; grafos de comportamento; qualidade de grafos; example-tracing; CTAT; agentes de LLM; misconceptions; dicas; LLM como juiz.

Abstract

This article investigates the extent to which EducaOFF’s legacy pipeline provides the evidence needed for technical validation of the behavior graphs it assembles. Validation is operationalized as a layered profile covering the correct path, buggy branches and remediation, hint scaffolds, preservation of content and identity during transport, and reproducible integrity of assembly. Campaigns 1–3 developed and tested the instrument in an adapted harness; Campaign 4, the main study, directly evaluates the deployed agents while separating their outputs from the deterministic GraphForge assembler. Twenty-four fraction number-line exercises were grouped into six four-problem states and executed in three replications using a frozen production image. Agents 3a, 3b, and 3c received the deployed multi-problem contract and used `google/gemini-3.5-flash`; CTAT reference graphs remained inaccessible until outputs were closed. Seventeen of 18 states completed, with the remaining failure scored as zero/absence under the intention-to-run policy. Agent 3a had zero ordered concrete recall because its own prompt requires generic placeholders; exact final-answer match was 0.111 (95% CI 0.028–0.222). Agent 3b recalled 0.176 (0.113–0.242) of unique wrong values in the reference. In Agent 3c’s forced-capacity arm, strict problem success was 0.278 (0.167–0.403), the exercise-level macro mean of strict validity among emitted chains was 0.382 (0.257–0.507), and the macro mean literal-leakage rate among emitted hints was 0.226 (0.172–0.285). The extractor retained 22.1% of Agent 3a items, 86.0% of Agent 3b errors, and 82.9% of Agent 3c hints; `problemId` was lost in every flow, and the operational policy skipped Agent 3c in all 17 completed states. GraphForge was deterministic in 34/34 rerun pairs. At graph level, these findings locate weaknesses in concrete-path instantiation, coverage and localization of buggy branches, use and safety of hints, and traceability; deterministic assembly does not repair those losses. Under the observed criteria, this profile does not support describing the pipeline’s graphs as well generated and ready for autonomous use: assembly is repeatable, but content, safety, and traceability show essential weaknesses. A blinded auxiliary panel using GLM-5.2, Qwen 3.7 Plus, and DeepSeek V4 Pro provided at least two valid ratings for median aggregation on all 204 observed outputs, but showed a severe ceiling effect, 65 missing ratings concentrated in GLM, and sensitivity in only six of eight mutated dimensions. Historical campaigns are not statistically pooled with Campaign 4 because their inputs, runtimes, and estimands differ. BRDs can therefore support reference-concordance testing, but are not universal pedagogical ground truth. The evidence supports partial technical validation and layer-specific diagnosis, not equivalence to experts, pedagogical validity of the final tutor, or educational effectiveness.

Keywords: intelligent tutoring systems; behavior graphs; graph quality; example tracing; CTAT; LLM agents; misconceptions; hints; LLM-as-a-judge.

1 Introdução

Tutores do paradigma *example-tracing* interpretam as ações do estudante em relação a caminhos previamente autorados, erros esperados e intervenções associadas. No CTAT (Cognitive Tutor Authoring Tools), essa estrutura é registrada em um grafo de comportamento; sua autoria pode exigir a enumeração de múltiplos caminhos e erros sistemáticos por exercício (Alevén et al., 2009, 2016). A literatura clássica sobre *bugs* procedimentais sustenta que parte dos erros dos estudantes é sistemática e, portanto, passível de modelagem (Brown; Burton, 1978; VanLehn, 1990).




Figura 1: Anatomia de um grafo de comportamento. O caminho horizontal representa uma resolução correta; o desvio inferior associa uma misconception à remediação e ao retorno; o bloco superior representa uma cadeia progressiva de dicas. A figura é conceitual: os agentes avaliados propõem conteúdo, enquanto o GraphForge monta a topologia.

A EducaOFF automatiza parte dessa autoria por meio de três agentes baseados em modelos de linguagem: o 3a propõe um traço correto, o 3b propõe erros, diagnósticos e remediações, e o 3c propõe hesitações e dicas. Esses agentes não criam sozinhos a topologia final. Um extrator reduz e reorganiza suas saídas; depois, o GraphForge cria nós, arestas, scaffolds e manifestos. Avaliar somente o grafo montado mistura pelo menos quatro fontes de variação: conteúdo gerado, contrato de entrada, perdas no extrator e regras determinísticas do montador.

Por concisão, a expressão “grafos gerados pelos agentes” designa neste artigo os grafos produzidos pelo **fluxo assistido por agentes**: conteúdo proposto por 3a, 3b e 3c, transformado pelo extrator e montado pelo GraphForge. Ela não significa que o modelo de linguagem, isoladamente, produza a topologia final. Essa precisão é necessária para atribuir a qualidade — ou a falha — ao estágio em que ela efetivamente surge.

Neste trabalho, validar tecnicamente o processo de autoria de um grafo de comportamento significa reunir evidências separadas sobre: (a) o conteúdo do caminho correto; (b) a cobertura, o diagnóstico e a remediação de comportamentos errôneos; (c) a progressividade e a segurança dos scaffolds de dicas; (d) a preservação dessas informações até o artefato montado; e (e) a integridade estrutural e a reprodutibilidade da montagem. Cada dimensão é necessária para um grafo utilizável, mas nenhuma, isoladamente, estabelece validade pedagógica. Essa definição impede que topologia bem formada mas vazia, conteúdo plausível perdido no transporte ou montagem determinística de informações inadequadas sejam confundidos com um “bom grafo”.

Versões anteriores deste trabalho mediram o subsistema integrado em uma bancada adaptada, mas não preservaram sem perdas as três saídas brutas. A Campanha 4 corrige essa limitação ao executar o código e as configurações da imagem implantada, congelar as saídas antes de abrir as referências CTAT e calcular métricas próprias para cada papel. A pergunta central é: **em que medida o fluxo legado de autoria assistida da EducaOFF produz componentes observáveis de um grafo de comportamento concordantes com a referência CTAT, preservados no transporte e estruturalmente reproduzíveis?** Ela é decomposta nas seguintes subperguntas:

QP1. Caminho correto: em que medida o 3a produz uma sequência concreta concordante com o BRD?

QP2. Ramos buggy e remediação: em que medida o 3b recupera valores errados da referência




Figura 2: Diferença entre grafo de conhecimento (currículo e pré-requisitos compartilhados) e grafo de comportamento (estados e ações de um exercício). O estudo não avalia a criação de um grafo de conhecimento.

e emite informação remediativa utilizável?

- QP3. Scaffold de dicas:** em que medida o 3c produz cadeias completas, distintas e sem revelação prematura da resposta?
- QP4. Fidelidade de transporte:** que conteúdo e identidade de problema são preservados da saída bruta até a configuração e o artefato GraphForge?
- QP5. Fidelidade e estrutura:** a execução corresponde ao código, às configurações e ao fluxo legado implantados, e a montagem é reproduzível?
- QP6.** Um painel cego de LLMs acrescenta evidência auxiliar de qualidade textual às métricas determinísticas?

A contribuição central não é um escore único de “qualidade do grafo”, mas um perfil de evidências de validação por componente. O trabalho oferece uma decomposição auditável entre geração, concordância com referência, propriedades intrínsecas das dicas, transporte e montagem. Essa decomposição também define o limite da alegação: concordar com um BRD de autoria humana é evidência de alinhamento a uma referência, mas não prova que o BRD seja completo nem que comportamentos alternativos sejam inválidos. Avaliação humana independente e dados de estudantes continuam necessários para validade pedagógica.

2 Fundamentação e escopo de validade

2.1 Grafo de comportamento, saída de agente e grafo final

Um grafo de conhecimento organiza habilidades e pré-requisitos entre exercícios. Um grafo de comportamento, por sua vez, representa estados, ações, erros e intervenções em um exercício. O presente estudo trata apenas do segundo objeto. Mesmo assim, é necessário distinguir o conteúdo proposto pelos agentes da estrutura criada pelo montador. A Figura 3 explicita as fronteiras observadas.




Figura 3: Fluxo efetivamente avaliado. Os agentes produzem conteúdo candidato; o extrator e o GraphForge transformam esse conteúdo. O BRD entra somente depois do fechamento das saídas, na etapa de comparação. Agentes posteriores que adaptam o tutor final e a rota atual *tool-first* estão fora do escopo.

2.2 Modelo de validação técnica em camadas

A unidade conceitual de validação é o processo que forma o grafo e seus artefatos intermediários, não apenas o arquivo final. Como os agentes propõem componentes sem emitir a topologia CTAT completa, uma comparação monolítica entre “grafo do agente” e BRD atribuiria ao modelo decisões do extrator e do GraphForge. A Tabela 1 explicita a ligação entre anatomia do grafo, evidência observada e alcance da inferência. Não há limiar global de aprovação nem regra pós-hoc de “válido/inválido”.

Tabela 1: Modelo de validação técnica do grafo de comportamento.

Camada	Componente observado	Evidência produzida	O que não demonstra
Fidelidade de produção	código, configuração, entrada e política	identidade por digest e hashes do fluxo auditado	réplica externa byte a byte da imagem não publicada
Caminho correto	saída 3a e resposta final	instanciação concreta e concordância com ações corretas da referência	correção matemática abstrata de templates genéricos
Ramos buggy	saída 3b, diagnóstico e remediação	cobertura por valor do catálogo do BRD e presença de campos remediativos	validade de excedentes ou concordância por estado/SAI
Scaffold de dicas	saída 3c	completude, distinção, progressividade formal e vazamento literal	efeito das dicas sobre a aprendizagem
Transporte	configuração, grafo e manifesto de slots	retenção de conteúdo, campos e identidade de problema	qualidade pedagógica do conteúdo preservado
Montagem	topologia GraphForge	invariantes implementadas e identidade em reexecução	validade semântica ou pedagógica do grafo

Para responder à questão prática de qualidade, o estudo usa uma síntese interpretativa pós-hoc com três estatutos: **evidência favorável no limite testado**, quando a propriedade foi observada sem defeito crítico conhecido; **fragilidade observada**, quando ausências ou falhas mensuradas comprometem o uso pretendido; e **não estimável**, quando a fonte externa necessária não existe. Como não foi congelado um limiar global de aprovação, esses estatutos não constituem teste de hipótese nem nota composta. A conclusão “não pronto para uso autônomo” é uma conclusão de risco de engenharia: basta que propriedades essenciais de executabilidade, segurança ou rastreabilidade estejam comprometidas; ela não afirma que todo conteúdo gerado seja pedagogicamente incorreto.

2.3 O papel legítimo e limitado dos BRDs

Os BRDs foram produzidos para tutores CTAT e constituem uma referência tecnicamente pertinente quando a pergunta é se o sistema reproduz os comportamentos registrados nesses tutores. Seu uso é particularmente informativo para ações concretas corretas e valores errados observáveis. Contudo, um único grafo não enumera necessariamente todas as soluções ou misconceptions pedagogicamente defensáveis. A discordância entre avaliadores qualificados pode refletir ambiguidade da tarefa, não apenas erro (Amidei; Piwek; Willis, 2018).

Por isso, este artigo usa os termos **concordância**, **recall da referência** e **cobertura**, nunca “correção universal”. A identidade, a credencial do autor original e a licença específica dos BRDs não constam de modo suficiente no pacote recebido. O corpus é denominado “referência CTAT”; a expressão “padrão-ouro especialista” não é usada. Uma demonstração de equivalência a especialistas exigiria múltiplos autores independentes, uma banda humano–humano e margem prospectiva de não inferioridade (Shavelson; Webb, 1991).

2.4 Não inferioridade e banda humano–humano

Quando não há um único grafo correto, igualdade exata com um autor não é um critério adequado de validade. A pergunta formal relevante seria se a divergência do sistema excede a divergência observada entre autores humanos independentes. Esse enquadramento requer uma margem de não inferioridade justificada antes da análise (Lakens, 2017; Lakens; Scheel;

Isager, 2018) e uma estimativa da variabilidade entre autores. Pela Teoria da Generalizabilidade, um único grafo humano por exercício não permite separar a faceta exercício da faceta autor (Shavelson; Webb, 1991). Consequentemente, a não inferioridade permanece **não estimável** nas quatro campanhas. Os intervalos de concordância reportados não devem ser convertidos em um limiar informal de aprovação.

2.5 Comparação assimétrica e territórios de divergência

Métricas simétricas, como F1, penalizam todo item produzido que não apareça na referência. Isso mistura duas situações distintas: uma alucinação inválida e uma alternativa pedagogicamente plausível não registrada pelo autor. A comparação assimétrica de Tversky (1977) motiva separar três territórios: interseção, excedentes do sistema e omissões em relação à referência. As Campanhas 1–3 usaram cobertura por valor, inclusão de traços e F1 como medidas históricas; a Campanha 4 substitui o escore agregado por métricas específicas de cada agente e por retenção de campos. Em nenhum caso um excedente é automaticamente verdadeiro ou falso: sua validade exige outra fonte de evidência.

2.6 Integridade estrutural como camada independente

Propriedades topológicas podem ser testadas sem assumir que o conteúdo do BRD seja completo. O verificador do projeto procura violações duras — ciclo fora de remediação, nó inalcançável, beco sem saída, scaffold ou aresta órfãos e ausência de início ou objetivo — e sinais moles, como ramificação excessiva. Testes de propriedades sobre 10.000 configurações e mutation testing com 260 defeitos injetados exercitam as classes implementadas. Essa evidência demonstra consistência entre montador e verificador para a taxonomia coberta; não prova ausência de defeitos desconhecidos nem qualidade pedagógica. A Campanha 4 acrescenta uma verificação distinta: identidade byte a byte em reexecuções do mesmo GraphForge.

2.7 LLMs como juízes auxiliares

LLMs podem aplicar rubricas em escala, mas carregam vieses de preferência, família e estilo. Há evidência de que avaliadores reconhecem e favorecem produções da própria família (Panickssery; Bowman; Feng, 2024), e nem mesmo preferência humana agregada representa automaticamente todos os critérios de validade (Hosking; Blunsom; Bartolo, 2024). Neste estudo, os juízes pertencem a famílias diferentes da geradora, recebem códigos opacos e não veem o GraphForge. Ainda assim, suas notas são tratadas como evidência auxiliar. Mutações sintéticas medem sensibilidade a degradações óbvias; não substituem calibração com especialistas.

3 Método

3.1 Programa de pesquisa e evolução do instrumento

As quatro campanhas formam uma sequência de desenvolvimento, não quatro réplicas do mesmo experimento. As Campanhas 1 e 2 usaram um protocolo de dois envelopes derivados do BRD e avaliaram a bancada integrada; a Campanha 2 variou o modelo gerador. A Campanha 3 construiu a entrada sem ler o conteúdo do grafo de referência e introduziu uma bateria comportamental, mas continuou avaliando o subsistema depois de mapeamento e montagem. Essas três fases não retiveram de forma comparável todas as saídas de 3a, 3b e 3c. A Campanha 4 foi criada para fechar essa lacuna: usa o contrato multi-problema da rota legada, preserva saídas brutas e mede separadamente agente, extrator e GraphForge.




Figura 4: Evolução do instrumento. As Campanhas 1–3 são fases históricas exploratórias; a Campanha 4 é a avaliação principal de componentes. A seta representa aprendizado metodológico, não comparabilidade direta dos estímulos.

Tabela 2: Comparabilidade e função das quatro campanhas.

Fase	Objeto	Entrada	Desfecho central	Bruto preservado?	Identificação permitida
C1	bancada integrada	envelope derivado do BRD	cobertura por valor; integridade; juiz histórico	não integralmente	piloto do instrumento
C2	bancada integrada, quatro geradores	protocolo v1	robustez exploratória da cobertura	não integralmente	contrastes entre braços da bancada
C3	grafo integrado e executor analítico	interface e gabarito independentes do conteúdo do grafo	conformidade comportamental e ablações	insuficiente para atribuição	desempenho integrado sob protocolo v2
C4	agentes, extrator e GraphForge	contrato legado implantado com quatro problemas	métricas por agente e transporte	sim, antes da referência	diagnóstico direto por componente

O corpus de 24 exercícios foi reutilizado. Logo, as campanhas não ampliam a amostra para 96 exercícios independentes. Entradas, runtime, unidade observacional, modelos auxiliares e estímulos também mudaram. Nenhuma estimativa é combinada entre campanhas, nenhum teste de tendência temporal é calculado e diferenças numéricas não são interpretadas como melhora ou piora do sistema. Os resultados históricos são apresentados porque documentam por que a separação da Campanha 4 se tornou necessária e permitem verificar se as novas observações oferecem mecanismos plausíveis para limitações antes vistas no agregado.

3.2 Desenho, corpus e unidade de análise

O corpus `frac-numberline-6.17` contém 24 exercícios sobre localização de frações na reta numérica. Enunciados e respostas esperadas foram materializados de uma chave independente derivada da interface, sem leitura dos BRDs. Quatro identificadores de KC foram construídos por regras de domínio: três comuns aos 24 exercícios e um adicional nos 12 casos de fração imprópria; cada exercício trazia três ou quatro KCs e quatro passos canônicos. Os exercícios foram agrupados em seis estados de quatro problemas, cardinalidade esperada pela rota implantada; em cada estado, as estratégias `polya`, `exemplo_trabalhado`, `problema_invertido` e `descoberta_guiada` aparecem uma vez.

Cada um dos seis estados foi planejado em três réplicas estocásticas, totalizando 18 unidades estado-réplica e 72 unidades exercício-réplica por agente. “Réplica” significa nova chamada com a mesma configuração; o runtime não expõe semente. A unidade inferencial registrada é o exercício, não a chamada nem cada passo. Primeiro se calcula a média das réplicas dentro do exercício; depois, a média macro dos 24 exercícios. Como quatro exercícios compartilham cada chamada, foi acrescentada após auditoria uma sensibilidade que reamostra os seis batches. Ela não substitui o intervalo registrado e, com apenas seis clusters, é descritiva e grosseira.

As métricas e o protocolo inicial dos juízes foram congelados antes da primeira chamada paga. Em seguida, três estados da réplica 1 foram executados como piloto; suas nove chamadas

foram retidas no conjunto final. O plano das 45 chamadas geradoras restantes foi formalizado depois do piloto, usando apenas critérios operacionais previamente declarados de parse, custo e cobertura do gate, sem inspeção das métricas de qualidade. A Campanha 4 é, portanto, exploratória e auditável, mas não constitui um pré-registro integral concluído antes de qualquer coleta.

3.3 Fidelidade à implantação e isolamento da referência

A execução usou a imagem de contêiner `sha256:15b29e8063099d40fc62899da2795db6e97d3e252e486315428a0690bb9abf5b`. O `filesystem diff` estava vazio. Os hashes dos agentes 3, do `pipeline-core`, do GraphForge e do catálogo de 33 misconceptions foram comparados com o manifesto antes de cada grupo. A imagem não contém rótulo VCS; o commit `7d3a676a94c3833bc95b1bde929d41bdbde94f1e` é um candidato fortemente corroborado, não identidade provada.

As chamadas ocorreram em cópia descartável da imagem, fora da VPS operacional. A credencial foi mantida em memória e não persistida nos artefatos. Cache, fallback e retries internos foram desabilitados. O preflight substituiu somente a chamada de rede por resposta simulada e congelou hashes das mensagens efetivas. O processo de autoria não podia abrir BRDs, envelopes históricos ou resultados anteriores; a referência CTAT era aplicada somente após persistência e fechamento das saídas brutas.

Uma auditoria posterior do depósito detectou que a atestação inicial da ontologia enumerava apenas três dos quatro identificadores de KC das fixtures. Segundo uma atestação operacional produzida pelo pesquisador, a consulta somente leitura do quarto identificador ao bridge implantado retornou HTTP 200 e vetor vazio nos três endpoints; durante a execução, o snapshot local respondeu 404 para esse identificador, resposta que o cliente de produção converte deterministicamente no mesmo vetor vazio. Assim, o enriquecimento efetivo permaneceu vazio nos dois ambientes, sem alteração dos grafos ou estimandos. Essa verificação é pós-hoc e não é externamente reproduzível com o depósito: as respostas HTTP brutas não foram preservadas. A omissão de cobertura no gate, a qualificação da evidência e os hashes do cliente constam da emenda `protocol/production-freeze-2026-07-15/AMENDMENT-C4-ONTOLOGY-KC4-POST-AUDIT-2026-07-15.md` e da atestação `protocol/production-freeze-2026-07-15/ontology-fixture-kc-attestation-v2.json`, SHA-256 `00dc41394488d56299a23e39fa14dccdd9dbfc369aab372b0651d80ef3f19394`.

3.4 Agentes e configurações

Tabela 3: Papéis e configurações primárias da rota legada congelada.

Agente	Papel	Saída principal	Temp.	Tokens máx.
3a	aluno avançado	soluções com traço correto genérico, ações, resultados e KCs	0,2	16.000
3b	aluno em risco	tentativas, respostas erradas, diagnóstico, feedback e remediação	0,7	24.000
3c	aluno mediano	hesitações e cadeias de dicas em quatro níveis	0,4	16.000

Nota. Os três agentes usaram `google/gemini-3.5-flash` via OpenRouter no tier *balanced*. As diferenças de temperatura pertencem à configuração implantada e não são fatores experimentais.

Os agentes 3a e 3b foram chamados em paralelo; o 3c seria chamado depois deles apenas se a política operacional não o pulasse. Como a condição operacional pulou o 3c em todos os estados completos, executou-se também um braço de **capacidade**: o mesmo agente e o mesmo prompt

foram chamados diretamente, sem atribuir essa política à produção. As saídas de capacidade servem para avaliar o que o 3c consegue emitir; a política operacional serve para mostrar o que efetivamente chegaria ao restante do fluxo.

3.5 Desfechos determinísticos

A Tabela 4 transforma o modelo conceitual em estimandos observáveis para cada componente do grafo. Nenhum escore composto foi criado, pois as camadas têm construtos e denominadores diferentes; portanto, seus valores não podem ser somados nem convertidos em uma nota global de validade.

Tabela 4: Componentes do grafo, desfechos e limites de interpretação.

Camada do grafo	Desfecho	Definição operacional	Interpretação permitida
Caminho correto (3a)	$R_{3a,concreto}$	$LCS(E, G_c)/ E $, com ações corretas concretas e ordenadas da referência (E) e resultados concretos gerados (G_c). Placeholders entre chaves recebem zero crédito.	Instanciação e concordância concreta; zero não implica, sozinho, erro matemático quando o contrato pede generalidade.
Caminho correto (3a)	resposta final	Igualdade exata, após canonização, entre finalAnswer e resposta esperada.	Diagnóstico secundário de instanciação.
Ramos buggy (3b)	$R_{3b,valor}$	Recall de valores errados concretos únicos presentes nas ações buggy comparáveis do BRD.	Cobertura da referência por valor; excedentes não são falsos automaticamente.
Localização buggy (3b)	proxy ordinal	Pareamento entre número ordinal do passo e valor.	Sensibilidade; não equivale a estado CTAT ou SAI.
Scaffold de dicas (3c)	$C_{3c,estrito}$ por problema	Sucesso se há passo elegível e todas as cadeias são estritas: exatamente quatro níveis e tipos esperados, textos não vazios e distintos, sem resposta literal.	Qualidade operacional intrínseca; não mede aprendizagem.
Scaffold de dicas (3c)	completude e vazamento	Proporção de passos com níveis 1–4; proporção de dicas contendo literalmente a resposta final.	Diagnóstico de contrato e segurança pedagógica.
Transporte	retenção por campo	Correspondência exata entre saída bruta, configuração, grafo genérico e manifesto de slots.	Preservação de informação, não validade pedagógica.
Topologia GraphForge	determinismo	Identidade byte a byte do resultado em duas execuções da mesma configuração.	Reprodutibilidade do montador para os casos observados.

O parser CTAT preservou estados e triplas SAI (*Selection–Action–Input*). A referência contém 96 ações corretas comparáveis e 192 ações buggy, das quais 110 passaram o filtro primário de conteúdo; ações mecânicas e sentinelas exatas foram excluídas conforme regra congelada. O 3b não emite a combinação estado+SAI, de modo que o recall direto por estado planejado originalmente é **não estimável**. Substituí-lo silenciosamente pelo número do passo produziria uma alegação mais forte que os dados.

Para o 3c, passo elegível é aquele com `hesitation=true` ou dicas emitidas. Uma cadeia estrita exige níveis 1–4, tipos `conceptual`, `procedural`, `specific` e `bottom_out`, quatro textos distintos e ausência da resposta literal. A taxa de vazamento usa cada mensagem de dica como unidade descritiva; o sucesso estrito por problema usa exercício–réplica e entra como zero na ausência de estado.

3.6 Falhas, análise ITT e incerteza

O plano determinou tentativa única, sem reparo, retry, fallback ou imputação para os geradores. Falha de chamada, parse ou estado atômico entra como zero/ausência no estimando ITT. A análise restrita a estados completos é secundária. Intervalos de confiança percentis de 95% foram obtidos por 20.000 reamostragens com reposição dos 24 exercícios, usando sementes fixas diferentes por métrica (Efron; Tibshirani, 1993). Esses intervalos quantificam estabilidade entre exercícios do corpus, mas não modelam a chamada compartilhada. A sensibilidade pós-hoc por batch preserva esse agrupamento; nenhum dos dois procedimentos corrige viés de seleção do domínio nem transforma o estudo em confirmatório.

3.7 Painel auxiliar de qualidade textual

Cada uma das 204 saídas principais observadas (68 por agente) foi apresentada separadamente a três famílias de juiz: `z-ai/glm-5.2`, `qwen/qwen3.7-plus` e `deepseek/deepseek-v4-pro`. O modelo gerador pertence à família Google. Os juízes receberam enunciado, resposta, KCs, passos independentes e a saída bruta do respectivo agente, mas não receberam identidade do agente, réplica, modelo, lote ou artefato GraphForge. A ordem foi derivada deterministicamente de hash próprio por modelo.

Cada papel tinha cinco dimensões em escala ordinal 0–4. Para o 3a, os placeholders eram declarados intencionais e avaliados por coerência e transferibilidade; para o 3b, erros plausíveis não eram penalizados apenas por não aparecerem no BRD; para o 3c, a resposta esperada era mostrada para permitir detecção de revelação prematura. A agregação por dimensão é a mediana quando pelo menos dois juízes são válidos. Ausências não foram imputadas.

Como controle de sensibilidade, seis exercícios predeterminados receberam uma mutação por papel: contradição e remoção de passo no 3a; resposta errada igual ao gabarito e remoção de diagnóstico/remediação no 3b; e quatro dicas idênticas que entregam a resposta no 3c. Isso produziu 18 unidades mutadas e 54 julgamentos adicionais. Uma dimensão foi considerada sensível se a nota mutada caiu em pelo menos 80% dos pares válidos. Foram calculados alfa ordinal de Krippendorff, kappa quadrático pareado, distribuição de escores e taxa de divergência maior que um ponto (Krippendorff, 2018). Com marginais quase constantes, estatísticas corrigidas pelo acaso são instáveis; por isso, distribuição e calibração têm prioridade interpretativa.

O protocolo do painel foi congelado antes dos resultados dos geradores, mas a composição de modelos foi alterada depois por custo. Três lançamentos técnicos parciais foram excluídos integralmente: v1 por keywords de JSON Schema não portáteis; v2 por limite de compilação de gramáticas remotas; e v4 após retirada de GPT-5.4. A execução final v5 começou do zero. Rubricas, unidades, mutações e análises permaneceram inalteradas. Trata-se, portanto, de evidência auxiliar pós-registro, não teste confirmatório.

3.8 Rastreabilidade e testes

Estados, prompts, respostas, usage, custos, erros, configurações intermediárias, grafos e manifestos foram preservados. Cada lançamento possui journal append-only e hashes SHA-256. A análise final foi executada depois do fechamento das saídas. Uma errata v2.1 corrigiu somente quatro taxas descritivas de campos do 3a; contagens, saídas, estimandos diretos e métricas de

outras funções não mudaram. O código e os testes da versão v2 foram recuperados com os hashes exatos registrados no congelamento, respectivamente `4f8ae7d374bb08fe9ac59cedc622fde92f40379f635b47a05fc69d9044dfd6fa` e `eb9be4ff5f651b858e6b6d0038796bf930e67bab849132ad4af139803340b335`. Contudo, o JSON piloto v2 original, cujo hash começava por `35dee4`, foi sobrescrito e não pôde ser recuperado byte a byte; seus valores científicos permanecem recomputáveis, mas o timestamp original não. Uma errata analítica v5.1 preservou o painel original e marcou alfa/kappa como não estimáveis quando havia uma única categoria observada. Testes automatizados cobrem fixtures, contrato, identidade de produção, filtros CTAT, denominadores, transporte, segurança financeira e estatística.

4 Resultados da validação técnica em camadas

4.1 Execução e falha preservada

De 18 estados planejados, 17 foram concluídos (94,4%). Na réplica 3 do batch 03, o provedor retornou as respostas de 3a e 3b, mas o JSON de 3b era malformatado. O 3a foi aceito pelo parser antes da falha atômica; o 3c não foi chamado. O estado, que continha quatro exercícios, não foi repetido nem reparado. O 3a, portanto, retornou 72/72 soluções brutas identificáveis, mas somente 68/72 foram integradas e pontuadas sob a política atômica. Para 3b e 3c, 68/72 ficaram integráveis. As 72 unidades permanecem no denominador ITT. Logo, o ITT estima efetividade do pipeline atômico; o zero imposto ao 3a no estado falho não mede sua capacidade isolada.

Tabela 5: Execução dos geradores na Campanha 4.

Componente	N	Tokens entrada	Tokens saída	Custo (US\$)	Latência mediana	Estado
Agente 3a	18	42.540	36.254	0,3901	11,47 s	18 respostas retornadas; 17 estados integrados
Agente 3b	18	53.268	87.248	0,8651	30,22 s	uma resposta malformatada
Agente 3c	17	49.607	69.372	0,6988	23,46 s	não chamado no estado falho
Total	53	145.415	192.874	1,9540	23,22 s	52 respostas aceitas pelo parser; 51 integradas

Nota. O percentil 95 da latência foi 34,0 s. Não houve retry nem fallback. Uma resposta 3a parseável ficou fora da análise integrada porque o estado falhou atômicamente.

4.2 Validade de conteúdo por componente autorado

Tabela 6: Métricas diretas, sem escore composto.

Agente	Métrica	Estimativa	IC95% bootstrap	Denominador/estatuto
3a	Recall concreto ordenado ITT	0,000	[0,000; 0,000]	24 exercícios, 72 unidades ITT
3a	Igualdade exata da resposta final ITT	0,111	[0,028; 0,222]	24 exercícios, 72 unidades ITT
3a	Resultados genéricos entre saídas integradas	1,000	[1,000; 1,000]	68 saídas pontuáveis
3b	Recall de valores errados únicos ITT	0,176	[0,113; 0,242]	24 exercícios, 72 unidades ITT
3b	Recall de valores, estados completos	0,190	[0,124; 0,260]	68 saídas observadas

Agente	Métrica	Estimativa	IC95% bootstrap	Denominador/estatuto
3b	Proxy ordinal passo-valor ITT	0,060	[0,023; 0,105]	sensibilidade; não é estado CTAT
3c	Sucesso estrito por problema ITT	0,278	[0,167; 0,403]	braço de capacidade; 72 unidades ITT
3c	Sucesso estrito, estados completos	0,299	[0,188; 0,424]	braço de capacidade; 68 saídas
3c	Compleitude 1-4 condicional	1,000	[1,000; 1,000]	82 passos elegíveis
3c	Validade estrita condicional	0,382	[0,257; 0,507]	média macro; cadeias emitidas
3c	Vazamento literal da resposta	0,226	[0,172; 0,285]	média macro; dicas emitidas

Na sensibilidade pós-hoc que reamostrou os seis batches de chamada, a estimativa pontual foi preservada, mas o IC do acerto final do 3a ampliou-se para [0,000; 0,333]; os intervalos do recall do 3b e do sucesso estrito do 3c foram, respectivamente, [0,117; 0,244] e [0,153; 0,444]. Os valores registrados por exercício continuam sendo os resultados principais da Tabela 6; a sensibilidade mostra que a precisão do 3a foi superestimada quando a dependência intra-chamada foi ignorada.

Agente 3a. Todos os resultados intermediários emitidos continham placeholders como `\{A\}`, `\{B\}` e `\{C\}`, conforme exigência explícita do prompt. Consequentemente, a LCS concreta foi zero em todas as unidades. Esse resultado diagnostica incompatibilidade entre um contrato de traço genérico e uma referência de ações concretas; não permite afirmar que as relações abstratas eram matematicamente erradas. A baixa correspondência da resposta final (11,1%) confirma, contudo, que a saída não está pronta para execução concreta sem uma etapa de instanciação validada.

Agente 3b. O agente emitiu 136 erros concretos observados, e nenhum tinha `wrongAnswer` igual à resposta correta. O recall macro dos valores registrados no BRD foi 17,6% sob ITT e 19,0% entre estados completos. A referência pode omitir erros plausíveis; por isso, o complemento não é “taxa de erro” do agente. O resultado demonstra apenas baixa recuperação do catálogo específico. A concordância por estado/SAI permanece não estimável porque o contrato não emite estado e tripla SAI CTAT; isso é distinto da perda posterior de `problemId` no extrator.

Agente 3c. Os 82 passos elegíveis continham 328 dicas e todos apresentavam quatro níveis. Apenas 32 cadeias satisfizeram simultaneamente os critérios estritos; 75 mensagens continham a resposta final literal. As taxas agrupadas por item (39,0% de cadeias estritas e 22,9% de vazamento) são próximas, mas não idênticas, às médias macro da Tabela 6. A completude formal dos quatro níveis, portanto, não garante progressividade, distinção ou ausência de entrega da resposta.

4.3 Fidelidade de transporte e montagem GraphForge

Tabela 7: Retenção ponderada por item da saída bruta ao artefato de destino.

Agente	Bruto	Config.	Destino	Retenção bruto- config.	Perdas e campos críticos
3a	272	60	60 nós	22,1%	212 itens truncados; ação e KC chegam aos nós, mas resultado e índice original não; <code>problemId</code> não chega à configuração.
3b	136	117	117 erros	86,0%	19 itens perdidos por ausência de ID, deduplicação ou truncamento; pergunta diagnóstica, localização e <code>problemId</code> não chegam à configuração; registros restantes chegam integralmente ao grafo.
3c capacidade	328	272	272 dicas no manifesto	82,9%	nível, tipo e <code>problemId</code> são perdidos; textos ficam no <code>slotManifest.existingHints</code> ; nenhum texto aparece nos nós do grafo genérico.
3c operacional	328 ^a	0	0	0,0%	a política implantada pulou o 3c em todos os 17 estados completos; nenhuma dica seguiria no fluxo operacional.

^a Os 328 itens existem no braço forçado de capacidade. A linha operacional aplica a decisão real de skip ao mesmo conjunto de estados; ela não significa que a produção ordinária tenha chamado o 3c.

O corte do 3a ocorre antes do GraphForge, no extrator que concatena soluções e retém um prefixo global. Entre configuração e grafo, ações e KCs são preservados, mas resultados concretos deixam de existir como campo de nó. Para o 3b, a maior parte do registro reduzido chega ao grafo, porém campos pedagogicamente relevantes já foram descartados. Para o 3c, a topologia genérica não transporta dicas; somente o manifesto de slots conserva textos, sem nível nem tipo. Em todos os agentes, a perda de `problemId` impede rastrear com segurança a origem depois da fusão multi-problema.

O GraphForge produziu resultados idênticos em 34/34 pares de reexecução, cobrindo as políticas operacional e de capacidade nos 17 estados completos. Isso sustenta determinismo observado do montador; não recupera dados removidos pelo extrator nem prova correção pedagógica da topologia.

4.4 Juízo sobre a qualidade dos grafos produzidos

As métricas por agente respondem a componentes diferentes do mesmo objeto final. Para o caminho correto, o 3a não produziu instanciação concreta concordante nas ações intermediárias e acertou a resposta final em 11,1% das unidades ITT, embora isso não permita condenar a correção abstrata de seus templates. Para os ramos buggy, o 3b recuperou 17,6% dos valores de erro da referência e não forneceu identidade estado/SAI suficiente para localizar esses ramos no grafo CTAT. Para o scaffold, o 3c sempre formou quatro níveis quando emitiu uma cadeia, mas a média macro por exercício da validade estrita entre cadeias observadas foi 38,2% e a média macro da taxa de vazamento literal entre dicas emitidas foi 22,6%; sua contribuição ao fluxo operacional foi nula nos 17 estados completos porque a política o pulou.

Esses conteúdos ainda sofreram transformação antes do artefato final: a retenção bruto-configuração foi 22,1% no 3a, 86,0% no 3b e 82,9% no braço de capacidade do 3c, com perda universal de `problemId`. O GraphForge repetiu a montagem de forma idêntica em 34/34 pares, mas montou somente o que sobreviveu ao extrator. Portanto, a evidência sustenta uma validação técnica **parcial e localizada**: identifica quais componentes do grafo estão presentes, ausentes ou não rastreáveis, sem fornecer base para aprovar o grafo para publicação autônoma.

Inversamente, a referência de autor único também não permite declarar que todo comportamento excedente seja pedagogicamente inválido.

O estudo não pré-especificou um escore composto nem um limiar global de aprovação; portanto, não se estima uma proporção de “grafos corretos”. Ainda assim, as métricas permitem responder qualitativamente à pergunta sobre sua qualidade. Um grafo utilizável requer simultaneamente caminho correto executável, erros localizados, intervenções adequadas, preservação da identidade do problema e montagem íntegra. Na versão auditada, somente a regularidade das saídas e a reprodutibilidade da montagem receberam evidência favorável, e mesmo a primeira não foi livre de falhas. As demais dimensões necessárias ao comportamento do tutor apresentaram fragilidades ou permaneceram não estimáveis. A Tabela 8 torna explícita essa síntese interpretativa; ela reorganiza resultados já apresentados e não introduz novo estimando.

Tabela 8: Perfil pós-hoc de qualidade dos grafos produzidos pelo fluxo auditado.

Dimensão necessária	Evidência observada	Estatuto	Consequência para o grafo
Regularidade da geração	17/18 estados concluídos; 52 respostas aceitas pelo parser e 51 saídas integradas; uma resposta 3b malformada	favorável no limite testado, com falha observada	o fluxo normalmente produz artefatos processáveis, mas não é livre de falhas de geração ou integração
Caminho correto executável	recall concreto intermediário 0; correspondência exata da resposta final 0,111; resultados intermediários genéricos em 1,000 das saídas integradas	fragilidade observada	o grafo não recebe do 3a um traço concreto suficiente para execução direta; isso não prova erro abstrato dos templates
Ramos buggy localizados	recall por valor 0,176; identidade estado/SAI não estimável; nenhum dos 136 erros emitidos coincidiu com a resposta correta	fragilidade observada	há candidatos de erro potencialmente úteis, mas cobertura e localização são insuficientes para uso automático confiável
Scaffold seguro e utilizável	sucesso estrito por problema 0,278; médias macro por exercício de 0,382 para validade estrita condicional e 0,226 para taxa de vazamento literal; 3c pulado nos 17 estados completos	fragilidade observada	completude formal das cadeias não garante progressão segura, e o grafo operacional observado não recebeu as dicas
Rastreabilidade e transporte	retenção 22,1%/86,0%/82,9% para 3a/3b/3c-capacidade; problemId perdido nos três fluxos; nível, tipo e localização também descartados	fragilidade crítica observada	conteúdo não pode ser atribuído com segurança ao exercício ou ao ponto comportamental de origem depois da fusão
Montagem reprodutível	34/34 pares de reexecução GraphForge idênticos	favorável no limite testado	a mesma entrada sobrevivente produz o mesmo artefato; determinismo não recupera perdas nem valida semântica
Plausibilidade textual	painel com forte efeito teto, dez dimensões degeneradas e sensibilidade em seis de oito dimensões mutadas	evidência auxiliar inconclusiva	notas altas não autorizam aprovação do conteúdo ou do grafo

Dimensão necessária	Evidência observada	Estatuto	Consequência para o grafo
Adequação pedagógica	ausência de novos especialistas independentes e de estudo com estudantes	não estimável	não se pode afirmar validade pedagógica, eficácia educacional ou equivalência a especialistas
Juízo global	forma geralmente processável e montagem estável, mas conteúdo comportamental incompleto, segurança inconsistente e rastreabilidade insuficiente	não pronto para uso autônomo	papel defensável: rascunho assistivo submetido a gates automáticos e revisão humana antes da implantação

Esse juízo é deliberadamente assimétrico. Ele não afirma que todos os grafos ou todos os conteúdos excedentes sejam pedagogicamente errados. Afirma que as propriedades essenciais observadas não foram satisfeitas em conjunto e que, por isso, os dados não sustentam tratar o artefato final como um tutor autorado autonomamente e pronto para publicação.

4.5 Painel auxiliar de juízes

O painel final executou 666 unidades primárias e 102 reparos, totalizando 768 chamadas. Houve 601 julgamentos válidos e 65 ausentes. Qwen e DeepSeek completaram 222/222 unidades cada um, sem reparo. GLM completou 157/222; 102 de suas respostas iniciais exigiram reparo e 65 permaneceram inválidas. Entre as ausências finais do GLM, 59 decorreram de **confidence** fora do intervalo local 0–1 e seis de JSON malformato. Todas as 204 unidades principais conservaram pelo menos dois juízes válidos.

Tabela 9: Cobertura e custo do painel auxiliar v5.

Juiz	Unid.	Válidas	Reparos	Ausentes	Custo (US\$)
GLM-5.2	222	157	102	65	0,7964
Qwen 3.7 Plus	222	222	0	0	0,1901
DeepSeek V4 Pro	222	222	0	0	0,2567
Total	666	601	102	65	1,2432

Nota. O custo contábil público canônico usa preços-teto congelados. Uma variação de uso da chave de US\$ 0,9955 consta apenas de registro privado de conta, omitido do depósito público, e não é usada como estimativa de custo do painel. O painel permaneceu abaixo da trava de execução de US\$ 3. Não houve fallback.

As medianas agregadas foram 4 em todas as 15 dimensões. Entre avaliações válidas, o escore 4 correspondeu a 99,79% das notas do 3a, 99,67% das notas do 3b e 99,54% das notas do 3c (2.746/2.755 notas no total). Dez das 15 dimensões usaram somente a categoria 4. Nelas, $D_o = D_e = 0$: não há variação suficiente para estimar confiabilidade corrigida pelo acaso. Trinta e três dos 45 kappas pareados são igualmente degenerados. Nas cinco dimensões restantes, o alfa ordinal variou de $-0,0055$ a $0,3294$. A concordância quadrática bruta ponderada variou de $0,9856$ a $1,000$, e apenas duas dimensões tiveram uma unidade com divergência maior que um ponto. A combinação de teto, marginais degeneradas e perdas seletivas do GLM torna enganosa qualquer leitura de “confiabilidade perfeita”; unanimidade bruta sob uma única categoria não demonstra poder discriminativo.

Tabela 10: Calibração por mutações sintéticas; Δ = nota mutada menos nota original.

Papel	Dimensão alvo	Pares	$\bar{\Delta}$	Queda	Gate 80%
Traço correto	correção/coerência	14	-4,000	14/14	passou
Traço correto	cobertura/ordem	14	-3,000	14/14	passou
Erros/remediação	plausibilidade do erro	15	0,000	0/15	falhou
Erros/remediação	diagnóstico causal	15	0,000	0/15	falhou
Erros/remediação	remediação acionável	15	-3,200	15/15	passou
Dicas	progressão de scaffold	15	-3,600	15/15	passou
Dicas	distinção	15	-3,533	15/15	passou
Dicas	não vazamento	15	-3,867	15/15	passou

Os juízes detectaram contradições, remoção de passo, remediação vazia e dicas repetitivas com entrega da resposta. Porém, quando a resposta errada foi substituída pela resposta correta e `diagnosticQuestion/howToFix` foram removidos, eles não reduziram plausibilidade nem diagnóstico causal. A mutação ainda preservava descrição e localização do erro; portanto, esse controle testa degradação parcial, não ausência total de evidência causal. O painel passou em seis de oito dimensões mutadas; sete das 15 dimensões da rubrica não foram alvo de mutação. Em conjunto, o resultado apoia apenas uma conclusão estreita: os textos principais pareceram bem formados e coerentes para os modelos, mas as notas absolutas têm baixa capacidade discriminativa e não podem validar pedagogicamente os agentes.

4.6 Custos e lançamentos excluídos

O custo contábil do experimento analítico foi US\$ 1,9540 para geração e US\$ 1,2432 para o painel final. Três lançamentos técnicos de juízes foram preservados e excluídos universalmente: v1 (58 tentativas concluídas, dois escores válidos, US\$ 0,00245 contabilizado), v2 (329 concluídas, 240 válidas, US\$ 1,80965) e v4 (124 concluídas, todas válidas, US\$ 0,40896). O overhead conhecido excluído soma US\$ 2,22106; chamadas diagnósticas e tentativas em voo impedem tratá-lo como custo financeiro total exato. Nenhum escore desses lançamentos foi usado para selecionar unidades, rubricas ou conclusões. A trava lógica de US\$ 3 do painel era verificada após a conclusão de cada tarefa; com concorrência nove, chamadas já em voo poderiam produzir pequeno *overshoot*. Isso não ocorreu: o custo contábil final foi US\$ 1,2432.

5 Campanhas 1–3: desenvolvimento e evidência histórica

5.1 Estatuto e função no manuscrito consolidado

As Campanhas 1–3 são mantidas porque documentam o desenvolvimento do instrumento e resultados integrados que motivaram a Campanha 4. Elas não são usadas para confirmar as estimativas atuais, escolher métricas retrospectivamente ou ampliar o tamanho amostral. Todas empregaram os mesmos 24 exercícios, com três réplicas por condição, mas variaram fonte de entrada, modelos, preparação da configuração e objeto medido. Na bancada histórica, os agentes alimentavam um adaptador experimental antes do GraphForge; portanto, suas métricas caracterizam a cadeia integrada sob aquele adaptador, não a capacidade isolada de 3a, 3b ou 3c.

O protocolo v1, usado nas Campanhas 1 e 2, separava o BRD em dois envelopes: um envelope de entrada com interface, resposta correta e KCs, e um envelope de referência aberto somente para comparação. A lista de campos proibidos e testes de vazamento impediam acesso lexical às misconceptions, dicas e arestas. Todavia, ambos os envelopes eram derivados do mesmo arquivo; havia blindagem parcial, não independência de fonte. Na Campanha 3, a

entrada passou a ser construída a partir da interface e do gabarito de produção em massa, sem ler o conteúdo comportamental do BRD. Essa mudança removeu a dependência direta, mas alterou simultaneamente idioma, disponibilidade de KCs e representação da tarefa.

5.2 Campanha 1: piloto do instrumento integrado

A Campanha 1 verificou integridade estrutural, cobertura direcional do catálogo de valores e funcionamento de um juiz cego histórico. A média de completude conceitual foi 0,376 (IC95% 0,309–0,442); a completude de passos foi 0,510 (0,497–0,525). O kappa médio da classificação sobre a união dos catálogos foi 0,007 (−0,069 a 0,089), resultado essencialmente nulo. A bateria não possuía verdadeiros negativos por construção, o que limita, mas não transforma o kappa baixo em concordância positiva.

Tabela 11: Síntese auditada da Campanha 1; 24 exercícios com três réplicas agregadas por exercício.

Métrica	Estimativa [IC95%]	Limite interpretativo
Completude conceitual por valor	0,376 [0,309; 0,442]	cobertura do catálogo de um autor, não correção universal
Completude bruta, incluindo registros mecânicos	0,234 [0,195; 0,273]	sensível a sentinelas e ações de interface
Completude de passos	0,510 [0,497; 0,525]	granularidade de passos difere entre artefatos
Concordância bruta de classificação	0,396 [0,345; 0,449]	união de catálogos sem verdadeiros negativos
Kappa médio de Cohen	0,007 [−0,069; 0,089]	não excede o acaso de modo demonstrável
Excedentes julgados plausíveis pelo GLM-4.5	0,83 [0,74; 0,91]	juiz único, sem calibração humana

O juiz GLM-4.5 classificou 55 de 66 excedentes decididos como plausíveis, com dois empates excluídos; aprovou 82/83 itens da referência e rejeitou os 48 controles formados por resposta correta e valor absurdo. A taxa de 83% significa apenas “plausível segundo esse juiz e essa rubrica”. Em campanha posterior, outro juiz alterou substancialmente níveis absolutos de calibração e de centralidade das omissões. Por isso, a Campanha 1 não fornece validação pedagógica dos excedentes.

Um caso ilustra o significado de cobertura. Em `04soccerSeason`, cuja resposta é 3/4, a referência registrava 2/4, 3 e 4; o sistema produziu 2/4, 3 e 4/4. Assim, cobriu dois de três valores conceituais, omitiu o denominador isolado e acrescentou uma confusão entre total de partes e fração. A comparação identifica interseção e divergências, mas não decide sozinha se 4/4 deve integrar um tutor. O padrão do denominador isolado reapareceu em vários exercícios e motivou as análises por tipo de erro.

5.3 Campanha 2: repetibilidade interna e variação do gerador

A Campanha 2 repetiu o baseline e variou apenas o modelo usado nos três agentes da bancada. A nova execução do Gemini obteve completude conceitual de 0,368 (0,300–0,442), próxima da Campanha 1, 0,376 (0,309–0,442). Isso é repetibilidade interna no mesmo corpus, não replicação independente. Os braços históricos foram Gemini 3.5 Flash, GLM-5.2, DeepSeek V4 Pro e Claude Sonnet 5. A presença do Claude nesta seção é um fato da Campanha 2 e não significa que ele tenha participado da Campanha 4 ou do painel final v5.

Tabela 12: Resultados históricos por modelo gerador na Campanha 2.

Métrica	Gemini	GLM-5.2	DeepSeek V4 Pro	Claude Sonnet 5
Compleitude conceitual	0,368 [0,300; 0,442]	0,415 [0,323; 0,504]	0,371 [0,292; 0,454]	0,416 [0,339; 0,488]
Compleitude de passos	0,508 [0,493; 0,523]	0,501 [0,479; 0,521]	0,477 [0,458; 0,496]	0,500 [0,487; 0,516]
Kappa médio	0,051	-0,027	-0,074	-0,033
Excedentes plausíveis segundo Mistral	0,74	0,78	0,73	0,73

Nenhuma diferença da completude conceitual primária foi detectada contra o baseline após Holm (p ajustado 0,988 nas três comparações). Isso não demonstra equivalência: os intervalos das diferenças ainda admitem efeitos relevantes. Entre métricas secundárias, somente a menor completude de passos do DeepSeek sobreviveu ao ajuste ($\Delta = -0,031$, p -Holm=0,035). Os níveis absolutos do juiz Mistral não são comparáveis aos do GLM-4.5 usado na Campanha 1. A principal conclusão é negativa e útil: trocar o modelo não removeu o teto de cobertura observado na bancada.

A anatomia da referência continha 83 instâncias conceituais únicas: 30 frações incorretas, 24 numeradores isolados, 24 denominadores isolados e cinco outros inteiros. Em uma execução do baseline, as coberturas médias foram 39%, 50%, 14% e 73%, respectivamente. A união de três réplicas elevou a cobertura total de 37% para 64%, mostrando diversidade estocástica, mas o denominador isolado permaneceu um ponto cego (33% mesmo na união). Uma curva adicional de cinco chamadas mostrou ganhos decrescentes: 31,3% em $K = 1$, 43,2% em $K = 2$, 48,9% em $K = 3$, 52,6% em $K = 4$ e 55,6% em $K = 5$. Gerar mais candidatos amplia a cobertura potencial, mas também aumenta custo e carga de revisão.

5.4 Campanha 3: entrada independente e conformidade integrada

A Campanha 3 introduziu uma bateria de 636 itens: 240 itens derivados da referência, 135 mutações e 261 sondas de domínio que forneciam verdadeiros negativos. Nove condições em três réplicas produziram 648 autorias. O executor implementava um subconjunto declarado de *example tracing*; não era o runtime CTAT completo. O estimando R_{bug} mede o reconhecimento de uma ação buggy no estado correspondente e R_{ok} exige que um traço correto inteiro seja aceito passo a passo.

No baseline, a estimativa reconstruída de R_{bug} foi 0,054 (0,016–0,095) sobre as 192 ações buggy pré-especificadas, e R_{ok} foi zero em todos os nove braços. A sensibilidade que exclui 42 ações mecânicas não ancoráveis produziu $R_{\text{bug,anchor}}=0,065$ (0,020–0,113). A cobertura secundária por valor foi 0,243 (0,163–0,324). Os relatórios preservaram a taxa ancorável, mas não os vereditos item a item; a reconstrução do numerador principal usa o denominador conhecido, tolerância de arredondamento e teste de regressão. Esses resultados caracterizam o subsistema integrado sob a bancada e o executor, não cada agente isolado.

Tabela 13: Resultados selecionados da Campanha 3; estimativas macro por exercício.

Condição	R_{bug} [IC95%]	R_{ok}	Cobertura por valor	Observação
Baseline Gemini	0,054 [0,016; 0,095]	0	0,243 [0,163; 0,324]	referência histórica
GLM-5.2	0,040 [0,016; 0,068]	0	0,178 [0,122; 0,236]	sem diferença coprimária
DeepSeek V4 Pro	0,023 [0,010; 0,036]	0	0,199 [0,143; 0,260]	sem diferença coprimária

Condição	R_{bug} [IC95%]	R_{ok}	Cobertura por valor	Observação
Limite de seis candidatos	0,078 [0,028; 0,134]	0	0,419 [0,342; 0,495]	maior cobertura; 61/72 sinais moles
Catálogo interno	0,021 [0,005; 0,040]	0	0,215 [0,152; 0,282]	ganho não detectado
Chamada única	0,010 [0; 0,024]	0	0,203 [0,147; 0,264]	ganho não detectado

Elevar o pedido de 2–3 para seis candidatos aumentou a cobertura por valor em 17,7 pontos ($p\text{-Holm} = 2,4 \times 10^{-5}$), mas não demonstrou ganho em R_{bug} e coincidiu com 61/72 sinais estruturais moles. Nos 648 grafos, não ocorreu violação dura; 62 (9,6%) acionaram sinal mole, quase todos naquela condição. O mutation testing detectou 260/260 defeitos deliberadamente injetados nas dez classes cobertas. A interpretação correta é que o montador respeitou as invariantes implementadas, enquanto maior quantidade de candidatos elevou complexidade e revisão potencial.

Duas limitações invalidadas permanecem documentadas. O braço DOM continha um enunciado não relacionado ao corpus e o braço de screenshot reutilizou a mesma imagem nos 24 exercícios; seus contrastes não sustentam alegações sobre multimodalidade. Além disso, o painel planejado para os excedentes leu o campo **extras**, enquanto os relatórios armazenavam **extra**; os 179 itens julgados continham referências e controles, mas nenhum excedente do sistema. Seus kappas foram retirados das conclusões. Essas falhas motivaram fechamento por hash, validação de contrato e snapshots explícitos na Campanha 4.

5.5 O que as campanhas históricas acrescentam

As três campanhas convergem em um ponto: integridade estrutural não basta para estabelecer concordância comportamental. Elas também mostram que cobertura depende de amostragem e representação, que níveis de juiz mudam com o modelo avaliador e que uma bancada integrada não localiza a origem da divergência. A Campanha 4 não é uma repetição dessas estimativas. Ela responde à limitação de atribuição ao revelar que o 3a emite placeholders genéricos, que o 3b recupera apenas parte do catálogo e que o extrator elimina identidade e conteúdo. Esses mecanismos são compatíveis com a baixa conformidade anterior, mas o desenho não prova que expliquem causalmente todo o resultado da Campanha 3.

6 Síntese entre campanhas

Tabela 14: Triangulação sem combinação estatística entre fases.

Camada	Evidência das Campanhas 1–3	Evidência da Campanha 4	Síntese permitida
Estrutura	zero violações duras nos grafos observados; 62 sinais moles em C3; mutantes detectados	GraphForge idêntico em 34/34 pares	montador previsível para invariantes e casos testados; não prova qualidade
Concordância	baixa conformidade comportamental integrada e cobertura parcial	fragilidades específicas em 3a e 3b	limitações surgem antes e depois da montagem, sem atribuição causal entre campanhas

Camada	Evidência das Campanhas 1–3	Evidência da Campanha 4	Síntese permitida
Quantidade	mais candidatos elevaram cobertura, com ganhos decrescentes e mais sinais moles	212 itens de 3a truncados antes do grafo	gerar mais itens não garante preservá-los ou utilizá-los melhor
Dicas	conteúdo de 3c não foi medido adequadamente	3c diretamente medido no braço de capacidade; omitido operacionalmente	C4 fecha uma lacuna histórica, mas não avalia efeito em estudantes
Juízes	níveis absolutos variaram por modelo; painel C3 não recebeu excedentes	efeito teto, GLM parcial e mutações 6/8 sensíveis	LLMs servem para triagem auxiliar, não validação pedagógica
Referência	cobertura de um catálogo finito	recall e transporte por agente contra o mesmo corpus	BRD permite concordância com STI existente, não verdade universal

O conjunto das quatro campanhas fortalece a *decomposição* do problema, não uma alegação promocional. A evidência estrutural é forte dentro das regras implementadas; a concordância de conteúdo é parcial; o transporte acrescenta perdas; e a régua pedagógica externa permanece ausente. Essa leitura explica por que uma versão completa precisa preservar a história metodológica sem misturar seus números com o estudo principal.

7 Discussão

7.1 Que validade do grafo o instrumento sustenta

A resposta à pergunta central é deliberadamente estratificada. A evidência alcançada sustenta validade técnica e diagnóstica de componentes: verifica (i) se o código e as configurações da rota legada foram usados; (ii) se cada agente respeita schema e identidade de problema; (iii) quanto do conteúdo concreto coincide com uma referência CTAT; (iv) propriedades intrínsecas mensuráveis das dicas; (v) onde campos são descartados; e (vi) se o GraphForge é determinístico. A evidência ainda não alcançada inclui completude semântica universal, equivalência a especialistas, adequação pedagógica do tutor e eficácia com estudantes.

Os resultados também mostram por que essa separação é necessária. O 3a pode produzir relações genéricas que juízes LLM consideram coerentes, mas obter recall concreto zero porque não instancia valores. O 3b pode produzir erros plausíveis novos e, simultaneamente, recuperar pouco do catálogo de referência. O 3c pode sempre emitir quatro níveis e, ainda assim, apresentar média macro de vazamento literal próxima de uma em cada cinco dicas. Finalmente, um conteúdo de boa qualidade pode não chegar ao grafo se o extrator o truncar ou eliminar campos essenciais. Logo, o instrumento valida em camadas o processo e os artefatos intermediários que formam o grafo; ele não valida integralmente o tutor final.

À pergunta “os agentes produzem bons grafos?”, a resposta depende da camada analisada. Em sentido restrito de engenharia, o fluxo produz saídas geralmente bem formadas e uma montagem reproduzível. No sentido central para um tutor *example-tracing* — representar concretamente a resolução, localizar erros esperados e oferecer intervenções seguras e rastreáveis — a evidência é desfavorável ou insuficiente. Isso não significa que todo conteúdo excedente seja inválido: o 3b pode gerar misconceptions plausíveis ausentes do BRD, e os templates do 3a podem representar relações abstratamente corretas. Significa que o sistema auditado não demonstrou selecionar, localizar e transportar esse conteúdo de modo confiável sem supervisão.

Seu papel empiricamente justificável é o de **gerador assistivo de candidatos**, não o de autor autônomo do tutor final.

7.2 BRDs como referência, não verdade universal

É metodologicamente legítimo comparar as saídas aos BRDs quando o objetivo é reproduzir os STIs existentes, especialmente porque enunciado, interface e resposta pertencem ao mesmo conjunto de exercícios. O erro seria transformar essa comparação em julgamento binário de validade pedagógica. O recall do 3b mede cobertura do inventário do autor; ele não condena automaticamente excedentes. Da mesma forma, o traço correto concreto mede executabilidade e concordância, não todas as estratégias possíveis.

Para transformar o corpus em benchmark público mais forte, ainda são necessários: documentação de autoria e licença; pelo menos dois novos especialistas cegos por exercício; manual de anotação; adjudicação; estimativa de banda humano–humano; e separação entre conjunto de desenvolvimento e teste. Outros STIs podem ser adicionados depois, desde que cada um preserve sua referência, interface e contrato e seja analisado como cluster, sem pseudoreplicar passos internos.

7.3 Implicações para a EducaOFF

Os dados apontam correções concretas para o fluxo legado:

1. **Escolher explicitamente entre traço genérico e concreto no 3a.** Se o objetivo é execução, o contrato deve exigir valores instanciados e validá-los antes da montagem. Se o objetivo é template reutilizável, deve existir um instanciador determinístico testado; comparar placeholders diretamente ao BRD deixa de ser o desfecho adequado.
2. **Adicionar e preservar identidade CTAT no fluxo do 3b.** O contrato do 3b deve passar a emitir estado e tripla Selection–Action–Input. O extrator deve preservar `problemId`, localização, pergunta diagnóstica e remediação, campos já presentes na saída bruta. Sem ambos os ajustes, concordância state/SAI não pode ser medida e o tutor perde explicabilidade.
3. **Tratar dicas como estrutura, não apenas texto.** Nível e tipo precisam ser preservados; um detector determinístico de vazamento deve bloquear resposta literal antes da publicação. A política que pula o 3c deve ser uma decisão explícita e observável, não uma suposição sobre sua contribuição.
4. **Eliminar truncamento global multi-problema.** Limites devem ser aplicados dentro de cada `problemId`, com contadores e motivos de descarte. A origem de cada item precisa acompanhar configuração, nó e manifesto.
5. **Manter gates separados.** Validade de schema, concordância com referência, preservação de campos, integridade estrutural e revisão pedagógica humana não devem ser fundidas em um único “quality score”.

Essas mudanças alterariam o sistema avaliado e, portanto, exigiriam nova versão e replicação. Os resultados atuais não devem ser substituídos por uma reexecução corretiva; eles funcionam como baseline auditável.

7.4 O painel LLM não resgata as limitações determinísticas

O efeito teto do painel contrasta com falhas objetivas: recall concreto baixo, perda de identidade e vazamento literal. Parte do teto decorre deliberadamente das rubricas: o 3a não era penalizado

por generalidade e o 3b podia receber nota alta por erro plausível ausente do BRD. Ainda assim, falhar em duas dimensões de mutação mostra que os juízes não são um árbitro externo suficiente. O painel é útil para triagem textual e identificação de degradações grosseiras; seus níveis absolutos não devem ser usados para aprovar publicação automática.

8 Ameaças à validade

8.1 Construto e comparabilidade entre campanhas

As quatro campanhas medem construtos diferentes. Cobertura por valor, reconhecimento comportamental integrado, recall do agente 3b e retenção no extrator não são versões intercambiáveis de uma mesma variável. $R_{3a,concreto}$ penaliza placeholders exigidos pelo próprio prompt; mede instanciação concreta, não correção abstrata. $R_{3b,valor}$ por valor ignora estado CTAT porque o contrato não o emite. As métricas do 3c capturam completude formal, distinção e vazamento literal, não efeito das dicas sobre aprendizagem. Preservação de campo não equivale a qualidade pedagógica, e determinismo não equivale a correção.

A reutilização do mesmo corpus não cria 96 exercícios independentes. Campanhas, modelos e réplicas são observações repetidas sobre 24 exercícios de um mesmo template. Fonte, idioma, KCs, passos de solução, preparação do adaptador e executor mudaram entre fases. Por isso, o manuscrito não agrega estimativas, não testa tendência e não atribui diferenças numéricas a evolução do sistema.

8.2 Validade interna das Campanhas 1–3

As duas primeiras campanhas usaram uma entrada derivada do mesmo BRD da referência. As guardas de vazamento demonstram separação de campos proibidos, não independência semântica completa. A Campanha 3 removeu essa dependência, mas o executor implementava somente um subconjunto de *example tracing*. Seus relatórios não preservaram decisões item a item; parte do numerador de R_{bug} foi reconstruída de agregados e denominadores conhecidos. Os braços DOM e screenshot tinham correspondência incorreta, e o painel C3 recebeu zero excedente do sistema. Esses braços e julgamentos são preservados, porém excluídos das alegações.

As Campanhas 1–3 executaram uma bancada adaptada: cliente LLM, preparação da configuração e contexto efetivo não eram idênticos ao runtime implantado. O GraphForge central era compartilhado, mas isso não certifica o fluxo inteiro. A retenção incompleta impede separar retrospectivamente agente, adaptador e montador.

8.3 Validade interna da Campanha 4

Um estado falhou por JSON 3b malformatado. A política ITT evita selecionar apenas sucessos, mas a atomicidade atribui ausência ao 3a apesar de sua resposta ter sido aceita pelo parser. Assim, o ITT mede efetividade end-to-end do estado, não capacidade isolada do 3a. O braço do 3c foi forçado para capacidade; ele não representa conteúdo efetivamente transportado pela política operacional observada.

As chamadas ocorreram em cópia local descartável da imagem, e não na VPS ativa. A ontologia foi substituída por um snapshot local somente leitura. O gate inicial omitiu o quarto KC das fixtures; uma atestação operacional pós-hoc do pesquisador registrou que o 404 local e o vetor vazio da implantação produzem o mesmo valor efetivo no cliente de produção. Como as respostas HTTP brutas da VPS não foram preservadas, terceiros não podem reproduzir externamente essa verificação. A imagem e os hashes sustentam correspondência ao estado implantado auditado em 15 de julho de 2026, mas a imagem não possui rótulo VCS; o commit

associado é corroborado, não provado. O erratum v2.1 ocorreu após os resultados e corrigiu quatro taxas descritivas de campo do 3a, sem alterar contagens nem estimandos principais.

8.4 Validade estatística

A unidade principal é o exercício, com réplicas agregadas antes da média macro. Quatro exercícios compartilham uma chamada, de modo que erros intra-batch podem ser correlacionados. O bootstrap registrado por exercício não modela essa dependência; a sensibilidade por batch amplia alguns intervalos, mas possui somente seis clusters e também é instável. Intervalos bootstrap descrevem o corpus e o mecanismo de reamostragem adotado, não uma população bem definida de STIs ou autores.

Algumas métricas têm marginais degeneradas. No painel final, dez dimensões receberam apenas categoria 4 e não admitem alfa ou kappa corrigido pelo acaso. Nas cinco dimensões variáveis, os coeficientes foram fracos. Concordância bruta sob efeito teto não deve ser chamada de confiabilidade forte. Os testes históricos usam famílias e correções diferentes da Campanha 4 e não são reutilizados para inferência conjunta.

8.5 Referência e validade externa

Há um BRD por exercício e não existe banda humano–humano. Autoria, credencial, instituição, data e licença não estão suficientemente documentadas. O BRD pode omitir soluções, errors e remediações legítimas; excedentes não foram classificados por humanos. A referência é adequada para perguntar se o sistema reproduz um STI existente, mas insuficiente para declarar validade pedagógica universal.

O estudo cobre frações na reta numérica, praticamente um template, 24 exercícios, uma rota legada e um modelo gerador principal. Não cobre agentes posteriores, adaptação final ao aluno, a rota *tool-first*, outros domínios, níveis escolares, interfaces ou autores. Três réplicas quantificam alguma variação estocástica, mas não diversidade de modelos. Transformar o corpus em benchmark requer múltiplos STIs, templates, autores documentados e condições de licença compatíveis.

8.6 Modelos comerciais, painel e conflito de interesses

A composição dos juízes da Campanha 4 mudou pós-registro por custo, embora a execução final tenha reiniciado universalmente. O GLM perdeu 29,3% das unidades; Qwen e DeepSeek forneceram os dois julgamentos mínimos. O efeito teto e as duas dimensões que falharam à mutação reduzem validade discriminante. Não houve calibração humana. Todos os modelos foram acessados por um agregador, e identificadores comerciais podem apontar para pesos atualizados sob o mesmo nome; hashes do código não congelam os pesos remotos.

O autor é responsável pela plataforma avaliada. Retenção de resultados adversos, arquivos brutos, hashes, lançamentos excluídos, testes e alegações limitadas mitigam, mas não eliminam, risco de viés. Replicação por equipe externa e anotação por especialistas independentes continuam necessárias.

9 Conclusão

À pergunta prática “os grafos são bem gerados?”, a resposta sustentada pelos critérios observados é: **os dados não sustentam classificá-los como artefatos completos e prontos para uso autônomo.** A qualidade é heterogênea. A forma das saídas é geralmente processável e o GraphForge mostrou montagem estruturalmente reproduzível, mas componentes necessários ao

comportamento pedagógico permanecem incompletos, pouco concordantes com a referência ou não rastreáveis. Esse juízo se restringe ao domínio, ao modelo, à rota legada e à versão auditados; ele não declara que todos os conteúdos gerados sejam errados nem estabelece invalidade pedagógica universal.

O estudo não produz um selo binário de “grafo correto”; ele estabelece uma validação técnica parcial e localizada do processo de autoria comportamental. A Campanha 4 demonstra que é possível avaliar diretamente os componentes propostos pelos agentes da rota legada da EducaOFF sem confundir geração, transporte e montagem. O 3a emite um contrato genérico incompatível com execução concreta direta; o 3b cobre aproximadamente um quinto dos valores errados registrados, seu contrato não emite estado/SAI e o extrator descarta identidade de problema e localização; o 3c completa quatro níveis, mas as médias macro por exercício foram cerca de 38% para validade estrita entre cadeias emitidas e 23% para vazamento literal entre dicas emitidas. O transporte elimina 78% dos itens do 3a, parte dos registros do 3b e metadados essenciais das dicas; a política operacional não usa o 3c nos estados observados. Assim, as fragilidades estão em componentes necessários para um grafo utilizável — instanciação, cobertura e localização de ramos, scaffold e rastreabilidade. Determinismo não compensa perda de informação nem valida o conteúdo.

As Campanhas 1–3 fornecem o histórico que levou a essa decomposição: cobertura parcial na referência, sensibilidade à amostragem, baixa conformidade comportamental do subsistema integrado e limitações de painéis automatizados. Elas não são réplicas da Campanha 4 nem permitem calcular deltas entre versões. Em conjunto, os estudos mostram que quantidade gerada, qualidade intrínseca, retenção e integridade estrutural precisam permanecer como gates separados.

Os BRDs são referências apropriadas para um benchmark de concordância com STIs existentes, desde que não sejam tratados como verdade pedagógica universal. O painel de LLMs fornece somente evidência auxiliar e mostrou efeito teto e falhas de calibração. Portanto, o instrumento é defensável para diagnóstico técnico, comparação futura de versões e construção de benchmark multi-STI; não sustenta equivalência a especialistas, aprovação autônoma de conteúdo ou eficácia educacional. No estado atual, o uso tecnicamente defensável dos artefatos exige instanciação determinística do caminho correto, validação por problema, filtros contra vazamento, preservação integral da proveniência, gates automáticos separados e aprovação humana antes da implantação. A próxima etapa cientificamente necessária é combinar o protocolo já automatizado com múltiplos especialistas independentes, proveniência regularizada e domínios adicionais.

Disponibilidade de dados, código e rastreabilidade

O pacote de replicação está organizado em github.com/Joaoqueiroz-silva/sti-graph-validation. A análise determinística principal é `resultados/campanha4-2026-07-15/campaign4-final-analysis-v2.1.json`; o painel final está em `resultados/campanha4-2026-07-15/judge-panel-v5/`. A Tabela 15 fornece hashes críticos. Os BRDs já constam do histórico remoto, mas isso não demonstra autorização: até regularizar autoria e licença, não se declara o corpus como abertamente licenciado, e uma release arquivística v6 deve excluir o corpus e seu histórico ou permanecer privada. Hashes e métricas não conferem permissão de redistribuição.

As cópias públicas dos resultados C4 removem somente saldo, uso acumulado, rótulo e sufixo de credencial da conta OpenRouter. Saídas científicas, tokens, custos por chamada, modelos e falhas foram preservados. O manifesto `protocol/publication-redactions-v6.0.json` liga cada hash privado original ao hash público correspondente sem expor os metadados de conta.

O depósito permite recalcular offline métricas, sensibilidades e tabelas a partir dos resultados retidos. Ele ainda não permite a terceiros repetir integralmente a coleta da Campanha 4: a imagem é identificada por digest local, mas não está publicada em registry nem como arquivo OCI, e o commit candidato não substitui a imagem sem rótulo VCS. Uma replicação externa da geração exige publicar, quando juridicamente possível, a imagem ou snapshot fonte reproduzível e substituir os lançadores históricos dependentes do ambiente privado.

Tabela 15: Hashes SHA-256 dos artefatos centrais.

Artefato	SHA-256
Imagem de produção	15b29e8063099d40fc62899da2795db6e97d3e252e486315428a0690bb9abf5b
Plano de execução	77de38a7bfe25f6dcfb34527081e9b5f73de4b1316ebd414f6129677aae3a074
Código de métricas v2.1	a228f60e8838055c69e90e91e671ca0653339c8c3af5e2b6b582e98eedec9be2
Atestação ontológica v2 pós-hoc	00dc41394488d56299a23e39fa14dccdd9dbfc369aab372b0651d80ef3f19394
Análise determinística final	dae582fd1179b20b7b42472bcb84bb6075b2fce7d813a61d2e0f6693f0df9b17
Sensibilidade por batch	1ae514350fc2afc53d7e7c65783eea207f713a4f443a32aec6b62c1c5c992fe4
Manifesto de conclusão observado	3568b8dc690d916a7857896efc753845dde18ef394e7144062e650fc73fc59c0
Manifesto de redação pública	7445c9dd0f3f511be7ef8bd53ca17cd9ce7488fddc6eec719384d13807146aba
Runner do painel v5	eca324bb990170baf771e6331b752c169566f0ce6cd2014c42c85fda75180b86
Resultados do painel v5	29a615580973a9d5dce1634b22d53cece960f0e8d3e3f9cf657fb6ebdb6361fb
Análise original do painel v5	5cf5b5ddd74d4a6376836b35da19e6bf90ccce3410e2c58102df76a51dd4c5b2
Análise corrigida v5.1	f32583a08d20ececda98d1e7ff0d117b7d6e0402d7db55b082ad373146addd6c
Journal do painel v5	38499f63dc3cf7ddd8e45d3793e5cc94a86059942f6fc418232f1c17ba4bc56e

Declarações

Conflito de interesses. O autor é fundador da EducaOFF, plataforma cujo subsistema foi avaliado.

Financiamento. Não foi informada fonte de financiamento externo nesta versão técnica. A declaração deve ser confirmada pelo autor antes de submissão editorial.

Ética. O estudo não envolveu participantes humanos, dados pessoais ou dados de estudantes. Uma fase futura com especialistas ou estudantes requer avaliação ética conforme a instituição e a jurisdição aplicáveis.

Uso de inteligência artificial. Modelos de linguagem são objeto do experimento e também apoiaram engenharia, auditoria e redação. Decisões metodológicas, interpretação e responsabilidade pelo texto permanecem com o autor. Julgamentos automatizados não substi-




Figura 5: Síntese histórica da Campanha 1 no plano cobertura–plausibilidade. A ordenada é uma avaliação de juiz único e não uma probabilidade de validade pedagógica; a figura documenta o instrumento v1 e não representa os desfechos da Campanha 4.

tuíram revisão editorial nem anotação humana.

Proveniência e licença. Os arquivos BRD e a interface pertencem a um conjunto CTAT recebido para pesquisa. O pacote disponível não documenta suficientemente autor original, instituição, data de criação e licença de redistribuição. Esses elementos precisam ser regularizados antes de publicação aberta do corpus como benchmark.

A Detalhamento histórico das Campanhas 1 e 2

A.1 Matriz de concordância da Campanha 1

A matriz histórica foi construída sobre a união dos catálogos, após agregação das três réplicas. Ela evidencia a limitação estrutural que motivou a bateria posterior: a célula “surpresa–surpresa” é impossível, pois um item ausente dos dois catálogos não entra na união.

Tabela 16: Matriz agregada de classificação na Campanha 1; linhas: referência, colunas: sistema.

	correto	erro previsto	surpresa
correto	72	0	0
erro previsto	0	91	158
surpresa	0	116	0 por construção

A concordância no acerto é total, mas apenas 91 de 249 registros de erro da referência aparecem também no sistema, enquanto 116 itens são exclusivos do sistema. Esse arranjo explica por que concordância bruta, cobertura e kappa respondem a perguntas diferentes. O kappa próximo de zero não deve ser reinterpretado como consequência benigna da ausência de verdadeiros negativos; a Campanha 3 introduziu 261 sondas de domínio e também encontrou concordância comportamental baixa.

A.2 Cobertura por tipo e efeito de múltiplas chamadas

Tabela 17: Cobertura histórica por tipo de erro no baseline da Campanha 2.

Tipo na referência	N	Uma execução	União de três
Fração incorreta, por exemplo 2/4 quando a resposta é 3/4	30	39%	73%
Numerador isolado, por exemplo “3”	24	50%	79%
Denominador isolado, por exemplo “4”	24	14%	33%
Outros inteiros	5	73%	80%
Total	83	37%	64%

O ganho da união mostra diversidade entre chamadas, mas não estabelece que todos os itens adicionais sejam utilizáveis. Na Campanha 4 aparece uma segunda limitação: mesmo quando itens são gerados, o extrator pode removê-los antes do grafo. A decisão de repetir chamadas precisa, portanto, considerar quatro custos simultaneamente: API, revisão pedagógica, complexidade estrutural e taxa efetiva de retenção.

A.3 Testes pareados selecionados da Campanha 2

As diferenças foram calculadas dentro do exercício e avaliadas por permutação exata com ajuste de Holm. A tabela preserva os resultados que orientaram a interpretação; ela não transforma ausência de significância em equivalência.

Tabela 18: Comparações históricas contra o Gemini na Campanha 2.

Comparação	Δ médio [IC95%]	p exato	p-Holm	Resultado
GLM-5.2, completude conceitual	+0,047 [−0,048; 0,143]	0,381	0,988	não detectado
DeepSeek, completude conceitual	+0,003 [−0,089; 0,091]	0,957	0,988	não detectado
Claude Sonnet 5, completude conceitual	+0,047 [−0,038; 0,142]	0,329	0,988	não detectado
DeepSeek, completude de passos	−0,031 [−0,047; −0,015]	0,003	0,035	diferença detectada
DeepSeek, F1 estrutural	−0,056 [−0,092; −0,023]	0,005	0,052	limítrofe após Holm
Claude Sonnet 5, inclusão de traços	+0,059 [0,017; 0,101]	0,011	0,114	não após Holm

B Método e resultados completos da Campanha 3

B.1 Bateria e estimandos

O protocolo v2 gerou a entrada sem abrir o conteúdo comportamental do BRD. A bateria, por outro lado, não era integralmente independente da referência: 375 de 636 itens derivavam dela, e 261 eram sondas construídas do gabarito.

Tabela 19: Composição da bateria comportamental da Campanha 3.

Família	Origem e função	Itens
A — referência	24 traços corretos, 192 ações buggy e 24 pedidos de dica	240
B — mutações	traços perturbados derivados da referência	135
C — sondas	itens de domínio oriundos do gabarito; verdadeiros negativos	261
Total	24 a 28 itens por exercício	636

Para cada ação buggy, R_{bug} verifica se o executor aceita a ação como erro previsto no estado correspondente. Para cada caminho correto, R_{ok} exige aceitação integral e chegada ao objetivo. A sensibilidade $R_{\text{bug,anchor}}$ remove 42 ações mecânicas que não puderam ser ancoradas; $r_{\text{ok,completed}}$ relaxa a igualdade de caminho e exige apenas conclusão. A cobertura por valor ignora estado e ordem e, por isso, é secundária.

B.2 Nove condições

Tabela 20: Desfechos e cobertura nas nove condições da Campanha 3.

Condição	R_{bug} [IC95%]	R_{ok}	Cobertura [IC95%]	Sinal mole
Baseline Gemini	0,054 [0,016; 0,095]	0	0,243 [0,163; 0,324]	0/72
GLM-5.2	0,040 [0,016; 0,068]	0	0,178 [0,122; 0,236]	0/72
DeepSeek V4 Pro	0,023 [0,010; 0,036]	0	0,199 [0,143; 0,260]	0/72
Catálogo interno	0,021 [0,005; 0,040]	0	0,215 [0,152; 0,282]	0/72
Limite de seis candidatos	0,078 [0,028; 0,134]	0	0,419 [0,342; 0,495]	61/72
Saturação textual	0,042 [0,010; 0,082]	0	0,238 [0,171; 0,307]	0/72
DOM inválido para inferência	0,028 [0,005; 0,056]	0	0,207 [0,134; 0,279]	0/72
Screenshot inválido para inferência	0,023 [0,009; 0,036]	0	0,251 [0,180; 0,324]	0/72
Chamada única	0,010 [0; 0,024]	0	0,203 [0,147; 0,264]	1/72

Os braços DOM e screenshot permanecem na tabela para preservar a trilha, mas não recebem interpretação causal. O resultado do limite de seis candidatos demonstra aumento de cobertura por valor; não demonstra melhora comportamental e coincide com maior frequência de alerta estrutural.

B.3 Sensibilidades da Campanha 3

Tabela 21: Sensibilidades exploratórias da Campanha 3.

Condição	$R_{\text{bug,anchor}}$ [IC95%]	$r_{\text{ok,completed}}$ [IC95%]
Baseline	0,065 [0,020; 0,113]	0,069 [0; 0,167]
GLM-5.2	0,048 [0,019; 0,080]	0,042 [0; 0,111]
DeepSeek	0,027 [0,013; 0,044]	0,097 [0,042; 0,167]
Catálogo interno	0,025 [0,006; 0,049]	0,097 [0; 0,222]
Limite de seis candidatos	0,094 [0,037; 0,157]	0,125 [0,042; 0,236]
Saturação	0,050 [0,014; 0,096]	0,083 [0; 0,194]
DOM, não interpretável	0,033 [0,007; 0,066]	0,292 [0,125; 0,472]
Screenshot, não interpretável	0,030 [0,012; 0,049]	0,014 [0; 0,042]
Chamada única	0,014 [0; 0,032]	0 [0; 0]

Os relatórios históricos não retiveram o veredito de cada ação. O numerador de R_{bug} foi reconstruído a partir da taxa ancorável e do denominador conhecido, com tolerância de arredondamento e teste de regressão. Outros matchers não podem ser recomputados item a item sem nova execução. Essa limitação é uma razão adicional para manter a Campanha 3 como evidência histórica secundária.




Figura 6: Exemplos conceituais de violações estruturais procuradas pelo verificador. A ausência desses defeitos não implica conteúdo pedagogicamente correto.

C Análises invalidadas e incidentes preservados

1. **Envelope v1 derivado do BRD.** A entrada das Campanhas 1–2 e a referência vinham do mesmo arquivo. Testes impediam campos proibidos, mas não demonstravam independência semântica.
2. **Braço DOM.** A representação compartilhada continha um enunciado veterinário alheio aos exercícios. Seus contrastes não medem efeito de DOM válido.
3. **Braço screenshot.** A imagem do exercício 00bubble foi usada nos 24 exercícios. Seus resultados não medem efeito visual corretamente pareado.
4. **Painel da Campanha 3.** O coletor esperava **extras**, enquanto os relatórios gravavam **extra**. Os 179 itens julgados incluíam 83 itens da referência e 96 controles, mas zero excedente do sistema. Os kappas não apoiam alegações sobre saídas dos agentes.
5. **Denominador de R_{bug} .** A implementação inicial excluiu 42 ações mecânicas; a análise corrigida restaura as 192 ações planejadas e mantém 150 ancoráveis como sensibilidade.
6. **Painéis técnicos da Campanha 4.** Lançamentos v1, v2 e v4 foram excluídos integralmente por incompatibilidades de schema, gramática e mudança de composição. Nenhum score foi reaproveitado no painel final.
7. **Concordância degenerada.** Dez dimensões constantes do painel final eram exibidas como alfa/kappa 1. A errata v5.1 as marca como não estimáveis; as notas brutas permanecem inalteradas.

Registrar esses incidentes não enfraquece a rastreabilidade; impede que correções técnicas sejam confundidas com seleção favorável de resultados. Nenhum resultado invalidado é usado na conclusão consolidada.

D Engenharia e limites do GraphForge

Tabela 22: Camadas de evidência estrutural do GraphForge.

Ensaio	Resultado	Alegação permitida
Testes de propriedades	10.000 configurações aleatórias sem violação dura implementada	robustez observada dentro da taxonomia e do gerador de casos
Mutation testing	260/260 mutantes detectados em dez classes; bases intactas sem sinal espúrio	sensibilidade e especificidade para as mutações cobertas
Campanha 3	0/648 violações duras; 62/648 sinais moles	conformidade estrutural dura nos grafos observados; alertas de complexidade persistem
Campanha 4	34/34 pares de reexecução idênticos	determinismo observado para configurações operacional e de capacidade
Transporte C4	perdas antes e depois da configuração	montador não pode recuperar campos que não recebe

Determinismo, integridade estrutural e validade pedagógica são propriedades diferentes. O GraphForge pode reproduzir exatamente uma topologia que contém conteúdo incompleto; também pode satisfazer todas as invariantes e ainda organizar uma remediação inadequada. O verificador deve permanecer como gate de engenharia, acompanhado de gates separados de schema, conteúdo, transporte e revisão pedagógica.

E Registro de modelos, funções e custos

Tabela 23: Modelos e custos por campanha; valores históricos aproximados não devem ser somados como cobrança exata.

Fase	Objeto	Gerador(es)	Juiz(es)	Custo declarado
C1	bancada integrada	Gemini 3.5 Flash	GLM-4.5	aprox. US\$ 4
C2	robustez histórica	Gemini 3.5 Flash; GLM-5.2; DeepSeek V4 Pro; Claude Sonnet 5	Mistral Large comum aos braços	aprox. US\$ 30
C3	conformidade e ablações	Gemini; braços GLM e DeepSeek; ablações	painel planejado sem validade sobre excedentes	US\$ 16,72 em 1.970 chamadas
C4 geração	agentes implantados	Gemini 3.5 Flash	não aplicável	US\$ 1,9540
C4 painel final	saídas congeladas	não aplicável	GLM-5.2; Qwen 3.7 Plus; DeepSeek V4 Pro	US\$ 1,2432 conservador
C4 lança- mentos excluí- dos	testes técnicos	não aplicável	composições técnicas anteriores	US\$ 2,2211 conhecido, incompleto

Os custos aproximados das Campanhas 1 e 2 provêm da narrativa operacional e não possuem journal de chamadas suficiente para reconciliação financeira independente; são mantidos somente como ordem de grandeza. O custo da Campanha 3 reconcilia 1.970 registros e inclui dois erros primários seguidos de fallback bem-sucedido, portanto houve zero falha *final* de autoria, não zero falha de chamada. Os modelos históricos Claude e GPT não pertencem

ao painel final da Campanha 4. Claude aparece apenas como gerador de um braço da Campanha 2 e em lançamento técnico excluído; GPT aparece somente em planejamento e lançamento excluído. A mudança do painel não altera as saídas Gemini, as métricas determinísticas ou o GraphForge; altera apenas a evidência subjetiva auxiliar, razão pela qual o painel final é declarado pós-registro.

F Desvios, emendas e decisões pós-registro

O congelamento foi local e baseado em hashes; não corresponde a registro público independente com carimbo de tempo. As emendas são preservadas para que um leitor possa distinguir decisões prospectivas de correções pós-resultado.

Tabela 24: Trilha resumida de emendas da Campanha 4.

Momento	Emenda	Motivo	Efeito analítico
Pré-geração	métricas v2	contrato multi-problema, placeholders e ausência de estado/SAI	estimandos por <code>problemId</code> ; 3b por valor; 3c estrito; transporte por campo
Pós-falha	retomada limitada	JSON 3b malformatado no grupo 5	estado falho não repetido; grupo 6 independente autorizado
Pós-resultado	errata v2.1	vetor incorreto em quatro taxas de campo do 3a	apenas taxas descritivas corrigidas; estimandos e contagens inalterados
Pós-auditoria	sensibilidade por batch	quatro exercícios compartilham cada chamada	ICs descritivos por seis clusters; não substituem análise registrada
Pós-auditoria	cobertura do quarto KC	gate inicial enumerava três de quatro KCs; verificação operacional não reteve respostas HTTP brutas	atestação v2 qualificada como não externamente reproduzível; enriquecimento efetivo vazio e estimandos inalterados
Pré-painel final	schemas v2/v3	incompatibilidade de keywords e gramáticas por unidade	lançamentos parciais excluídos; três schemas estáveis por papel
Pré-painel final	modelos v4/v5	retirada de Claude e GPT por custo	painel final reiniciado com GLM, Qwen e DeepSeek; composição pós-registro declarada
Pós-auditoria	errata de concordância v5.1	categoria única era exibida como alfa/kappa 1	coeficientes degenerados marcados como não estimáveis; escores inalterados

G Checklist para submissão editorial

Antes da submissão a uma revista, quatro itens dependem de informação externa ao experimento automatizado:

1. confirmar nome institucional, afiliação, ORCID e fonte de financiamento do autor;
2. documentar autoria, instituição, data e licença do corpus CTAT;
3. depositar uma versão imutável do repositório em arquivo com DOI e registrar seu hash, incluindo o script de correção de R_{bug} e os derivados históricos da Campanha 3;
4. adequar estilo, extensão, anonimização e declaração de uso de IA às normas da revista escolhida.

Nenhum desses itens autoriza alterar resultados, omitir falhas ou substituir o painel final por lançamentos excluídos.

Referências

- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; KOEDINGER, K. R. A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, v. 19, n. 2, p. 105–154, 2009.
- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; VAN VELSEN, M.; POPESCU, O.; DEMI, S.; RINGENBERG, M.; KOEDINGER, K. R. Example-tracing tutors: intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, v. 26, n. 1, p. 224–269, 2016.
- AMIDEI, J.; PIWEK, P.; WILLIS, A. Rethinking the agreement in human evaluation tasks. In: *Proceedings of COLING 2018*. Santa Fe: Association for Computational Linguistics, 2018.
- BROWN, J. S.; BURTON, R. R. Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, v. 2, n. 2, p. 155–192, 1978.
- EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.
- HOSKING, T.; BLUNSOM, P.; BARTOLO, M. Human feedback is not gold standard. In: *International Conference on Learning Representations*. 2024.
- KRIPPENDORFF, K. *Content Analysis: an introduction to its methodology*. 4. ed. Thousand Oaks: SAGE, 2018.
- LAKENS, D. Equivalence tests: a practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, v. 8, n. 4, p. 355–362, 2017.
- LAKENS, D.; SCHEEL, A. M.; ISAGER, P. M. Equivalence testing for psychological research: a tutorial. *Advances in Methods and Practices in Psychological Science*, v. 1, n. 2, p. 259–269, 2018.
- PANICKSSERY, A.; BOWMAN, S. R.; FENG, S. LLM evaluators recognize and favor their own generations. In: *Advances in Neural Information Processing Systems*, v. 37, 2024. DOI: 10.52202/079017-2197.
- SHAVELSON, R. J.; WEBB, N. M. *Generalizability Theory: a primer*. Newbury Park: SAGE, 1991.
- TVERSKY, A. Features of similarity. *Psychological Review*, v. 84, n. 4, p. 327–352, 1977.
- VANLEHN, K. *Mind Bugs: the origins of procedural misconceptions*. Cambridge: MIT Press, 1990.