

Validação de grafos de comportamento gerados por agentes de IA contra grafos de especialistas CTAT: previsão teórica offline e aterramento na interface

João Carlos Queiroz
EducaOFF / STI Unplugged
contato@educaoff.com.br

Artigo completo · estudo exploratório auditável · versão 7.0
Experimento final e previsão teórica offline: 19 de julho de 2026

Resumo

Especialistas humanos constroem à mão, no CTAT, grafos de comportamento: a estrutura que registra, para cada exercício, os passos de resolução, as respostas erradas que um estudante real daria e as remediações associadas. Este artigo pergunta se agentes de IA conseguem construir grafos de comportamento com qualidade comparável à desses grafos de especialista, e valida a configuração final de um pipeline de autoria da bancada de avaliação da EducaOFF sobre o dataset congelado `frac-numberline-6.17` (24 problemas de frações na reta numérica, três réplicas, 72 runs). O mecanismo de autoria é um simulador de alunos: recebendo apenas o envelope A de cada exercício (enunciado, interface e resposta correta), o simulador produz traces de alunos simulados, e o compilador determinístico GraphForge transforma esses traces no grafo de comportamento dos agentes; o grafo completo do especialista permanece escondido como gabarito (envelope B) e entra somente no comparador intocado, com cegamento programático e bootstrap por cluster (10.000 reamostragens, semente 42). A configuração final combina reconstrução determinística da interface renderizada, inventário de fatos da tela, eliciação focada em três causas nomeadas de erro, passos de interface e autochecagem de plausibilidade de formato; o modelo de linguagem é `qwen/qwen3-max`. O desenho inclui uma previsão teórica offline formulada e preservada antes da medição, sem nenhuma chamada de modelo, verificada por reexecução independente (*back-out* exato dos 72 runs, erro 0,000) e com F1 conceitual previsto de 0,609; após o banimento de três parâmetros que vazariam o gabarito (`mfNum`, `badCount` e `doubleDiv`), a reexecução dentro do pacote computa 69/75 deriváveis estritas (92%) e um teto honesto de completude de 0,992, não 1,000. A completude conceitual de misconceptions medida foi 0,913 (IC95% por cluster 0,861–0,962), com F1 conceitual 0,626 (0,608–0,643), completude estrita 0,618 (0,601–0,632) e precisão 0,548 (0,527–0,569); o F1 medido ficou 0,017 acima da previsão pontual. Em termos do objeto: de cada dez rotas de erro que o especialista desenhou no grafo dele, os agentes desenharam cerca de nove nas deles. A configuração de partida do desenvolvimento provém da campanha de referência anterior (2026-07-02), que registrou completude conceitual de 0,376. O kappa de Cohen foi abandonado como métrica funcional por paradoxo de prevalência agravado por marginais endógenas do desenho da bateria; reportam-se concordância bruta, 0,452 (0,427–0,477), e PABAK, 0,178 (0,140–0,216). O valor 0,913 não é lido como quase perfeito: o resíduo tem causas nomeadas, a exploração incompleta de fatos já disponíveis no prompt e um typo legado deliberadamente deixado descoberto por decisão de integridade (caso `17pencils`). A configuração final mudou prompt e modelo simultaneamente em relação à configuração anterior (confounder declarado), o protocolo foi documentado retrospectivamente e a referência é um grafo de autor único por exercício. Os resultados sustentam concordância dos grafos dos agentes com essa referência e previsibilidade determinística do desfecho; não sustentam equivalência a especialistas, transferência ao runtime implantado ou eficácia educacional.

Palavras-chave: grafos de comportamento; agentes de IA; sistemas tutores inteligentes; misconceptions; CTAT; simulação de estudantes; previsão teórica; validação.

Abstract

Human experts hand-build behavior graphs in CTAT: the structure that records, for each exercise, the solution steps, the wrong answers a real student would give, and the associated remediations. This article asks whether AI agents can build behavior graphs of quality comparable to those expert graphs, and validates the final configuration of an authoring pipeline from EducaOFF’s evaluation bench on the frozen dataset `frac-numberline-6.17` (24 fraction number-line problems, three replications, 72 runs). The authoring mechanism is a student simulator: given only each exercise’s envelope A (statement, interface, and correct answer), the simulator produces traces of simulated students, and the deterministic GraphForge compiler turns those traces into the agents’ behavior graph; the expert’s complete graph remains hidden as the answer key (envelope B) and enters only the untouched comparator, with programmatic blinding and cluster bootstrap (10,000 resamples, seed 42). The final configuration combines deterministic reconstruction of the rendered interface, an on-screen fact inventory, elicitation focused on three named error causes, interface steps, and a format plausibility self-check; the language model is `qwen/qwen3-max`. The design includes an offline theoretical prediction formulated and preserved before measurement, with zero model calls, verified by an independent re-run (exact back-out of all 72 runs, error 0.000) and predicting a conceptual F1 of 0.609; after banning three answer-key-leaking parameters (`mfNum`, `badCount`, and `doubleDiv`), the in-package re-run computes 69/75 strictly derivable misses (92%) and an honest completeness ceiling of 0.992, not 1.000. The measured conceptual misconception completeness was 0.913 (cluster 95% CI 0.861–0.962), with conceptual F1 0.626 (0.608–0.643), strict completeness 0.618 (0.601–0.632), and precision 0.548 (0.527–0.569); the measured F1 was 0.017 above the point prediction. In terms of the object: of every ten error routes the expert drew in the reference graph, the agents drew about nine in theirs. The development starting configuration comes from the previous reference campaign (2026-07-02), which recorded a conceptual completeness of 0.376. Cohen’s kappa was abandoned as a functional metric owing to a prevalence paradox aggravated by the battery’s endogenous marginals; raw agreement, 0.452 (0.427–0.477), and PABAK, 0.178 (0.140–0.216), are reported instead. The value 0.913 is not read as near-perfect: the residual has named causes, namely incomplete exploration of facts already available in the prompt and a legacy typo deliberately left uncovered by an integrity decision (the `17pencils` case). The final configuration changed prompt and model simultaneously with respect to the preceding configuration (declared confounder), the protocol was documented retrospectively, and the reference is a single author’s graph per exercise. The evidence supports concordance of the agents’ graphs with that reference and deterministic predictability of the outcome; it does not support equivalence to experts, transfer to the deployed runtime, or educational effectiveness.

Keywords: behavior graphs; AI agents; intelligent tutoring systems; misconceptions; CTAT; student simulation; theoretical prediction; validation.

1 Introdução

Tutores do paradigma *example-tracing* interpretam as ações do estudante em relação a caminhos previamente autorados, erros esperados e intervenções associadas. No CTAT (Cognitive Tutor Authoring Tools), essa estrutura é registrada em um grafo de comportamento: o artefato que enumera, para cada exercício, os passos de resolução, as respostas erradas que um estudante real daria em cada componente da interface e as remediações associadas (Aleven et al., 2009, 2016).




Figura 1: Anatomia de um grafo de comportamento. O caminho horizontal representa uma resolução correta; o desvio inferior associa uma *misconception* à remediação e ao retorno; o bloco superior representa uma cadeia progressiva de dicas. A figura é conceitual: o grafo do especialista registra, para cada problema, as ações corretas e os valores errados esperados; os agentes avaliados tentam construir, às cegas, um grafo com as mesmas rotas.

A literatura clássica sobre *bugs* procedimentais sustenta que parte dos erros dos estudantes é sistemática e, portanto, passível de modelagem (Brown; Burton, 1978; VanLehn, 1990). Construir o grafo à mão é a parte mais cara da autoria: o autor humano precisa prever, para cada exercício e cada componente de interface, o que um estudante real digitaria ou clicaria de errado, e desenhar cada uma dessas rotas.

A pergunta deste artigo é direta: agentes de IA conseguem construir grafos de comportamento com a qualidade dos grafos que especialistas humanos constroem à mão no CTAT? O objeto de avaliação é sempre o grafo de comportamento gerado pelos agentes. O mecanismo de autoria é declarado desde já e detalhado na Seção 2: um simulador de alunos propõe as *misconceptions* que um estudante real cometeria e as materializa em traces de alunos simulados, e o compilador determinístico GraphForge transforma esses traces no grafo de comportamento dos agentes, com garantias estruturais por construção. O simulador é o meio; o grafo é o fim, e é sobre o grafo que todas as medidas deste artigo incidem.

A mecânica de comparação é a de um exame com gabarito escondido. O `expert.brd` de cada exercício é um grafo de comportamento feito à mão por um especialista CTAT: passos de resolução, respostas erradas previstas e remediações. Desse artefato derivam dois envelopes com papéis opostos. O envelope A contém o que qualquer autor vê antes de autorar: o enunciado, a interface e a resposta correta. O envelope B é o grafo completo do especialista, escondido como gabarito. Os agentes autoram às cegas, somente com o envelope A; a nota compara o grafo deles com o envelope B, que entra apenas no comparador, sob travas programáticas contra vazamento (Subseção 2.2).

Dois compromissos metodológicos completam o desenho e são apresentados no método. O primeiro é a previsão teórica offline: antes da medição final, uma análise determinística dos artefatos, sem nenhuma chamada de modelo, classificou as faltas da configuração anterior quanto à derivabilidade a partir do que o aluno vê na tela, estimou o desfecho esperado e foi preservada como artefato, transformando a intervenção de engenharia em um teste de hipótese (Subseção 3.3). O segundo é o registro de integridade: três parâmetros que vazariam o gabarito foram banidos dos fatos de interface, e o teto honesto de completude passou a ser 0,992, não 1,000 (Subseção 3.4).

O estudo responde a duas perguntas:

QP1. Concordância: em que medida os grafos de comportamento gerados pelos agentes, na

configuração final, reproduzem as rotas de erro registradas nos grafos do especialista CTAT, medida por completude conceitual de misconceptions (métrica primária), F1 conceitual, completude estrita e precisão?

QP2. Previsibilidade: o desfecho pode ser antecipado por análise determinística offline dos artefatos, formulada e preservada antes da medição?

A contribuição é dupla: um resultado empírico (os grafos gerados pelos agentes, aterrados na interface renderizada, reproduziram a grande maioria das rotas de erro que o especialista registrou nos grafos de referência) e uma disciplina metodológica (previsão teórica computada e preservada antes da medição, com registro explícito das recusas de integridade que limitam os tetos reportáveis). O limite da alegação é declarado desde já: concordar com os grafos de um único autor é evidência de alinhamento a uma referência de autoria, não prova de completude pedagógica universal, e nenhuma conclusão se transfere ao tutor servido a estudantes.

2 O pipeline de autoria e a referência de comparação

2.1 Do simulador de alunos ao grafo dos agentes

O objeto de estudo são os grafos de comportamento produzidos pelo pipeline de autoria do shim consolidado de avaliação (`simulate-students.js`, `author-graph.js`, `graphforge.js` e `author-from-ctat.js`). A autoria acontece em três atos: o simulador de alunos recebe o envelope A e propõe as misconceptions que um estudante real cometeria; essas propostas viram traces de alunos simulados, restritos aos componentes da interface; e o compilador determinístico GraphForge transforma os traces no grafo de comportamento dos agentes, garantindo por construção a integridade estrutural (todo passo tem aresta correta, todo desvio retorna ao caminho, o caminho do início ao objetivo existe). O modelo de linguagem preenche conteúdo, nunca estrutura. Esse pipeline não é o runtime implantado da EducaOFF, e nenhuma conclusão deste artigo se aplica ao tutor servido a estudantes. A configuração final avaliada combina cinco componentes:

1. **Reconstrução determinística da interface renderizada** (`interface-reconstruction.js`). O dataset traz a tabela `massproduction.txt` (24 problemas por 22 variáveis) e o template CTAT; juntos, eles determinam a interface efetivamente renderizada de cada problema: valores canônicos das marcas da reta, rótulos inteiros, contagens de intervalos e caixas de resposta. A reconstrução é necessária porque a reta numérica é desenhada por JavaScript em tempo de execução: o HTML bruto do envelope A não contém as marcas, e nenhum inventário do HTML poderia enxergá-las.
2. **Inventário determinístico de fatos da tela** (`interface-inventory.js`), injetado no prompt. O inventário contém somente o que a interface mostra (contagens, rótulos, escalas); nunca contém o gabarito nem respostas erradas prontas: o simulador continua derivando os erros, agora com os números da tela à mão.
3. **Eliciação focada em três causas nomeadas de erro:** inversão de numerador e denominador, marca vizinha da escala e inteiro nu digitado sozinho. Os exemplos do prompt usam denominador 9, ausente do dataset, de modo que nenhum exemplo coincide com uma falta real da referência.
4. **Passos de interface:** o prompt orienta o primeiro gesto do aluno a configurar a escala (o maior inteiro que a reta cobre) e ancora os passos subsequentes nos componentes visíveis.
5. **Autochecagem de plausibilidade de formato**, do tipo corrige e não corta: cada resposta errada candidata é relida contra o formato do componente que a registraria; se o

formato não bate, o valor é corrigido, nunca removido por dúvida. Isso protege a precisão sem criar um teto artificial de completude.

O modelo de linguagem da configuração final é `qwen/qwen3-max`, seguindo recomendação pré-existente do repositório EducaOFF implantado (`tiers.js`, que não integra este pacote de replicação; o espelho verificável no pacote é a função `resolveEvalStudentConfig` de `simulate-students.js`, com a variável de ambiente `STI_EVAL_3B_MODEL` como override explícito). A configuração de desenvolvimento anterior usava outro modelo; a consequência dessa troca simultânea de prompt e modelo é um confounder declarado, discutido na Subseção 3.5.

2.2 Envelopes do especialista CTAT e papel da referência

A referência de comparação são os grafos de comportamento CTAT de um especialista (autor único), um por exercício, dos quais o comparador deriva o envelope B: o catálogo das ações corretas e dos valores errados esperados que o autor registrou no grafo dele. Os agentes permanecem cegos: recebem somente o envelope A (enunciado, resposta esperada e interface compartilhada); o envelope B entra apenas no comparador, e a função `findLeaksInRobotInput` atua como trava programática contra vazamento de dados. O comparador (`metrics.js` e `schema.js`) permaneceu intocado durante todo o desenvolvimento e a medição final: qualquer mudança no comparador invalidaria a leitura.

O papel da referência é deliberadamente limitado. O grafo do especialista registra o inventário de um autor, não a verdade pedagógica universal: um único grafo não enumera necessariamente todas as misconceptions defensáveis, e uma rota a mais no grafo dos agentes não é automaticamente falsa. Por isso, este artigo usa os termos concordância, completude e cobertura da referência, nunca correção universal. Uma demonstração de equivalência a especialistas exigiria múltiplos autores independentes e uma banda de divergência humano-humano, que não existem neste corpus (Shavelson; Webb, 1991).

3 Método

3.1 Desenho, corpus e unidade de análise

O corpus congelado `frac-numberline-6.17` contém 24 exercícios sobre localização de frações na reta numérica, praticamente um único template de interface. Cada exercício foi executado em três réplicas estocásticas, totalizando 72 runs; réplica significa nova chamada com a mesma configuração, e cada run produz um grafo dos agentes comparado ao grafo do especialista daquele exercício. A unidade inferencial é o exercício: primeiro se calcula a média das réplicas dentro do exercício, depois a média macro dos 24 exercícios. Os intervalos de confiança de 95% provêm de bootstrap por cluster com o exercício como unidade, 10.000 reamostragens e semente 42 (Efron; Tibshirani, 1993); eles quantificam estabilidade entre exercícios do corpus, não uma população bem definida de domínios ou autores. Os 72 runs brutos e o resumo com os intervalos estão preservados no pacote (Seção de disponibilidade).

3.2 Por que estas medidas

Cada medida deste artigo responde a uma pergunta específica sobre o grafo dos agentes, e nenhum valor é reportado sem interpretação. Esta subseção declara, para cada medida, o que ela mede, por que foi escolhida e como ler o valor obtido; os nomes entre parênteses são as chaves dos artefatos.

1. **Completude conceitual de misconceptions** (`recallMisconceptionsConceptual`), a métrica primária. Mede a fração das rotas de erro previstas no grafo do especialista que

o grafo dos agentes também prevê. É primária por uma assimetria de custo pedagógico: uma rota de erro ausente no grafo significa que o tutor não reconhece o erro do aluno quando ele acontece, e esse custo é maior que o de prever um erro a mais, que no pior caso adiciona uma rota nunca visitada. A distinção entre estrita e conceitual é pré-registrada: o gabarito contém entradas mecânicas do `.brd`, como fragmentos de digitação, inatingíveis por qualquer previsor de misconceptions; a variante conceitual as exclui por marcação pré-registrada, e a estrita permanece como linha crua auditável, resistente a manipulação porque nenhum critério de exclusão posterior pode inflá-la.

2. **Precisão (precision).** Mede a fração do que os agentes preveem que consta do gabarito. Sua interpretação é declaradamente assimétrica (Tversky, 1977): o protocolo desconta toda previsão extra por rigor, mas um extra pode ser um erro real de aluno que o especialista não anotou no grafo dele, e a validade do excedente exigiria outra fonte de evidência. Por isso a precisão é acompanhamento, não veto: um valor moderado sinaliza margem de melhoria, não invalida a completude.
3. **F1 conceitual (conceptual).** Resume o balanço entre completude e precisão em uma única linha auditável e é o alvo da previsão teórica, por condensar o desfecho em um escalar. Não é a métrica primária porque mistura dois custos assimétricos em um número só.
4. **Bootstrap por cluster, 10.000 reamostragens, semente fixa.** O cluster é o problema porque as três réplicas do mesmo problema são correlacionadas: compartilham enunciado, interface e gabarito, e tratá-las como observações independentes estreitaria o intervalo indevidamente. O bootstrap foi escolhido porque dispensa suposição de normalidade, insustentável com apenas 24 clusters; a semente fixa (42) torna cada intervalo exatamente reproduzível por terceiros.
5. **Como ler o IC de 95%.** O intervalo quantifica a incerteza da amostra de problemas: $[0,861; 0,962]$ para a completude conceitual significa que, reamostrando os 24 problemas do corpus, a estimativa fica nessa faixa em 95% das reamostragens. Ele descreve estabilidade entre exercícios do corpus, não uma população externa.
6. **Concordância funcional e PABAK no lugar do kappa de Cohen.** Para a concordância funcional entre o comportamento previsto e o registrado, reportam-se a concordância bruta com intervalo e o PABAK (*prevalence-adjusted bias-adjusted kappa*; Byrt; Bishop; Carlin, 1993), computado como $(3p_o - 1)/2$ para as três categorias da bateria. O kappa de Cohen foi abandonado como métrica desta bancada porque colapsa aqui por paradoxo de prevalência com marginais endógenas: os itens da bateria são a união das previsões dos próprios avaliadores, a célula surpresa com surpresa é impossível por construção e o acaso esperado fica inflado (Feinstein; Cicchetti, 1990). O PABAK corrige prevalência e viés e é computável dos mesmos dados; o kappa bruto permanece reportado por transparência, sem leitura de confiabilidade corrigida pelo acaso. A investigação determinística completa que motivou o abandono está preservada em `docs/INVESTIGACAO-KAPPA-2026-07-19.md`.
7. **Completude de passos e seu teto determinístico (recallSteps nos artefatos).** Mede a fração dos passos do grafo do especialista que o grafo dos agentes reproduz. Seu teto é determinístico e declarado: parte dos itens do gabarito de passos não é alcançável por nenhum autor externo, como o passo `done` com a constante de runtime, e a recusa de eliciar essa constante mantém o teto previsto em 0,66 (Subseção 3.4); os valores por run permanecem nos artefatos do pacote.
8. **A previsão teórica offline como hipótese falsificável.** Prever o valor antes da medição transforma a intervenção de engenharia em teste de hipótese, com desfecho esperado

Tabela 1: Previsão teórica offline: cobertura derivável e teto computado (artefato `previsao-recheck-pos-banimento.json`).

Quantidade	Valor
Faltas conceituais não mecânicas (configuração anterior)	75
Deriváveis estritas dos fatos admissíveis pós-banimento	69 (92%)
Deriváveis apenas via estados de entrada parcial	3
Não deriváveis (três réplicas de <code>17pencils:5/7</code>)	3
F1 conceitual previsto (previsão preservada, pré-banimento)	0,609
F1 conceitual previsto (reexecução pós-banimento)	0,607
Teto de completude computado (pós-banimento)	0,992

declarado por escrito e preservado. O *back-out* com erro 0,000 valida a calculadora antes de confiar na previsão: significa que a reimplantação da métrica reproduz exatamente os 72 runs medidos da configuração anterior. Só depois dessa validação a previsão pontual (0,609) é confrontada com o valor medido (0,626), na Subseção 4.2.

9. **O teto honesto 0,992 e o resíduo 0,079.** O teto é o máximo que o grafo dos agentes poderia atingir respeitando as recusas de integridade da Subseção 3.4. O resíduo entre teto e medição tem nome: fatos que já estavam disponíveis no prompt e não foram explorados pelo modelo, e o caso `17pencils`, excluído por integridade. O resíduo é caracterizado, não especulativo.

3.3 Previsão teórica offline como parte do desenho

O compromisso metodológico central do estudo é prever antes de medir. O desenho inclui uma previsão teórica formulada antes da medição final, inteiramente offline e sem nenhuma chamada de modelo. A análise partiu das 75 faltas conceituais não mecânicas observadas na configuração de desenvolvimento imediatamente anterior do pipeline (preservada no pacote) e classificou cada falta quanto à derivabilidade: o valor errado que o especialista registrou no grafo dele pode ser derivado, por transformações elementares, do que o aluno vê na tela? A aritmética da classificação foi verificada por reexecução independente, com *back-out* exato dos 72 runs daquela configuração e erro 0,000 em 72/72. A mesma análise produziu dois achados qualitativos que redirecionaram a eliciação: a maior parte das faltas rotuladas como inversão de numerador e denominador era, na verdade, a marca vizinha da escala em forma reduzida (por exemplo, 2/4 lida como 1/2), um erro de leitura de escala e não de conceito; e as faltas da classe *whole number bias* eram determinadas por valores concretos da interface renderizada (marcas, rótulos e contagens da reta) que não existiam na entrada dos agentes.

Dessa análise saiu uma previsão quantitativa preservada antes da medição: se os agentes cobrissem todas as faltas classificadas como deriváveis, o F1 conceitual esperado seria 0,609. A previsão preservada é anterior ao banimento de integridade descrito na Subseção 3.4; por isso, a cobertura foi recomputada dentro do pacote, já sem as fontes banidas, pelo script `analysis/previsao-recheck-pos-banimento.mjs`, que deposita o artefato `previsao-recheck-pos-banimento.json`. A Tabela 1 resume o resultado: 69/75 deriváveis estritas (92%), três faltas deriváveis apenas dos estados de entrada parcial anunciados pela interface, três faltas não deriváveis (as três réplicas de `17pencils:5/7`, consequência aceita do banimento) e teto de completude computado de 0,992. A reexecução pós-banimento reproduz a previsão pontual em 0,607, variação de 0,002 em relação ao artefato preservado.

3.4 Registro de integridade

Três decisões de integridade limitam deliberadamente os números reportáveis deste experimento.

1. **Três parâmetros banidos dos fatos de interface.** `mfNum`, `badCount` e `doubleDiv` são parâmetros da tabela de produção em massa que não são renderizados na interface; materializam-se somente nas arestas buggy do grafo do especialista. Um verificador adversarial independente detectou seu uso como fato de interface e o classificou como vazamento de gabarito; os três foram removidos da reconstrução antes da medição final, e a proibição foi travada por teste automatizado (`__tests__/interface-reconstruction.test.mjs`). A consequência é aceita e quantificada: o tipo legado do exercício `17pencils` (`mfNum` registra 5/7 onde a aritmética do problema produziria 5/12) torna-se estruturalmente indescobrível a partir da tela, e o teto honesto da previsão é 0,992, não 1,000.
2. **Cronologia declarada da previsão.** O banimento ocorreu depois da análise preservada e antes da medição final. A análise preservada, portanto, ainda contém a fonte banida; ela é declarada aqui como pré-banimento em vez de silenciosamente reescrita, e a cobertura válida é a recomputada dentro do pacote (Tabela 1).
3. **Passo done recusado.** A estrutura de oito passos do especialista termina em um passo `done` com a constante de runtime `-1`. Eliciar essa constante elevaria o teto previsto de `recallSteps` de 0,66 para 0,83, mas seria eliciação de trivía de protocolo, não de conhecimento pedagógico; foi recusada.

3.5 Emendas exploratórias declaradas e confounder

O estudo é exploratório por construção, e duas emendas de desenho são declaradas. Primeira: a reconstrução da interface e a eliciação focada foram desenhadas depois de inspecionar as faltas do próprio dataset congelado; é *leakage* de desenho, não de dados. As classes de erro consideradas durante o desenvolvimento foram ancoradas na literatura: *whole number bias* e desenvolvimento do valor numérico de frações (Ni; Zhou, 2005; Stafylidou; Vosniadou, 2004), identificação de frações na reta numérica e ordem e equivalência de racionais (Bright et al., 1988; Behr et al., 1984), sondagem clínica de concepções de frações (Pearn; Stephens, 2004), flexibilidade com o sinal negativo (Vlassis, 2004), modelos implícitos de multiplicação e divisão (Fischbein et al., 1985), padrões procedimentais de erro (Ashlock, 2010) e compreensão de enunciados (Hegarty; Mayer; Monk, 1995). O *leakage* de desenho compromete a leitura confirmatória; não compromete a validade dos fatos usados no prompt, que derivam apenas do que aluno e especialista viam na tela, e as travas programáticas contra vazamento de dados permaneceram ativas o tempo todo.

Segunda: a configuração final mudou prompt e modelo simultaneamente em relação à configuração de desenvolvimento anterior. O efeito conjunto não foi decomposto, e este é o confounder declarado central do estudo: nenhuma alegação atribui o desfecho ao prompt ou ao modelo isoladamente. A troca de modelo seguiu recomendação pré-existente do repositório implantado e é reversível por configuração explícita (`STI_EVAL_3B_MODEL`), o que permite a decomposição em trabalho futuro sob pré-registro.

4 Resultados

4.1 Concordância com a referência

Os 72 runs planejados foram concluídos e comparados; o resumo com bootstrap por cluster está em `resultados/campanha5-2026-07-19/6-final-megabrain/summary.json`. A Tabela 2 apresenta os desfechos; cada número recebe, a seguir, a leitura declarada na Subseção 3.2.

Tabela 2: Desfechos do experimento final: média macro com IC95% de bootstrap por cluster (24 exercícios, 10.000 reamostragens, semente 42).

Desfecho	Estimativa	IC95% por cluster
Compleitude conceitual de misconceptions (primária)	0,913	[0,861; 0,962]
F1 conceitual	0,626	[0,608; 0,643]
Compleitude estrita	0,618	[0,601; 0,632]
Precisão	0,548	[0,527; 0,569]
Concordância funcional bruta	0,452	[0,427; 0,477]
PABAK	0,178	[0,140; 0,216]

Na configuração final, os grafos gerados pelos agentes cobriram 0,913 (IC95% por cluster 0,861–0,962) das misconceptions conceituais que o especialista registrou nos grafos de referência. Em termos do objeto: de cada dez rotas de erro que o especialista desenhou no grafo dele, os agentes desenharam cerca de nove nas deles. O F1 conceitual de 0,626 (0,608–0,643) resume o balanço entre cobrir o gabarito e não desenhar rotas a mais, e é a linha confrontada com a previsão offline na Subseção 4.2. A completude estrita de 0,618 (0,601–0,632) é a linha crua auditável: inclui as entradas mecânicas do gabarito, inatingíveis por qualquer previsor de misconceptions, e por isso é estruturalmente mais baixa que a conceitual. A precisão de 0,548 (0,527–0,569) significa que pouco mais da metade das rotas de erro desenhadas pelos agentes consta do gabarito; pelo protocolo, todo o restante é descontado por rigor, embora parte possa corresponder a erros reais que o especialista não anotou, e por isso a precisão acompanha o resultado sem vetá-lo: a completude subiu sem colapso da precisão, que permanece o eixo com maior margem de melhoria. A configuração de partida do desenvolvimento provém da campanha de referência anterior (2026-07-02), que registrou completude conceitual de 0,376 sob o mesmo desenho de bancada; essa é a única comparação com estado anterior citada neste artigo, e nenhum contraste adicional entre configurações é apresentado.

O valor 0,913 não é lido como quase perfeito. O resíduo tem causas nomeadas na Subseção 4.2: exploração incompleta, pelo modelo, de fatos que já estavam disponíveis no prompt, e um caso estruturalmente descoberto por decisão de integridade (17pencils, Subseção 3.4).

4.2 Previsto versus medido

A previsão offline é lida como hipótese falsificável (Subseção 3.2): o desfecho esperado foi declarado por escrito e preservado antes de qualquer medição paga, e a calculadora da previsão foi validada antes pela reprodução exata dos 72 runs medidos (*back-out* de erro 0,000). O experimento mediu F1 conceitual de 0,626 (IC 0,608–0,643), 0,017 acima da previsão pontual de 0,609. A previsão antecipou corretamente o eixo do desfecho e sua ordem de grandeza, com a medição dentro de dois centésimos do valor previsto. A completude conceitual medida, 0,913 (IC 0,861–0,962), fica 0,079 abaixo do teto computado de 0,992. Esse resíduo é caracterizado, não especulativo: as faltas restantes correspondem majoritariamente a fatos que já estavam no prompt e não foram explorados pelo modelo (fronteira aberta de eliciação), e as três réplicas de 17pencils:5/7 são indescobríveis por construção após o banimento de mfNum. Relaxar as recusas de integridade elevaria os números e invalidaria a leitura.

4.3 Concordância funcional e PABAK

A concordância funcional entre o comportamento previsto e o registrado ficou em concordância funcional bruta de 0,452 (IC 0,427–0,477) e PABAK de 0,178 (0,140–0,216), a transformação linear $(3p_o - 1)/2$ aplicada à concordância bruta e a seu intervalo. A leitura declarada na Subseção 3.2 vale aqui: pelo desenho da bateria, com marginais endógenas, o kappa de Cohen

não é interpretável nesta bancada; o κ medido no experimento final, 0,152, permanece nos artefatos como registro, sem leitura de confiabilidade corrigida pelo acaso.

5 Discussão

5.1 Visibilidade da interface como mecanismo

O resultado central admite um mecanismo verificável no nível do objeto: a maior parte das rotas de erro que o especialista registrou no grafo dele é função de valores da interface renderizada (marcas da reta, rótulos e contagens) que não existem no HTML bruto que os agentes recebiam, porque a reta é desenhada em tempo de execução. Nenhum autor, humano ou artificial, poderia desenhar no grafo o que não estava na entrada. Quando esses fatos foram reconstruídos deterministicamente e a eliciação foi focada nas causas diagnosticadas, a completude conceitual alcançou 0,913 com o comparador congelado, e o desfecho foi antecipado por análise offline. A lacuna histórica de completude dos grafos gerados era, majoritariamente, um problema de visibilidade de fatos, não de capacidade genérica do gerador; a atribuição fina entre prompt e modelo, porém, permanece aberta pelo confounder declarado.

5.2 Prever antes de medir como disciplina

A previsão teórica offline cumpre duas funções. Epistemicamente, ela converte a iteração de engenharia em um teste com desfecho esperado: a previsão pontual de F1 (0,609) foi formulada e preservada antes da medição, e o valor medido (0,626) ficou 0,017 acima. Operacionalmente, ela desloca o esforço de medições pagas para análise determinística de artefatos: a classificação de derivabilidade, o *back-out* exato dos 72 runs e o teto de completude são todos recomputáveis offline por terceiros com o pacote. O registro de integridade é parte inseparável dessa disciplina: um teto de 0,992 obtido após recusar três fontes que vazariam o gabarito é menos impressionante e mais honesto do que um teto de 1,000 obtido com elas.

5.3 O que o resultado não sustenta

Três leituras são explicitamente recusadas. Primeira: o resultado não se transfere ao runtime implantado da EducaOFF; o objeto é o grafo produzido pelo pipeline do shim de avaliação, e a hipótese de que o aterramento na interface renderizada beneficiaria o contrato de produção é hipótese de engenharia a testar sob nova versão congelada. Segunda: concordância de 0,913 com os grafos de um autor não é equivalência a especialistas nem completude pedagógica; o grafo de referência pode omitir misconceptions legítimas, e as rotas excedentes dos agentes não foram julgadas por humanos. Terceira: nada aqui mede efeito sobre aprendizagem; a validação é técnica, contra uma referência de autoria, e a régua pedagógica externa permanece ausente.

6 Limitações

Caráter exploratório e cronologia. O protocolo foi documentado retrospectivamente e as intervenções foram desenhadas após inspeção de faltas do próprio dataset congelado (*leakage* de desenho declarado); nenhuma leitura confirmatória é permitida. Entre a configuração de partida e a final, intervenções intermediárias de prompt e de compilação foram testadas durante o desenvolvimento, incluindo intervenções taxonômicas que não somaram ganho líquido, e seus registros completos permanecem no pacote (`resultados/` e `docs/PROTOCOLO-CAMPANHA-5.md`) sem serem analisados neste artigo.

Confounder modelo e prompt. A configuração final mudou prompt e modelo simultaneamente; o efeito conjunto não foi decomposto. A decomposição sob pré-registro é o passo imediato de trabalho futuro.

Corpus e generalização. O estudo cobre 24 exercícios de frações na reta numérica, praticamente um único template de interface, reutilizados de campanhas anteriores do programa de pesquisa; os runs não são amostras independentes do domínio. O bootstrap por cluster descreve o corpus e o mecanismo de reamostragem adotado, não uma população de domínios, interfaces ou autores.

Referência de autor único. Há um grafo por exercício, de um único especialista, sem banda de divergência humano-humano; autoria, instituição e licença do corpus CTAT não estão suficientemente documentadas. A referência é adequada para medir concordância com um tutor existente e insuficiente para declarar validade pedagógica universal (Shavelson; Webb, 1991).

Tetos deliberadamente reduzidos. As decisões de integridade (banimento de `mfNum`, `badCount` e `doubleDiv`; recusa do passo `done`) reduzem os tetos reportáveis por construção. Relaxá-las elevaria os números e invalidaria a leitura.

Conflito de interesses. O autor é responsável pela plataforma de que o shim de avaliação deriva. Preservação integral dos artefatos, previsão anterior à medição, verificação adversarial e validação automatizada dos números citados mitigam, mas não eliminam, o risco de viés; replicação externa continua necessária.

7 Conclusão

Na configuração final auditada, os grafos de comportamento gerados pelos agentes, aterrados na interface renderizada, reproduziram a grande maioria das rotas de erro que o especialista CTAT registrou nos grafos de referência: completude conceitual de 0,913 (IC95% por cluster 0,861–0,962), com F1 conceitual 0,626, completude estrita 0,618 e precisão 0,548. Em termos do objeto: de cada dez rotas de erro que o especialista desenhou no grafo dele, os agentes desenharam cerca de nove nas deles, sem colapso da precisão. O desfecho foi antecipado por previsão teórica offline preservada antes da medição (F1 previsto 0,609; medido 0,626), e o teto honesto de completude, 0,992, incorpora a recusa deliberada de três fontes que vazariam o gabarito. O resíduo é caracterizado em vez de arredondado para cima: exploração incompleta de fatos já disponíveis no prompt e um typo legado estruturalmente descoberto por decisão de integridade.

O resultado sustenta duas alegações estreitas: que, nesta bancada e neste corpus, a completude das rotas de erro dos grafos gerados era majoritariamente um problema de visibilidade de fatos da interface renderizada; e que o desfecho de uma intervenção desse tipo pode ser previsto por análise determinística offline antes de qualquer medição paga. Ele não sustenta equivalência a especialistas, cobertura universal de misconceptions, transferência ao runtime implantado ou eficácia educacional. Os próximos passos cientificamente necessários são a decomposição do confounder modelo e prompt sob pré-registro, a anotação das rotas excedentes dos agentes por especialistas independentes e a extensão do protocolo a outros domínios e interfaces com proveniência regularizada do corpus.

Disponibilidade de dados, código e rastreabilidade

O pacote de replicação está organizado em github.com/Joaoqueiroz-silva/sti-graph-validation. Os artefatos do experimento final estão em `resultados/campanha5-2026-07-19/6-final-megabraim/`: os 72 runs brutos e o `summary.json` com o bootstrap por cluster. A previsão teórica está em `resultados/campanha5-2026-07-19/previsao-teorica/`: a reconstrução preservada

Tabela 3: Hashes SHA-256 dos artefatos centrais do experimento final.

Artefato	SHA-256
Resumo do experimento final	2d70751644696630e842fe71590f6e64f7c00db1367f9ed2ec2980926123f0b6
Previsão preservada (recheck)	b46ea0f2f2e562e607d52bd70224d20862754bc0863782c3ae0060506a9e1b05
Reexecução pós-banimento	d7ef1f3fdd62b1204355ac8472fdad9ba198628c63889b48ecdec55f5bb863b
Script da reexecução pós-banimento	b8e51735c276af6ccd3f844dcfb1e9c952e683b460bdf54bd8cc9d4667c0ee0e
Resumo da campanha de referência 2026-07-02	5546945697a5e57bf308f8851d25fd8f26e34f25b25fb67969670b1d697fb05a
Protocolo retrospectivo	59c8112019bf07159a40b5db4c88bb1813783098eb0d186724bba8e2f0c4f34c
Investigação do kappa	75d1f396c29829228940f69c418ed6c6cf278481579b736ec74ed34e0a4a9240

(`reconstruir_interface.py`, `fatos-reconstruidos.json`, `previsao-cobertura.json`), a reexecução independente preservada (`previsao-recheck.mjs`, `previsao-recheck.json`) e o artefato pós-banimento `previsao-recheck-pos-banimento.json`, gerado dentro do pacote por `analysis/previsao-recheck-pos-banimento.mjs`. Os registros do desenvolvimento que precedeu o experimento final, incluindo as intervenções intermediárias e o protocolo retrospectivo, estão em `resultados/campanha5-2026-07-19/` e `docs/PROTOCOLO-CAMPANHA-5.md`; a investigação que motivou o abandono do kappa é `docs/INVESTIGACAO-KAPPA-2026-07-19.md`. O resumo congelado da campanha de referência 2026-07-02, citada como configuração de partida, é `resultados/campanha-2026-07-02/campaign-summary.json`.

O código que produziu o experimento final está espelhado no pacote (`simulate-students.js`, `interface-reconstruction.js`, `interface-inventory.js`, `author-graph.js`, `graphforge.js`, `run-ctat-eval.mjs`), com testes offline que travam prompt, banimento de parâmetros, anti-vazamento e determinismo sem nenhuma chamada de modelo. Os números citados neste manuscrito são verificados automaticamente contra os artefatos por `analysis/validate-article-v7.mjs` e pelo teste `__tests__/article-v7-consistency.test.mjs`, que também rejeitam qualquer travessão no texto. Dois artefatos históricos da previsão (`reconstruir_interface.py` e `previsao-recheck.mjs`) referenciam caminhos absolutos do ambiente privado e são preservados como registro; a reexecução da cobertura dentro do pacote, com caminhos relativos, é `analysis/previsao-recheck-pos-banimento.mjs`. Os grafos CTAT de origem pertencem a um conjunto recebido para pesquisa cuja autoria e licença ainda não estão suficientemente documentadas; hashes e métricas não conferem permissão de redistribuição do corpus. A Tabela 3 fornece os hashes SHA-256 dos artefatos centrais deste artigo.

Declarações

Conflito de interesses. O autor é fundador da EducaOFF, plataforma de cujo programa de pesquisa o shim de avaliação deriva.

Financiamento. Não foi informada fonte de financiamento externo nesta versão técnica. A declaração deve ser confirmada pelo autor antes de submissão editorial.

Ética. O estudo não envolveu participantes humanos, dados pessoais ou dados de estudantes. Uma fase futura com especialistas ou estudantes requer avaliação ética conforme a instituição e a jurisdição aplicáveis.

Uso de inteligência artificial. Modelos de linguagem são objeto do experimento e também apoiaram engenharia, auditoria e redação. Decisões metodológicas, interpretação e

responsabilidade pelo texto permanecem com o autor. A previsão teórica offline e a validação dos números citados não envolvem chamadas de modelo.

Proveniência e licença. Os arquivos CTAT de origem e a interface pertencem a um conjunto recebido para pesquisa. O pacote disponível não documenta suficientemente autor original, instituição, data de criação e licença de redistribuição. Esses elementos precisam ser regularizados antes de publicação aberta do corpus como benchmark.

Referências

- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; KOEDINGER, K. R. A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, v. 19, n. 2, p. 105–154, 2009.
- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; VAN VELSEN, M.; POPESCU, O.; DEMI, S.; RINGENBERG, M.; KOEDINGER, K. R. Example-tracing tutors: intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, v. 26, n. 1, p. 224–269, 2016.
- ASHLOCK, R. B. *Error Patterns in Computation: using error patterns to help each student learn*. 10. ed. Boston: Allyn & Bacon, 2010.
- BEHR, M. J.; WACHSMUTH, I.; POST, T. R.; LESH, R. Order and equivalence of rational numbers: a clinical teaching experiment. *Journal for Research in Mathematics Education*, v. 15, n. 5, p. 323–341, 1984.
- BRIGHT, G. W.; BEHR, M. J.; POST, T. R.; WACHSMUTH, I. Identifying fractions on number lines. *Journal for Research in Mathematics Education*, v. 19, n. 3, p. 215–232, 1988.
- BROWN, J. S.; BURTON, R. R. Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, v. 2, n. 2, p. 155–192, 1978.
- BYRT, T.; BISHOP, J.; CARLIN, J. B. Bias, prevalence and kappa. *Journal of Clinical Epidemiology*, v. 46, n. 5, p. 423–429, 1993.
- EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.
- FEINSTEIN, A. R.; CICCHETTI, D. V. High agreement but low kappa: I. The problems of two paradoxes. *Journal of Clinical Epidemiology*, v. 43, n. 6, p. 543–549, 1990.
- FISCHBEIN, E.; DERI, M.; NELLO, M. S.; MARINO, M. S. The role of implicit models in solving verbal problems in multiplication and division. *Journal for Research in Mathematics Education*, v. 16, n. 1, p. 3–17, 1985.
- HEGARTY, M.; MAYER, R. E.; MONK, C. A. Comprehension of arithmetic word problems: a comparison of successful and unsuccessful problem solvers. *Journal of Educational Psychology*, v. 87, n. 1, p. 18–32, 1995.
- NI, Y.; ZHOU, Y.-D. Teaching and learning fraction and rational numbers: the origins and implications of whole number bias. *Educational Psychologist*, v. 40, n. 1, p. 27–52, 2005.
- PEARN, C.; STEPHENS, M. Why you have to probe to discover what year 8 students really think about fractions. In: *Proceedings of the 27th Annual Conference of the Mathematics Education Research Group of Australasia (MERGA)*. Townsville: MERGA, 2004. p. 430–437.
- SHAVELSON, R. J.; WEBB, N. M. *Generalizability Theory: a primer*. Newbury Park: SAGE, 1991.
- STAFYLIDOU, S.; VOSNIADOU, S. The development of students' understanding of the numerical value of fractions. *Learning and Instruction*, v. 14, n. 5, p. 503–518, 2004.
- TVERSKY, A. Features of similarity. *Psychological Review*, v. 84, n. 4, p. 327–352, 1977.

VANLEHN, K. *Mind Bugs: the origins of procedural misconceptions*. Cambridge: MIT Press, 1990.

VLASSIS, J. Making sense of the minus sign or becoming flexible in “negativity”. *Learning and Instruction*, v. 14, n. 5, p. 469–484, 2004.