

Geração por LLM de catálogos candidatos de respostas erradas e montagem determinística de grafos de comportamento: estudo exploratório em exercícios de frações

João Carlos Queiroz

EducaOFF / STI Unplugged · contato@educaoff.com.br

Versão 3.2, 14 de julho de 2026 (campanhas exploratórias: 2, 8 a 10 e 13 de julho; reanálise: 12 de julho) · Dados e código: github.com/Joaoqueiroz-silva/sti-graph-validation (tag `legacy-campaigns-2026-07` preserva o estado original)

RESUMO. Sistemas tutores inteligentes do paradigma *example-tracing* dependem de grafos de comportamento: estruturas que codificam, por exercício, o caminho de resolução correto, os erros previstos e as remediações. A autoria manual desses grafos é o principal gargalo de escala do paradigma. Este estudo exploratório caracteriza três propriedades dos grafos produzidos por um pipeline que separa geração probabilística (agentes de LLM) de montagem determinística: a integridade estrutural, a cobertura dos valores de respostas erradas registrados no grafo CTAT de referência de um especialista e a plausibilidade, segundo um modelo-juiz, dos erros previstos além desse catálogo. O corpus reúne 24 exercícios de frações na reta numérica derivados de um único template, com um especialista de referência; o sistema autora a partir da interface, sem acesso ao grafo de referência (blindagem parcial, verificada por testes de vazamento). Nenhum dos grafos gerados violou as invariantes estruturais implementadas (72 grafos da campanha e 10.000 em testes de propriedades). A cobertura conceitual média foi de 0,376 (IC95% de 0,309 a 0,442), sem diferença detectável entre quatro famílias de modelos (p ajustado de 0,988 nas três comparações primárias) e crescente com a agregação de execuções (37% em execução única; 64% na união de três). O modelo-juiz classificou 83% dos excedentes como plausíveis, com taxas sensíveis à identidade do juiz. A concordância de classificação de respostas, corrigida pelo acaso, ficou próxima de zero (kappa médio de 0,007), resultado negativo atribuível à bateria autorreferente e que motiva uma bateria independente de traços. Uma terceira campanha, sob protocolo congelado antes da execução e entrada independente do grafo de referência, mediu os desfechos coprimários comportamentais e obteve o resultado central do estudo: a conformidade comportamental com a referência é BAIXA (reconhecimento de erros no estado correspondente de 0,065, IC95% de 0,020 a 0,113; nenhum traço correto completo da referência aceito passo a passo em nenhum braço). A cobertura por valor, métrica secundária de comparabilidade histórica, foi de 0,243 (IC95% de 0,163 a 0,324), 13,3 pontos abaixo do protocolo anterior; como fonte, KCs e idioma da entrada mudaram simultaneamente, o contraste não isola a contribuição de cada fator. Entre seis ablações, o alvo numérico do prompt foi o único efeito de cobertura que sobreviveu à correção de Holm (+17,7

pontos ao pedir seis candidatos, sob maior orçamento de saída); a representação com screenshot aumentou a concordância comportamental (+0,056, família exploratória). A não inferioridade em relação a especialistas não é estimável sem a banda humano-humano; a validade pedagógica dos excedentes e a eficácia educacional permanecem indeterminadas.

PALAVRAS-CHAVE: sistemas tutores inteligentes; grafos de comportamento; example-tracing; agentes de LLM; estudo exploratório; misconceptions; juiz de LLM.

ABSTRACT. Example-tracing intelligent tutoring systems rely on behavior graphs: per-exercise structures encoding the correct solution path, anticipated errors, and their remediations. Manual authoring of such graphs is the paradigm's main scalability bottleneck. This exploratory study characterizes three properties of graphs produced by a pipeline that separates probabilistic generation (LLM agents) from deterministic assembly: structural integrity, coverage of the wrong-answer values recorded in an expert's reference CTAT graph, and the plausibility, according to a judge model, of errors predicted beyond that catalog. The corpus comprises 24 fraction number-line exercises derived from a single template, with one reference expert; the system authors from the interface without access to the reference graph (partial shielding, verified by leakage tests). No generated graph violated the implemented structural invariants (72 campaign graphs and 10,000 property-tested graphs). Mean conceptual coverage was 0.376 (95% CI 0.309 to 0.442), with no detectable difference across four model families (adjusted p of 0.988 in all three primary comparisons), and increased with run aggregation (37% single run; 64% for the union of three). The judge model classified 83% of the surplus errors as plausible, with rates sensitive to judge identity. Chance-corrected response-classification agreement was near zero (mean kappa 0.007), a negative result attributable to the self-referential battery and motivating an independent trace battery. A third campaign, under a protocol frozen before execution and with input independent of the reference graph, measured the behavioral coprimary outcomes and yielded the study's central result: behavioral conformity with the reference is LOW (in-context error recognition of 0.065, 95% CI 0.020 to 0.113; no complete correct reference trace accepted step by step in any arm). Value coverage, a secondary metric kept for historical comparability, was 0.243 (95% CI 0.163 to 0.324), 13.3 points below the previous protocol; since input source, KCs, and language changed simultaneously, the contrast does not isolate each factor. Among six ablations, the prompt's numeric target was the only coverage effect surviving Holm correction (+17.7 points when requesting six candidates, under a larger output budget); the screenshot representation increased behavioral agreement (+0.056, exploratory family). Non-inferiority to experts is not estimable without a human-to-human band; pedagogical validity of surpluses and educational effectiveness remain undetermined.

KEYWORDS: intelligent tutoring systems; behavior graphs; example-tracing; LLM agents; exploratory study; misconceptions; LLM-as-judge.

1 Introdução

Sistemas tutores inteligentes (STIs) do paradigma *example-tracing* (Aleven et al., 2009, 2016) reagem ao aluno de forma diagnóstica: reconhecem qual erro específico foi cometido, oferecem a remediação correspondente e dosam dicas em níveis progressivos. Essa capacidade depende de uma estrutura subjacente por exercício, o **grafo de comportamento**, que codifica o caminho de resolução correto, os erros conceituais previstos (misconceptions) e, para cada erro, o desvio de remediação (*scaffold*) que devolve o aluno ao caminho. A Figura 1 ilustra a anatomia dessa estrutura em um exercício de frações.




Figura 1: anatomia de um grafo de comportamento. O eixo horizontal contém o caminho de resolução correto; o desvio inferior representa uma misconception com sua remediação, formando um ciclo legítimo de retorno ao passo; o bloco superior representa a cadeia de dicas.

A autoria manual desses grafos é reconhecidamente o gargalo de escala do paradigma: mesmo com ferramentas maduras como o CTAT (Cognitive Tutor Authoring Tools, Carnegie Mellon), produzir um grafo rico para cada exercício exige tempo de especialista. A plataforma EducaOFF automatiza essa autoria com um pipeline de agentes de LLM. A automação, porém, desloca o problema para a qualidade do que é gerado. Este relatório NÃO pergunta se os grafos gerados equivalem aos de especialistas em geral (pergunta que exigiria múltiplos especialistas, margem justificada e dados de alunos); pergunta algo mais estreito e respondível com os dados disponíveis: **em que medida o sistema reconstrói os comportamentos registrados em grafos CTAT de referência, mantendo integridade estrutural e estabilidade, e que propriedades objetivas têm os comportamentos que ele adiciona?**

A pergunta é menos trivial do que aparenta, porque não existe um único grafo correto por exercício. Dois especialistas competentes produzem grafos distintos e igualmente defensáveis, e parte da

discordância entre avaliadores qualificados reflete ambiguidade legítima da tarefa, não ruído (Amidei; Piwek; Willis, 2018). A validação, portanto, não pode assumir o grafo humano como gabarito absoluto. Este relatório enfrenta essa dificuldade com um desenho de três componentes: (i) verificação estrutural que independe de gabarito; (ii) comparação direcional contra um especialista sob protocolo de autoria cega; e (iii) julgamento pedagógico cego das divergências, em ambas as direções.

As contribuições deste relatório são:

1. um protocolo de **autoria cega com interface fixa**, que separa mecanicamente a entrada dos agentes (interface) do material de comparação (grafo humano), com verificação automatizada de vazamento;
2. uma **métrica primária direcional** (completude) fundamentada na assimetria de similaridade de Tversky (1977), acompanhada de um veredito bidimensional que trata excedentes como hipóteses a julgar, e não como erro;
3. um **juiz de LLM cego e de família distinta** da geradora, com calibração positiva e controles negativos internos a cada rodada, complementado por um segundo julgamento sobre a importância do que o sistema deixa de cobrir;
4. um **verificador de invariantes estruturais** para grafos de comportamento, com sinais duros exercitados por testes de propriedades em 10.000 grafos;
5. três **campanhas empíricas exploratórias** (24 exercícios, três réplicas por condição, quatro famílias de modelos, a terceira sob protocolo integralmente congelado antes da execução), com dados brutos, manifestos de execução, código e corpus publicados para reprodução independente.

O escopo das conclusões segue uma escada explícita de reivindicações. Este estudo sustenta dois níveis: (A) o montador satisfaz as invariantes estruturais implementadas, e (B) os grafos gerados reproduzem parte dos comportamentos registrados nos grafos de referência deste corpus. Três níveis ficam explicitamente FORA do alcance dos dados atuais e são tratados como agenda futura: (C) equivalência ou não inferioridade em relação a especialistas em geral, que requer múltiplos especialistas e margem justificada; (D) validade pedagógica dos comportamentos adicionais, que requer anotação humana e prevalência empírica; e (E) efeito sobre aprendizagem, que requer estudo com estudantes. Todas as análises aqui reportadas são exploratórias (Seção 3.8).

O restante do documento está organizado da seguinte forma: a Seção 2 apresenta a fundamentação e os trabalhos que sustentam cada decisão metodológica; a Seção 3 detalha o método; a Seção 4 reporta

os resultados; a Seção 5 os discute; a Seção 6 examina ameaças à validade; a Seção 7 delinea os próximos passos; a Seção 8 conclui.

2 Fundamentação

2.1 Grafos de comportamento e grafos de conhecimento

Dois artefatos com nomes semelhantes cumprem papéis distintos em um STI. O **grafo de conhecimento** organiza o currículo: seus nós são habilidades (*knowledge components*, KCs) e suas arestas expressam pré-requisito; ele responde o que o aluno precisa saber e em que ordem, e é compartilhado por muitos exercícios. O **grafo de comportamento** descreve um único exercício: seus nós são passos e estados da resolução, e suas arestas são ações do aluno (acerto, erro previsto, retorno de remediação). A Figura 2 contrasta as duas estruturas.




Figura 2: grafo de conhecimento (esquerda) e grafo de comportamento (direita). No presente experimento, as habilidades entram como insumo, extraídas do próprio CTAT, e o objeto autorado e comparado é exclusivamente o grafo de comportamento.

Delimitação de escopo: neste estudo, os agentes autoram apenas o grafo de comportamento. Os KCs chegam prontos no material de entrada e são usados como rótulos dos passos. A plataforma, em sua versão atual, não constrói nem atualiza um grafo de conhecimento a partir de descobertas dos agentes; essa segunda saída está registrada como trabalho futuro.

2.2 Erros sistemáticos e a premissa do catálogo

A utilidade de catalogar misconceptions repousa em um resultado clássico: erros de alunos não são aleatórios, mas sistemáticos e enumeráveis, como demonstrado para procedimentos aritméticos por Brown e Burton (1978) e consolidado por VanLehn (1990). É essa regularidade que torna viável, e pedagogicamente valioso, prever erros específicos e associar remediações dirigidas a cada um.

2.3 Avaliação sem gabarito único: não-inferioridade e banda humana

Se não há grafo correto único, a pergunta adequada não é "o sistema é igual ao especialista?", e sim "o sistema difere do especialista mais do que especialistas diferem entre si?". Esse enquadramento corresponde ao teste de não-inferioridade (Lakens, 2017; Lakens; Scheel; Isager, 2018), com margem derivada empiricamente da variação interespecialistas (a banda humano-humano). A estimativa dessa banda requer pelo menos dois, idealmente três especialistas por exercício, exigência que decorre da Teoria da Generalizabilidade (Shavelson; Webb, 1991): com um único par há uma única medida de discordância por direção, insuficiente para estimar variância. Na presente campanha havia um especialista por exercício; consequentemente, o veredito de não-inferioridade é reportado como não estimável por construção (Seção 4.7), e a coleta da banda é a frente prioritária de continuidade.

2.4 Similaridade assimétrica e a métrica primária

Métricas simétricas de comparação de conjuntos, como o F1, penalizam o candidato por itens excedentes. Para um sistema generativo cujo valor reside em enriquecer a cobertura de erros, essa penalização confunde duas situações opostas: o excedente inválido (alucinação de conteúdo) e o excedente válido (erro real de aluno que o especialista não catalogou). Tversky (1977) demonstrou que julgamentos de similaridade são naturalmente assimétricos e formalizou um modelo de contraste com pesos independentes para os traços exclusivos de cada lado. A métrica primária deste estudo, a **completude**, é o caso direcional desse modelo: mede a fração do catálogo do especialista coberta pelo sistema, sem punir excedentes; os excedentes são encaminhados a julgamento pedagógico (Seção 3.6). Para a comparação de caminhos de resolução sem penalizar diferenças de granularidade, emprega-se a noção de inclusão de traços da teoria de equivalência de processos (van Glabbeek, 2001), com colapso de passos intermediários sem conteúdo. Distâncias clássicas de edição (Sanfeliu; Fu, 1983; Zhang; Shasha, 1989) e o próprio F1 são mantidos como métricas auditáveis, para comparabilidade com a literatura.

2.5 Juízes baseados em LLM

O julgamento pedagógico em escala exige um avaliador automatizado, e o uso de LLMs como juízes introduz um viés documentado: modelos tendem a avaliar mais favoravelmente produções da própria família (Panickssery; Bowman; Feng, 2024; ver também Hosking; Blunsom; Bartolo, 2024, sobre limitações do julgamento como padrão-ouro). As salvaguardas adotadas derivam diretamente dessa literatura: juiz de família distinta da geradora, cegamento quanto à origem dos itens, julgamento item a item com justificativa (à maneira de GraphEval; arXiv:2407.10793) e controles internos por rodada. A calibração contra julgamento humano, com estatística kappa (Landis; Koch, 1977), está prevista no instrumento e em execução.

2.6 Detecção estrutural de alucinação em grafos

Trabalhos recentes sobre confiabilidade de saídas de LLM em estruturas de grafo informam a camada estrutural da validação: a métrica de validade como violações por verificação (arXiv:2601.17717), a comparação contra referência determinística com limiar dinâmico $\mu + \lambda\sigma$ e o reconhecimento explícito de que a própria referência é falível (arXiv:2509.03857), a taxonomia de anomalias por nó, aresta e caminho (arXiv:2505.24201) e a combinação aditiva de camadas de detecção (arXiv:2512.22396). A falibilidade da referência é incorporada aqui como argumento central: o especialista tampouco é gabarito perfeito, o que motiva o enquadramento de não-inferioridade da Seção 2.3.


3 Método

3.1 Desenho geral e questões de pesquisa

O estudo responde a três questões:

1. **QP1 (estrutural):** a boa-formação dos grafos é uma invariante verificável do gerador? (Trata-se de verificação de propriedade de engenharia, não de descoberta empírica: a arquitetura delega a estrutura a um montador determinístico, e a QP1 verifica que as invariantes implementadas se sustentam sob teste adversarial.)
2. **QP2 (cobertura da referência):** que proporção dos valores de respostas erradas registrados no grafo CTAT de referência o sistema reproduz, e qual a concordância de classificação de respostas entre os dois grafos?
3. **QP3 (comportamentos adicionais):** que avaliação um modelo-juiz cego faz dos erros previstos apenas pelo sistema, e da importância dos erros não cobertos? (Avaliação automatizada exploratória: mede plausibilidade segundo o juiz declarado, não validade pedagógica.)

A Figura 3 posiciona os instrumentos: a QP1 é respondida por verificação estrutural sem gabarito; a QP2 e a QP3, por comparação e julgamento sob protocolo cego. Um terceiro nível, de eficácia de aprendizagem com alunos reais, está fora do escopo desta campanha.



Um grafo ruim teria de passar nos três ao mesmo tempo. É a validade convergente do Design Science.

Figura 3: os três níveis de validação e sua correspondência com as questões de pesquisa. A campanha reportada cobre os níveis 1 e 2, com as limitações registradas nas Seções 4.7 e 6.

3.2 Corpus e materiais

O corpus é composto por 24 exercícios de frações na reta numérica (6º ano), autorados por um especialista na ferramenta CTAT sobre uma mesma interface (produção em massa via template, prática padrão da ferramenta). Os grafos desse autor são tratados como **grafos CTAT de referência**: registros legítimos e finitos dos comportamentos que seu autor catalogou, não como a verdade completa dos erros possíveis; toda métrica direcional deste relatório é relativa a esse registro. [Credenciais do especialista a preencher pelos autores: formação, tempo de docência em matemática e experiência prévia com a ferramenta.] Cada exercício é exportado como um arquivo `.brd`: um documento XML que contém, simultaneamente, a descrição da interface e o grafo de comportamento do especialista, incluindo o catálogo de misconceptions com as respostas erradas concretas e as mensagens de remediação. O corpus integral, com as interfaces, está disponível no repositório do experimento. A homogeneidade decorrente da produção em massa é quantificável: o coeficiente de correlação intraclasse da completude conceitual entre exercícios, $ICC(1)=0,32$, indica que cerca de um terço da variância da métrica é atribuível a diferenças consistentes entre exercícios (os itens de catálogos maiores e frações impróprias são sistematicamente mais difíceis), e o restante à estocasticidade das execuções; o corpus, portanto, não se comporta como um único item repetido, mas permanece restrito a um template, limitação tratada na Seção 6.

3.3 Protocolo de autoria cega: os dois envelopes

A validade do experimento depende de os agentes jamais acessarem o material do especialista. O parser do experimento divide cada `.brd` em dois envelopes disjuntos (Figura 4): o **Envelope A** contém exclusivamente a interface (enunciado, componentes de resposta, resposta correta e KCs) e constitui a única entrada dos agentes; o **Envelope B** contém o grafo do especialista e ingressa no fluxo somente na etapa de comparação. Três salvaguardas mecânicas sustentam o protocolo: funções de extração separadas para cada envelope; uma lista de campos proibidos no Envelope A (misconceptions, dicas, arestas, mensagens de feedback), varrida pela função `findLeaksInRobotInput`; e um teste automatizado que falha na presença de qualquer vazamento, incluindo um controle negativo com envelope deliberadamente contaminado, que o teste deve acusar. Registra-se que a resposta correta integra o Envelope A por decisão de desenho: a previsão de erros plausíveis pressupõe o conhecimento do acerto, como ocorre com o professor humano.

Uma qualificação honesta é necessária: o Envelope A é hoje DERIVADO do mesmo arquivo `.brd` que contém o grafo de referência (o parser percorre a estrutura para descobrir componentes e tipos), e o teste de vazamento é lexical, por lista de campos proibidos, não semântico. O protocolo garante, portanto, **blindagem parcial**, não independência total de fonte. A reconstrução do Envelope A a partir de fonte independente do grafo (o HTML e o DOM da interface, o screenshot e o gabarito do arquivo de produção em massa, todos disponíveis no corpus), acompanhada de teste metamórfico (mutações no grafo de referência não alteram um byte do envelope), FOI EXECUTADA: é o protocolo v2 da campanha 3 (Seções 3.11 e 4.11). A descrição acima documenta o protocolo v1, usado nas campanhas 1 e 2.




Figura 4: fluxo geral do experimento. O arquivo `.brd` é dividido em dois envelopes disjuntos; o sistema autora às cegas a partir do Envelope A; o Envelope B ingressa apenas no comparador, sobre um esquema neutro comum.

3.4 O sistema sob avaliação

O sistema avaliado é o pipeline de autoria da plataforma EducaOFF, empregado sem modificação. Três agentes de LLM operam sobre a interface do Envelope A com papéis inspirados em perfis de aluno: o agente 3a ("aluno avançado") produz o caminho de resolução correto; o agente 3b ("aluno com dificuldades") produz as misconceptions, cada qual com a resposta errada concreta correspondente; o agente 3c ("aluno mediano") produz as dicas em quatro níveis. Os papéis são heurísticas de prompt, não modelos de aluno validados contra comportamento de estudantes reais; o relatório os trata como geradores de candidatos. Um montador determinístico, o GraphForge, combina os três insumos no grafo final, criando nós de passo, um scaffold por misconception e as arestas de erro e retorno (Figura 5). A separação é deliberada: o conteúdo pedagógico provém dos agentes; a estrutura provém de um algoritmo clássico e é, por construção, verificável.




Figura 5: a autoria em duas fases: os três agentes de produção (conteúdo) e o montador determinístico (estrutura). Os agentes são os mesmos da plataforma em produção, sem modificação de código ou de prompts.

Dois cuidados de fidelidade merecem registro. Primeiro, os agentes de produção operam nativamente sobre templates com variáveis genéricas; para o experimento, a instrução de instanciar valores concretos trafega como dado, pelo mesmo canal de entrada que os agentes já consomem, sem alteração de seus prompts de sistema. Segundo, a orquestração replica a política condicional de produção (o agente 3c é acionado sob as mesmas condições). Ambos os pontos foram objeto de correção após a primeira rodada de revisão adversarial (Seção 3.8).

Dois fatores do prompt do agente de erros devem ser declarados por afetarem a interpretação dos resultados. Primeiro, o prompt consulta um catálogo interno de misconceptions comuns por tópico (`MISC_DB`, versionado no repositório), herdado da plataforma em produção. Segundo, o prompt orienta a produção de duas a três tentativas erradas por exercício. Ambos podem induzir convergência artificial de cobertura entre modelos distintos e estão entre as ablações prioritárias do programa experimental (Seção 7): catálogo ligado contra desligado, e limite de candidatos contra geração até saturação.


3.5 Métricas

A comparação entre o grafo do sistema e o do especialista opera sobre um esquema neutro comum, com casamento de itens por âncora semântica: respostas equivalentes em valor (por exemplo, $2/8$, $1/4$ e $0,25$) recebem a mesma chave canônica, e erros mecânicos de interface (respostas em branco, resíduos de interação como "-1") são marcados e excluídos das contagens conceituais. Sobre esse alinhamento definem-se (Figura 6):

- **Compleitude conceitual** (métrica primária, eixo X): fração dos valores de respostas erradas conceituais do grafo de referência cobertos pelo sistema. A operacionalização é declarada: uma

misconception é representada pelo VALOR canônico da resposta errada, não pela regra cognitiva que a produz; dois raciocínios distintos que geram o mesmo valor contam como um item, e a mesma regra que gera valores diferentes em exercícios diferentes conta como itens distintos. A métrica mede, portanto, cobertura de valores do catálogo de referência (limitação discutida na Seção 6);

- **Plausibilidade dos excedentes** (eixo Y): fração dos erros previstos apenas pelo sistema classificados como plausíveis pelo modelo-juiz cego (Seção 3.6); mede o veredito do juiz declarado, não validade pedagógica;
- **Completo de passos**: cobertura do caminho de resolução, reportada separadamente por constituir modo de falha independente;
- **Concordância de classificação de respostas** (denominada "equivalência funcional" nas versões 1.0 a 2.1; renomeada porque o instrumento não executa o tutor): concordância de veredito entre os dois grafos ante uma mesma bateria de respostas (acerto, erro previsto, surpresa), com concordância bruta, kappa de Cohen e matriz de confusão. A bateria atual é a união das respostas dos dois grafos, o que a torna autorreferente: um item classificado como surpresa pelos dois lados é impossível por construção, a concordância esperada por acaso é alta e o kappa é estruturalmente deprimido (resultado negativo reportado na Seção 4.2). A bateria independente que corrige isso foi construída e usada na campanha 3;
- **Inclusão de traços**: fração do caminho do especialista contida, em ordem, no caminho do sistema, com colapso de passos sem conteúdo (insensível a granularidade);
- **Métricas auditáveis**: F1 estrutural e conceitual, precisão, Jaccard e distância de edição aproximada, mantidas para comparabilidade.



O F1 mistura os três territórios num número só. O veredito 2D trata cada um do jeito certo: mede a cobertura, manda os extras para um juiz de plausibilidade e os perdidos para um juiz de importância.

Figura 6: os três territórios do alinhamento entre catálogos. A completude mede a interseção relativa ao especialista; os excedentes seguem para julgamento de plausibilidade; as omissões seguem para julgamento de importância.

O **veredito bidimensional** (completude conceitual, plausibilidade dos excedentes) constitui o desfecho primário do plano de análise (Seção 3.8). O par substitui o F1 como critério de mérito por um argumento de função de perda: em um instrumento generativo, o excedente não é defeito por definição, mas hipótese a verificar.

3.6 O juiz cego e o juiz de importância

Duas funções de julgamento operam sobre o mesmo modelo avaliador (Figura 7). O **juiz de plausibilidade** (denominado "juiz de validade" nas versões 1.0 a 2.1) recebe, um item por vez e sem qualquer indicação de origem, o enunciado, a resposta correta e uma resposta errada candidata, e responde em formato estruturado: veredito (erro plausível de aluno; implausível; correspondente à resposta correta; impossível no contexto), denominação do erro quando válido e justificativa breve. O **juiz de importância** recebe as misconceptions do especialista não cobertas pelo sistema e as classifica em centrais (que um tutor precisa remediar), periféricas ou mecânicas, sem informação de que se trata de omissões.





Figura 7: protocolo do juiz cego. Cada rodada julga, indistintamente, excedentes do sistema, erros do próprio especialista (calibração positiva) e distratores (controles negativos); o segundo julgamento classifica a importância das omissões.

A confiabilidade do instrumento é verificada dentro de cada rodada por dois mecanismos: os erros do próprio especialista funcionam como calibração positiva (espera-se aprovação alta) e distratores por exercício funcionam como controle negativo (espera-se rejeição). A partir da revisão de 2026-07-10, os controles incluem, além dos distratores triviais (a resposta correta e um valor absurdo), dois distratores difíceis: a forma não-canônica da própria resposta correta (por exemplo, $\frac{6}{8}$ quando a resposta é $\frac{3}{4}$) e um valor impossível no contexto físico (fração negativa de uma grandeza). A auditoria correspondente (24 exercícios) revelou que o juiz de LLM rejeita corretamente três das quatro classes, mas aprova integralmente a forma equivalente da resposta correta (24 de 24 na auditoria registrada na Emenda 2 do plano de análise; o relatório bruto dessa auditoria será versionado com a próxima campanha), uma falha de fronteira que não contaminou os resultados publicados (nenhum dos 669 excedentes julgados nas campanhas era um equivalente aprovado) e que passou a ser impedida, nos casos cobertos pela âncora semântica, por uma guarda determinística: candidato com a mesma âncora da resposta correta é classificado automaticamente, sem consulta ao modelo. O episódio ilustra o desenho recomendável para juízes de LLM: julgamento pedagógico ao modelo, invariantes matemáticas a código. Adicionalmente, o instrumento prevê calibração externa contra anotação humana independente, com concordância medida por kappa (Landis; Koch, 1977); essa anotação está em curso e será reportada em versão futura.

3.7 Verificação estrutural

Independentemente de gabarito, todo grafo gerado é submetido a um verificador de invariantes estruturais que distingue duas classes de sinal. Os **sinais duros** invalidam o grafo: ciclo que não atravessa remediação (raciocínio circular), nó inalcançável a partir do início, beco sem saída (nó que não alcança o objetivo), scaffold órfão (remediação de erro inexistente), aresta órfã, ciclo no caminho correto e ausência de nós de início ou objetivo. Os **sinais moles** (ramificação excessiva relativa à mediana, erro sem remediação, laços e arestas duplicadas) compõem um escore com limiar dinâmico $\mu + \lambda\sigma$ sobre a banda histórica. A Figura 8 exemplifica os defeitos duros.



Todos estes defeitos são detectados sem olhar o grafo do especialista. É pura teoria dos grafos.

Figura 8: defeitos estruturais detectáveis sem gabarito, ilustrados em um grafo hipotético. Nenhum deles ocorreu nos grafos da campanha.

A robustez do montador determinístico foi exercitada por teste de propriedades: 10.000 configurações aleatórias de exercício foram submetidas ao GraphForge e nenhuma produziu violação dura. A leitura correta é circunscrita: **nenhuma violação das invariantes implementadas foi observada**. Como verificador e montador implementam o mesmo conjunto de regras, o resultado não constitui prova de ausência de defeito em geral; a sensibilidade do verificador foi medida por mutation testing: dez classes de defeito deliberadamente injetadas em 26 grafos-base produziram 260 mutantes, todos detectados (sensibilidade 100%), com zero sinal espúrio nas bases intactas (especificidade 100%); a conclusão vale para as classes cobertas pela suíte, e o relatório integra o repositório. O verificador foi ainda incorporado à plataforma como barreira de produção, de modo que um grafo que viole as invariantes não alcança alunos.

3.8 Procedimento estatístico, estatuto exploratório e garantias de rigor

Estatuto exploratório. O documento de protocolo deste estudo é um plano de análise com histórico datado de decisões, não um pré-registro confirmatório: ele foi tornado público junto dos resultados, a métrica primária foi substituída (do F1 para a completude) após corridas exploratórias de junho e a correção de Holm foi adotada após a campanha multimodelo. Em consequência, e conforme registrado na Emenda 3 do plano, TODAS as análises deste relatório são classificadas como exploratórias. A cronologia completa das decisões, com datas e motivos, consta das Emendas 1 a 3; o primeiro estudo confirmatório exigirá registro público imutável (OSF) anterior à coleta, em corpus novo e não inspecionado.

Unidade de análise e testes. Os 72 registros por braço correspondem a 24 exercícios observados em três réplicas; a unidade inferencial é o exercício, e as réplicas são medições aninhadas, agregadas por média dentro de cada exercício antes de qualquer comparação. Comparações entre condições são pareadas por exercício e testadas por permutação por troca de sinais EXATA (as 2^{24} atribuições são enumeradas; não há aproximação de Monte Carlo). A correção de múltiplas comparações usa Holm em duas famílias declaradas: a primária (completude conceitual, cada braço contra o baseline; $m=3$) e a secundária, exploratória (demais métricas; $m=12$). Intervalos de confiança de médias usam bootstrap com reamostragem por exercício e semente fixa. As proporções do juiz são estimadas sobre itens ÚNICOS (deduplicação por exercício e âncora canônica), com decisão agregada por maioria entre réplicas, empates excluídos e declarados, intervalo por bootstrap de exercício e autoconsistência do juiz reportada em separado. Esta versão substitui o procedimento das versões anteriores (p-valor por contagem de cruzamentos no bootstrap percentil e intervalos de Wilson sobre julgamentos repetidos), cujos defeitos foram apontados em revisão externa; os dados brutos são os mesmos, congelados na tag `legacy-campaigns-2026-07`.

Fonte única dos números. Todos os números deste relatório são gerados pelo script `analysis/reanalyze.mjs` a partir dos relatórios brutos, sem transcrição manual; a reconciliação formal com os números das versões 1.0 a 2.1 está em `analysis/derived/TABELAS.md`. A reanálise foi verificada por quatro recomputações independentes em sala limpa (implementações separadas, sem acesso ao script) e por revisão de código independente, cujos quatro achados foram corrigidos antes desta versão.

Revisão adversarial. Antes das campanhas, o desenho e o código passaram por duas rodadas de revisão independente com mandato explícito de refutação; as inconsistências (divergência de âncora entre módulos, infidelidade de temperatura) foram corrigidas e cobertas por testes de regressão. Após

as campanhas, um parecer externo motivou a reanálise e o reposicionamento desta versão. A suíte do pacote de reprodução compreende 117 testes.

O desenho da campanha 1 (Figura 9) compreende nove relatórios: três réplicas de avaliação com os agentes de produção, três com uma variante simplificada (baseline interno de robustez) e três de julgamento. As corridas de avaliação com agentes de produção e as de julgamento autoram, juntas, 144 grafos (72 + 72); os 498 julgamentos individuais do juiz reduzem-se a 199 itens únicos após deduplicação.




Figura 9: desenho da campanha de 2026-07-02: três réplicas de avaliação e três de julgamento sobre os 24 exercícios. A agregação estatística (reanálise de 2026-07-12) usa o exercício como unidade, permutação exata pareada com Holm e juiz sobre itens únicos.

3.9 Transparência de modelos e infraestrutura

A Tabela 1 especifica os modelos empregados em cada função, com as respectivas temperaturas, idênticos aos da plataforma em produção. As temperaturas diferem por função: a simulação do aluno avançado requer quase-determinismo; a do aluno com dificuldades requer diversidade para a emergência de erros; o julgamento requer estabilidade. O juiz pertence a família distinta da geradora (Seção 2.5). Todos os identificadores de modelo referem-se às versões servidas pela OpenRouter nas datas das campanhas e da bancada de juízes (2 e 8 a 10 de julho de 2026); provedores podem atualizar modelos sob o mesmo identificador, limitação padrão de estudos com APIs comerciais. O custo total de API foi de aproximadamente US\$ 4 na campanha 1 e US\$ 30 na campanha 2 (dominado pelos braços GLM-5.2 e Claude Sonnet 5); por grafo autorado, o custo marginal do sistema fica na ordem de US\$ 0,05 e cerca de um minuto de máquina. Para referência do gargalo que motiva a automação, estimativas clássicas situam o desenvolvimento de tutores inteligentes em 200 a 300 horas por hora de instrução, razão que o paradigma example-tracing reduz substancialmente, mas não elimina (Aleven et

al., 2009); o tempo do especialista deste corpus por grafo [dado a coletar com o autor do corpus] completará a comparação. Todos os modelos são acessados por um único provedor (OpenRouter), o que permite reprodução com uma única credencial; o pacote publicado inclui o comando `npm run models`, que exibe a configuração ativa e valida o acesso, e permite a substituição de qualquer modelo por variável de ambiente. A montagem do grafo não emprega modelo algum.

Tabela 1: modelos, temperaturas e limites por função do experimento.

Função	Agente	Modelo	Temp.	Máx. tokens
Caminho de resolução correto	3a, aluno avançado	google/gemini-3.5-flash	0,2	16.000
Misconceptions	3b, aluno com dificuldades	google/gemini-3.5-flash	0,7	24.000
Dicas em 4 níveis	3c, aluno mediano	google/gemini-3.5-flash	0,4	16.000
Julgamento (plausibilidade e importância)	juiz cego	z-ai/glm-4.5	0,1	32.000
Contingência de falha	fallback	deepseek/deepseek-chat	0,3	16.000
Montagem do grafo	GraphForge	nenhum (determinístico)	n/a	n/a

3.10 Campanha 2: variação do modelo gerador

A segunda campanha responde a uma pergunta de robustez levantada pela orientação: os resultados dependem do modelo de linguagem empregado nos agentes? O protocolo, o corpus, os prompts, as temperaturas por papel e a infraestrutura foram mantidos idênticos; variou-se apenas o modelo que anima os três agentes, em quatro braços experimentais: o baseline da produção (`google/gemini-3.5-flash`) e três famílias alternativas (`z-ai/glm-5.2`, `deepseek/deepseek-v4-pro` e `anthropic/claude-sonnet-5`). Cada braço executou três réplicas de avaliação e três de julgamento (24 corridas no total), e os três agentes de um braço compartilham o mesmo modelo, para que qualquer diferença observada tenha atribuição inequívoca.

Duas salvaguardas adicionais foram necessárias. Primeira: o juiz da campanha 1 (GLM-4.5) pertence à família de um dos braços testados, o que violaria a exigência de neutralidade; adotou-se, para todos os braços, um juiz único de família alheia às quatro geradoras (`mistralai/mistral-large-2512`, temperatura 0,1), selecionado após um comparativo de latência e adequação (1,9 s por julgamento, contra 14 a 28 s de candidatos com raciocínio interno). A concordância entre candidatos foi medida empiricamente em bancada de 45 itens estratificados: o κ de Cohen par a par entre Mistral Large, Mistral Medium e Qwen3.7-plus situa-se entre 0,644 e 0,700 (concordância substancial na escala de Landis e Koch, inclusive entre famílias distintas), com taxas de aprovação de 67 a 69%; nessa bancada, não se detectou viés de veredito associado à escolha por latência e custo. Em decorrência, o próprio baseline foi reavaliado e rejuizado integralmente dentro da campanha 2, permitindo comparar os braços sob a mesma régua de julgamento; os níveis absolutos de julgamento, contudo, não são

comparáveis entre campanhas (Seção 4.9). Segunda: o mecanismo de contingência de cada corrida de avaliação usa o próprio modelo do braço (uma falha não introduz outra família no braço), e o das corridas de julgamento usa um modelo neutro menor.

3.11 Campanha 3: protocolo v2 (entrada independente, ablações e painel de juízes)

A terceira campanha (13 de julho) estreia o protocolo v2, congelado integralmente ANTES de qualquer chamada (Emenda 4 do plano de análise): o Envelope A passa a ser construído de fonte independente do grafo de referência (o HTML da interface e o gabarito da tabela de produção em massa do CTAT, com teste metamórfico de independência), os KCs saem da entrada (só existiam dentro do grafo), o esquema neutro v2 representa estados e transições com um executor de example-tracing, e uma bateria congelada de 636 traços em três famílias substitui a bateria autorreferente. Duas consequências declaradas: os enunciados da fonte independente estão em inglês (os arquivos `.brd` traziam tradução), e os níveis absolutos desta campanha NÃO são comparáveis aos das campanhas 1 e 2. A campanha compreende nove condições em três réplicas cada (27 corridas de 24 exercícios, 648 autorias), a curva de ensemble $K=1$ a 10 e um painel de três famílias de juízes (Mistral Large, Qwen 3.7 Plus e Llama 4 Maverick) julgando o mesmo conjunto congelado de 179 itens. Cada chamada foi registrada em manifesto de execução (modelo, temperatura, hash do prompt e do envelope, tokens, custo e latência), com trava dura de orçamento; o custo total foi de US\$ 16,72 em 1.970 chamadas, sem nenhuma falha de autoria em 648 exercícios-execução. A comparação comportamental usa níveis de correspondência declarados por lado (referência no vocabulário exato; lado gerado no nível de equivalência de input por âncora semântica), com passos não ancoráveis contados à parte. A análise foi verificada por recomputação independente em sala limpa, com coincidência bit a bit dos p-valores.

4 Resultados

4.1 QP1: integridade estrutural

Nenhum dos 72 grafos autorados na avaliação apresentou violação dura ou sinal mole, e o mesmo vale para os 10.000 grafos dos testes de propriedades. A banda histórica do escore de sinais moles resultou degenerada em zero ($\mu=0$, $\sigma=0$, $n=144$), o que estabelece um regime de vigilância estrito: qualquer sinal mole em geração subsequente constitui anomalia. Conclui-se que nenhuma violação das invariantes implementadas foi observada, e a QP1 é respondida afirmativamente PARA as invariantes

cobertas; a sensibilidade do verificador a defeitos injetados foi demonstrada pelo mutation testing (260/260 nas dez classes cobertas; Seção 3.7).

4.2 QP2: comparação com o especialista

A Tabela 2 consolida as métricas comparativas da campanha 1 (24 exercícios em três réplicas; unidade inferencial: exercício), com intervalos de confiança de 95% por bootstrap de exercício.

Tabela 2: métricas comparativas da campanha 1 (média por exercício e IC95%; 24 exercícios × 3 réplicas agregadas). Todos os valores gerados por `analysis/reanalyze.mjs`.

Métrica	Estimativa [IC95%]
Compleitude conceitual (primária)	0,376 [0,309; 0,442]
Compleitude bruta (com erros mecânicos)	0,234 [0,195; 0,273]
Compleitude de passos	0,510 [0,497; 0,525]
Concordância de classificação: bruta	0,396 [0,345; 0,449]
Concordância de classificação: κ de Cohen (médio por par)	0,007 [-0,069; 0,089] (faixa -0,436 a 0,583; κ agregado da matriz: -0,033)
Inclusão de traços	0,461 [0,433; 0,490]
F1 estrutural (auditável)	0,485 [0,459; 0,511]
F1 conceitual (auditável)	0,548 [0,517; 0,578]

O κ próximo de zero é um resultado negativo e deve ser lido como tal: pela própria correção de acaso que o método promete, a concordância de classificação entre os dois grafos não excede o acaso. A matriz de confusão agregada (abaixo) explica o mecanismo: os dois lados concordam integralmente na resposta correta (72 de 72), o sistema cobre 91 dos 249 itens de erro da referência e adiciona 116 itens que a referência não registra; como a bateria é a união dos dois catálogos, a célula surpresa×surpresa é impossível por construção, não há verdadeiros negativos e o κ é estruturalmente deprimido. O achado desautoriza o uso do termo "equivalência funcional" para o instrumento atual e motivou a bateria independente de traços da campanha 3 (com verdadeiros negativos por construção; o κ comportamental medido sob o instrumento corrigido, 0,037, confirma o diagnóstico).

Matriz de confusão agregada da concordância de classificação (72 pares da campanha 1; linhas: referência; colunas: sistema).

	correto	erro previsto	surpresa
correto	72	0	0
erro previsto	0	91	158
surpresa	0	116	0 (impossível por construção)

Como verificação de robustez, uma variante simplificada do gerador (os três papéis consolidados em uma única chamada de modelo) foi avaliada em paralelo sob protocolo idêntico. Na reanálise pareada por exercício, os agentes de produção mantêm vantagem clara na completude de passos ($\Delta=+0,089$ [0,055; 0,130], p exato=0,0001) e vantagem sugestiva no F1 estrutural ($\Delta=+0,050$ [0,003; 0,106], $p=0,074$); na métrica primária, porém, nenhuma diferença foi detectada, com ponto estimado

favorável à variante simplificada ($\Delta = -0,073$ $[-0,165; 0,031]$, $p = 0,17$). A arquitetura multiagente, portanto, não demonstra vantagem de cobertura conceitual sobre a chamada única neste corpus; a comparação formal entre arquiteturas integra as ablações planejadas (Seção 7).

4.3 Caso ilustrativo

O exercício `04soccerSeason` (representar $3/4$ na reta numérica) ilustra a mecânica da comparação. O especialista catalogou três erros conceituais: $2/4$, 3 e 4. O sistema previu $2/4$, 3 e $4/4$. A Tabela 3 detalha o alinhamento.

Tabela 3: alinhamento de catálogos no exercício `04soccerSeason` (primeira réplica).

Resposta errada	Especialista	Sistema	Classificação
$2/4$	sim	sim	coberta
3	sim	sim	coberta (numerador isolado)
4	sim	não	omissão (denominador isolado)
$4/4$	não	sim	excedente; julgado válido (confusão entre total de partes e fração)
"-1", "-"	sim	não	mecânicos de interface; excluídos da contagem conceitual

A completude conceitual do exercício é $2/3 \approx 0,67$. O excedente $4/4$ foi aprovado pelo juiz, enquanto o distrator da mesma rodada (a resposta correta, $3/4$) foi rejeitado, como esperado.

4.4 Análise por exercício

A completude conceitual variou de 0,11 a 0,67 entre os 24 exercícios, com os menores valores concentrados nos exercícios de catálogos maiores e mais específicos (frações impróprias e numeradores elevados). A inspeção das omissões revela um padrão dominante: a resposta composta apenas pelo denominador (o aluno que, solicitado a marcar $3/4$, responde 4) consta do catálogo do especialista em quase todos os exercícios e raramente é prevista pelo sistema. Trata-se do diagnóstico mais acionável da campanha: uma classe única de erro, de origem plausivelmente ligada à interpretação do campo de resposta, responde por parcela substancial da lacuna de cobertura. A tabela completa por exercício integra o relatório expandido e o repositório.

4.5 QP3: plausibilidade dos excedentes segundo o modelo-juiz

A Tabela 4 consolida os julgamentos das três réplicas por origem do item. Seguindo a reanálise, as taxas são estimadas sobre itens únicos (deduplicação por exercício e âncora), com decisão por maioria entre réplicas, empates excluídos e declarados, e IC por bootstrap de exercício; a coluna de autoconsistência reporta a fração de vereditos unânimes entre os itens julgados mais de uma vez.

Tabela 4: julgamentos do modelo-juiz (GLM-4.5) por origem do item, campanha 1. Itens únicos; decisão por maioria; 498 julgamentos sobre 199 itens.

Origem do item	Itens únicos (julgamentos)	Plausíveis	IC95%	Autoconsistência
Excedentes do sistema	68 (105)	83% (55/66; 2 empates excluídos)	[74%; 91%]	0,93
Erros da referência (calibração positiva)	83 (249)	99% (82/83)	[96%; 100%]	0,99
Distrator: resposta correta (controle)	24 (72)	0%	[0%; 0%]	1,00
Distrator: valor absurdo (controle)	24 (72)	0%	[0%; 0%]	1,00

Os controles comportaram-se como o desenho exige: a calibração positiva aproximou-se do teto e ambos os distratores foram integralmente rejeitados. Nesse instrumento, 83% dos excedentes do sistema foram classificados como plausíveis PELO MODELO-JUIZ; a sensibilidade ao empate é pequena (81% com empate contado como implausível; 84% como plausível). A diferença em relação à calibração positiva (99%) não foi submetida a teste de equivalência e não se afirma proximidade estatística; a validade pedagógica dos excedentes permanece dependente da anotação humana em curso.

4.6 Importância das omissões

Das misconceptions conceituais da referência não cobertas pelo sistema (em média 50,3 por réplica na campanha 1), o juiz de importância classificou 56% como centrais, 42% como periféricas e 2% como mecânicas (média entre réplicas por exercício). Mais da metade do que o sistema omite corresponderia, portanto, a erros que um tutor precisa remediar, o que impede a leitura de que a divergência seria meramente complementar. **Esta leitura deve ser tratada como preliminar:** a Seção 4.9 demonstra que a classificação de centralidade é altamente sensível ao juiz empregado (56% sob GLM-4.5; 97 a 99% sob Mistral), e o nível confiável dessa taxa só será estabelecido pela calibração humana em curso (Seção 3.6). A conclusão qualitativa que sobrevive à sensibilidade é a direcional: uma fração não desprezível das omissões é classificada como central por ambos os juizes; se essa fração é de fato pedagogicamente relevante, só a calibração humana em curso poderá dizer.

4.7 Síntese: o veredito bidimensional

A Figura 10 posiciona o resultado agregado no plano do desfecho primário: completude conceitual de 0,376 no eixo X e plausibilidade dos excedentes de 0,83 no eixo Y (itens únicos, decisão por maioria). O sistema ocupa o quadrante "plausível segundo o juiz, porém incompleto": a maior parte do que produz é classificada como plausível pelo modelo-juiz; o quanto cobre do registro de referência permanece parcial.




Figura 10: veredito bidimensional da campanha, com intervalos de confiança de 95%. A referência de validade do especialista (0,99) e o comportamento nulo dos distratores delimitam o instrumento.

Quanto à não inferioridade formal: com um único especialista por exercício não existe banda humano-humano, o estimando NÃO É IDENTIFICADO e o teste retorna, desde a reanálise, o veredito "não estimável" (a versão anterior reportava "inconclusivo" com indicador de confiabilidade positivo, defeito apontado em revisão externa e corrigido em código com teste de regressão). Este relatório abstém-se, por desenho, de converter a completude de 0,376 em juízo de inferioridade ou aceitabilidade até que a banda seja coletada e a margem seja justificada por relevância pedagógica, não apenas pela dispersão observada.

4.8 Campanha 2: repetição interna do baseline

A reexecução integral do baseline na campanha 2 (nova infraestrutura, nova data, mesmo protocolo) constitui um teste de repetibilidade interna do experimento. A completude conceitual resultou em 0,368 [0,300; 0,442], contra 0,376 [0,309; 0,442] na campanha 1, com sobreposição quase integral dos intervalos e concordância análoga nas demais métricas. A estimativa foi, portanto, reproduzida internamente, no mesmo corpus e sob condições semelhantes; replicação independente (outra equipe, outro corpus) permanece em aberto.

4.9 Comparação entre modelos geradores

A Tabela 5 consolida as métricas dos quatro braços (média por exercício e IC95%; 24 exercícios × 3 réplicas por braço), e a Tabela 6, os julgamentos sob o juiz comum sobre itens únicos. As diferenças são pareadas por exercício contra o baseline, testadas por permutação exata com Holm por família (Seção 3.8).

Tabela 5: métricas comparativas por modelo gerador (campanha 2; média por exercício e IC95%). Todos os valores gerados por `analysis/reanalyze.mjs` ; significância na prosa e na Tabela 5b.

Métrica	Gemini 3.5 Flash (baseline)	GLM-5.2	DeepSeek V4 Pro	Claude Sonnet 5
Compleitude conceitual (primária)	0,368 [0,300; 0,442]	0,415 [0,323; 0,504]	0,371 [0,292; 0,454]	0,416 [0,339; 0,488]
Compleitude bruta	0,232 [0,188; 0,278]	0,258 [0,203; 0,313]	0,230 [0,181; 0,278]	0,258 [0,213; 0,302]
Compleitude de passos	0,508 [0,493; 0,523]	0,501 [0,479; 0,521]	0,477 [0,458; 0,496]	0,500 [0,487; 0,516]
Concordância de classificação (bruta)	0,411 [0,353; 0,478]	0,380 [0,322; 0,438]	0,345 [0,288; 0,405]	0,377 [0,330; 0,423]
Concordância de classificação (κ médio)	0,051 [-0,037; 0,151]	-0,027 [-0,115; 0,060]	-0,074 [-0,167; 0,022]	-0,033 [-0,107; 0,040]
Inclusão de traços	0,444 [0,412; 0,479]	0,475 [0,443; 0,504]	0,458 [0,437; 0,478]	0,503 [0,483; 0,526]
F1 estrutural / conceitual	0,496 / 0,562	0,479 / 0,539	0,440 / 0,495	0,471 / 0,529

Tabela 5b: testes pareados contra o baseline (permutação exata por troca de sinais; Holm por família). Família primária: m=3; família secundária, exploratória: m=12.

Comparação	Δ médio [IC95%]	p exato	p-Holm	Rejeita H0
GLM-5.2 · completude conceitual (primária)	+0,047 [-0,048; 0,143]	0,381	0,988	não
DeepSeek · completude conceitual (primária)	+0,003 [-0,089; 0,091]	0,957	0,988	não
Sonnet 5 · completude conceitual (primária)	+0,047 [-0,038; 0,142]	0,329	0,988	não
DeepSeek · completude de passos	-0,031 [-0,047; -0,015]	0,003	0,035	sim
DeepSeek · F1 estrutural	-0,056 [-0,092; -0,023]	0,005	0,052	não (limítrofe)
Sonnet 5 · inclusão de traços	+0,059 [0,017; 0,101]	0,011	0,114	não
Demais nove comparações secundárias: p-Holm $\geq$ 0,817 (íntegras em <code>analysis/derived/TABELAS.md</code>).				

Tabela 6: julgamentos sob o juiz comum da campanha 2 (Mistral Large; itens únicos, decisão por maioria, empates excluídos e declarados; IC por bootstrap de exercício).

Braço	Excedentes plausíveis (itens únicos)	IC95%	Calibração positiva	Omissões centrais
Gemini 3.5 Flash (baseline)	74% (67 itens; 1 empate)	[62; 86]	83% [74; 91]	97%
GLM-5.2	78% (96 itens; 2 empates)	[70; 85]	84% [77; 91]	98%
DeepSeek V4 Pro	73% (127 itens; 1 empate)	[65; 81]	83% [76; 90]	99%
Claude Sonnet 5	73% (103 itens; 2 empates)	[67; 81]	82% [75; 89]	98%

Quatro observações resumem a comparação. Primeira, e central: **nenhuma diferença de completude conceitual foi detectada entre os quatro modelos com a amostra disponível** (todas as diferenças pareadas cruzam zero; p-Holm de 0,988 nas três comparações primárias). O resultado é compatível com a hipótese de que o teto de cobertura pertence ao procedimento de amostragem única, e não ao modelo; ele NÃO estabelece equivalência entre modelos, pois nenhum teste de equivalência foi executado e os intervalos das diferenças admitem efeitos de até 14 pontos percentuais. Segunda: há um padrão sugestivo de porte, com os dois modelos maiores no topo (0,416 e 0,415) e os dois menores

na base (0,368 e 0,371), efeito pequeno e não significativo com o presente n. Terceira: sob a permutação exata com Holm, sobrevive exatamente UM resultado: a inferioridade do DeepSeek na completude de passos ($\Delta=-0,031$, $p\text{-Holm}=0,035$); o F1 estrutural do DeepSeek fica limítrofe ($p\text{-Holm}=0,052$) e a melhora de inclusão de traços do Sonnet 5, significativa isoladamente ($p=0,011$), não sobrevive ($p\text{-Holm}=0,114$). A reanálise substitui o quadro da versão 2.1, na qual três inferioridades do DeepSeek exibiam o mesmo $p\text{-Holm}=0,0105$, artefato do piso de resolução do procedimento bootstrap então empregado. Quarta: no julgamento comum, o GLM-5.2 obteve a maior taxa de excedentes plausíveis (78% [70; 85], contra 74% [62; 86] do baseline), com ampla sobreposição dos intervalos.

Registra-se, ainda, a sensibilidade do instrumento de julgamento: o juiz da campanha 2 (Mistral) mostrou-se sistematicamente mais rígido que o da campanha 1 (GLM-4.5), tanto na calibração positiva (82 a 84%, contra 99%) quanto na classificação de centralidade das omissões (97 a 99%, contra 56%). As comparações entre braços permanecem válidas por compartilharem a régua; níveis absolutos entre campanhas e entre juízes, não. Nenhuma conclusão deste relatório depende de um único juiz para comparação entre braços, mas os NÍVEIS absolutos de plausibilidade devem ser lidos como "segundo o modelo-juiz declarado"; a âncora externa virá da anotação humana em curso (Seção 3.6).

4.10 Anatomia da lacuna de cobertura e efeito de agregação

A classificação dos 83 erros conceituais únicos da referência por tipo, cruzada com a cobertura do baseline (Tabela 7), revela que a lacuna não é difusa: concentra-se em uma classe específica. A tabela desta versão é gerada automaticamente dos dados brutos e substitui a da versão 2.1, cujo total de execução única (47%) não era reproduzível de nenhuma definição testada (a reconciliação completa está em `analysis/derived/TABELAS.md`); o valor auditado é 37%, coerente com a completude média, e a união de três réplicas confirma os 64%.

Tabela 7: cobertura por tipo de erro da referência (braço baseline, campanha 2; 83 instâncias conceituais únicas). "1 execução" é a média das três execuções isoladas; "união de 3", a cobertura por qualquer réplica.

Tipo de erro no catálogo de referência	Ocorrências	Cobertura (1 execução)	Cobertura (união de 3)
Fração incorreta (ex.: 2/4 quando a resposta é 3/4)	30	39%	73%
Numerador isolado (ex.: "3")	24	50%	79%
Denominador isolado (ex.: "4")	24	14%	33%
Outros inteiros	5	73%	80%
Total	83	37%	64%

Dois mecanismos distintos explicam a lacuna. O primeiro é **amostragem**: a união de apenas três execuções eleva a cobertura agregada de 37% para 64% (27 pontos percentuais, fechando cerca de

43% da distância até a cobertura total), e a do numerador isolado de 50% para 79%. Os agentes geram catálogos parcialmente disjuntos a cada execução, como observações independentes. O segundo é um **ponto cego qualitativo**: a resposta composta apenas pelo denominador, presente no catálogo da referência em praticamente todos os exercícios, é raramente prevista (14% em execução única; 33% mesmo na união) por qualquer um dos quatro modelos. Trata-se de um erro de natureza pragmática (interpretação do campo de resposta pela criança), e não matemática; uma hipótese alternativa, não descartável com os dados atuais, é a assimetria informacional do protocolo: o autor da referência via a interface real do CTAT, enquanto os agentes recebem uma serialização textual dela. A ablação com representação visual foi executada na campanha 3 (Seção 4.11), com resultado misto: cobertura por valor inalterada, mas concordância comportamental maior (+0,056, $p\text{-Holm}=9,6\times 10^{-4}$ na família exploratória).

A revisão de 2026-07-10 acrescentou a medição controlada do mecanismo de amostragem: a **curva de saturação do ensemble**. Para cada exercício, o agente de misconceptions foi executado cinco vezes de forma independente, e a cobertura conceitual acumulada foi calculada para cada K de 1 a 5 (média sobre as rotações da ordem, eliminando o viés de sequência). A curva resultante, média dos 24 exercícios, é côncava e ainda crescente em K=5: 31,3% (K=1), 43,2% (K=2), 48,9% (K=3), 52,6% (K=4) e 55,6% (K=5). O maior ganho marginal ocorre de K=1 para K=2 (+11,9 pontos) e decai monotonicamente (+5,7; +3,7; +2,9), sugerindo ponto de operação prático entre K=3 e K=4 e confirmando, sob protocolo controlado, que a execução única deixa na mesa uma fração substancial de candidatos que o próprio agente é capaz de produzir. A escolha do K operacional não deve maximizar apenas cobertura: a curva completa com plausibilidade dos adicionais, custo e carga de revisão por K integra as ablações planejadas. Os dados da curva integram o repositório (resultados/).

4.11 Campanha 3: o vazamento quantificado e o freio do prompt

Sob a entrada independente, a completude conceitual do baseline caiu de 0,376 [0,309; 0,442] para **0,243 [0,163; 0,324]**. A anatomia por tipo de erro localiza a diferença: a previsão de frações incorretas não mudou (39% nas duas condições de entrada), enquanto a de valores isolados desabou (numerador de 50% para 24%; outros inteiros de 73% para 0%). Uma causa plausível e localizada é a remoção dos KCs da entrada, que eram extraídos das regras de produção do grafo (nomes como `IdenNumerator` e `IdenDenominator`) e sinalizavam a existência de passos de identificação isolada. A leitura correta do contraste, porém, é a modesta: sob o protocolo v2, que removeu os KCs derivados do grafo E mudou simultaneamente a fonte e o idioma da entrada, a cobertura foi 13,3 pontos menor; a diferença é entre PROTOCOLOS, e não identifica isoladamente a contribuição de cada mudança. A anatomia

por categoria torna a explicação dos KCs a mais plausível, e a ablação que isola cada fator está declarada como trabalho futuro.

Desfechos coprimários (o resultado central da campanha). Pelo dicionário de métricas congelado antes da execução, os desfechos coprimários da campanha 3 são comportamentais: o reconhecimento das ações de erro da referência no estado correspondente (R_bug) e a conclusão dos traços corretos da referência (R_ok), ambos medidos pela bateria congelada sobre o executor de traços, com o nível de correspondência declarado por lado. O resultado é o achado mais importante do estudo e deve ser lido de frente: **a conformidade comportamental do grafo gerado com o grafo de referência é baixa.** No baseline, R_bug=0,065 [0,020; 0,113] e R_ok=0 (nenhum traço correto completo da referência é aceito passo a passo, em NENHUM dos nove braços); o κ da bateria independente, agora com verdadeiros negativos, fica em 0,037 [0,034; 0,039]. A anatomia item a item atribui o resultado à distância de granularidade e de ordem entre os ~4 passos conceituais do grafo gerado e os ~8 micropassos de interface da referência: mesmo cobrindo valores de erro, o grafo gerado não conduz um aluno que segue o caminho da referência até o fim, nem reconhece o erro NO passo em que a referência o espera. Cobertura de valores, o desfecho histórico, mede outra coisa e fica registrada como secundária.

Tabela 8a: desfechos coprimários comportamentais por condição (média por exercício, IC95%; bateria congelada; níveis de correspondência: referência exata, gerado por âncora de input).

Condição	R_bug (erros em contexto)	R_ok (traços corretos)	Concordância
Baseline (Gemini)	0,065 [0,020; 0,113]	0	0,275 [0,254; 0,296]
GLM-5.2	0,048 [0,019; 0,080]	0	0,299 [0,257; 0,343]
DeepSeek V4 Pro	0,027 [0,013; 0,044]	0	0,284 [0,255; 0,311]
Limite de 6 candidatos	0,094 [0,037; 0,157]	0	0,276 [0,253; 0,297]
Screenshot	0,030 [0,012; 0,049]	0	0,331 [0,311; 0,353]

Demais condições no repositório (`analysis/derived/TABELAS-C3.md`). Entre braços de modelo, nenhuma diferença coprimária detectada ($p\text{-Holm} \geq 0,44$).

Tabela 8b: campanha 3 (protocolo v2), completude conceitual por condição (média por exercício, IC95%; 3 réplicas; zero falha de autoria). Testes pareados contra o baseline por permutação exata; Holm por família declarada (ablações: $m=6$).

Condição	Completude conceitual	Δ vs baseline [IC95%]	p-Holm
Baseline (Gemini, envelope independente)	0,243 [0,196; 0,290]	—	—
GLM-5.2	0,178 [0,122; 0,236]	-0,065	n.s.
DeepSeek V4 Pro	0,199 [0,143; 0,260]	-0,044	n.s.
Limite de 6 candidatos (em vez de 2 a 3)	0,419 [0,342; 0,495]	+0,177 [0,123; 0,233]	$2,4 \times 10^{-5}$
Saturação ("liste todas as plausíveis")	0,238 [0,171; 0,307]	-0,005	n.s.
Catálogo interno ligado (MISC_DB)	0,215 [0,152; 0,282]	-0,028	n.s.
Representação DOM	0,207 [0,134; 0,279]	-0,036	n.s.
Representação com screenshot	0,251 [0,180; 0,324]	+0,008	n.s.
Chamada única (sem multiagente)	0,203 [0,147; 0,264]	-0,040	n.s.

Da família de seis ablações, exatamente UMA sobrevive à correção: elevar o alvo numérico do prompt de 2 a 3 para 6 candidatos quase dobra a cobertura (+17,7 pontos, $p\text{-Holm}=2,4\times 10^{-5}$). O efeito do limite pede duas qualificações: a condição também recebeu maior orçamento de saída (4,1 candidatos por exercício contra ~ 2 do baseline), e o ganho NÃO se transfere ao desfecho coprimário (R_bug de 0,094 contra 0,065; diferença não detectada), então o achado demonstra alavanca de cobertura por valor, não melhoria comportamental global. Nos demais contrastes de cobertura, nenhuma diferença foi detectada com a amostra disponível: catálogo interno (que a auditoria da campanha revelou estar efetivamente INERTE nas campanhas anteriores, por defeito de normalização de acento na chave de disciplina, de modo que a cobertura histórica não pode ser atribuída a ele), instrução aberta de saturação (o agente segue produzindo ~ 2 candidatos; para este gerador, alvo quantitativo explícito funciona e instrução aberta não), DOM, screenshot e chamada única. Na família exploratória comportamental, porém, o screenshot AUMENTOU a concordância de vereditos (+0,056, $p\text{-Holm}=9,6\times 10^{-4}$): ver a interface não muda quais valores o agente prevê, mas muda como o grafo responde à bateria; o efeito merece investigação própria.

A curva de ensemble sobre o envelope independente reproduz o mecanismo de amostragem: 24% em $K=1$, 35% em $K=3$, 42% em $K=6$ e 47% em $K=10$, ainda crescente. Combinada ao efeito do limite (0,42 com uma única execução de alvo 6), a engenharia de recuperação de cobertura fica quantificada em duas alavancas independentes e baratas. As métricas comportamentais (bateria congelada, executor de traços) confirmaram o quadro entre braços (nenhuma diferença entre famílias de modelo; $p\text{-Holm}\geq 0,44$) e expuseram com honestidade a distância de granularidade entre o grafo gerado e o de referência: no nível de correspondência declarado, o reconhecimento de erros em contexto fica em 0,06 e nenhum traço correto completo da referência é aceito passo a passo, anatomia registrada item a item nos relatórios.

O painel de três juízes sobre os mesmos 179 itens congelados entregou concordância entre famílias de substancial a moderada: κ de 0,72 (Mistral $\times$ Qwen), 0,70 (Mistral $\times$ Llama) e 0,55 (Qwen $\times$ Llama), com zero itens sem veredito. Nenhuma conclusão de julgamento desta campanha depende de um único juiz; a calibração humana (anotação em curso) dirá qual família julga mais próximo de uma pessoa.

5 Discussão

Três leituras emergem dos resultados. Primeira: **a separação entre estrutura e conteúdo funcionou**. Ao confinar a criatividade dos LLMs ao conteúdo pedagógico e delegar a estrutura a um montador determinístico, o pipeline impede as violações cobertas pelas invariantes implementadas, resultado

corroborado pelos testes de propriedades e pela campanha (QP1). A implicação prática é imediata: a discussão de qualidade desloca-se integralmente para o plano do conteúdo.

Segunda: **a maior parte do que o sistema produz é classificada como plausível pelo modelo-juiz, e parte do excedente pode constituir enriquecimento.** A plausibilidade de 83% dos excedentes (itens únicos, juiz cego com controles íntegros) sugere que o sistema não infla o catálogo com ruído óbvio; previu, em diversos exercícios, candidatos ausentes do registro humano. A confirmação de que esses candidatos são pedagogicamente válidos, porém, depende de anotação humana, ainda em curso. Sob a métrica simétrica tradicional, esse enriquecimento teria sido contabilizado como defeito, o que reforça a adequação da função de perda direcional adotada.

Terceira: **a lacuna de cobertura é real e diagnosticável.** A completude de 0,376, combinada à classificação preliminar de 56% das omissões como centrais (estimativa altamente sensível ao juiz; Seção 4.9), desaconselha a leitura de complementaridade inócua. O padrão do denominador isolado (Seção 4.4) sugere que parcela substancial da lacuna provém de uma classe específica e endereçável de erro, ligada à interpretação pragmática do campo de resposta, dimensão em que a experiência de sala de aula do especialista excede a simulação atual. A lacuna, contudo, ainda carece de régua: sem a banda interespecialistas, não se sabe que fração do catálogo um segundo humano cobriria.

A campanha 2 acrescenta uma quarta leitura: **os resultados são compatíveis com a hipótese de que o teto de cobertura pertence ao procedimento, não ao modelo,** sem que isso estabeleça equivalência entre modelos (Seção 4.9). Quatro famílias independentes de LLM, incluindo dois modelos de maior porte, produziram completudes na mesma faixa, nenhuma diferença primária foi detectada, e o único contraste que sobrevive à correção (a completude de passos do DeepSeek) não toca a métrica primária. Duas explicações alternativas para a convergência permanecem em aberto e são alvo de ablação: o catálogo interno e o limite de candidatos do prompt, comuns aos quatro braços, podem induzir convergência artificial. Combinada à evidência de agregação (37% para 64% com três execuções) e à anatomia da lacuna, a comparação multimodelo sugere, como decisão de engenharia provisória, manter o modelo mais eficiente e atacar a cobertura por agregação de execuções e pelo enriquecimento dirigido da geração, não por troca de modelo.

A campanha 3 reordena a leitura do estudo. O resultado central é comportamental e é baixo: o grafo gerado cobre parte dos VALORES de erro da referência, mas não reproduz o COMPORTAMENTO dela ($R_{ok}=0$; $R_{bug}=0,065$), sobretudo por granularidade e ordem dos passos. Sobre as suspeitas da revisão externa: o contraste entre protocolos (13,3 pontos de cobertura) é compatível com vazamento pela entrada antiga, com os KCs como explicação mais plausível pela anatomia por categoria, mas

fonte, KCs e idioma mudaram juntos e a atribuição causal exata fica para a ablação futura; a dependência do catálogo interno não foi detectada (e ele estava inerte nas campanhas anteriores); o alvo numérico do prompt é a única alavanca de cobertura confirmada (+17,7 pontos, sob maior orçamento de saída e sem ganho coprimário detectável); e a representação visual não moveu cobertura, mas aumentou a concordância comportamental, resultado misto que mantém a hipótese de affordance viva no plano do comportamento. O caminho de engenharia continua barato e mensurável, agora com a régua certa: qualquer melhoria futura deve ser cobrada nos desfechos coprimários, não apenas na cobertura por valor.

Cabe ainda registrar uma lição metodológica: parcela expressiva do déficit inicialmente aferido decorreu de artefatos de medição (grafias distintas do mesmo valor, erros mecânicos contabilizados como conceituais, divergência de âncora entre módulos), corrigidos ao longo das revisões adversariais sem qualquer alteração nos agentes. Em avaliação de sistemas generativos, o refinamento do instrumento precede legitimamente o refinamento do sistema.

6 Ameaças à validade e limitações

Validade de construto. A operacionalização de misconception como VALOR canônico de resposta errada mede coincidência de valores, não de raciocínios: raciocínios distintos podem produzir o mesmo valor, a mesma regra cognitiva produz valores diferentes em exercícios diferentes, e o valor final não informa o passo nem a estratégia. A leitura correta da métrica primária é "cobertura de valores de respostas erradas do catálogo de referência". A representação por regra, passo e trajetória, com codificação humana às cegas, integra a agenda futura. A completude depende ainda do casamento por âncora semântica; formas de resposta não previstas pela canonicalização podem gerar falsos negativos. A anotação humana em curso e os testes de regressão da âncora mitigam, sem eliminar, o risco. Uma análise de sensibilidade quantifica o efeito do refinamento semântico: recomputando a completude conceitual com a âncora crua (sem redução de frações equivalentes), a média move-se de 0,376 para 0,347 ($\Delta=0,029$; cálculo integrado ao script gerador, entrada "sensibilidade da âncora" em `analysis/derived/TABELAS.md`), indicando que o resultado principal não é artefato do refinamento; a validação em conjunto verdadeiramente reservado permanece dependente do segundo template (Seção 7). O juiz de plausibilidade é um LLM: apesar do cegamento, da família distinta e dos controles por rodada, sua calibração definitiva contra julgamento humano (kappa) permanece em execução.

Validade interna. O protocolo de envelopes é verificado mecanicamente e o teste de vazamento inclui controle negativo, mas a blindagem é PARCIAL: o Envelope A deriva do mesmo arquivo que contém o grafo de referência e o teste é lexical (Seção 3.3). Há ainda assimetria informacional entre as condições: o autor da referência via a interface real, enquanto os agentes recebem uma serialização textual dela, o que pode explicar parte do ponto cego pragmático (Seção 4.10). A resposta correta no Envelope A é decisão declarada de desenho. As réplicas e os intervalos reportados absorvem a estocasticidade dos agentes; falhas de chamada e acionamentos de contingência não foram registrados nas campanhas 1 e 2; a campanha 3 corrigiu a lacuna com manifesto por chamada (zero falha de autoria em 648 execuções).

Validade externa. O corpus restringe-se a um domínio (frações na reta numérica), um ÚNICO template de interface, uma faixa etária, um idioma e um autor de referência, em 24 exercícios. Para generalização entre interfaces, o suporte efetivo aproxima-se de $N=1$: variações do mesmo template não criam diversidade de interface. Toda conclusão deste relatório vale para os exercícios e o template estudados; a extensão a outros domínios, interfaces e populações requer replicação com novos corpora e novos especialistas; o pacote publicado facilita a reexecução do protocolo. Os resultados quantitativos aplicam-se aos modelos e versões da Tabela 1.

Comparabilidade entre juízes. Os níveis absolutos de julgamento diferem entre os juízes das duas campanhas (GLM-4.5 e Mistral Large), como documentado na Seção 4.9; nenhuma conclusão deste relatório compara níveis absolutos entre campanhas, e a calibração humana em curso fornecerá a âncora externa.

Validade de conclusão estatística. Com um especialista por exercício, a não inferioridade não é estimável, e assim é reportada. As comparações pareadas usam o exercício como unidade, permutação exata por troca de sinais e Holm por família declarada (Emenda 3 do plano de análise); as afirmações de significância refletem exclusivamente os valores desta reanálise. Ausência de significância não é evidência de equivalência; nenhuma alegação de equivalência é feita.

7 Trabalhos futuros

1. **Banda interespecialistas:** coleta com dois a três especialistas adicionais autorando, às cegas entre si, cerca de dez exercícios do corpus, para estimar a banda humano-humano nas duas direções, derivar a margem pré-registrada e decidir a não-inferioridade. É a frente prioritária.

2. **Calibração humana do juiz:** conclusão da anotação independente e reporte do kappa juiz-humano.
3. **Cobertura por agregação (ensemble):** executar o agente de misconceptions múltiplas vezes e agregar os catálogos por âncora. A hipótese conta com evidência direta em dois estimadores (Seção 4.10): a união de três réplicas completas da campanha (37% para 64%) e a curva de saturação controlada do agente de erros (31% em $K=1$ a 56% em $K=5$, ainda crescente), com ponto de operação sugerido em $K=3$ a 4. Resta formalizar o ensemble como modo de autoria da plataforma e decidir K pela curva de custo. Em paralelo, o ponto cego do denominador isolado orienta o enriquecimento dirigido do prompt do agente de erros (categoria de erros pragmáticos de interface) em campanha subsequente, com o sistema devidamente reversionado.
4. **EXECUTADO (campanha 3):** Envelope A independente com teste metamórfico, esquema v2 com executor de traços, bateria independente congelada e mutation testing do verificador. Permanecem futuras: a execução dos grafos no runtime real do CTAT e a ablação que isole os fatores confundidos do contraste entre protocolos (KCs, idioma e fonte da entrada).
5. **EXECUTADAS (campanha 3):** as ablações de catálogo, limite, saturação, DOM, screenshot e chamada única, e o painel de três famílias de juízes. Permanecem futuras: KCs presentes contra ausentes (isolamento do confundidor) e baselines sem LLM com o mesmo orçamento de candidatos.
6. **Nível 3:** avaliação de eficácia com alunos reais (curvas de aprendizagem sob AFM; Cen; Koedinger; Junker, 2006), fora do escopo da presente campanha.

8 Conclusão

Neste corpus de 24 exercícios derivados de um único template, o sistema cobriu 37,6% (IC95% de 0,309 a 0,442) dos valores canônicos de respostas erradas presentes no catálogo de um especialista de referência, taxa que a união de três execuções eleva a 64% e que nenhuma troca de modelo, entre quatro famílias testadas, alterou de forma detectável. A montagem determinística não apresentou violação das invariantes estruturais implementadas, em 72 grafos de campanha e 10.000 grafos de teste. Um modelo-juiz cego classificou 83% dos erros excedentes como plausíveis, com taxas sensíveis à identidade do juiz e ainda não calibradas contra avaliadores humanos. A concordância de classificação de respostas corrigida pelo acaso ficou próxima de zero, resultado negativo que expõe a limitação da bateria autorreferente e motiva a bateria independente de traços. A anatomia das omissões identifica uma classe dominante e acionável (a resposta composta apenas pelo denominador), com

duas explicações candidatas separáveis por ablação (lacuna de simulação pragmática ou assimetria informacional da entrada textual).

O que este estudo NÃO estabelece, por desenho: a qualidade do grafo completo (dicas, remediações e múltiplos caminhos não são comparados), a equivalência funcional entre tutores, a não inferioridade em relação a especialistas (não estimável sem banda humano-humano), a validade pedagógica dos excedentes e qualquer efeito sobre aprendizagem. Esses níveis exigem, respectivamente, a comparação baseada em traços sobre o esquema ampliado, a bateria independente, a coleta com múltiplos especialistas, a anotação humana e o estudo com estudantes, todos especificados como fases futuras. Os resultados atuais são compatíveis, no domínio e no template estudados, com o uso do sistema como FERRAMENTA DE APOIO à autoria, com revisão humana, e não como substituto do especialista. A campanha 3, sob protocolo integralmente congelado antes da execução e entrada independente do grafo de referência, mediu pela primeira vez os desfechos coprimários comportamentais e entregou o resultado central do estudo: a conformidade comportamental é baixa ($R_{\text{bug}}=0,065$; $R_{\text{ok}}=0$), com anatomia identificada na granularidade e na ordem dos passos. A cobertura por valor sob o protocolo v2 é 0,243 (13,3 pontos abaixo do protocolo anterior, contraste que não isola causa); o alvo numérico do prompt é a única alavanca de cobertura que sobrevive à correção (+17,7 pontos, sob maior orçamento de saída e sem ganho coprimário detectável); a representação com screenshot aumentou a concordância comportamental; e o painel de três famílias de juízes apresentou concordância de moderada a substancial. O experimento completo, com corpus, dados brutos congelados das três campanhas, manifestos de execução com custo por chamada, reanálises verificadas em sala limpa, código e documentação, está publicado para reprodução e extensão independentes.

Disponibilidade de dados e código

O repositório github.com/Joaoqueiroz-silva/sti-graph-validation contém o código integral do experimento, o corpus de 24 exercícios (`.brd` e interface), a base de dados com os envelopes A e B por exercício, os relatórios brutos das três campanhas (nove da campanha 1, vinte e quatro da campanha 2 multimodelo e vinte e sete da campanha 3, esta com manifestos de execução por chamada, curva de ensemble e painel de juízes) com os agregados estatísticos, as reanálises geradoras de todos os números desta versão (`analysis/`), a metodologia, o dicionário formal de métricas, o plano de análise com as Emendas 1 a 4 datadas e as instruções de reprodução (Node.js 18+ e uma credencial OpenRouter; aproximadamente US\$ 1 por corrida completa). A análise estatística usa

mente fixa e é exatamente reproduzível a partir dos dados publicados; a tag `legacy-campaigns-2026-07` preserva, com manifesto SHA-256, o estado exato que produziu as versões anteriores deste relatório.

Declarações

Conflito de interesses. O autor é fundador da plataforma EducaOFF, cujo pipeline de autoria é o sistema sob avaliação. O desenho com dados brutos públicos, números gerados por script auditável, verificação independente da reanálise e classificação exploratória explícita visa mitigar, sem eliminar, o viés de interesse; replicação por terceiros é bem-vinda e o pacote facilita a reexecução do protocolo.

Financiamento. [A preencher: fonte de financiamento ou declaração de ausência.]

Contribuições e uso de inteligência artificial. Concepção, decisão metodológica e supervisão: o autor. Modelos de linguagem são objeto de estudo deste trabalho e foram também empregados como ferramenta de engenharia, análise e apoio à redação, sob revisão e responsabilidade integral do autor; os julgamentos automatizados reportados são resultados experimentais, nunca decisões editoriais.

Ética. O estudo não envolve seres humanos, dados pessoais ou dados de alunos; a fase futura com especialistas e estudantes será submetida à apreciação ética cabível.

Proveniência do corpus. Os 24 arquivos `.brd` e a interface foram autorados na ferramenta CTAT (Carnegie Mellon) [completar: autor do corpus, instituição, licença de redistribuição e data]; hashes SHA-256 de todos os artefatos estão versionados no repositório.

Referências

- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; KOEDINGER, K. R. A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, v. 19, n. 2, p. 105-154, 2009.
- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; VAN VELSEN, M.; POPESCU, O.; DEMI, S.; RINGENBERG, M.; KOEDINGER, K. R. Example-tracing tutors: intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, v. 26, n. 1, p. 224-269, 2016.
- AMIDEI, J.; PIWEK, P.; WILLIS, A. Rethinking the agreement in human evaluation tasks. In: *Proceedings of COLING 2018*. Santa Fe: ACL, 2018.
- BROWN, J. S.; BURTON, R. R. Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, v. 2, n. 2, p. 155-192, 1978.

- GUPTA, K. D.; HAQUE, M. A.; ALI, H.; KAMAL, M.; ALAM, S. B.; RAHMAN, M. A. Continuous monitoring of large-scale generative AI via deterministic knowledge graph structures. *arXiv preprint* arXiv:2509.03857, 2025.
- CEN, H.; KOEDINGER, K. R.; JUNKER, B. Learning Factors Analysis: a general method for cognitive model evaluation and improvement. In: *Intelligent Tutoring Systems*. Berlin: Springer, 2006.
- HE, X.; WU, D.; ZHAI, Y.; SUN, K. SentinelAgent: graph-based anomaly detection in multi-agent systems. *arXiv preprint* arXiv:2505.24201, 2025.
- HOSKING, T.; BLUNSOM, P.; BARTOLO, M. Human feedback is not gold standard. In: *ICLR 2024*. 2024.
- LAKENS, D. Equivalence tests: a practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, v. 8, n. 4, p. 355-362, 2017.
- LAKENS, D.; SCHEEL, A. M.; ISAGER, P. M. Equivalence testing for psychological research: a tutorial. *Advances in Methods and Practices in Psychological Science*, v. 1, n. 2, p. 259-269, 2018.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159-174, 1977.
- PANICKSSERY, A.; BOWMAN, S. R.; FENG, S. LLM evaluators recognize and favor their own generations. In: *NeurIPS 2024*. 2024.
- SANSFORD, H.; RICHARDSON, N.; MARETIC, H. P.; SAADA, J. N. GraphEval: a knowledge-graph based LLM hallucination evaluation framework. *arXiv preprint* arXiv:2407.10793, 2024.
- SANFELIU, A.; FU, K. S. A distance measure between attributed relational graphs for pattern recognition. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 13, n. 3, p. 353-362, 1983.
- SHAVELSON, R. J.; WEBB, N. M. *Generalizability Theory: a primer*. Newbury Park: Sage, 1991.
- TVERSKY, A. Features of similarity. *Psychological Review*, v. 84, n. 4, p. 327-352, 1977.
- VANGALA, B. P.; MAHMUD, S.; NEUPANE, P.; SELVARAJ, J.; CHENG, J. HalluMat: detecting hallucinations in LLM-generated materials science content through multi-stage verification. *arXiv preprint* arXiv:2512.22396, 2025.
- VAN GLABBEEK, R. J. The linear time-branching time spectrum I. In: *Handbook of Process Algebra*. Amsterdam: Elsevier, 2001. p. 3-99.
- VANLEHN, K. *Mind Bugs: the origins of procedural misconceptions*. Cambridge: MIT Press, 1990.
- ZHANG, K.; HU, M.; LE, H. A. D.; TORSHA, F. K.; JIANG, Z.; BUI, M. K.; CHANG, C.-Y.; CHUANG, Y.-N.; XIONG, Z.; LIN, Y.; WANG, G.; ZOU, N. A survey on evaluating quality and trustworthiness in LLM-generated data. *arXiv preprint* arXiv:2601.17717, 2026.
- ZHANG, K.; SHASHA, D. Simple fast algorithms for the editing distance between trees and related problems. *SIAM Journal on Computing*, v. 18, n. 6, p. 1245-1262, 1989.

Dados brutos das duas campanhas versionados em **resultados/** no repositório do experimento.