

Geração por LLM de catálogos candidatos de respostas erradas e montagem determinística de grafos de comportamento: estudo exploratório em exercícios de frações

João Carlos Queiroz

EducaOFF / STI Unplugged · contato@educaoff.com.br

Versão 3.4, 14 de julho de 2026 (campanhas exploratórias: 2, 8 a 10 e 13 de julho; auditoria corretiva: 14 de julho) · Dados e código: github.com/Joaoqueiroz-silva/sti-graph-validation (a versão 3.3 permanece preservada no histórico)

RESUMO. Este estudo exploratório avalia grafos de comportamento produzidos por um pipeline que combina agentes baseados em modelos de linguagem de grande porte (LLMs) para conteúdo e montagem determinística. O corpus contém 24 exercícios de frações na reta numérica derivados de um único template e um único grafo CTAT de referência por exercício. A terceira campanha (C3) é o experimento principal: os estimandos foram pré-especificados, o executor foi finalizado após um smoke test e antes das corridas analíticas, e a entrada dos agentes foi construída sem ler o conteúdo do grafo de referência. Em 648 autorias não ocorreu violação estrutural dura; 62 grafos (9,6%) acionaram sinal mole, concentrado na condição de seis candidatos (61/72). A conformidade comportamental com a referência foi baixa: no baseline, o reconhecimento de ações buggy no estado correspondente foi $R_{\text{bug}}=0,054$ (IC95% 0,016 a 0,095) usando todas as 192 ações pré-especificadas, e nenhum traço correto foi aceito integralmente passo a passo em qualquer braço ($R_{\text{ok}}=0$). A versão ancorável de R_{bug} , que exclui 42 ações mecânicas, foi 0,065 (0,020 a 0,113) e é reportada como sensibilidade. A cobertura por valor, secundária, foi 0,243 (0,163 a 0,324). Pedir seis candidatos elevou essa cobertura em 17,7 pontos ($p\text{-Holm}=2,4\times 10^{-5}$), mas não demonstrou ganho comportamental e coincidiu com alta incidência de sinais moles. Nas campanhas históricas, um único modelo-juiz classificou 83% dos excedentes como plausíveis; a auditoria mostrou que o painel multijuiz posterior omitiu todos os excedentes do sistema, de modo que essa confirmação foi retirada até nova execução. O trabalho sustenta um protocolo piloto reproduzível e um resultado negativo de conformidade neste corpus; não estabelece benchmark, não inferioridade a especialistas, validade pedagógica dos excedentes nem eficácia educacional.

PALAVRAS-CHAVE: sistemas tutores inteligentes; grafos de comportamento; example-tracing; agentes de LLM; estudo exploratório; misconceptions; juiz de LLM.

ABSTRACT. This exploratory study evaluates behavior graphs produced by a pipeline that combines large language model (LLM) agents for content with deterministic assembly. The corpus comprises 24 fraction number-line exercises derived from a single template and one CTAT reference graph per exercise. The third campaign (C3) is the main experiment: estimands were prespecified, the executor was finalized after a smoke test and before analytical runs, and agent input was built

without reading reference-graph content. Across 648 authoring runs, no hard structural violation occurred; 62 graphs (9.6%) triggered a soft signal, concentrated in the six-candidate condition (61/72). Behavioral conformity with the reference was low. In the baseline, in-state recognition of buggy actions was $R_{\text{bug}}=0.054$ (95% CI 0.016 to 0.095) over all 192 prespecified actions, and no correct trace was accepted completely step by step in any arm ($R_{\text{ok}}=0$). An anchorable R_{bug} excluding 42 mechanical actions was 0.065 (0.020 to 0.113) and is reported as a sensitivity analysis. Secondary value coverage was 0.243 (0.163 to 0.324). Requesting six candidates increased value coverage by 17.7 points (Holm-adjusted $p=2.4\times 10^{-5}$), but did not demonstrate behavioral improvement and coincided with frequent soft structural signals. In historical campaigns, one LLM judge rated 83% of surplus errors as plausible; an audit found that the later multi-judge panel omitted every system surplus, so that confirmation is withdrawn pending rerun. The study supports a reproducible pilot protocol and a negative conformity result for this corpus; it does not establish a benchmark, expert non-inferiority, pedagogical validity of surpluses, or educational effectiveness.

KEYWORDS: intelligent tutoring systems; behavior graphs; example-tracing; LLM agents; exploratory study; misconceptions; LLM-as-judge.

1 Introdução

Sistemas tutores inteligentes (STIs) do paradigma *example-tracing* (Alevén et al., 2009, 2016) reagem ao aluno de forma diagnóstica: reconhecem qual erro específico foi cometido, oferecem a remediação correspondente e dosam dicas em níveis progressivos. Essa capacidade depende de uma estrutura subjacente por exercício, o **grafo de comportamento**, que codifica o caminho de resolução correto, os erros conceituais previstos (misconceptions) e, para cada erro, o desvio de remediação (*scaffold*) que devolve o aluno ao caminho. A Figura 1 ilustra a anatomia dessa estrutura em um exercício de frações.




Figura 1: anatomia de um grafo de comportamento. O eixo horizontal contém o caminho de resolução correto; o desvio inferior representa uma misconception com sua remediação, formando um ciclo legítimo de retorno ao passo; o bloco superior representa a cadeia de dicas.

A autoria manual desses grafos é reconhecidamente o gargalo de escala do paradigma: mesmo com ferramentas maduras como o CTAT (Cognitive Tutor Authoring Tools, Carnegie Mellon), produzir um grafo rico para cada exercício exige tempo de especialista. A plataforma EducaOFF automatiza essa autoria com um pipeline de agentes de LLM. A automação, porém, desloca o problema para a qualidade do que é gerado. Este relatório NÃO pergunta se os grafos gerados equivalem aos de especialistas em geral (pergunta que exigiria múltiplos especialistas, margem justificada e dados de alunos); pergunta algo mais estreito e respondível com os dados disponíveis: **em que medida o sistema reconstrói os comportamentos registrados em grafos CTAT de referência, mantendo integridade estrutural e estabilidade, e que propriedades objetivas têm os comportamentos que ele adiciona?**

A pergunta é menos trivial do que aparenta, porque não existe um único grafo correto por exercício. Dois especialistas competentes produzem grafos distintos e igualmente defensáveis, e parte da discordância entre avaliadores qualificados reflete ambiguidade legítima da tarefa, não ruído (Amidei; Piwek; Willis, 2018). A validação, portanto, não pode assumir o grafo humano como gabarito absoluto. Este relatório enfrenta essa dificuldade com um desenho de três componentes: (i) verificação estrutural que independe de gabarito; (ii) comparação direcional contra um especialista sob protocolo de autoria cega; e (iii) julgamento pedagógico cego das divergências, em ambas as direções.

As contribuições deste relatório são:

1. um protocolo v2 de **autoria cega com entrada proveniente da interface**, independente das saídas geradas e do conteúdo do grafo CTAT usado na comparação, acompanhado de teste metamórfico de separação;

2. dois **desfechos coprimários comportamentais**, R_bug e R_ok, que verificam reconhecimento de erros no estado correspondente e aceitação do caminho correto; a completude por valor permanece como medida secundária e histórica;
3. um protocolo exploratório de **juiz de LLM cego**, com calibração positiva e controles negativos; a auditoria da versão 3.4 identificou que o painel multijuiz da campanha 3 não recebeu os excedentes do sistema, de modo que essa confirmação está suspensa até nova execução;
4. um **verificador de invariantes estruturais** para grafos de comportamento, com sinais duros exercitados por testes de propriedades em 10.000 grafos;
5. três **campanhas empíricas exploratórias** sobre 24 exercícios e três réplicas por condição, com a campanha 3 como teste principal e as duas anteriores como desenvolvimento do instrumento; o pacote publica código, agregados, manifestos e os artefatos efetivamente retidos, com limites explícitos para recomputação.

O escopo das conclusões segue uma escada explícita de reivindicações. Este estudo sustenta dois níveis: (A) o montador satisfaz as invariantes estruturais implementadas, e (B) os grafos gerados reproduzem parte dos comportamentos registrados nos grafos de referência deste corpus. Três níveis ficam explicitamente FORA do alcance dos dados atuais e são tratados como agenda futura: (C) equivalência ou não inferioridade em relação a especialistas em geral, que requer múltiplos especialistas e margem justificada; (D) validade pedagógica dos comportamentos adicionais, que requer anotação humana e prevalência empírica; e (E) efeito sobre aprendizagem, que requer estudo com estudantes. Todas as análises aqui reportadas são exploratórias (Seção 3.8).

O restante do documento está organizado da seguinte forma: a Seção 2 apresenta a fundamentação e os trabalhos que sustentam cada decisão metodológica; a Seção 3 detalha o método; a Seção 4 reporta os resultados; a Seção 5 os discute; a Seção 6 examina ameaças à validade; a Seção 7 delineia os próximos passos; a Seção 8 conclui.

2 Fundamentação

2.1 Grafos de comportamento e grafos de conhecimento

Dois artefatos com nomes semelhantes cumprem papéis distintos em um STI. O **grafo de conhecimento** organiza o currículo: seus nós são habilidades (*knowledge components*, KCs) e suas arestas expressam pré-requisito; ele responde o que o aluno precisa saber e em que ordem, e é compartilhado por muitos exercícios. O **grafo de comportamento** descreve um único exercício: seus nós

são passos e estados da resolução, e suas arestas são ações do aluno (acerto, erro previsto, retorno de remediação). A Figura 2 contrasta as duas estruturas.




Figura 2: grafo de conhecimento (esquerda) e grafo de comportamento (direita). No protocolo v1 (campanhas 1 e 2), as habilidades entravam como insumo, extraídas do próprio CTAT, e o objeto autorado e comparado é exclusivamente o grafo de comportamento.

Delimitação de escopo: os agentes autoram apenas o grafo de comportamento. No protocolo v1, os KCs chegavam prontos na entrada e eram usados como rótulos; no protocolo v2, foram removidos porque só estavam disponíveis dentro do grafo de referência. A plataforma não constrói nem atualiza um grafo de conhecimento a partir das saídas dos agentes.

2.2 Erros sistemáticos e a premissa do catálogo

A utilidade de catalogar misconceptions repousa em um resultado clássico: erros de alunos não são aleatórios, mas sistemáticos e enumeráveis, como demonstrado para procedimentos aritméticos por Brown e Burton (1978) e consolidado por VanLehn (1990). É essa regularidade que torna viável, e pedagogicamente valioso, prever erros específicos e associar remediações dirigidas a cada um.

2.3 Avaliação sem gabarito único: não-inferioridade e banda humana

Se não há grafo correto único, a pergunta adequada não é "o sistema é igual ao especialista?", e sim "o sistema difere do especialista mais do que especialistas diferem entre si?". Esse enquadramento corresponde ao teste de não-inferioridade (Lakens, 2017; Lakens; Scheel; Isager, 2018), com margem derivada empiricamente da variação interespecialistas (a banda humano-humano). A estimativa dessa banda requer pelo menos dois, idealmente três especialistas por exercício, exigência que decorre da Teoria da Generalizabilidade (Shavelson; Webb, 1991): com um único par há uma única

medida de discordância por direção, insuficiente para estimar variância. Na presente campanha havia um especialista por exercício; conseqüentemente, o veredito de não-inferioridade é reportado como não estimável por construção (Seção 4.7), e a coleta da banda é a frente prioritária de continuidade.

2.4 Similaridade assimétrica e a métrica histórica de cobertura

Métricas simétricas de comparação de conjuntos, como o F1, penalizam o candidato por itens excedentes. Para um sistema generativo cujo valor potencial reside em enriquecer a cobertura de erros, essa penalização confunde duas situações opostas: o excedente inválido e o excedente pedagogicamente defensável que o autor de referência não catalogou. Tversky (1977) formalizou a comparação assimétrica com pesos independentes para os traços exclusivos de cada lado. A **completude por valor**, primária apenas nas campanhas 1 e 2 e secundária na campanha 3, é o caso direcional adotado: mede a fração do catálogo de valores da referência coberta pelo sistema, sem atribuir validade aos excedentes. Os desfechos principais atuais são comportamentais, R_bug e R_ok (Seções 3.5 e 3.11). Distâncias de edição (Sanfeliu; Fu, 1983; Zhang; Shasha, 1989), inclusão de traços e F1 permanecem como medidas auditáveis e históricas.

2.5 Juízes baseados em LLM

O julgamento pedagógico em escala exige um avaliador automatizado, e o uso de LLMs como juízes introduz um viés documentado: modelos tendem a avaliar mais favoravelmente produções da própria família (Panickssery; Bowman; Feng, 2024; ver também Hosking; Blunsom; Bartolo, 2024, sobre limitações do julgamento como padrão-ouro). As salvaguardas adotadas derivam diretamente dessa literatura: juiz de família distinta da geradora, cegamento quanto à origem dos itens, julgamento item a item com justificativa (à maneira de GraphEval; arXiv:2407.10793) e controles internos por rodada. A calibração contra julgamento humano, com estatística kappa (Landis; Koch, 1977), está prevista no instrumento e em execução.

2.6 Detecção estrutural de alucinação em grafos

Trabalhos recentes sobre confiabilidade de saídas de LLM em estruturas de grafo informam a camada estrutural da validação: a métrica de validade como violações por verificação (arXiv:2601.17717), a comparação contra referência determinística com limiar dinâmico $\mu + \lambda\sigma$ e o reconhecimento explícito de que a própria referência é falível (arXiv:2509.03857), a taxonomia de anomalias por nó, aresta e caminho (arXiv:2505.24201) e a combinação aditiva de camadas de detecção (arXiv:2512.22396). A falibilidade da referência é incorporada aqui como argumento central: o es-

pecialista tampouco é gabarito perfeito, o que motiva o enquadramento de não-inferioridade da Seção 2.3.


3 Método

3.1 Desenho geral e questões de pesquisa

O estudo responde a três questões:

1. **QP1 (estrutural):** a boa-formação dos grafos é uma invariante verificável do gerador? (Trata-se de verificação de propriedade de engenharia, não de descoberta empírica: a arquitetura delega a estrutura a um montador determinístico, e a QP1 verifica que as invariantes implementadas se sustentam sob teste adversarial.)
2. **QP2 (conformidade com a referência):** em que medida o grafo gerado REPRODUZ O COMPORTAMENTO do grafo de referência: reconhece as ações de erro no estado correspondente (R_bug) e aceita e conclui os traços corretos (R_ok)? Secundariamente, que proporção dos VALORES de respostas erradas ele cobre (a métrica histórica das campanhas 1 e 2)?
3. **QP3 (comportamentos adicionais):** que avaliação um modelo-juiz cego faz dos erros previstos apenas pelo sistema, e da importância dos erros não cobertos? (Avaliação automatizada exploratória: mede plausibilidade segundo o juiz declarado, não validade pedagógica.)

A Figura 3 posiciona os instrumentos: a QP1 é respondida por verificação estrutural sem gabarito; a QP2 e a QP3, por comparação e julgamento sob protocolo cego. Um terceiro nível, de eficácia de aprendizagem com alunos reais, está fora do escopo desta campanha.



Cada nível responde a uma pergunta distinta; nenhum substitui evidência de aprendizagem com estudantes.

Figura 3: os três níveis de validação e sua correspondência com as questões de pesquisa. A campanha reportada cobre os níveis 1 e 2, com as limitações registradas nas Seções 4.7 e 6.

3.2 Corpus e materiais

O corpus é composto por 24 exercícios de frações na reta numérica (6º ano), produzidos na ferramenta CTAT sobre uma mesma interface por uma pessoa com experiência de autoria no CTAT, conforme informação fornecida ao estudo. Os grafos são tratados como **grafos CTAT de referência**: registros legítimos e finitos do que seu autor catalogou, não como verdade completa dos erros possíveis. Formação, tempo de docência e experiência detalhada desse autor não estão documentados no pacote; por isso, o relatório não usa essas credenciais como evidência e inclui a lacuna como limitação de proveniência. Cada exercício é exportado como arquivo `.brd`, que reúne interface e grafo de comportamento. A homogeneidade decorrente da produção em massa é quantificável: o coeficiente de correlação intraclasse de tipo 1, ICC(1), é 0,32 para a completude conceitual, mas a diversidade efetiva de interfaces permanece próxima de $N=1$. O corpus, portanto, fornece 24 variações de exercício, não 24 templates independentes.

3.3 Protocolo v1 de autoria cega: os dois envelopes

A validade do experimento depende de os agentes jamais acessarem o material do especialista. O parser do experimento divide cada `.brd` em dois envelopes disjuntos (Figura 4): o **Envelope A** contém exclusivamente a interface (enunciado, componentes de resposta, resposta correta e KCs) e constitui a única entrada dos agentes; o **Envelope B** contém o grafo do especialista e ingressa no fluxo somente na etapa de comparação. Três salvaguardas mecânicas sustentam o protocolo: funções de extração separadas para cada envelope; uma lista de campos proibidos no Envelope A (misconceptions, dicas, arestas, mensagens de feedback), varrida pela função `findLeaksInRobotInput`; e um teste automatizado que falha na presença de qualquer vazamento, incluindo um controle negativo com envelope deliberadamente contaminado, que o teste deve acusar. Registra-se que a respos-

ta correta integra o Envelope A por decisão de desenho: a previsão de erros plausíveis pressupõe o conhecimento do acerto, como ocorre com o professor humano.

Uma qualificação honesta é necessária: o Envelope A é hoje DERIVADO do mesmo arquivo `.brd` que contém o grafo de referência (o parser percorre a estrutura para descobrir componentes e tipos), e o teste de vazamento é lexical, por lista de campos proibidos, não semântico. O protocolo v1 garantia, portanto, **blindagem parcial**, não independência total de fonte; o protocolo v2 da campanha 3 eliminou a dependência (Seção 3.11). A reconstrução do Envelope A a partir de fonte independente do grafo (o HTML e o Document Object Model, DOM, da interface, o screenshot e o gabarito do arquivo de produção em massa, todos disponíveis no corpus), acompanhada de teste metamórfico (mutações no grafo de referência não alteram um byte do envelope), FOI EXECUTADA: é o protocolo v2 da campanha 3 (Seções 3.11 e 4.11). A descrição acima documenta o protocolo v1, usado nas campanhas 1 e 2.




Figura 4: fluxo do protocolo v1, usado nas campanhas 1 e 2. O arquivo `.brd` é dividido em dois envelopes; como ambos derivam da mesma fonte, o desenho garante blindagem parcial, não independência de fonte. O protocolo v2 é descrito na Seção 3.11.

3.4 O sistema sob avaliação

O sistema avaliado é o pipeline de autoria da plataforma EducaOFF, empregado sem modificação. Três agentes de LLM operam sobre a interface do Envelope A com papéis inspirados em perfis de aluno: o agente 3a ("aluno avançado") produz o caminho de resolução correto; o agente 3b ("aluno com dificuldades") produz as misconceptions, cada qual com a resposta errada concreta correspondente; o agente 3c ("aluno mediano") produz as dicas em quatro níveis. Os papéis são heurísticas de prompt, não modelos de aluno validados contra comportamento de estudantes reais; o relatório os

trata como geradores de candidatos. Um montador determinístico, o GraphForge, combina os três insumos no grafo final, criando nós de passo, um scaffold por misconception e as arestas de erro e retorno (Figura 5). A separação é deliberada: o conteúdo pedagógico provém dos agentes; a estrutura provém de um algoritmo clássico e é, por construção, verificável.




Figura 5: a autoria em duas fases: os três agentes de produção (conteúdo) e o montador determinístico (estrutura). Os agentes são os mesmos da plataforma em produção, sem modificação de código ou de prompts.

Dois cuidados de fidelidade merecem registro. Primeiro, os agentes de produção operam nativamente sobre templates com variáveis genéricas; para o experimento, a instrução de instanciar valores concretos trafega como dado, pelo mesmo canal de entrada que os agentes já consomem, sem alteração de seus prompts de sistema. Segundo, a orquestração replica a política condicional de produção (o agente 3c é acionado sob as mesmas condições). Ambos os pontos foram objeto de correção após a primeira rodada de revisão adversarial (Seção 3.8).

Dois fatores do prompt do agente de erros afetam a interpretação. Primeiro, o prompt pode consultar um catálogo interno de misconceptions (`MISC_DB`); a auditoria mostrou que ele permaneceu inerte nas campanhas 1 e 2 por uma incompatibilidade de normalização da chave de disciplina. Segundo, o prompt orienta a produção de duas a três tentativas erradas por exercício. A campanha 3 testou o catálogo ligado de forma efetiva, o alvo de seis candidatos e a instrução aberta de saturação. Essas condições alteram o procedimento completo de geração; em particular, o alvo seis também recebeu maior orçamento de saída.


3.5 Métricas

A comparação entre o grafo do sistema e o do especialista opera sobre um esquema neutro comum, com casamento de itens por âncora semântica: respostas equivalentes em valor (por exemplo, $2/8$, $1/4$ e $0,25$) recebem a mesma chave canônica, e erros mecânicos de interface (respostas em branco,

resíduos de interação como "-1") são marcados e excluídos das contagens conceituais. Sobre esse alinhamento definem-se (Figura 6):

- **R_bug** (coprimária da campanha 3): proporção das ações buggy registradas na referência que o grafo gerado reconhece como buggy após o prefixo correto, no estado correspondente. O denominador congelado contém todas as oito ações buggy de cada exercício (192 no corpus);
- **R_ok** (coprimária da campanha 3): proporção de traços corretos da referência aceitos passo a passo e completados. Há um único traço correto por exercício, de modo que $R_{ok}(i)$ é binário antes da agregação;
- **rOkCompleted** (sensibilidade exploratória): indica apenas se o traço chega ao estado final, mesmo que micropassos não sejam reconhecidos; não substitui R_{ok} ;
- **Compleitude conceitual** (métrica primária das campanhas 1 e 2; a partir da campanha 3, secundária histórica, com as coprimárias comportamentais R_{bug} e R_{ok} definidas no protocolo v2): fração dos valores de respostas erradas conceituais do grafo de referência cobertos pelo sistema. A operacionalização é declarada: uma misconception é representada pelo VALOR canônico da resposta errada, não pela regra cognitiva que a produz; dois raciocínios distintos que geram o mesmo valor contam como um item, e a mesma regra que gera valores diferentes em exercícios diferentes conta como itens distintos. A métrica mede, portanto, cobertura de valores do catálogo de referência (limitação discutida na Seção 6);
- **Plausibilidade dos excedentes** (eixo Y): fração dos erros previstos apenas pelo sistema classificados como plausíveis pelo modelo-juiz cego (Seção 3.6); mede o veredito do juiz declarado, não validade pedagógica;
- **Compleitude de passos**: cobertura do caminho de resolução, reportada separadamente por constituir modo de falha independente;
- **Concordância de classificação de respostas** (denominada "equivalência funcional" nas versões 1.0 a 2.1): concordância de veredito entre os dois grafos ante uma mesma bateria, com concordância bruta, kappa de Cohen e matriz de confusão. Nas campanhas 1 e 2, a bateria era a união dos dois catálogos e não continha verdadeiros negativos. Na campanha 3, foi substituída por uma bateria pré-congelada e independente das saídas geradas, com sondas de domínio que permitem a célula no-match x no-match;
- **Inclusão de traços**: fração do caminho do especialista contida, em ordem, no caminho do sistema, com colapso de passos sem conteúdo (insensível a granularidade);
- **Métricas auditáveis**: F1 estrutural e conceitual, precisão, Jaccard e distância de edição aproximada, mantidas para comparabilidade.

Estimandos comportamentais da campanha 3. Para o exercício i , seja B_i o conjunto das oito ações buggy registradas e T_i o único traço correto. Então $R_bug(i) = |\{b \text{ em } B_i: \text{ o gerado devolve buggy no estado correspondente}\}| / |B_i|$ e $R_ok(i) = 1$ somente quando todos os passos de T_i são aceitos como corretos e o estado final é alcançado; caso contrário, $R_ok(i) = 0$. As três réplicas são primeiro promediadas dentro de cada exercício e os 24 valores por exercício formam a média macro e o bootstrap. Denominadores vazios não ocorrem neste corpus.



O F1 mistura os três territórios num número só. O veredito 2D trata cada um do jeito certo: mede a cobertura, manda os extras para um juiz de plausibilidade e os perdidos para um juiz de importância.

Figura 6: os três territórios do alinhamento entre catálogos. A completude mede a interseção relativa ao especialista; excedentes seguem para julgamento de plausibilidade; as omissões seguem para julgamento de importância.

O **veredito bidimensional** (completude conceitual, plausibilidade dos excedentes) constituiu o desfecho primário das campanhas 1 e 2; no protocolo v2 da campanha 3, os desfechos coprimários passam a ser comportamentais (Seções 3.11 e 4.11). O par substitui o F1 como critério de mérito por um argumento de função de perda: em um instrumento generativo, o excedente não é defeito por definição, mas hipótese a verificar.

3.6 O juiz cego e o juiz de importância

Duas funções de julgamento operam sobre o mesmo modelo avaliador (Figura 7). O **juiz de plausibilidade** (denominado "juiz de validade" nas versões 1.0 a 2.1) recebe, um item por vez e sem qualquer indicação de origem, o enunciado, a resposta correta e uma resposta errada candidata, e responde em formato estruturado: veredito (erro plausível de aluno; implausível; correspondente à resposta correta; impossível no contexto), denominação do erro quando válido e justificativa breve. O **juiz de importância** recebe as misconceptions do especialista não cobertas pelo sistema e as

classifica em centrais (que um tutor precisa remediar), periféricas ou mecânicas, sem informação de que se trata de omissões.





Figura 7: protocolo do juiz cego. Cada rodada julga, indistintamente, excedentes do sistema, erros do próprio especialista (calibração positiva) e distratores (controles negativos); o segundo julgamento classifica a importância das omissões.

A confiabilidade do instrumento é verificada dentro de cada rodada por dois mecanismos: os erros da referência funcionam como calibração positiva e distratores por exercício, como controles negativos. Os controles incluem resposta correta, valor absurdo, forma não canônica da resposta correta e valor impossível no contexto físico. A auditoria de 24 exercícios mostrou que o juiz rejeitou corretamente três classes, mas aprovou 24/24 formas equivalentes da resposta correta. Uma guarda determinística passou, então, a interceptar candidatos com a mesma âncora semântica do acerto. O relatório dessa auditoria e a decisão constam da Emenda 2. A calibração externa contra anotação humana ainda não foi concluída; até lá, as taxas significam apenas "segundo o modelo-juiz declarado".

3.7 Verificação estrutural

Independentemente de gabarito, todo grafo gerado é submetido a um verificador de invariantes estruturais que distingue duas classes de sinal. Os **sinais duros** invalidam o grafo: ciclo que não atravessa remediação (raciocínio circular), nó inalcançável a partir do início, beco sem saída (nó que não alcança o objetivo), scaffold órfão (remediação de erro inexistente), aresta órfã, ciclo no caminho correto e ausência de nós de início ou objetivo. Os **sinais moles** (ramificação excessiva relativa à mediana, erro sem remediação, laços e arestas duplicadas) compõem um escore com limiar dinâmico $\mu + \lambda\sigma$ sobre a banda histórica. A Figura 8 exemplifica os defeitos duros.



Todos estes defeitos são detectados sem olhar o grafo do especialista. É pura teoria dos grafos.

Figura 8: defeitos estruturais detectáveis sem gabarito, ilustrados em um grafo hipotético. Nenhum deles ocorreu nos grafos da campanha.

A robustez do montador determinístico foi exercitada por teste de propriedades: 10.000 configurações aleatórias de exercício foram submetidas ao GraphForge e nenhuma produziu violação dura. A leitura correta é circunscrita: **nenhuma violação das invariantes implementadas foi observada**. Como verificador e montador implementam o mesmo conjunto de regras, o resultado não constitui prova de ausência de defeito em geral; a sensibilidade do verificador foi medida por mutation testing: dez classes de defeito deliberadamente injetadas em 26 grafos-base produziram 260 mutantes, todos detectados (sensibilidade 100%), com zero sinal espúrio nas bases intactas (especificidade 100%); a conclusão vale para as classes cobertas pela suíte, e o relatório integra o repositório. O verificador foi ainda incorporado à plataforma como barreira de produção, de modo que um grafo que viole as invariantes não alcança alunos.

3.8 Procedimento estatístico, estatuto exploratório e garantias de rigor

Estatuto exploratório. O protocolo é um plano de análise com histórico datado, não um pré-registro confirmatório: foi publicado com resultados, a métrica principal mudou após corridas exploratórias e a correção de Holm foi adotada após a campanha multimodelo. As Emendas 1 a 5 registram a cronologia; a Emenda 5 é explicitamente pós-dados e documenta a auditoria corretiva. Todas as análises são exploratórias; um estudo confirmatório exigirá registro público imutável anterior à coleta em corpus novo.

Unidade de análise e testes. Os 72 registros por braço correspondem a 24 exercícios observados em três réplicas. As réplicas são agregadas por média dentro do exercício; comparações são pareadas por exercício e usam permutação exata por troca de sinais, enumerando 2^{24} atribuições. Inter-

valos usam bootstrap de exercício com semente fixa. Nas campanhas 1-2, Holm foi aplicado à família de completude conceitual entre modelos ($m=3$) e às métricas secundárias ($m=12$). Na campanha 3, a família estatística F1 reúne R_{bug} e R_{ok} dos dois braços de modelo contra o baseline ($m=4$); a família F2 reúne a completude por valor das seis ablações ($m=6$); a família F3 reúne R_{bug} e concordância das seis ablações ($m=12$); a família F4, explicitamente pós-hoc, compara a completude dos dois braços de modelo ($m=2$). A exclusão de R_{ok} da família F3 decorre de sua degeneração em zero em todos os braços; esse resultado é descrito, não usado para multiplicar testes idênticos.

O bootstrap $[0; 0]$ de R_{ok} descreve a amostra observada, mas não prova que a taxa populacional seja zero. Como há 24 unidades independentes por braço e nenhuma conclusão observada, o limite superior unilateral de 95% para uma proporção binomial é aproximadamente 0,117; esta aproximação serve apenas para impedir a interpretação do intervalo degenerado como certeza populacional.

Proveniência dos números. As tabelas derivadas são geradas por `analysis/reanalyze.mjs` (campanhas 1-2) e `analysis/reanalyze-c3.mjs` (campanha 3). A prosa e o HTML são integrados manualmente e, portanto, não se afirma uma cadeia automática completa entre JSON e PDF. O validador `analysis/validate-report.mjs` trava os resultados centrais, a composição do painel, os sinais estruturais e a ausência de placeholders, sem substituir revisão editorial. A reconciliação histórica está em `analysis/derived/TABELAS.md`.

Revisão adversarial. Revisões sucessivas encontraram divergência de âncora, infidelidade de temperatura, erro de denominador em R_{bug} e omissão dos excedentes no painel. Cada defeito de código corrigível recebeu teste de regressão. A suíte completa deve ser executada antes de cada publicação; a contagem corrente é informada no pacote, não usada como evidência de validade científica.

O desenho da campanha 1 (Figura 9) compreende nove relatórios: três réplicas de avaliação com os agentes de produção, três com uma variante simplificada (baseline interno de robustez) e três de julgamento. As corridas de avaliação com agentes de produção e as de julgamento autoram, juntas, 144 grafos ($72 + 72$); os 498 julgamentos individuais do juiz reduzem-se a 199 itens únicos após deduplicação.




Figura 9: desenho da campanha de 2026-07-02: três réplicas de avaliação e três de julgamento sobre os 24 exercícios. A agregação estatística (reanálise de 2026-07-12) usa o exercício como unidade, permutação exata pareada com Holm e juiz sobre itens únicos.

3.9 Transparência de modelos e infraestrutura

A Tabela 1 especifica os modelos empregados em cada função, com as respectivas temperaturas, idênticos aos da plataforma em produção. As temperaturas diferem por função: a simulação do aluno avançado requer quase-determinismo; a do aluno com dificuldades requer diversidade para a emergência de erros; o julgamento requer estabilidade. O juiz pertence a família distinta da geradora (Seção 2.5). Todos os identificadores de modelo referem-se às versões servidas pela OpenRouter nas datas das campanhas e da bancada de juízes (2 e 8 a 10 de julho de 2026); provedores podem atualizar modelos sob o mesmo identificador, limitação padrão de estudos com APIs comerciais. O custo total de API foi de aproximadamente US\$ 4 na campanha 1 e US\$ 30 na campanha 2 (dominado pelos braços GLM-5.2 e Claude Sonnet 5); por grafo autorado, o custo marginal do sistema fica na ordem de US\$ 0,05 e cerca de um minuto de máquina. Para referência do gargalo que motiva a automação, estimativas clássicas situam o desenvolvimento de tutores inteligentes em 200 a 300 horas por hora de instrução, razão que o paradigma example-tracing reduz substancialmente, mas não elimina (Aleven et al., 2009). Todos os modelos são acessados por um único provedor (OpenRouter), o que permite reprodução com uma única credencial; o pacote publicado inclui o comando `npm run models`, que exibe a configuração ativa e valida o acesso, e permite a substituição de qualquer modelo por variável de ambiente. A montagem do grafo não emprega modelo algum.

Tabela 1: modelos, temperaturas e limites por função do experimento.

Função	Agente	Modelo	Temp.	Máx. tokens
Caminho de resolução correto	3a, aluno avançado	google/gemini-3.5-flash	0,2	16.000
Misconceptions	3b, aluno com dificuldades	google/gemini-3.5-flash	0,7	24.000
Dicas em 4 níveis	3c, aluno mediano	google/gemini-3.5-flash	0,4	16.000
Julgamento (plausibilidade e importância)	juiz cego	z-ai/glm-4.5	0,1	32.000
Contingência de falha	fallback	deepseek/deepseek-chat	0,3	16.000
Montagem do grafo	GraphForge	nenhum (determinístico)	n/a	n/a

3.10 Campanha 2: variação do modelo gerador

A segunda campanha responde a uma pergunta de robustez levantada pela orientação: os resultados dependem do modelo de linguagem empregado nos agentes? O protocolo, o corpus, os prompts, as temperaturas por papel e a infraestrutura foram mantidos idênticos; variou-se apenas o modelo que anima os três agentes, em quatro braços experimentais: o baseline da produção (google/gemini-3.5-flash) e três famílias alternativas (z-ai/glm-5.2 , deepseek/deepseek-v4-pro e anthropic/claude-sonnet-5). Cada braço executou três réplicas de avaliação e três de julgamento (24 corridas no total), e os três agentes de um braço compartilham o mesmo modelo, para que qualquer diferença observada tenha atribuição inequívoca.

Duas salvaguardas adicionais foram necessárias. Primeira: o juiz da campanha 1 (GLM-4.5) pertence à família de um dos braços testados, o que violaria a exigência de neutralidade; adotou-se, para todos os braços, um juiz único de família alheia às quatro geradoras (mistralai/mistral-large-2512 , temperatura 0,1), selecionado após um comparativo de latência e adequação (1,9 s por julgamento, contra 14 a 28 s de candidatos com raciocínio interno). A concordância entre candidatos foi medida empiricamente em bancada de 45 itens estratificados: o κ de Cohen par a par entre Mistral Large, Mistral Medium e Qwen3.7-plus situa-se entre 0,644 e 0,700 (concordância substancial na escala de Landis e Koch, inclusive entre famílias distintas), com taxas de aprovação de 67 a 69%; nessa bancada, não se detectou viés de veredito associado à escolha por latência e custo. Em decorrência, o próprio baseline foi reavaliado e rejuizado integralmente dentro da campanha 2, permitindo comparar os braços sob a mesma régua de julgamento; os níveis absolutos de julgamento, contudo, não são comparáveis entre campanhas (Seção 4.9). Segunda: o mecanismo de contingência de cada corrida de avaliação usa o próprio modelo do braço (uma falha não introduz outra família no braço), e o das corridas de julgamento usa um modelo neutro menor.

3.11 Campanha 3: protocolo v2 (entrada independente, ablações e painel de juízes)

A terceira campanha (13 de julho) é o experimento principal. Os estimandos, famílias de testes, corpus e bateria foram especificados na Emenda 4; um smoke test de dois exercícios precedeu o congelamento final do executor e do casamento, e ocorreu antes das corridas analíticas. Portanto, a formulação correta é **estimandos pré-especificados e implementação analítica finalizada após o smoke test**, não protocolo integralmente congelado antes de qualquer execução.

No protocolo v2, o Envelope A é construído a partir do HTML da interface e do gabarito da tabela de produção em massa, sem ler o conteúdo do grafo CTAT usado como referência. Um teste metamórfico verifica que mutações no grafo de referência não alteram o envelope. Os KCs foram removidos porque só existiam dentro do grafo; os enunciados da fonte independente estão em inglês, enquanto os `.brd` traziam tradução. Fonte, idioma e presença de KCs mudaram simultaneamente, de modo que os níveis das campanhas 1-2 e 3 descrevem protocolos diferentes e não isolam efeitos causais.

A bateria tem 636 itens pré-congelados, 24 a 28 por exercício, e é independente das **saídas geradas**, não integralmente independente da referência. A família A contém 240 itens derivados do grafo CTAT (24 traços corretos, 192 ações buggy inseridas após prefixos corretos e 24 pedidos de dica); a família B contém 135 mutações derivadas da referência; a família C contém 261 sondas de domínio construídas a partir do gabarito, que fornecem verdadeiros negativos. Assim, 375/636 itens dependem da referência e 261 são sondas de domínio.

Tabela 1b: composição da bateria comportamental congelada da campanha 3.

Família	Origem e função	Itens
A - referência	24 traços corretos, 192 ações buggy e 24 pedidos de dica	240
B - mutações	Traços perturbados derivados da referência	135
C - sondas	Sondas de domínio oriundas do gabarito; fornecem verdadeiros negativos	261
Total	24 a 28 itens por exercício	636

A campanha compreende nove condições em três réplicas (27 corridas de 24 exercícios; 648 autorias) e a curva de ensemble $K=1$ a 10. Cada chamada foi registrada em manifesto com modelo, temperatura, hashes, tokens, custo e latência; o custo total foi US\$ 16,72 em 1.970 chamadas, sem falha de autoria. O executor analítico implementa um subconjunto explícito da semântica de example-tracing sobre o esquema neutro v2. Ele não é o runtime CTAT e não representa integralmente `Edges-Groups`, relações `group/link` e todas as restrições de travessia; os resultados medem conformidade nesse executor, não equivalência operacional de tutores.

O casamento publicado usa a referência no nível da tripla Selection-Action-Input (SAI) exata e o grafo gerado por equivalência da entrada canônica. A implementação original excluiu 42 ações me-

cânicas não ancoráveis do denominador de R_bug, produzindo uma versão com 150 ações; isso não correspondia ao denominador de 192 ações definido antes da campanha. A versão 3.4 restaura todas as 192 ações como estimando principal e mantém o resultado ancorável como sensibilidade. Como os relatórios históricos não retiveram o veredito de cada ação, o numerador inteiro foi reconstruído da taxa ancorável e do denominador conhecido; todas as taxas ficaram dentro da tolerância de arredondamento e a rotina possui teste de regressão. Sensibilidades exact/exact e input/input não podem ser reconstruídas dos agregados e exigem nova execução.

O painel foi planejado com três famílias de juízes (Mistral Large, Qwen 3.7 Plus e Llama 4 Maverick). A auditoria da versão 3.4 detectou uma incompatibilidade de campo: o coletor lia `extras`, enquanto os relatórios armazenavam `extra`. O conjunto efetivamente julgado tinha 179 itens - 83 da referência e 96 distratores - e zero excedente do sistema. O extrator e o teste de regressão foram corrigidos; o conjunto correto contém 333 itens, incluindo 154 excedentes únicos. Como a nova chamada aos juízes ainda não foi executada, o painel não fornece, nesta versão, evidência multijuiz sobre saídas dos agentes.

4 Resultados

4.1 QP1: integridade estrutural

Nas campanhas 1 e 2, nenhum dos grafos reportados apresentou violação dura ou sinal mole; o mesmo ocorreu nos 10.000 grafos dos testes de propriedades. Na campanha 3, houve **zero violação dura em 648 grafos**, mas 62 grafos (9,6%) acionaram um sinal mole: 61/72 (84,7%) na condição de seis candidatos, 1/72 na chamada única e 0/504 nas demais condições. Como os relatórios históricos armazenaram apenas a contagem, não a classe detalhada do sinal, não é possível atribuir sua natureza retrospectivamente. O resultado sustenta a robustez contra as violações duras implementadas, mas rejeita a afirmação anterior de ausência total de alertas estruturais.

Tabela 1c: sinais estruturais na campanha 3.

Condição	Violações duras	Grafos com sinal mole
Baseline, GLM, DeepSeek, MISC_DB, saturação, DOM e screenshot	0/504	0/504
Limite de 6 candidatos	0/72	61/72 (84,7%)
Chamada única	0/72	1/72 (1,4%)
Total	0/648	62/648 (9,6%)

A sensibilidade do verificador a defeitos deliberadamente injetados foi 260/260 nas dez classes cobertas. Essa evidência valida o verificador apenas para as mutações implementadas; não prova au-

sência de defeitos estruturais fora da taxonomia.

4.2 QP2: comparação com o especialista

A Tabela 2 consolida as métricas comparativas da campanha 1 (24 exercícios em três réplicas; unidade inferencial: exercício), com intervalos de confiança de 95% por bootstrap de exercício.

Tabela 2: métricas comparativas da campanha 1 (média por exercício e IC95%; 24 exercícios $\times$ 3 réplicas agregadas). Todos os valores gerados por `analysis/reanalyze.mjs`.

Métrica	Estimativa [IC95%]
Compleitude conceitual (primária na campanha 1)	0,376 [0,309; 0,442]
Compleitude bruta (com erros mecânicos)	0,234 [0,195; 0,273]
Compleitude de passos	0,510 [0,497; 0,525]
Concordância de classificação: bruta	0,396 [0,345; 0,449]
Concordância de classificação: κ de Cohen (médio por par)	0,007 [-0,069; 0,089] (faixa -0,436 a 0,583; κ agregado da matriz: -0,033)
Inclusão de traços	0,461 [0,433; 0,490]
F1 estrutural (auditável)	0,485 [0,459; 0,511]
F1 conceitual (auditável)	0,548 [0,517; 0,578]

O κ próximo de zero é um resultado negativo e deve ser lido como tal: pela própria correção de acaso, a concordância de classificação entre os dois grafos não excede o acaso. A matriz agregada explica o mecanismo: os dois lados concordam na resposta correta (72/72), o sistema cobre 91/249 itens de erro da referência e adiciona 116 itens não registrados. Como a bateria é a união dos catálogos, a célula surpresa $\times$ surpresa é impossível e não há verdadeiros negativos; isso **limita a interpretação**, sem explicar sozinho o resultado. A bateria C3, pré-congelada e independente das saídas geradas, introduz verdadeiros negativos e ainda produz kappa comportamental baixo (0,037 na média macro e na matriz agrupada), confirmando a baixa concordância no instrumento novo.

Matriz de confusão agregada da concordância de classificação (72 pares da campanha 1; linhas: referência; colunas: sistema).

	correto	erro previsto	surpresa
correto	72	0	0
erro previsto	0	91	158
surpresa	0	116	0 (impossível por construção)

Como verificação histórica, uma variante de chamada única foi avaliada na campanha 1. Os agentes mantiveram maior completude de passos ($\Delta=+0,089$ [0,055; 0,130], p exato=0,0001), mas não houve diferença detectada na completude por valor ($\Delta=-0,073$ [-0,165; 0,031], $p=0,17$). A ablação foi repetida na campanha 3: chamada única apresentou $R_{\text{bug}}=0,010$ [0; 0,024] e completude por

valor=0,203 [0,147; 0,264], sem diferença após Holm. Esses dados não demonstram superioridade global de uma das arquiteturas.

4.3 Caso ilustrativo

O exercício 04soccerSeason (representar $3/4$ na reta numérica) ilustra a mecânica da comparação. O especialista catalogou três erros conceituais: $2/4$, 3 e 4. O sistema previu $2/4$, 3 e $4/4$. A Tabela 3 detalha o alinhamento.

Tabela 3: alinhamento de catálogos no exercício 04soccerSeason (primeira réplica).

Resposta errada	Especialista	Sistema	Classificação
$2/4$	sim	sim	coberta
3	sim	sim	coberta (numerador isolado)
4	sim	não	omissão (denominador isolado)
$4/4$	não	sim	excedente; julgado válido (confusão entre total de partes e fração)
"-1", "-"	sim	não	mecânicos de interface; excluídos da contagem conceitual

A completude conceitual do exercício é $2/3 \approx 0,67$. O excedente $4/4$ foi aprovado pelo juiz, enquanto o distrator da mesma rodada (a resposta correta, $3/4$) foi rejeitado, como esperado.

4.4 Análise por exercício

A completude conceitual variou de 0,11 a 0,67 entre os 24 exercícios, com os menores valores concentrados nos exercícios de catálogos maiores e mais específicos (frações impróprias e numeradores elevados). A inspeção das omissões revela um padrão dominante: a resposta composta apenas pelo denominador (o aluno que, solicitado a marcar $3/4$, responde 4) consta do catálogo do especialista em quase todos os exercícios e raramente é prevista pelo sistema. Trata-se do diagnóstico mais acionável da campanha: uma classe única de erro, de origem plausivelmente ligada à interpretação do campo de resposta, responde por parcela substancial da lacuna de cobertura. A tabela completa por exercício integra o relatório expandido e o repositório.

4.5 QP3: plausibilidade dos excedentes segundo o modelo-juiz

A Tabela 4 consolida os julgamentos das três réplicas por origem do item. Seguindo a reanálise, as taxas são estimadas sobre itens únicos (deduplicação por exercício e âncora), com decisão por maioria entre réplicas, empates excluídos e declarados, e IC por bootstrap de exercício; a coluna de autoconsistência reporta a fração de vereditos unânimes entre os itens julgados mais de uma vez.

Tabela 4: julgamentos do modelo-juiz (GLM-4.5) por origem do item, campanha 1. Itens únicos; decisão por maioria; 498 julgamentos sobre 199 itens.

Origem do item	Itens únicos (julgamentos)	Plausíveis	IC95%	Autoconsistência
Excedentes do sistema	68 (105)	83% (55/66; 2 empates excluídos)	[74%; 91%]	0,93
Erros da referência (calibração positiva)	83 (249)	99% (82/83)	[96%; 100%]	0,99
Distrator: resposta correta (controle)	24 (72)	0%	[0%; 0%]	1,00
Distrator: valor absurdo (controle)	24 (72)	0%	[0%; 0%]	1,00

Os controles comportaram-se como o desenho exige: a calibração positiva aproximou-se do teto e ambos os distratores foram integralmente rejeitados. Nesse instrumento, 83% dos excedentes do sistema foram classificados como plausíveis PELO MODELO-JUIZ; a sensibilidade ao empate é pequena (81% com empate contado como implausível; 84% como plausível). A diferença em relação à calibração positiva (99%) não foi submetida a teste de equivalência e não se afirma proximidade estatística; a validade pedagógica dos excedentes permanece dependente da anotação humana em curso.

4.6 Importância das omissões

Das misconceptions conceituais da referência não cobertas pelo sistema (em média 50,3 por réplica na campanha 1), o juiz de importância classificou 56% como centrais, 42% como periféricas e 2% como mecânicas (média entre réplicas por exercício). Mais da metade do que o sistema omite corresponderia, portanto, a erros que um tutor precisa remediar, o que impede a leitura de que a divergência seria meramente complementar. **Esta leitura deve ser tratada como preliminar:** a Seção 4.9 demonstra que a classificação de centralidade é altamente sensível ao juiz empregado (56% sob GLM-4.5; 97 a 99% sob Mistral), e o nível confiável dessa taxa só será estabelecido pela calibração humana em curso (Seção 3.6). A conclusão qualitativa que sobrevive à sensibilidade é a direcional: uma fração não desprezível das omissões é classificada como central por ambos os juízes; se essa fração é de fato pedagogicamente relevante, só a calibração humana em curso poderá dizer.

4.7 Síntese histórica da Campanha 1: o plano bidimensional

A Figura 10 posiciona o resultado agregado da Campanha 1 no plano bidimensional que foi o desfecho histórico das campanhas 1 e 2: completude conceitual de 0,376 no eixo X e plausibilidade dos excedentes de 0,83 no eixo Y (itens únicos, decisão por maioria). Esta visualização não representa as coprimárias comportamentais da Campanha 3. No plano histórico, o sistema ocupa a região

"plausível segundo o juiz, porém incompleto": a maior parte do que produz é classificada como plausível pelo modelo-juiz; o quanto cobre do registro de referência permanece parcial.




Figura 10: síntese bidimensional histórica da Campanha 1, com intervalos de confiança de 95%. A referência de plausibilidade do especialista (0,99) e o comportamento nulo dos distratores delimitam o instrumento; esta figura não representa as coprimárias comportamentais da Campanha 3.

Quanto à não inferioridade formal: com um único especialista por exercício não existe banda humano-humano, o estimando NÃO É IDENTIFICADO e o teste retorna, desde a reanálise, o veredito "não estimável" (a versão anterior reportava "inconclusivo" com indicador de confiabilidade positivo, defeito apontado em revisão externa e corrigido em código com teste de regressão). Este relatório abstém-se, por desenho, de converter a completude de 0,376 em juízo de inferioridade ou aceitabilidade até que a banda seja coletada e a margem seja justificada por relevância pedagógica, não apenas pela dispersão observada.

4.8 Campanha 2: repetição interna do baseline

A reexecução integral do baseline na campanha 2 (nova infraestrutura, nova data, mesmo protocolo) constitui um teste de repetibilidade interna do experimento. A completude conceitual resultou em 0,368 [0,300; 0,442], contra 0,376 [0,309; 0,442] na campanha 1, com sobreposição quase integral dos intervalos e concordância análoga nas demais métricas. A estimativa foi, portanto, reproduzida internamente, no mesmo corpus e sob condições semelhantes; replicação independente (outra equipe, outro corpus) permanece em aberto.

4.9 Comparação entre modelos geradores

A Tabela 5 consolida as métricas dos quatro braços (média por exercício e IC95%; 24 exercícios × 3 réplicas por braço), e a Tabela 6, os julgamentos sob o juiz comum sobre itens únicos. As diferenças são pareadas por exercício contra o baseline, testadas por permutação exata com Holm por família (Seção 3.8).

Tabela 5b: métricas comparativas por modelo gerador (campanha 2; média por exercício e IC95%). Todos os valores gerados por `analysis/reanalyze.mjs` ; significância na prosa e na Tabela 5b.

Métrica	Gemini 3.5 Flash (baseline)	GLM-5.2	DeepSeek V4 Pro	Claude Sonnet 5
Completude conceitual (primária na campanha 2)	0,368 [0,300; 0,442]	0,415 [0,323; 0,504]	0,371 [0,292; 0,454]	0,416 [0,339; 0,488]
Completude bruta	0,232 [0,188; 0,278]	0,258 [0,203; 0,313]	0,230 [0,181; 0,278]	0,258 [0,213; 0,302]
Completude de passos	0,508 [0,493; 0,523]	0,501 [0,479; 0,521]	0,477 [0,458; 0,496]	0,500 [0,487; 0,516]
Concordância de classificação (bruta)	0,411 [0,353; 0,478]	0,380 [0,322; 0,438]	0,345 [0,288; 0,405]	0,377 [0,330; 0,423]
Concordância de classificação (κ médio)	0,051 [−0,037; 0,151]	−0,027 [−0,115; 0,060]	−0,074 [−0,167; 0,022]	−0,033 [−0,107; 0,040]
Inclusão de traços	0,444 [0,412; 0,479]	0,475 [0,443; 0,504]	0,458 [0,437; 0,478]	0,503 [0,483; 0,526]
F1 estrutural / conceitual	0,496 / 0,562	0,479 / 0,539	0,440 / 0,495	0,471 / 0,529

Tabela 5b: testes pareados contra o baseline (permutação exata por troca de sinais; Holm por família). Família primária: m=3; família secundária, exploratória: m=12.

Comparação	Δ médio [IC95%]	p exato	p-Holm	Rejeita Ho
GLM-5.2 · completude conceitual (primária C2)	+0,047 [−0,048; 0,143]	0,381	0,988	não
DeepSeek · completude conceitual (primária C2)	+0,003 [−0,089; 0,091]	0,957	0,988	não
Sonnet 5 · completude conceitual (primária C2)	+0,047 [−0,038; 0,142]	0,329	0,988	não
DeepSeek · completude de passos	−0,031 [−0,047; −0,015]	0,003	0,035	sim
DeepSeek · F1 estrutural	−0,056 [−0,092; −0,023]	0,005	0,052	não (limítrofe)
Sonnet 5 · inclusão de traços	+0,059 [0,017; 0,101]	0,011	0,114	não
Demais nove comparações secundárias: p-Holm ≥ 0,817 (íntegras em <code>analysis/derived/TABELAS.md</code>).				

Tabela 6: julgamentos sob o juiz comum da campanha 2 (Mistral Large; itens únicos, decisão por maioria, empates excluídos e declarados; IC por bootstrap de exercício).

Braço	Excedentes plausíveis (itens únicos)	IC95%	Calibração positiva	Omissões centrais
Gemini 3.5 Flash (baseline)	74% (67 itens; 1 empate)	[62; 86]	83% [74; 91]	97%
GLM-5.2	78% (96 itens; 2 empates)	[70; 85]	84% [77; 91]	98%
DeepSeek V4 Pro	73% (127 itens; 1 empate)	[65; 81]	83% [76; 90]	99%
Claude Sonnet 5	73% (103 itens; 2 empates)	[67; 81]	82% [75; 89]	98%

Quatro observações resumem a comparação. Primeira, e central: **nenhuma diferença de completude conceitual foi detectada entre os quatro modelos com a amostra disponível** (todas as diferenças pareadas cruzam zero; p-Holm de 0,988 nas três comparações primárias). O resultado é compatível com a hipótese de que o teto de cobertura pertence ao procedimento de amostragem única, e não ao modelo; ele NÃO estabelece equivalência entre modelos, pois nenhum teste de equivalência foi executado e os intervalos das diferenças admitem efeitos de até 14 pontos percentuais. Segunda: há um padrão sugestivo de porte, com os dois modelos maiores no topo (0,416 e 0,415) e os dois menores na base (0,368 e 0,371), efeito pequeno e não significativo com o presente n. Terceira: sob a permutação exata com Holm, sobrevive exatamente UM resultado: a inferioridade do DeepSeek na completude de passos ($\Delta=-0,031$, p-Holm=0,035); o F1 estrutural do DeepSeek fica limítrofe (p-Holm=0,052) e a melhora de inclusão de traços do Sonnet 5, significativa isoladamente (p=0,011), não sobrevive (p-Holm=0,114). A reanálise substitui o quadro da versão 2.1, na qual três inferioridades do DeepSeek exibiam o mesmo p-Holm=0,0105, artefato do piso de resolução do procedimento bootstrap então empregado. Quarta: no julgamento comum, o GLM-5.2 obteve a maior taxa de excedentes plausíveis (78% [70; 85], contra 74% [62; 86] do baseline), com ampla sobreposição dos intervalos.

Registra-se, ainda, a sensibilidade do instrumento de julgamento: o juiz da campanha 2 (Mistral) mostrou-se sistematicamente mais rígido que o da campanha 1 (GLM-4.5), tanto na calibração positiva (82 a 84%, contra 99%) quanto na classificação de centralidade das omissões (97 a 99%, contra 56%). As comparações entre braços permanecem válidas por compartilharem a régua; níveis absolutos entre campanhas e entre juízes, não. Nenhuma conclusão deste relatório depende de um único juiz para comparação entre braços, mas os NÍVEIS absolutos de plausibilidade devem ser lidos como "segundo o modelo-juiz declarado"; a âncora externa virá da anotação humana em curso (Seção 3.6).

4.10 Anatomia da lacuna de cobertura e efeito de agregação

A classificação dos 83 erros conceituais únicos da referência por tipo, cruzada com a cobertura do baseline (Tabela 7), revela que a lacuna não é difusa: concentra-se em uma classe específica. A tabela desta versão é gerada automaticamente dos dados brutos e substitui a da versão 2.1, cujo total de execução única (47%) não era reproduzível de nenhuma definição testada (a reconciliação completa está em `analysis/derived/TABELAS.md`); o valor auditado é 37%, coerente com a completude média, e a união de três réplicas confirma os 64%.

Tabela 7: cobertura por tipo de erro da referência (braço baseline, campanha 2; 83 instâncias conceituais únicas). "1 execução" é a média das três execuções isoladas; "união de 3", a cobertura por qualquer réplica.

Tipo de erro no catálogo de referência	Ocorrências	Cobertura (1 execução)	Cobertura (união de 3)
Fração incorreta (ex.: 2/4 quando a resposta é 3/4)	30	39%	73%
Numerador isolado (ex.: "3")	24	50%	79%
Denominador isolado (ex.: "4")	24	14%	33%
Outros inteiros	5	73%	80%
Total	83	37%	64%

Dois mecanismos distintos explicam a lacuna. O primeiro é **amostragem**: a união de apenas três execuções eleva a cobertura agregada de 37% para 64% (27 pontos percentuais, fechando cerca de 43% da distância até a cobertura total), e a do numerador isolado de 50% para 79%. Os agentes geram catálogos parcialmente disjuntos a cada execução, como observações independentes. O segundo é um **ponto cego qualitativo**: a resposta composta apenas pelo denominador, presente no catálogo da referência em praticamente todos os exercícios, é raramente prevista (14% em execução única; 33% mesmo na união) por qualquer um dos quatro modelos. Trata-se de um erro de natureza pragmática (interpretação do campo de resposta pela criança), e não matemática; uma hipótese alternativa, não descartável com os dados atuais, é a assimetria informacional do protocolo: o autor da referência via a interface real do CTAT, enquanto os agentes recebem uma serialização textual dela. A ablação com representação visual foi executada na campanha 3 (Seção 4.11), com resultado misto: cobertura por valor inalterada, mas concordância comportamental maior (+0,056, p-Holm= $9,6 \times 10^{-4}$ na família exploratória).

A revisão de 2026-07-10 acrescentou a medição controlada do mecanismo de amostragem: a **curva de saturação do ensemble**. Para cada exercício, o agente de misconceptions foi executado cinco vezes de forma independente, e a cobertura conceitual acumulada foi calculada para cada K de 1 a 5 (média sobre as rotações da ordem, eliminando o viés de sequência). A curva resultante, média dos 24 exercícios, é côncava e ainda crescente em K=5: 31,3% (K=1), 43,2% (K=2), 48,9% (K=3), 52,6% (K=4) e 55,6% (K=5). O maior ganho marginal ocorre de K=1 para K=2 (+11,9 pontos) e decai monotonicamente (+5,7; +3,7; +2,9), sugerindo ponto de operação prático entre K=3 e K=4 e confirmando, sob protocolo controlado, que a execução única deixa na mesa uma fração substancial de candidatos que o próprio agente é capaz de produzir. A escolha do K operacional não deve maximizar apenas cobertura: a curva completa com plausibilidade dos adicionais, custo e carga de revisão por K integra as ablações planejadas. Os dados da curva integram o repositório (resultados/).

4.11 Campanha 3 (experimento principal): conformidade, contraste de protocolos e ablações

Sob o protocolo v2, a completude por valor do baseline foi **0,243 [0,163; 0,324]**, contra 0,376 [0,309; 0,442] no protocolo histórico. A cobertura de frações incorretas foi semelhante (38,9% no v1; 40,0% no v2), enquanto numeradores isolados caíram de 50% para 24% e outros inteiros de 73% para 0%. Como fonte, idioma e KCs mudaram simultaneamente, a diferença de 13,3 pontos é um contraste entre protocolos. A remoção dos KCs é uma hipótese compatível com a anatomia, mas não é identificada como causa; exige ablação própria.

Desfechos coprimários. Com o denominador pré-especificado de todas as 192 ações buggy, o baseline apresentou $R_{\text{bug}}=0,054$ [0,016; 0,095]. R_{ok} foi zero em todos os nove braços: nenhum traço correto da referência foi aceito integralmente passo a passo. O resultado central é, portanto, **baixa conformidade comportamental com a referência neste executor**. A implementação originalmente publicada excluía 42 ações não ancoráveis e produzia $R_{\text{bug_anchor}}=0,065$ [0,020; 0,113]; essa estimativa é mantida apenas como sensibilidade. O kappa sobre os pares comparáveis da bateria com verdadeiros negativos foi 0,037 [0,034; 0,039]. A diferença de granularidade - aproximadamente quatro passos conceituais no gerado e oito micropassos na referência - é uma explicação compatível com o padrão, não uma causa isolada pelo desenho.

A sensibilidade leniente $rOkCompleted$ mostra que terminar não equivale a reproduzir o caminho: 0,069 [0; 0,167] no baseline, 0,125 [0,042; 0,236] no limite-6 e 0,292 [0,125; 0,472] no DOM; na chamada única, 0 [0; 0]. A maior estimativa pontual foi, portanto, 29,2%, com intervalo amplo. Cobertura de valores mede outro construto e permanece secundária.

Tabela 8a: desfechos coprimários por condição. R_{bug} usa todas as ações buggy registradas (192 no corpus); média por exercício e IC95%.

Condição	R_{bug} [IC95%]	R_{ok} [IC95%]
Baseline (Gemini)	0,054 [0,016; 0,095]	0 [0; 0]
GLM-5.2	0,040 [0,016; 0,068]	0 [0; 0]
DeepSeek V4 Pro	0,023 [0,010; 0,036]	0 [0; 0]
Catálogo interno ligado (MISC_DB)	0,021 [0,005; 0,040]	0 [0; 0]
Limite de 6 candidatos	0,078 [0,028; 0,134]	0 [0; 0]
Saturação	0,042 [0,010; 0,082]	0 [0; 0]
Representação DOM	0,028 [0,005; 0,056]	0 [0; 0]
Representação com screenshot	0,023 [0,009; 0,036]	0 [0; 0]
Chamada única	0,010 [0; 0,024]	0 [0; 0]

Tabela 8a-s: sensibilidades exploratórias. R_bug_anchor exclui 42 ações mecânicas não ancoráveis; rOkCompleted exige somente chegada ao estado final.

Condição	R_bug_anchor [IC95%]	rOkCompleted [IC95%]
Baseline	0,065 [0,020; 0,113]	0,069 [0; 0,167]
GLM-5.2	0,048 [0,019; 0,080]	0,042 [0; 0,111]
DeepSeek	0,027 [0,013; 0,044]	0,097 [0,042; 0,167]
MISC_DB	0,025 [0,006; 0,049]	0,097 [0; 0,222]
Limite-6	0,094 [0,037; 0,157]	0,125 [0,042; 0,236]
Saturação	0,050 [0,014; 0,096]	0,083 [0; 0,194]
DOM	0,033 [0,007; 0,066]	0,292 [0,125; 0,472]
Screenshot	0,030 [0,012; 0,049]	0,014 [0; 0,042]
Chamada única	0,014 [0; 0,032]	0 [0; 0]

Tabela 8b: campanha 3, completude por valor (secundária). Média por exercício e IC95%; deltas com IC95% não ajustados; p-valores ajustados por Holm. Ablações: F2 (m=6); modelos em cobertura: F4 pós-hoc (m=2).

Condição	Completude conceitual	Δ vs baseline [IC95%]	p-Holm
Baseline (Gemini, envelope independente)	0,243 [0,163; 0,324]	—	—
GLM-5.2	0,178 [0,122; 0,236]	-0,065 [-0,129; -0,006]	0,095 (pós-hoc, F4)
DeepSeek V4 Pro	0,199 [0,143; 0,260]	-0,044 [-0,103; 0,013]	0,170 (pós-hoc, F4)
Limite de 6 candidatos (em vez de 2 a 3)	0,419 [0,342; 0,495]	+0,177 [0,123; 0,233]	$2,4 \times 10^{-5}$
Saturação ("liste todas as plausíveis")	0,238 [0,171; 0,307]	-0,005 [-0,057; 0,048]	1,000
Catálogo interno ligado (MISC_DB)	0,215 [0,152; 0,282]	-0,028 [-0,079; 0,021]	1,000
Representação DOM	0,207 [0,134; 0,279]	-0,036 [-0,087; 0,009]	0,938
Representação com screenshot	0,251 [0,180; 0,324]	+0,008 [-0,046; 0,065]	1,000
Chamada única (sem multiagente)	0,203 [0,147; 0,264]	-0,040 [-0,111; 0,032]	1,000

Da família de seis ablações, somente elevar o alvo numérico de 2-3 para 6 candidatos sobreviveu à correção na cobertura por valor (+17,7 pontos, p-Holm= $2,4 \times 10^{-5}$). A condição produziu, por exercício, 5,806 candidatos brutos (5,486 únicos), contra 2,764 brutos (2,722 únicos) no baseline; os excedentes não registrados foram 4,083 contra 1,903. Ela também recebeu maior orçamento de saída. O ganho não se transferiu ao R_bug coprimário (0,078 contra 0,054; p-Holm=1,000) e 61/72 grafos acionaram sinal estrutural mole. Assim, o resultado demonstra maior recuperação de valores acompanhada de maior carga potencial de revisão, não melhoria global. A instrução de saturação produziu 3,000 candidatos brutos e 2,153 excedentes médios, sem aumento detectado de cobertura. Catálogo, DOM, screenshot e chamada única também não alteraram a cobertura por valor de forma detectável. Na família exploratória comportamental, o screenshot elevou a concordância de vereditos em 0,056 (p-Holm= $9,6 \times 10^{-4}$); o resultado não implica maior R_bug ou R_ok.

A curva de ensemble sobre o envelope independente das saídas geradas cresce de 24% em K=1 para 35% em K=3, 42% em K=6 e 47% em K=10. Ela e a condição limite-6 aumentam quantidade de candidatos e não são mecanismos independentes. Entre modelos, nenhuma diferença coprimária foi detectada (R_bug: p-Holm=1,000 para GLM e 0,574 para DeepSeek; R_ok degenerado em zero). Os relatórios históricos preservam matrizes e agregados, mas não o detalhe item a item necessário para testar outro matcher; a versão futura do esquema passa a reter esse material.

Auditoria do painel. Os kappas anteriormente calculados sobre 179 itens não avaliam excedentes dos agentes: o conjunto continha 83 itens da referência e 96 controles, mas zero `robo-extra`. Eles são, portanto, inadequados para sustentar concordância multijuiz sobre a produção do sistema e foram retirados das conclusões. Após a correção do campo singular `extra`, o conjunto-alvo contém 333 itens, dos quais 154 são excedentes únicos. A nova execução dos três juízes permanece pendente e será reportada por origem do item.

5 Discussão

Quatro leituras emergem. Primeira: **a montagem determinística evitou violações duras nas classes implementadas**, mas não tornou a estrutura irrelevante. Os 62 sinais moles da campanha 3, quase todos no limite-6, mostram que maior produção de candidatos pode criar complexidade estrutural que exige inspeção. O verificador reduz uma classe de risco; não transfere toda a discussão de qualidade para o conteúdo.

Segunda: **o único julgamento válido dos excedentes continua sendo a avaliação histórica por um modelo**. Nela, 83% dos itens únicos foram classificados como plausíveis, mas a taxa é sensível à identidade do juiz e não recebeu confirmação humana ou multijuiz. O painel da campanha 3 avaliou apenas referência e controles por erro de extração. Consequentemente, "enriquecimento" permanece hipótese, não resultado pedagógico.

Terceira: **a lacuna de cobertura é real e diagnosticável**. A completude de 0,376, combinada à classificação preliminar de 56% das omissões como centrais (estimativa altamente sensível ao juiz; Seção 4.9), desaconselha a leitura de complementaridade inócua. O padrão do denominador isolado (Seção 4.4) sugere que parcela substancial da lacuna provém de uma classe específica e endereçável de erro, ligada à interpretação pragmática do campo de resposta, dimensão em que a experiência de sala de aula do especialista excede a simulação atual. A lacuna, contudo, ainda carece de régua: sem a banda interespecialistas, não se sabe que fração do catálogo um segundo humano cobriria.

A campanha 2 sugere que a cobertura por valor é mais sensível ao procedimento de amostragem do que à troca de modelo, sem demonstrar equivalência entre modelos. A campanha 3 testou duas ex-

plicações antes pendentes: o catálogo interno efetivamente ativado não aumentou cobertura e o alvo de seis candidatos aumentou cobertura por valor, mas trouxe maior orçamento e sinais estruturais. A decisão de engenharia, portanto, não pode maximizar apenas cobertura; deve otimizar conjuntamente R_{bug} , R_{ok} , estrutura, custo e carga de revisão.

A campanha 3 reordena a leitura do estudo. O grafo gerado cobre parte dos valores, mas reproduz pouco do comportamento registrado no executor analítico ($R_{bug}=0,054$; $R_{ok}=0$). A diferença de 13,3 pontos de cobertura entre protocolos é um **efeito conjunto** de fonte, idioma e remoção de KCs; os dados não permitem chamá-la de vazamento nem atribuí-la aos KCs. Granularidade e ordem são explicações compatíveis com a anatomia observada, mas ainda não foram isoladas. Melhorias futuras devem ser avaliadas nos desfechos comportamentais e estruturais, não apenas na coincidência de valores.

Cabe ainda registrar uma lição metodológica: parcela expressiva do déficit inicialmente aferido decorreu de artefatos de medição (grafias distintas do mesmo valor, erros mecânicos contabilizados como conceituais, divergência de âncora entre módulos), corrigidos ao longo das revisões adversariais sem qualquer alteração nos agentes. Em avaliação de sistemas generativos, o refinamento do instrumento precede legitimamente o refinamento do sistema.

6 Ameaças à validade e limitações

Validade de construto. A cobertura por valor mede coincidência de respostas, não de raciocínios, e é secundária na campanha 3. R_{bug} e R_{ok} avançam para estado e trajetória, mas dependem de um executor analítico simplificado e de casamento assimétrico: referência por SAI exato, gerado por input canônico. Esse executor não implementa integralmente o runtime CTAT, grupos de arestas e todas as restrições de travessia. Logo, os desfechos medem conformidade no instrumento publicado, não equivalência funcional entre tutores. A sensibilidade histórica de âncora crua moveu a completude de 0,376 para 0,347, mas sensibilidades comportamentais exact/exact e input/input não podem ser reconstruídas dos artefatos C3 retidos.

Validade interna. O protocolo v1 garantia blindagem parcial; o v2 constrói a entrada sem ler o grafo de referência e possui teste metamórfico. Isso afasta vazamento pelo conteúdo do grafo no v2, mas não elimina diferenças de informação: o autor de referência viu a interface real e os agentes receberam representações textuais, DOM ou screenshot. Além disso, fonte, idioma e KCs mudaram juntos entre v1 e v2. O smoke test ocorreu antes do congelamento final da implementação, e todas as análises permanecem exploratórias. Manifestos C3 registram 648 autorias sem falha; campanhas 1-2 não registraram de forma equivalente retries e contingências.

Validade externa. O corpus restringe-se a frações na reta numérica, um template de interface, uma faixa etária, os idiomas presentes nas fontes e um autor de referência. Para generalização entre STIs e interfaces, o suporte efetivo aproxima-se de $N=1$. O trabalho é um protocolo piloto reproduzível, não um benchmark. Um benchmark exigiria múltiplos STIs, interfaces e domínios, corpus retido com licença, orçamento comum, baterias congeladas por sistema e análise hierárquica por STI e template.

Comparabilidade entre juízes. Os níveis absolutos diferem entre GLM-4.5 e Mistral Large. O painel C3 não julgou excedentes por erro de campo e, portanto, não fornece confiabilidade multijuiz para a produção dos agentes. A calibração humana permanece pendente.

Retenção e reprodutibilidade. Os relatórios C3 históricos guardam métricas, listas e matrizes agregadas, mas não os grafos completos, saídas estruturadas dos agentes, detalhes item a item ou a classe dos sinais moles. Assim, a análise publicada pode ser regenerada a partir dos agregados, porém um terceiro não consegue recalcular todos os desfechos, testar outro matcher ou auditar os 62 sinais sem repetir chamadas estocásticas. O esquema `c3-v2`, criado após esta auditoria, passa a reter esses artefatos e hashes em campanhas futuras; texto bruto do provedor continua fora da retenção.

Validade de conclusão estatística. Com um autor de referência por exercício, a não inferioridade não é estimável. Comparações usam exercício, permutação exata e Holm nas famílias das Emendas 3-4; a Emenda 5 documenta a correção pós-dados. A correção de `R_bug` alterou o baseline de 0,065 para 0,054 sem inverter a conclusão de baixa conformidade. Ausência de significância não constitui equivalência, e o bootstrap degenerado de `R_ok` não constitui prova de taxa populacional nula.

7 Trabalhos futuros

1. **Correção instrumental imediata:** executar novamente os três juízes sobre os 333 itens corretos, reportar taxas e kappas estratificados por origem; numa nova campanha C3, reter grafos, traços e sinais detalhados no esquema `c3-v2` e executar as sensibilidades `exact/exact`, `input/input` e `exact/input`.
2. **Banda interespecialistas:** coletar dois a três autores adicionais às cegas entre si, com margem definida antes dos dados. Somente então a não inferioridade poderá ser estimada.
3. **Calibração humana do juiz:** concluir a anotação independente e reportar kappa juiz-humano.

4. **Agregação:** integrar o ensemble já medido como condição formal e escolher K considerando R_bug, R_ok, sinais estruturais, custo e carga de revisão, não apenas cobertura por valor.
5. **Runtime real e desconusão do contraste:** executar os grafos no runtime do CTAT e realizar a ablação que isole os fatores confundidos entre os protocolos v1 e v2 (KCs, idioma e fonte da entrada).
6. **Baselines e extensão:** comparar amostragem sem LLM com o mesmo orçamento e replicar o protocolo em múltiplos STIs, templates, interfaces e domínios antes de denominar o conjunto como benchmark.
7. **Nível 3:** avaliação de eficácia com alunos reais por meio do Additive Factors Model (AFM; Cen; Koedinger; Junker, 2006), fora do escopo da presente campanha.

8 Conclusão

O resultado central é negativo e comportamental: no protocolo v2, o baseline reconheceu 5,4% [1,6%; 9,5%] das ações buggy registradas no estado correspondente, considerando todas as 192 ações pré-especificadas, e nenhum traço correto foi aceito integralmente passo a passo. A maior estimativa leniente de conclusão foi 29,2% [12,5%; 47,2%], na condição DOM; isso não equivale a conformidade de trajetória. A cobertura por valor foi 24,3% [16,3%; 32,4%] no v2 e 37,6% [30,9%; 44,2%] no protocolo histórico, diferença entre protocolos que não identifica a contribuição de fonte, idioma ou KCs.

Não houve violação estrutural dura em 648 grafos C3, mas 62 acionaram sinal mole, incluindo 61/72 na condição limite-6. Essa condição elevou a cobertura por valor em 17,7 pontos, sem ganho comportamental detectado, e ilustra o trade-off entre quantidade e carga de revisão. O julgamento histórico de 83% dos excedentes por um único modelo continua exploratório; o painel multijuíz não incluiu excedentes e sua conclusão foi retirada. O estudo não estabelece qualidade pedagógica do grafo completo, equivalência de tutores, não inferioridade a especialistas, validade dos comportamentos adicionais ou efeito sobre aprendizagem. Os resultados justificam avaliar o pipeline como protótipo de apoio à autoria com revisão obrigatória; ainda não justificam uso autônomo nem a designação de benchmark.

Disponibilidade de dados e código

O repositório github.com/Joaoqueiroz-silva/sti-graph-validation contém código, corpus, envelopes, relatórios retidos, manifestos C3, curva de ensemble, scripts de reanálise, dicionário de métricas e Emendas 1 a 5. As tabelas derivadas e os testes estatísticos são regeneráveis com semente fixa a par-

tir dos agregados publicados. Contudo, os relatórios C3 históricos (c3-v1) não preservam grafos completos, saídas estruturadas, vereditos por item ou detalhes dos sinais moles; por isso, não permitem recomputação integral, mudança do matcher ou auditoria estrutural retrospectiva sem repetir as chamadas. O esquema c3-v2 corrige a retenção para campanhas futuras. O painel publicado também deve ser executado novamente após a correção do extrator; os arquivos atuais não devem ser interpretados como julgamento de excedentes.

Declarações

Conflito de interesses. O autor é fundador da plataforma EducaOFF, cujo pipeline de autoria é o sistema sob avaliação. Código, agregados, correções adversariais e limites de retenção são expostos para mitigar, sem eliminar, esse conflito. Replicação por equipe independente permanece necessária.

Financiamento. A informação de financiamento não foi fornecida para esta versão técnica. Uma declaração de financiamento ou de ausência de financiamento é obrigatória antes de submissão editorial.

Contribuições e uso de inteligência artificial. Concepção, decisão metodológica e supervisão: o autor. Modelos de linguagem são objeto de estudo deste trabalho e foram também empregados como ferramenta de engenharia, análise e apoio à redação, sob revisão e responsabilidade integral do autor; os julgamentos automatizados reportados são resultados experimentais, nunca decisões editoriais.

Ética. O estudo não envolve seres humanos, dados pessoais ou dados de alunos; a fase futura com especialistas e estudantes será submetida à apreciação ética cabível.

Proveniência e licença do corpus. Os 24 arquivos .brd e a interface foram produzidos na ferramenta CTAT. O pacote não documenta de forma suficiente o nome do autor original, a instituição, a data de criação nem a licença específica de redistribuição. Os hashes SHA-256 demonstram integridade, mas não conferem permissão de uso ou redistribuição. Esses quatro elementos devem ser regularizados antes de depósito em revista ou lançamento público como benchmark; até lá, o corpus deve ser tratado como material de pesquisa com proveniência pendente.

Referências

ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; KOEDINGER, K. R. A new paradigm for intelligent tutoring systems: example-tracing tutors. *International Journal of Artificial Intelligence in Education*, v. 19, n. 2, p. 105-154, 2009.

- ALEVEN, V.; MCLAREN, B. M.; SEWALL, J.; VAN VELSEN, M.; POPESCU, O.; DEMI, S.; RINGENBERG, M.; KOEDINGER, K. R. Example-tracing tutors: intelligent tutor development for non-programmers. *International Journal of Artificial Intelligence in Education*, v. 26, n. 1, p. 224-269, 2016.
- AMIDEI, J.; PIWEK, P.; WILLIS, A. Rethinking the agreement in human evaluation tasks. In: *Proceedings of COLING 2018*. Santa Fe: ACL, 2018.
- BROWN, J. S.; BURTON, R. R. Diagnostic models for procedural bugs in basic mathematical skills. *Cognitive Science*, v. 2, n. 2, p. 155-192, 1978.
- CEN, H.; KOEDINGER, K. R.; JUNKER, B. Learning Factors Analysis: a general method for cognitive model evaluation and improvement. In: *Intelligent Tutoring Systems*. Berlin: Springer, 2006.
- GUPTA, K. D.; HAQUE, M. A.; ALI, H.; KAMAL, M.; ALAM, S. B.; RAHMAN, M. A. Continuous monitoring of large-scale generative AI via deterministic knowledge graph structures. *arXiv preprint arXiv:2509.03857*, 2025.
- HE, X.; WU, D.; ZHAI, Y.; SUN, K. SentinelAgent: graph-based anomaly detection in multi-agent systems. *arXiv preprint arXiv:2505.24201*, 2025.
- HOSKING, T.; BLUNSOM, P.; BARTOLO, M. Human feedback is not gold standard. In: *ICLR 2024*. 2024.
- LAKENS, D. Equivalence tests: a practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, v. 8, n. 4, p. 355-362, 2017.
- LAKENS, D.; SCHEEL, A. M.; ISAGER, P. M. Equivalence testing for psychological research: a tutorial. *Advances in Methods and Practices in Psychological Science*, v. 1, n. 2, p. 259-269, 2018.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159-174, 1977.
- PANICKSSERY, A.; BOWMAN, S. R.; FENG, S. LLM evaluators recognize and favor their own generations. In: *NeurIPS 2024*. 2024.
- SANSFORD, H.; RICHARDSON, N.; MARETIC, H. P.; SAADA, J. N. GraphEval: a knowledge-graph based LLM hallucination evaluation framework. *arXiv preprint arXiv:2407.10793*, 2024.
- SANFELIU, A.; FU, K. S. A distance measure between attributed relational graphs for pattern recognition. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 13, n. 3, p. 353-362, 1983.
- SHAVELSON, R. J.; WEBB, N. M. *Generalizability Theory: a primer*. Newbury Park: Sage, 1991.
- TVERSKY, A. Features of similarity. *Psychological Review*, v. 84, n. 4, p. 327-352, 1977.
- VANGALA, B. P.; MAHMUD, S.; NEUPANE, P.; SELVARAJ, J.; CHENG, J. HalluMat: detecting hallucinations in LLM-generated materials science content through multi-stage verification. *arXiv preprint arXiv:2512.22396*, 2025.
- VAN GLABBEEK, R. J. The linear time-branching time spectrum I. In: *Handbook of Process Algebra*. Amsterdam: Elsevier, 2001. p. 3-99.
- VANLEHN, K. *Mind Bugs: the origins of procedural misconceptions*. Cambridge: MIT Press, 1990.
- ZHANG, K.; HU, M.; LE, H. A. D.; TORSHA, F. K.; JIANG, Z.; BUI, M. K.; CHANG, C.-Y.; CHUANG, Y.-N.; XI-ONG, Z.; LIN, Y.; WANG, G.; ZOU, N. A survey on evaluating quality and trustworthiness in LLM-generated data. *arXiv preprint arXiv:2601.17717*, 2026.
- ZHANG, K.; SHASHA, D. Simple fast algorithms for the editing distance between trees and related problems. *SIAM Journal on Computing*, v. 18, n. 6, p. 1245-1262, 1989.